模式识别

第七章：特征选择与提取

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022

内容

- 引言
- 特征选择
  - 子集搜索与评价
  - 过滤式选择、包裹式选择、嵌入式选择与正则化
- 特征提取
  - 主成分分析、核化线性降维、流型学习

背景

- 分类任务：好瓜还是坏瓜?

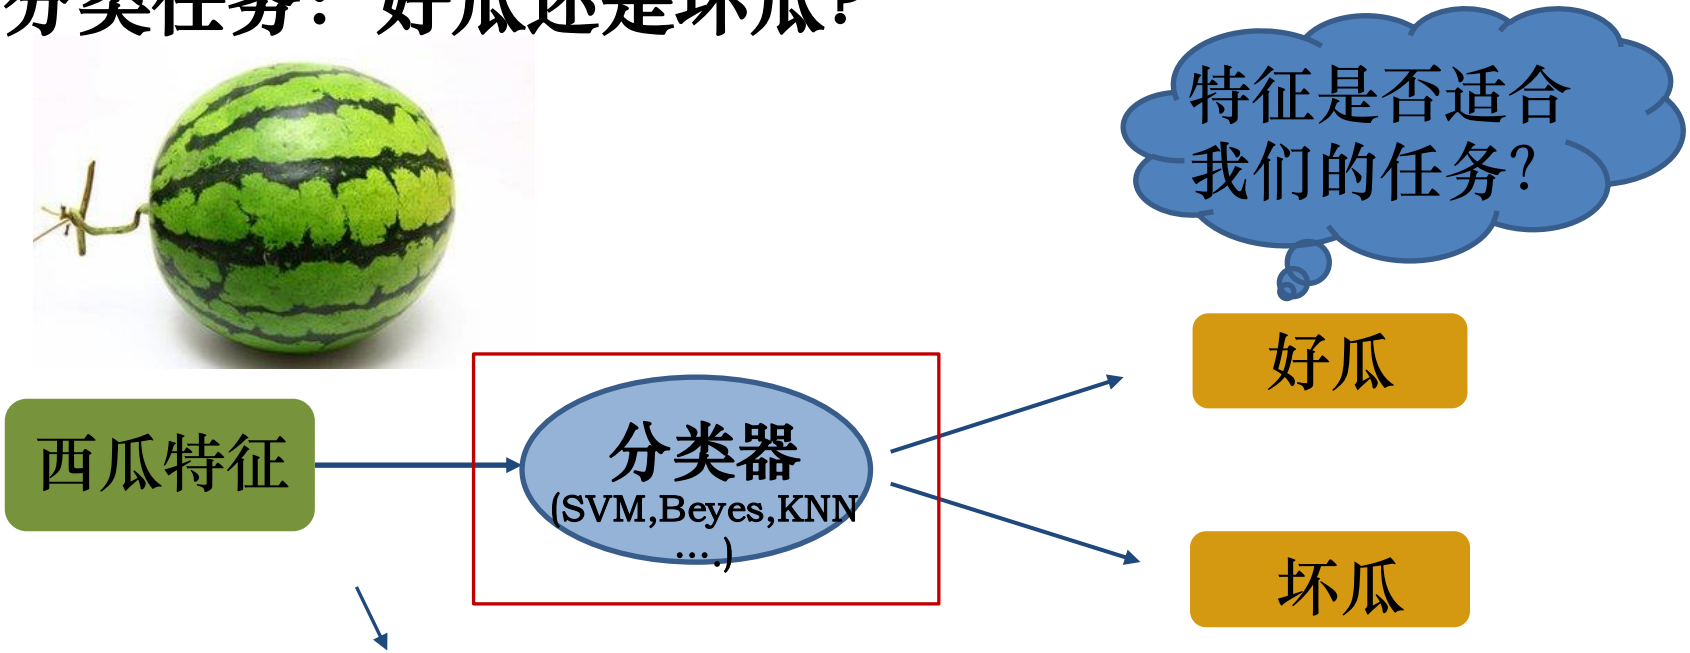

- 原始特征（一次特征）：西瓜{颜色，根蒂，敲声，纹理，触感…}

背景

举例: 对于一个有经验的瓜农，怎么判断西瓜是好还是坏?

特征		结果
①	颜色：绿色 根蒂：蜷缩 敲声：清脆 纹理：清晰 触感：光滑	好瓜
②	根蒂：蜷缩 敲声：清脆 纹理：清晰	好瓜
③	颜色：绿色	

① 相比 ②，部分特征冗余，需要选择特征

数据维数

- 维数(又称维度)
  - 数学中：独立参数的数目
  - 物理中：独立时空坐标的数目

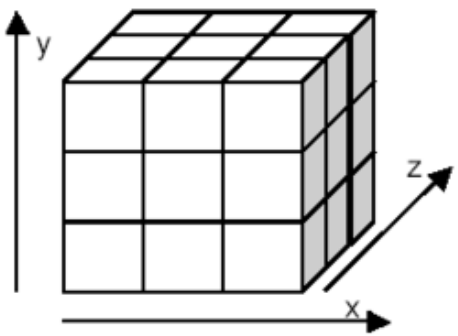

“点是0维、直线是1维、平面是2维、体是3维”

点基于点是0维 → 在点上定位一个点,不需要参数
点基于直线是1维 → 在直线上定位一个点，需要1个参数
点基于平面是2维 → 在平面上定位一个点，需要2个参数
点基于体是3维 → 在体上定位一个点，需要3个参数

引言

- 为什么要降维?
- 如果将数目很多的测量值不做分析，全部直接用作分类特征，不但耗时，而且会影响到分类的效果，产生“特征维数灾难”问题。
- 维数灾难：当维数增加时，输入空间(input space)的大小随维数指数级增加，训练数据占整个数据空间的比例将急剧下降，这将导致模型的泛化困难。在高维空间中，样本数据将变得十分稀疏，许多的相似性度量在高维都会失效。
- 在保证一定分类精度的前提下，减少特征维数，即进行“降维”处理，使分类器实现快速、准确和高效的分类。

数据降维

- 降维（维数约减）
  - 利用某种映射将原高维度空间的数据点投影到低维度的空间。
  - 很多时候，观测或收集到的数据样本虽是高维的，但与学习任务紧密相关的是某个低维“嵌入（embedding）”。

$$f : X \to Y$$

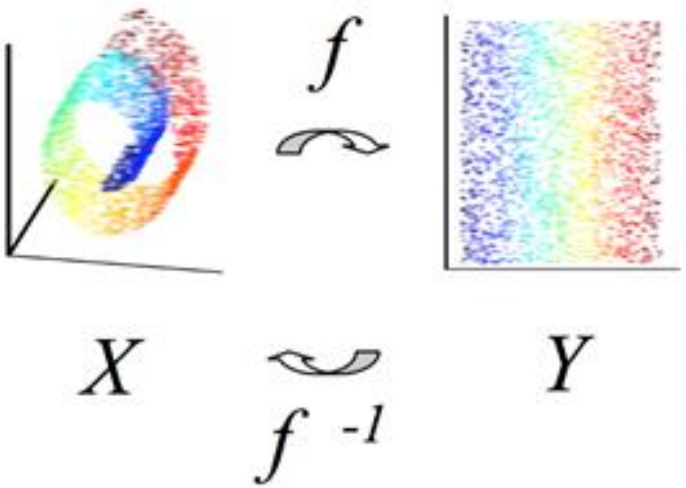

基本概念

- 为达到上述目的，关键是所提供的识别特征应具有很好的可分性，使分类器容易判别。为此，需对特征进行选择与提取：
- 特征选择：
  - 应去掉模棱两可、不易判别的特征（无关特征）；
  - 所提供的特征不要重复，即去掉那些相关性强且没有增加更多分类信息的特征（冗余特征）。
- 特征提取：
  - 用映射（或称变换）的方法把原始特征变换为较少的特征

基本概念

- 所谓特征选择，就是从n个度量值集合$\{x_1, x_2, \dots, x_n\}$中，按某一准则选取出供分类用的子集，作为降维（m维，$m < n$）的分类特征
- 所谓特征提取，就是使$(x_1, x_2, \dots, x_n)$通过某种变换，产生m个特征$(y_1, y_2, \dots, y_m)$ $(m < n)$，作为新的分类特征（或称为二次特征）
- 目的：都是为了在尽可能保留识别信息的前提下，降低特征空间的维数，以达到有效的分类

特征选择

特征选择

- 一般来说，特征选择步骤如下，主要包括**子集搜索**和**子集评估**

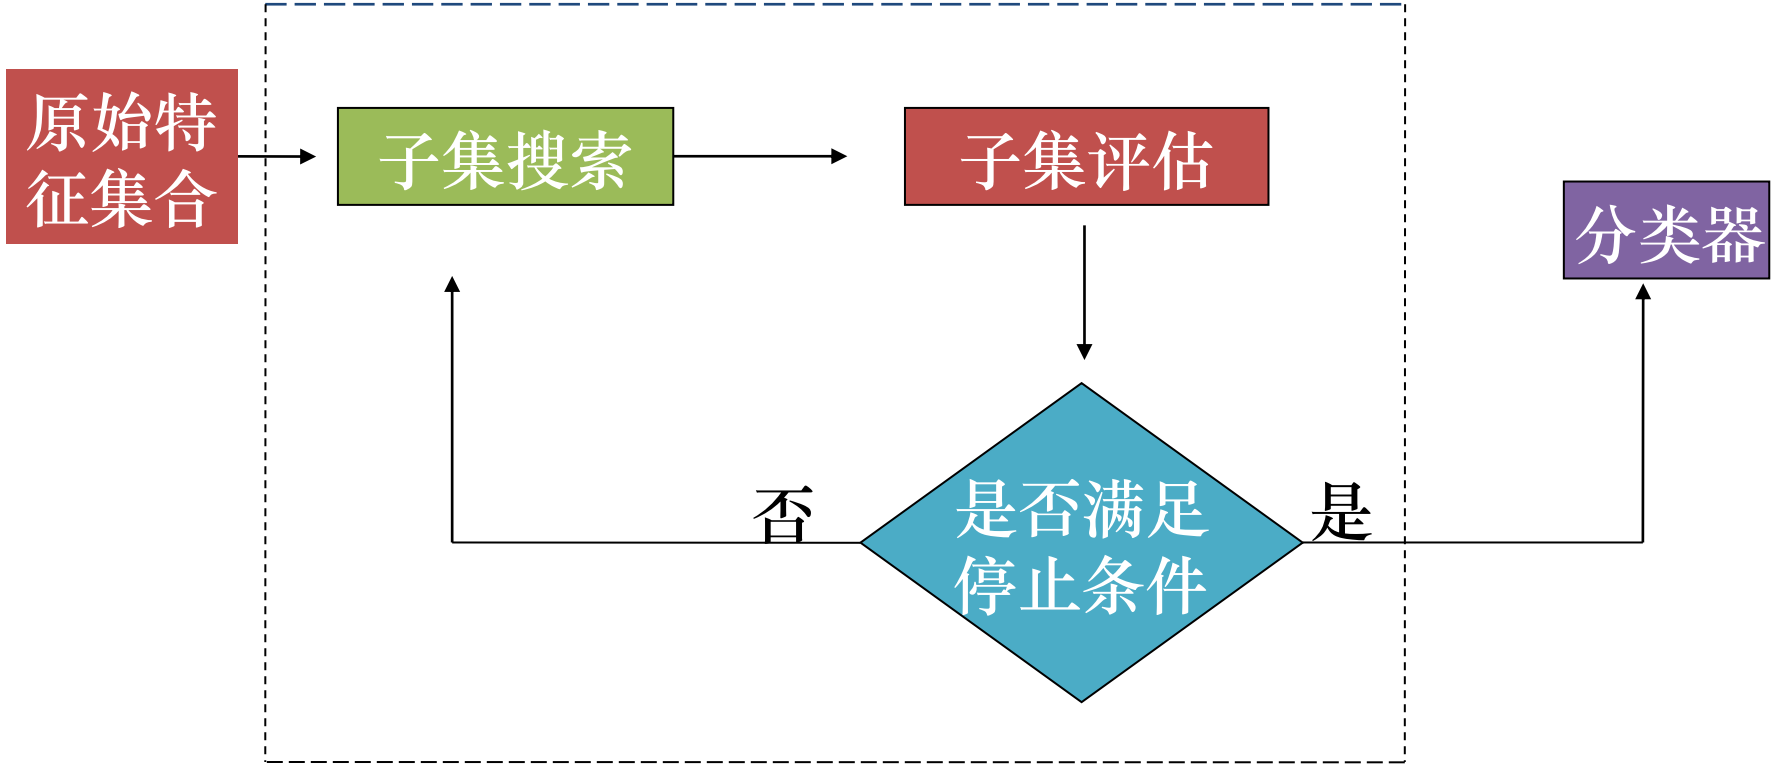

特征选择

- 严格定义：
  - 给定一个特征集$X = \{x_i | i = 1, 2, \dots, N\}$
  - 找到该特征集的子集

$$Y_M = \{x_{i_1}, x_{i_2}, \dots, x_{i_M}\}, M < N$$

  - 使得所定义的准则函数$J(Y)$最优
  - 注：该准则函数在理想状态下，是正确分类的概率

然而，错误率不易计算！

子集搜索

- 特征选择的最优算法：
  - 穷举
  - 分支定界
- 特征选择的次优算法：
  - 独立算法
  - 顺序前进法（Sequential forward selection，SFS）
  - 顺序后退法（Sequential backward selection，SBS）
  - 增*l*减*r*法
  - 遗传算法

子集搜索

1) **前向搜索**: 依次在候选集合中增加相关特征

子集评估

Optimal feature: $\{\quad\} \Rightarrow \{a_2\} \Rightarrow \{a_2, a_4\} \ldots\ldots$

2) **后向搜索**: 在候选集合中，依次去除不相关特征

Optimal feature: $\{a_1, a_2, \ldots, a_d\} \Rightarrow \{a_1, a_2, \ldots, a_{d-1}\} \Rightarrow \{a_1, a_2, \ldots, a_k, \ldots a_{d-2}\} \Rightarrow \ldots$

这些方法是**贪心**的策略，因为是在上一轮的基础上考虑**本轮**最优，所以不一定得到最优特征组合。

其他子集搜索方法：《模式识别》张学工，第三版第七章《特征选择》

子集评估

- 分类可区分性判据(Separation Criterion) 用于评估特征子集的类别区分性能力：
  - ① 基于距离的类可区分性判据
  - ② 基于概率分布的类可区分性判据
  - ③ 基于熵的类可区分性判据

基于距离的判据

- 搜索一个特征子集，我们希望：
  - 样本类内的距离尽可能小
  - 样本类间的距离尽可能大

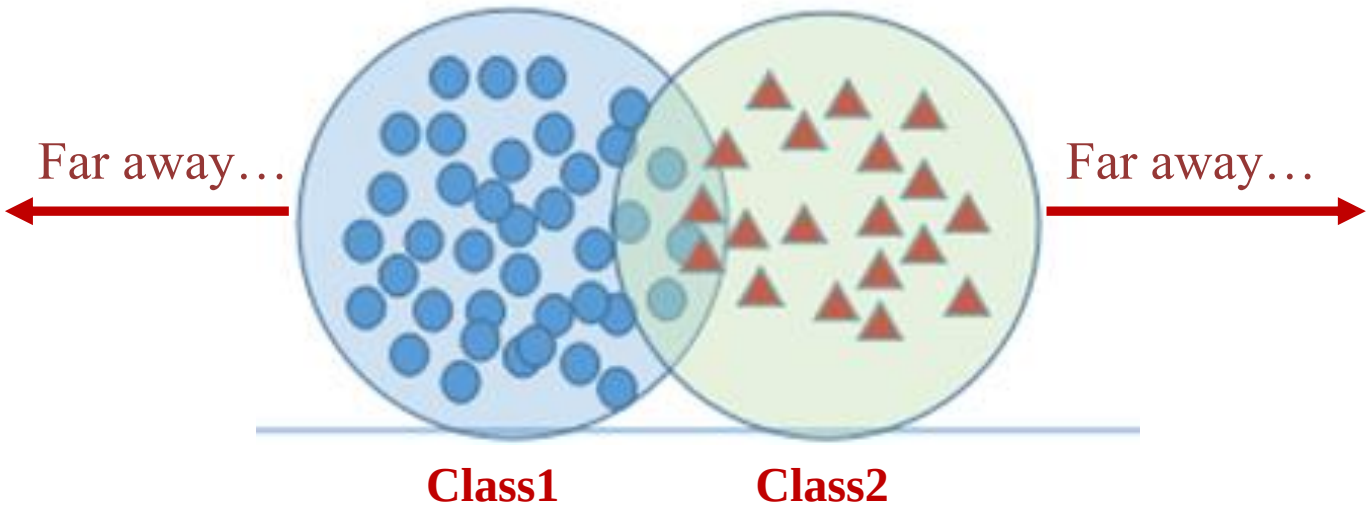

基于距离的判据

（1）各类样本的均值向量m_i $m_i = \frac{1}{N_i}\sum_{x \in D_i} x, \quad (i = 1, \dots, c)$

（2）所有各类样本的总平均向量m $m = \sum_{i=1}^{c} P_i m_i,$

（3）样本总类内离散度矩阵S_w

$$S_w = \sum_{i=1}^{c} P_i \frac{1}{N_i} \sum_{k=1}^{N_i} (x_k^i - m_i)(x_k^i - m_i)^T$$

（4）样本类间离散度矩阵S_b

$$S_b = \sum_{i=1}^{c} P_i (m_i - m)(m_i - m)^T$$

注：协方差矩阵的迹等同于方差

- 类可区分性判据，以各类特征向量的平均平方距离为判据:

$$J_d(x) = tr(S_w + S_b)$$

基于距离的判据

- 还可以定义一系列基于类内、类间距离的判据:

$$J_1 = tr(S_w + S_b)$$

$$J_2 = tr(S_w^{-1} S_b)$$

$$J_3 = ln \frac{|S_b|}{|S_w|}$$

$$J_4 = \frac{tr(S_b)}{tr(S_w)}$$

$$J_5 = \frac{|S_b - S_w|}{|S_w|}$$

1. 不同判据计算的数值虽然不同，但是对于特征的排序是相同的，**结果一致**。
2. 不足：**很难在理论上建立起与分类错误率的联系**；**没有考虑样本的分布情况**

基于概率分布的判据

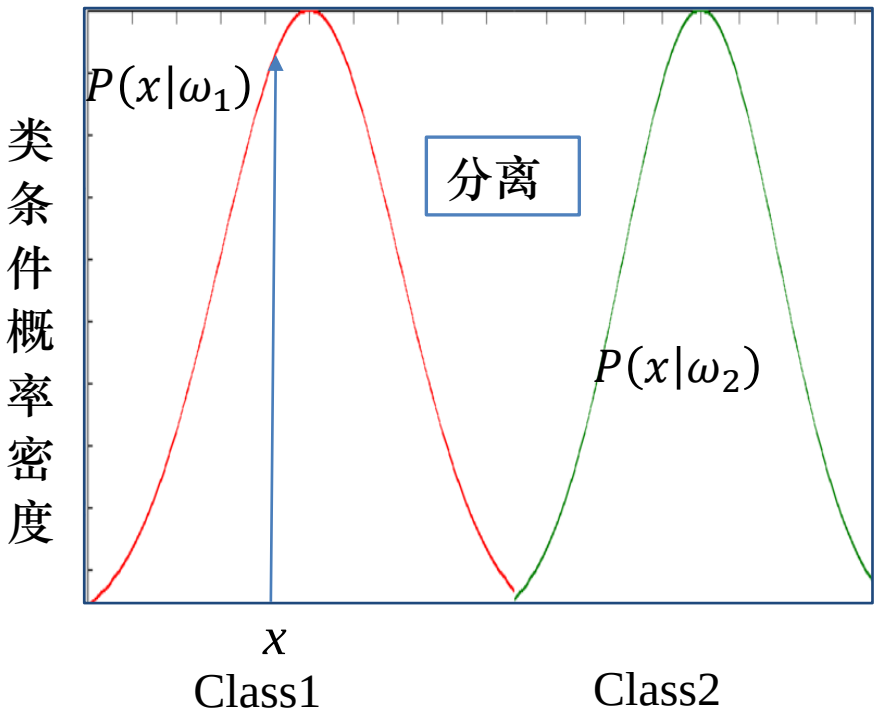

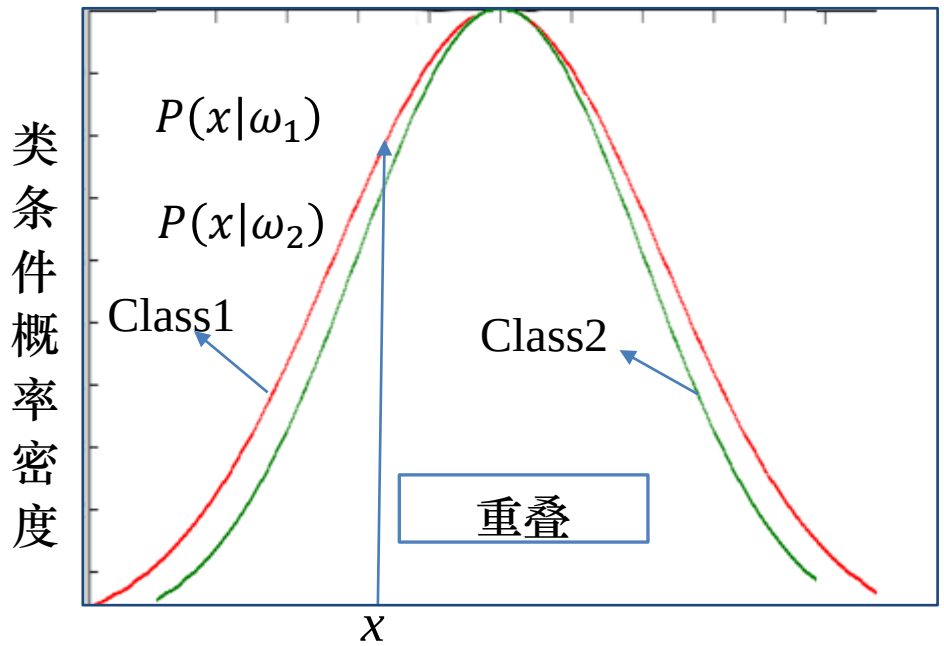

- 以上启发我们可用**两类概率密度函数的交叠程度（相似程度）**来度量可分性，构造基于类概率的可分性判据
- 它可以是概率密度函数的乘积、比或差的**积分**

基于概率分布的判据

- 交叠度可用两个分布密度函数之间的距离 J_p来度量：

$$J_p = \int g[\underbrace{P(x|\omega_1), P(x|\omega_2)}_{\text{类条件概率}}, \underbrace{P_1, P_2}_{\text{先验概率}}]\, dx$$

- 构造的基于类概率的可分性判据**应满足的条件**：

（1） $J_P \geq 0$

（2）当两类不重叠时， $J_P = \max$

（3）当两类概率密度完全重合时， $J_P = 0$

（4）相对于两个概率密度具有“对称性”

基于概率分布的判据

- 下面介绍三个判据 J_B, J_C, J_D
- J_B (Bhattacharyya 判据)

$$J_B = -\ln \int \left[p(\boldsymbol{x}|\omega_1) p(\boldsymbol{x}|\omega_2) \right]^{\frac{1}{2}} d\boldsymbol{x}$$

  - 直观分析：当两类的概率密度函数完全重合时，$J_B = 0$；当两类的概率密度函数完全没有交叠时，$J_B = \infty$
  - 它与错误率的上界有直接关系：

$$P(\boldsymbol{e}) \le \left[P(\omega_1) P(\omega_2) \right]^{\frac{1}{2}} \exp\left(-J_B\right)$$

基于概率分布的判据

- 下面介绍三个判据 J_B, J_C, J_D
- J_B (Bhattacharyya 判据)

$$J_B = -\ln \int \left[p(\mathbf{x}|\omega_1) p(\mathbf{x}|\omega_2) \right]^{\frac{1}{2}} d\mathbf{x}$$

– 简单证明：$P(\boldsymbol{e}) \le \left[P(\omega_1)P(\omega_2)\right]^{\frac{1}{2}} \exp\left(-J_B\right)$

– 思路：转成后验比较！

– $\Re_1$ ： $p(\omega_1|x) > p(\omega_2|x)$ ；反之亦然

$$p(e) = \int_{\Re_1} p(\omega_2|x)p(\mathrm{x})dx + \int_{\Re_2} p(\omega_1|x)p(\mathrm{x})dx$$

$$[P(\omega_1)P(\omega_2)]^{\frac{1}{2}} \exp(-J_B) = \int_{\Re_1} [p(\omega_2|x)p(\omega_2|x)]^{\frac{1}{2}} p(\mathrm{x})dx + \int_{\Re_2} [p(\omega_2|x)p(\omega_2|x)]^{\frac{1}{2}} p(\mathrm{x})dx$$

基于概率分布的判据

- J_C（Chernoff 判据）

$$J_C = -\ln \int \left[p(\boldsymbol{x}|\omega_1) \right]^s \left[p(\boldsymbol{x}|\omega_2) \right]^{1-s} d\boldsymbol{x} \qquad s \in [0,1]$$

（1）对一切 $0 \le s \le 1$，$J_C \ge 0$

（2）对一切 $0 \le s \le 1$，$J_C = 0 \leftrightarrow p(\boldsymbol{x}|\omega_1) = p(\boldsymbol{x}|\omega_2)$

（3）当x的各分量彼此独立时，

$$J_C(s; x_1, x_2, \cdots, x_n) = \sum_{i=1}^{n} J_C(s; x_i)$$

（4）当 x 的各分量彼此独立时，

$$J_C(s; x_1, x_2, \cdots, x_k) \le J_C(s; x_1, x_2, \cdots, x_k, x_{k+1})$$

基于概率分布的判据

- J_D（**D**-判据、散度）
- 在似然比的基础上定义了以下散度作为可分性度量：

$$J_D = I_{12}(\mathrm{x}) + I_{21}(\mathrm{x}) = \int [p(\mathrm{x}|\omega_1) - p(\mathrm{x}|\omega_2)] \ln \frac{p(\mathrm{x}|\omega_1)}{p(\mathrm{x}|\omega_2)} d\mathrm{x}$$

$$I_{12}(\mathrm{x}) = E_1\left[\frac{p(\mathrm{x}|\omega_1)}{p(\mathrm{x}|\omega_2)}\right] = \int p(\mathrm{x}|\omega_1) \ln \frac{p(\mathrm{x}|\omega_1)}{p(\mathrm{x}|\omega_2)} d\mathrm{x}$$

$$I_{21}(\mathrm{x}) = E_2\left[\frac{p(\mathrm{x}|\omega_2)}{p(\mathrm{x}|\omega_1)}\right] = \int p(\mathrm{x}|\omega_2) \ln \frac{p(\mathrm{x}|\omega_2)}{p(\mathrm{x}|\omega_1)} d\mathrm{x}$$

- 当两类均是正态分布且协方差矩阵相等时：

$$J_D = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = 8J_B$$

基于熵的判据

- 熵（Entropy），以Shannon熵为例:

$$H = -\sum_{i=1}^{c} P(w_i|x)\, log_2\, P(w_i|x)$$

- 样本类别确定：$P(w_i|x) = 1, H = 0$;
- 样本类别不确定：$P(w_i|x) < 1, H > 0$;
- 衡量后验概率的集中程度
- 熵值越大，说明样本的类别不确定性越大

基于熵的判据

- 香农熵（Shannon Entropy）：

$$H = -\sum_{i=1}^{c} P(w_i|x)\, log_2\, P(w_i|x)$$

- 平方熵（Square Entropy）：

$$H = J_C^2 = [P(w_1|x), P(w_2|x), \dots P(w_c|x)] = 2[1 - \sum_{i=1}^{c} P^2(w_i|x)]$$

- 在熵的基础上，对特征所有取值积分，得到可分性判据：

$$J_{\mathrm{E}} = \int H(x)p(x)dx$$

后验概率分散性越大，熵值越大，分类错误率越高

基于熵的判据

- 贝叶斯分类器中，分类的结果由后验概率确定；
- 对于一个样本，如果所有类的后验概率是相同的，则分类结果不可知。
- 例如:

$$if \quad P(w_i|x) = \frac{1}{c}, c\text{是类别数量}$$

分类错误率: $e = 1 - \frac{1}{c} = \frac{c-1}{c}$

$$if \quad P(w_i|x) = 1, P(w_j|x) = 0, \quad j \neq i$$

分类错误率: $e = 0$

熵值可以度量后验概率的分布（集中程度）！

特征选择

- 特征选择策略: 特征子集搜索和子集评估组合起来的过程
  - ①过滤式 (Filter)
  - ②包裹式（Wrapper）
    评估准则与分类的错误率直接相关！
  - ③嵌入式（Embedding）
    通过优化的方式同时实现特征选择与评估

特征选择

- **过滤式**：特征选择发生在训练过程之前，单独利用可分性准则来选择特征
  - 代表性方法: Relief
- **包裹式**：直接将分类器的性能作为特征选择中的子集评估方法
  - 代表性方法: LVW（拉斯维加斯算法）
- **嵌入式**：特征选择和学习器训练同时嵌入到一个优化过程中，特征选择在学习器训练过程中完成（有训练过程）

$$\min_{\omega} \sum_{i=1}^{m} (y_i - \omega^T x_i)^2 + \lambda \underbrace{\|\omega\|_1}_{\text{L1 norm}}$$

易获得稀疏解，是一种嵌入式特征选择方法

特征选择--过滤式

- **过滤式**：特征选择发生在训练过程之前

Relief (Relevant Features) [Kira and Rendell, 1992]

- 给定“相关统计量”，度量特征的重要性
- 设置一个阈值*t*，如果某一个特征的相关统计量大于阈值*t*，那么就将其加入特征子集
- 特征子集的重要性等于特征子集相关统计量的和

特征选择--过滤式

- **特征 j 的相关统计量：**

$$\delta^{\mathrm{j}} = \sum_i -diff(x_i^j, x_{i,nh}^j)^2 + diff(x_i^j, x_{i,nm}^j)^2$$

- **猜中近邻（near-hit instance） = similar class**
- **猜错近邻（near-miss instance ） = different class**

δ^{j} 越大，说明在特征 j 上，同类样本更接近（diff小于异类样本），特征 j 的类别区分能力越强、是有益特征

时间与对 x 的采样数和原始特征维数线性相关，效率较高

若 j 为离散型，则 $x_{a'}^j = x_b^j$ 时 $\mathrm{diff}(x_{a'}^j, x_b^j) = 0$，否则为1；若 j 为连续型，则 $\mathrm{diff}(x_{a'}^j, x_b^j) = |x_a^j - x_b^j|$，注意 $x_{a'}^j$，x_b^j 已规范化到[0,1]区间

特征选择--过滤式

- **Relief-F [Kononenko, 1994]**
- **Relief的扩展，处理多分类问题：**

$$\delta^{\mathrm{j}} = \sum_{i} -diff(x_i^j, x_{i,nh}^j)^2 + \sum_{l \neq k} (pl \times diff(x_i^j, x_{i,nm}^j)^2)$$

数据集*D*中第*L*类的比例

特征选择--包裹式

- 包裹式：直接将分类器的性能作为特征选择中的子集评估方法
- LVW(Las Vegas Wrapper) 是一种典型的包裹式框架

1）在候选特征集中自由选择特征子集

2）在特征子集表示的数据集上，运行学习算法

3）用分类的错误率来评估特征子集的好坏

特征选择--包裹式

输入: 数据集 D;
特征集 A;
学习算法 $\mathfrak{L}$;
停止条件控制参数 T.

过程:

$E = \infty$;
$d = |A|$;
$A^* = A$;
$t = 0$;
while $t < T$ **do**
  随机产生特征子集 A';
  $d' = |A'|$;
  $E' = \text{CrossValidation}(\mathfrak{L}(D^{A'}))$;
  if $(E' < E) \vee ((E' = E) \wedge (d' < d))$ **then**
    $t = 0$;
    $E = E'$;
    $d = d'$;
    $A^* = A'$
  else
    $t = t + 1$
  end if
end while

输出: 特征子集 A^*

图 11.1 LVW 算法描述

终止条件

循环条件

分类错误率比上一轮减小

分类错误率跟上一轮相等，但特征维数减少

特征选择--包裹式

- **特点：**
  - LVW 可以减少特征的维数，并且提高分类的准确率
  - 子集搜索采用随机策略。由于每次都要运行分类器，复杂性高
  - 算法运行速度慢

特征选择--嵌入式

- **嵌入式：特征选择和学习器训练同时嵌入到一个优化过程中，特征选择在学习器训练过程中完成**

- **目标函数：** $$\min_{\omega}\sum_{i=1}^{m}(y_i-\omega^T x_i)^2+\lambda\underbrace{\|\omega\|_1}_{L1\ \text{norm}}$$

解决过拟合；易获得稀疏解，是一种嵌入式特征选择方法

- **L1范数比L2范数更易获得稀疏解**

$$\min_{\omega}\sum_{i=1}^{m}(y_i-\omega^T x_i)^2+\lambda\underbrace{\|\omega\|_2^2}_{L2\ \text{norm}}$$

特征选择--嵌入式

- 假设x仅有两个属性，那么w有两个分量w_1和w_2。那么目标优化的解要在**平方误差项与正则化项之间折中**，即出现在图中平方误差项等值线与正则化等值线相交处。
- 从图中看出，采用$L1$范数时**交点常出现在坐标轴上**，即产生w_1或者w_2为0的稀疏解。

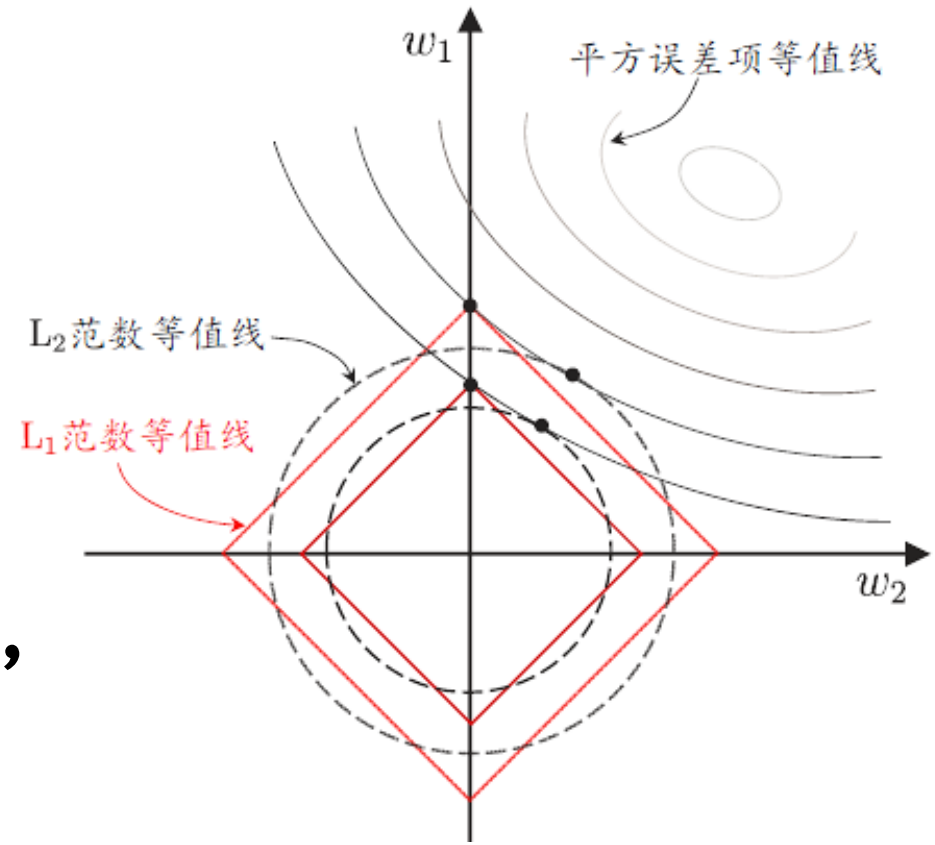

特征选择--小结

- 特征子集搜索方法
  - 前向搜索，后向搜索，双向搜索
- 特征子集评估方法
  - 基于距离的判据
  - 基于概率密度的判据
  - 基于熵的判据
- 特征选择的策略
  - 过滤式，包裹式，嵌入式

通常，在达到满意的分类的效果的前提下使用尽可能少的特征；或者不超过某个特征维度时，尽可能提高分类性能。

特征提取

特征提取

- 特征提取不同于特征选择
- 特征提取是将原始特征通过组合转换到新的特征空间，可学习
- 特征提取是特征工程的一种

特征提取

线性方法

- Principal Component Analysis (PCA)[Pearson , 1901]
- Linear Discriminant Analysis (LDA) [Ronald Fisher , 1936]
  [Belhumeur, 1996]

非线性方法

- Multi-dimensional Scaling (MDS) [Torgerson, W.S. et al. ,1958]
- Kernel principal component analysis (KPCA) [Scholkopf et al., 1998]
- Principal Curves [Hastie, 1989]
- Self-Organizing Feature Map (SOM) [Kohonen et al., 1995]
- Generative topographic map (GTM) [Bishop et al., 1998]
- Manifold Learning：Isomap,LLE,LE…….
- .....

特征提取代表性方法

- 主成分分析
  Principal Component Analysis
- 多维尺度分析
  Multi-dimensional Scaling
- 等距映射
  Isometric Mapping
- 局部线性嵌入
  Locally Linear Embedding
- …

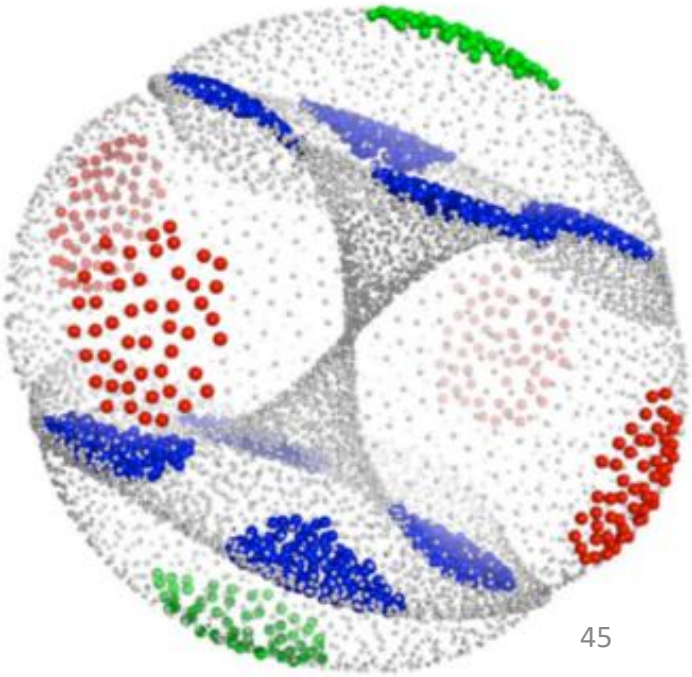

主成分分析-概述

- K. Pearson(1901年论文) 针对非随机变量
- H. Hotelling(1933年论文) 推广到随机向量

主成分分析(Principal Component Analysis, PCA)，将原有众多具有一定相关性的指标重新组合成一组少量互相无关的综合指标。

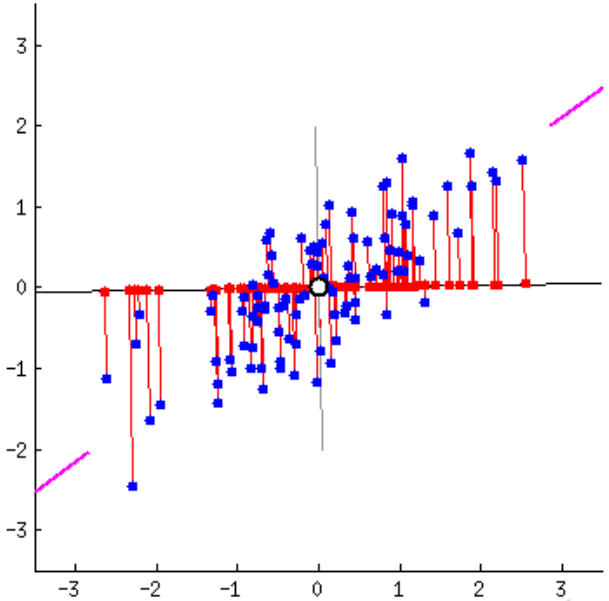

使得降维后样本的方差尽可能大

使得降维后数据的均方误差尽可能小

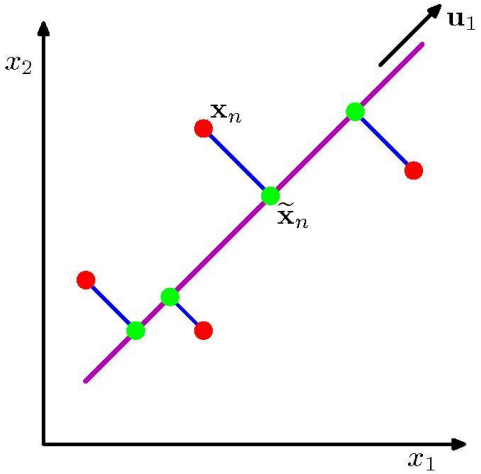

https://

主成分分析-算法

- **最大方差思想**

使用较少的数据维度保留住较多的原数据特性

将*D*维数据集 $\{\mathbf{x}_n\}, n = 1, 2, ..., N$ **降为*M*维，**$M < D$

首先考虑 $M = 1$**，定义这个空间的投影方向为*D*维向量** $\mathbf{u}_1$

出于方便且不失一般性，令 $\mathbf{u}_1^T\mathbf{u}_1 = 1$

每个数据点 $\mathbf{x}_n$ **在新空间中表示为标量** $\mathbf{u}_1^T\mathbf{x}_n$

样本均值在新空间中表示为 $\mathbf{u}_1^T\bar{\mathbf{x}}$**，其中** $\bar{\mathbf{x}} = \frac{1}{N}\sum_{n=1}^{N}\mathbf{x}_n$

投影后样本方差表示为 $\frac{1}{N}\sum_{n=1}^{N}\{\mathbf{u}_1^T\mathbf{x}_n - \mathbf{u}_1^T\bar{\mathbf{x}}\}^2 = \boxed{\mathbf{u}_1^T\mathbf{S}\mathbf{u}_1}$ **最大**

其中原样本方差矩阵 $\mathbf{S} = \frac{1}{N}\sum_{n=1}^{N}(\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^T$

主成分分析-算法

- **最大方差思想**

使用较少的数据维度保留住较多的原数据特性

目标是最大化 $\mathbf{u}_1^T\mathbf{S}\mathbf{u}_1, \quad s.t. \quad \mathbf{u}_1^T\mathbf{u}_1 = 1$

利用拉格朗日乘子法 $\mathbf{u}_1^T\mathbf{S}\mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^T\mathbf{u}_1)$

对 $\mathbf{u}_1$ **求导置零得到** $\mathbf{S}\mathbf{u}_1 = \lambda_1\mathbf{u}_1$

$\mathbf{u}_1$是S的特征向量

进一步得到 $\mathbf{u}_1^T\mathbf{S}\mathbf{u}_1 = \lambda_1$

$\mathbf{u}_1$是S最大特征值对应的特征向量时
方差取到极大值，称$\mathbf{u}_1$为第一主成分

主成分分析-算法

- **最大方差思想**

使用较少的数据维度保留住较多的原数据特性

考虑更一般性的情况($M > 1$), **新空间中数据方差最大的最佳投影方向由协方差矩阵S的*M*个特征向量**$\mathbf{u}_1, \ldots, \mathbf{u}_M$**定义, 其分别对应*M*个最大的特征值** $\lambda_1, \ldots, \lambda_M$

首先获得方差最大的1维，生成该维的补空间；

继续在补空间中获得方差最大的1维，生成新的补空间；

依次循环下去得到*M*维的空间。

主成分分析-算法

- **最小均方误差思想**

使原数据与降维后的数据(在原空间中的重建)的误差最小

定义一组正交的*D*维基向量 $\{\mathbf{u}_i\}, i = 1, \ldots, D$**，满足**

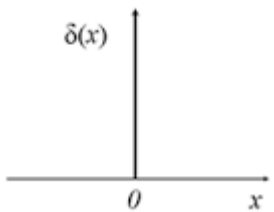

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$$

当基是完全的，每个数据点可以表示为基向量的线性组合

$$\mathbf{x}_n = \sum_{i=1}^{D} \alpha_{ni} \mathbf{u}_i$$

相当于进行了坐标变换

$$\{\mathbf{x}_{n1}, \ldots, \mathbf{x}_{nD}\} \xrightarrow{\{\mathbf{u}_i\}} \{\alpha_{n1}, \ldots, \alpha_{nD}\}$$

$\alpha_{nj} = \mathbf{x}_n^T \mathbf{u}_j$ **或** $\boldsymbol{\alpha} = \boldsymbol{A}^{\boldsymbol{T}} \boldsymbol{x}$ **其中A是由μ_i构成的变换矩阵**

反之， $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{\alpha}$

主成分分析-算法

- **最小均方误差思想**

使原数据与降维后的数据(在原空间中的重建)的误差最小

那么 $\mathbf{x}_n = \sum_{i=1}^{D} (\mathbf{x}_n^T \mathbf{u}_i) \mathbf{u}_i$

在*M*维变量$(M < D)$**生成的空间中对其进行表示**

$$\tilde{\mathbf{x}}_n = \sum_{i=1}^{M} z_{ni} \mathbf{u}_i + \sum_{i=M+1}^{D} b_i \mathbf{u}_i$$

独特的 **共享的**

目标最小化失真度 $J = \frac{1}{N} \sum_{n=1}^{N} \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2$

导数置零得到 $z_{nj} = \mathbf{x}_n^T \mathbf{u}_j, j = 1, ..., M$

$$b_j = \bar{\mathbf{x}}^T \mathbf{u}_j, j = M+1, ..., D$$

主成分分析-算法

- **最小均方误差思想**

使原数据与降维后的数据(在原空间中的重建)的误差最小

有 $\mathbf{x}_n - \tilde{\mathbf{x}}_n = \sum_{i=M+1}^{D} \{(\mathbf{x}_n - \bar{\mathbf{x}})^T \mathbf{u}_i\} \mathbf{u}_i$

$$J = \frac{1}{N} \sum_{n=1}^{N} \sum_{i=M+1}^{D} (\mathbf{x}_n^T \mathbf{u}_i - \bar{\mathbf{x}}^T \mathbf{u}_i)^2 = \sum_{i=M+1}^{D} \mathbf{u}_i^T \mathbf{S} \mathbf{u}_i$$

拉格朗日乘子法 $\tilde{J} = \sum_{i=M+1}^{D} \mathbf{u}_i^T \mathbf{S} \mathbf{u}_i + \sum_{i=M+1}^{D} \lambda_i (1 - \mathbf{u}_i^T \mathbf{u}_i)$

求导置零得到 $\mathbf{S}\mathbf{u}_i = \lambda_i \mathbf{u}_i$ **　　*J*最小时取*D-M*个最小的特征值**

对应失真度为 $J = \sum_{i=M+1}^{D} \lambda_i$ **　　主子空间对应*M*个最大特征值**

主成分分析-算法

- **计算步骤**

①计算给定样本$\{\mathbf{x}_n\}, n = 1, 2, ..., N$的均值$\bar{\mathrm{x}}$和协方差矩阵S;

②计算S的特征向量与特征值;

③将特征值从大到小排列，前*M*个特征值$\lambda_1, ..., \lambda_M$所对应的特征向量$\mathbf{u}_1, ..., \mathbf{u}_M$构成投影矩阵。

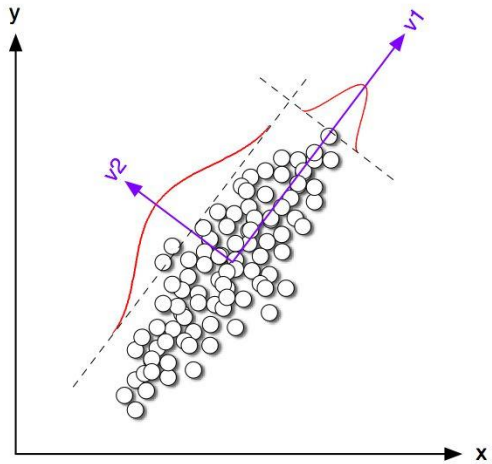

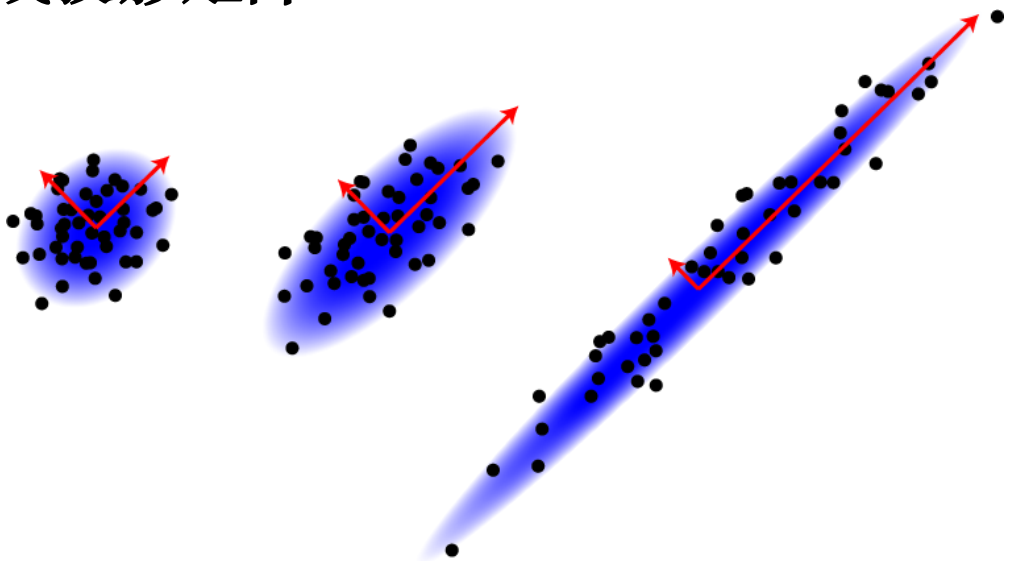

主成分分析-应用

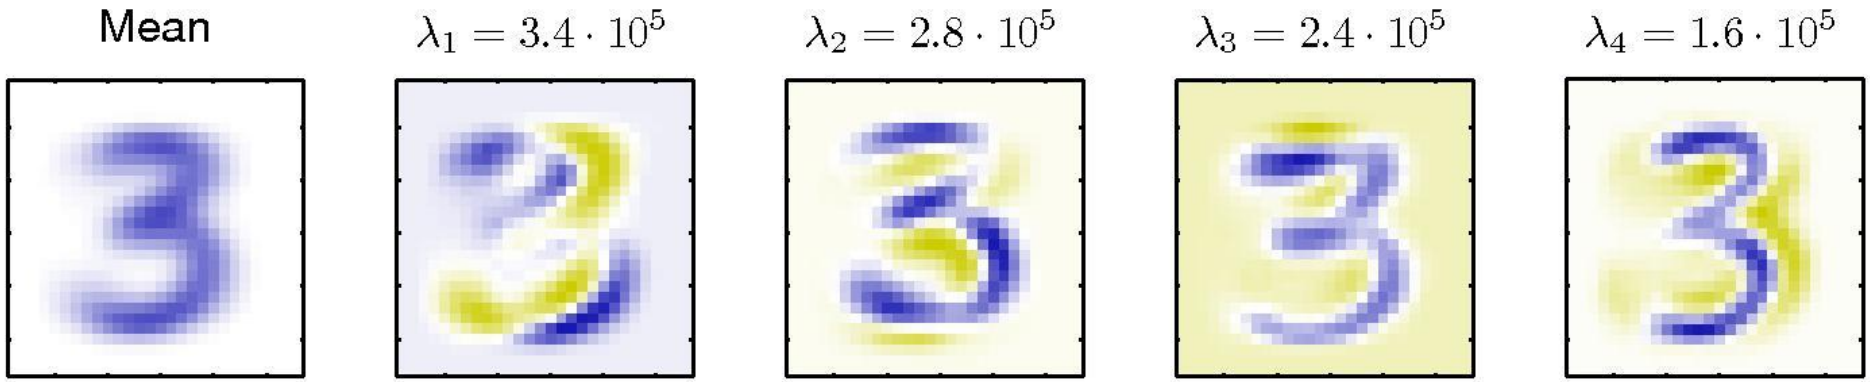

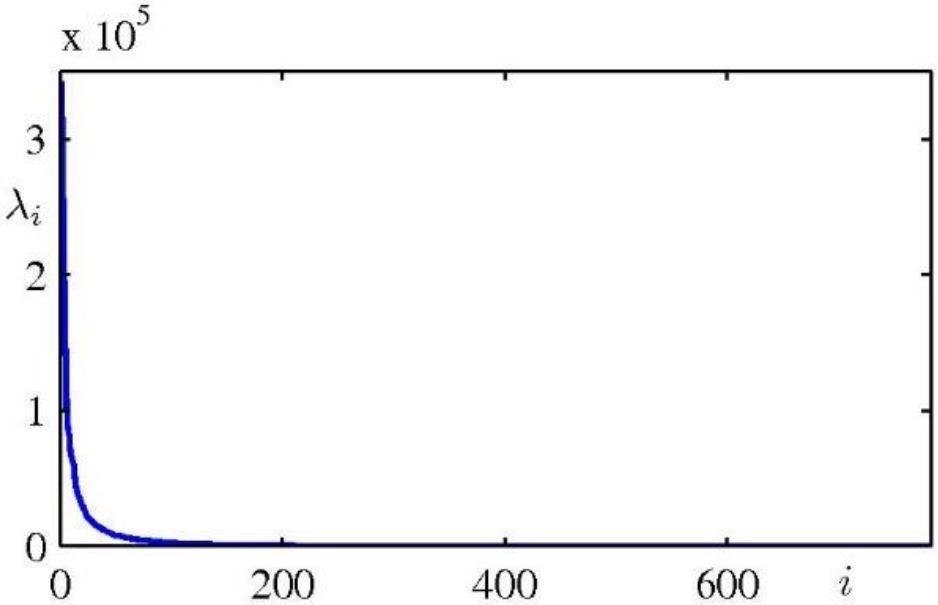

(a)

特征值分布谱
特征值由大到小排列

主成分分析-应用

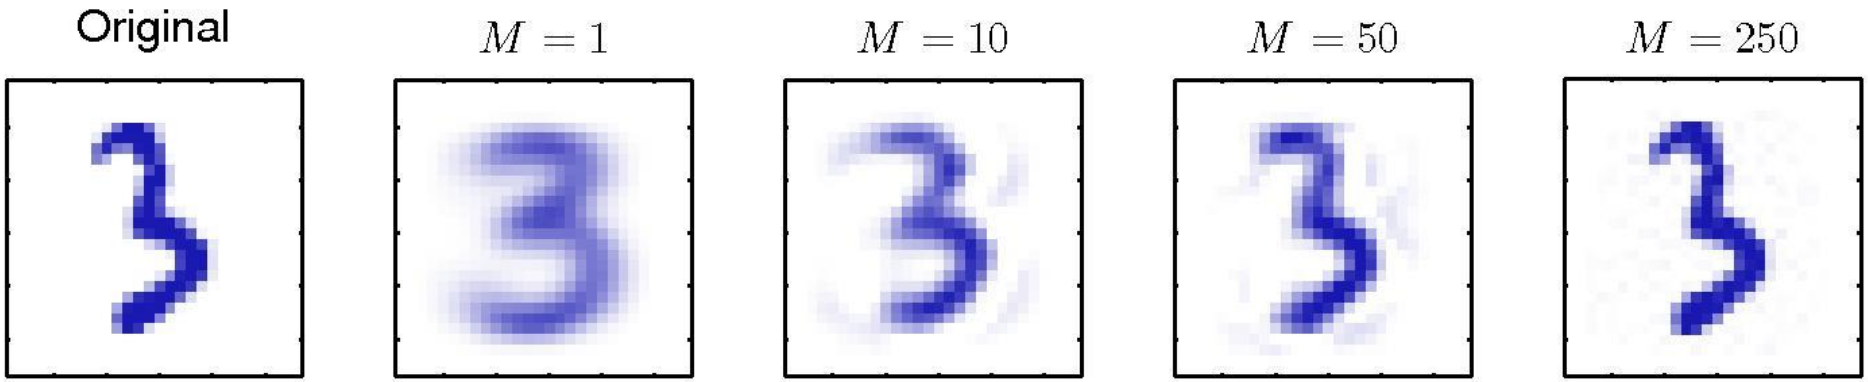

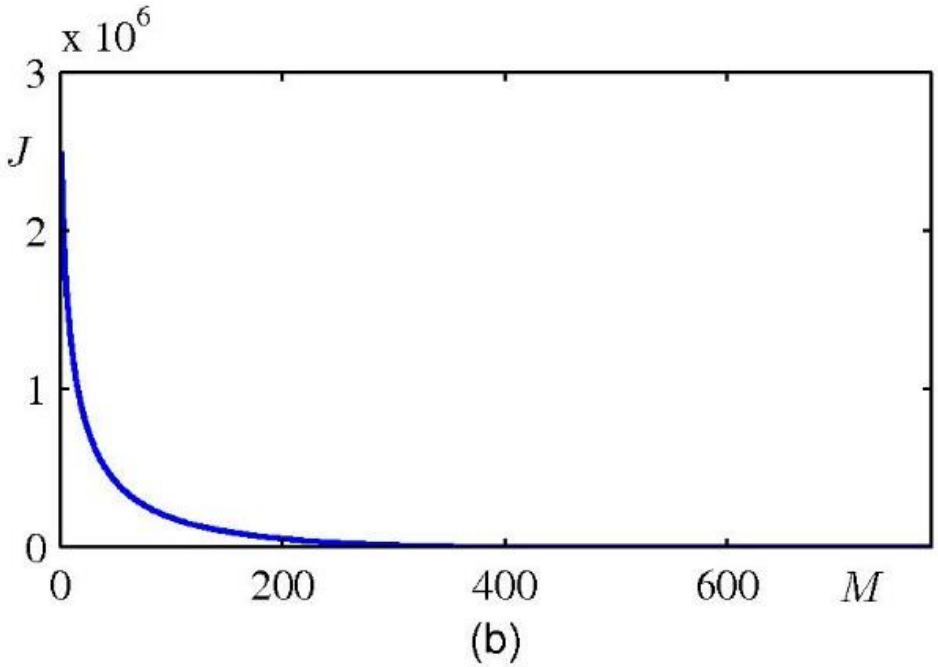

失真度分布谱
随M取值由小到大排列

主成分分析-应用

- **利用PCA处理高维数据**

  在实际应用中，样本维数可能很高，远大于样本的个数

  在人脸识别中，1000张人脸图像，每张图像100×100像素

  D维空间，N个样本点，D＞N

  X是$D \times N$维的数据矩阵，其列向量为$(x_n - \bar{x})$

$$S = \frac{1}{N}\sum_{n=1}^{N}(\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^T$$ 可以写为$S=\frac{1}{N}XX^T$

  S维数？　$D \times D$维　10,000×10,000

  考察样本集构成的另一个矩阵（内积矩阵）$R=\frac{1}{N}X^TX$，

  维数$N \times N$。通常（不妨假设）N <<D。

主成分分析-应用

- **利用PCA处理高维数据**

在实际应用中，样本维数可能很高，远大于样本的个数

在人脸识别中，1000张人脸图像，每张图像100×100像素

对 $R=\frac{1}{N}X^TX$ 求的特征值 λ_i 和特征向量 v_i

$$X^TXv_i = \lambda_i v_i$$

$$\Longrightarrow \quad XX^TXv_i = \lambda_i Xv_i$$

$$\Longrightarrow \quad SXv_i = \lambda_i \boxed{Xv_i}$$ S的特征向量

记：$\mu_i = Xv_i$，则$S\mu_i = \lambda_i\mu_i$

因此，R与S具有相同本征值，本征向量：$\mu_i = Xv_i$

调整尺度 $\mu_i = \frac{1}{\sqrt{\lambda_i}}Xv_i$ 满足:$\|\mathrm{u}_i\| = 1$

奇异值分解(Singular Value Decomposition, SVD)

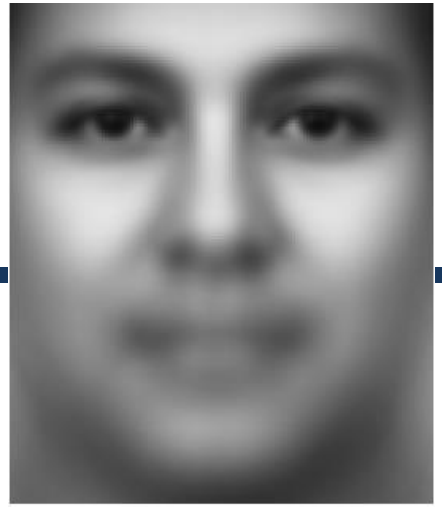

主成分分析-应用

特征脸(Eigenfaces)#1~#8

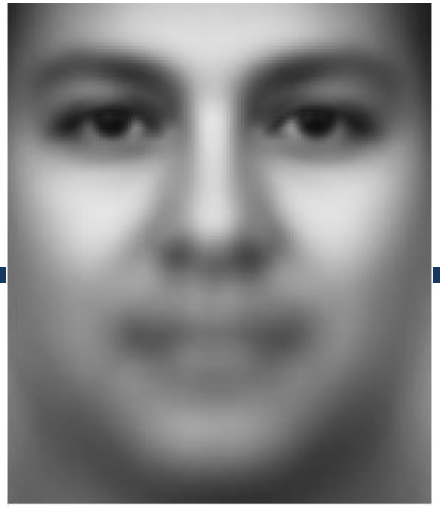

主成分分析-应用

特征脸(Eigenfaces)#101~#108

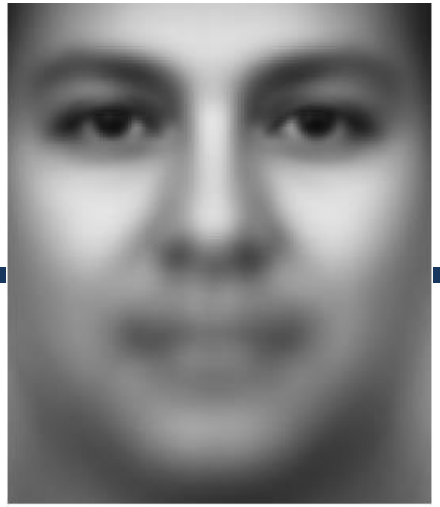

主成分分析-应用

特征脸(Eigenfaces)#501~#508

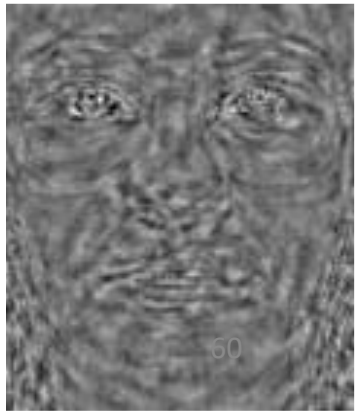

讨论

- **PCA的优点**

具有很高普适性，最大程度地保持了原有数据的信息；

可对主元的重要性进行排序，并根据需要略去部分维数，达到降维从而简化模型或对数据进行压缩的效果，采样密度增大。

当数据受到特征影响时，较小特征值所对应的特征向量往往与噪声有关。略去部分维数能起到一定的去噪效果。

完全无参数限制，在计算过程中不需要人为设定参数或是根据任何经验模型对计算进行干预，最终结果只与数据相关。

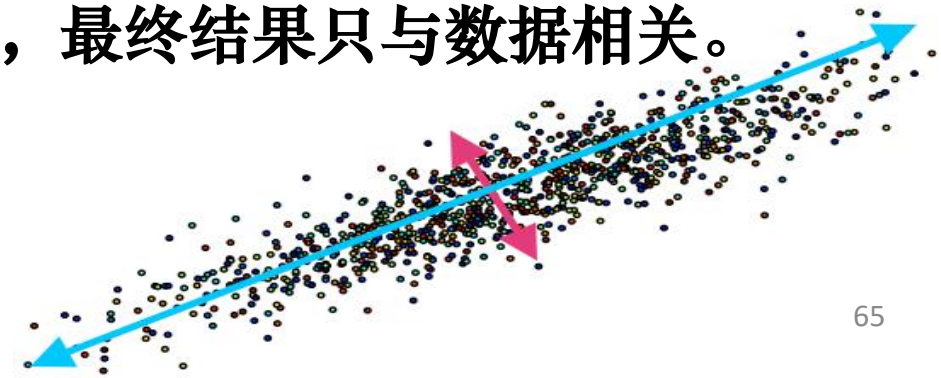

讨论

- **PCA的局限性**

假设模型是线性的，也就决定了它能进行的主元分析之间的关系也是线性的；

假设数据具有较高信噪比，具有最高方差的一维向量被看作是主元，而方差较小的变化被认为是噪声。

假设概率分布模型是指数型；

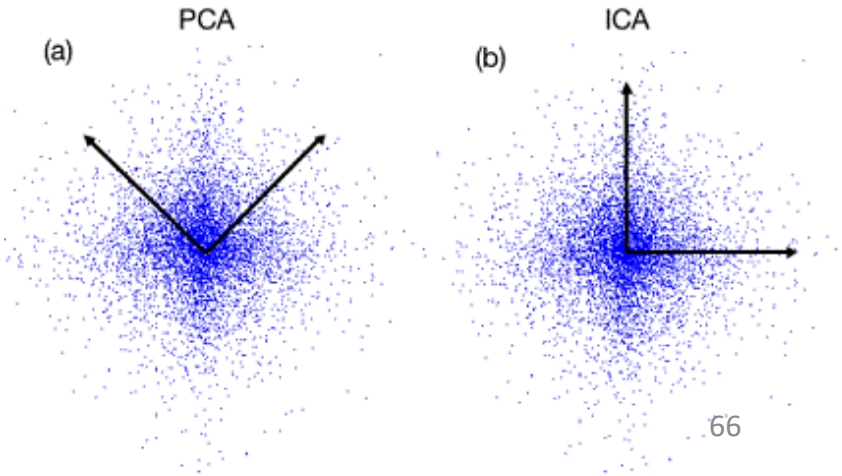

讨论

- **PCA *vs.* LDA**

PCA追求降维后能够最大化保持数据内在信息，并通过衡量在投影方向上的数据方差来判断其重要性。但这对数据的区分作用并不大，反而可能使得数据点混杂在一起。

LDA所追求的目标与PCA不同，不是希望保持数据最多的信息，而是希望数据在降维后能够很容易地被区分开。

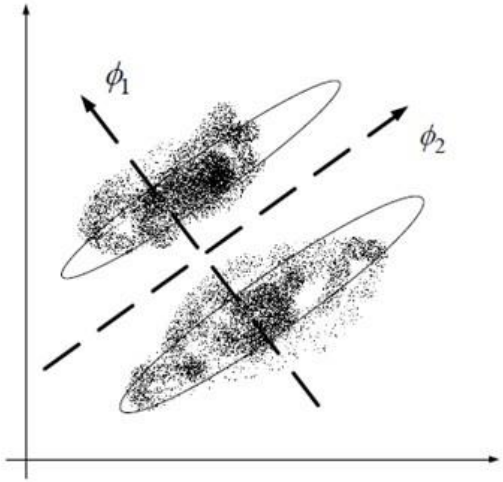

讨论

- **PCA *vs*. LDA**

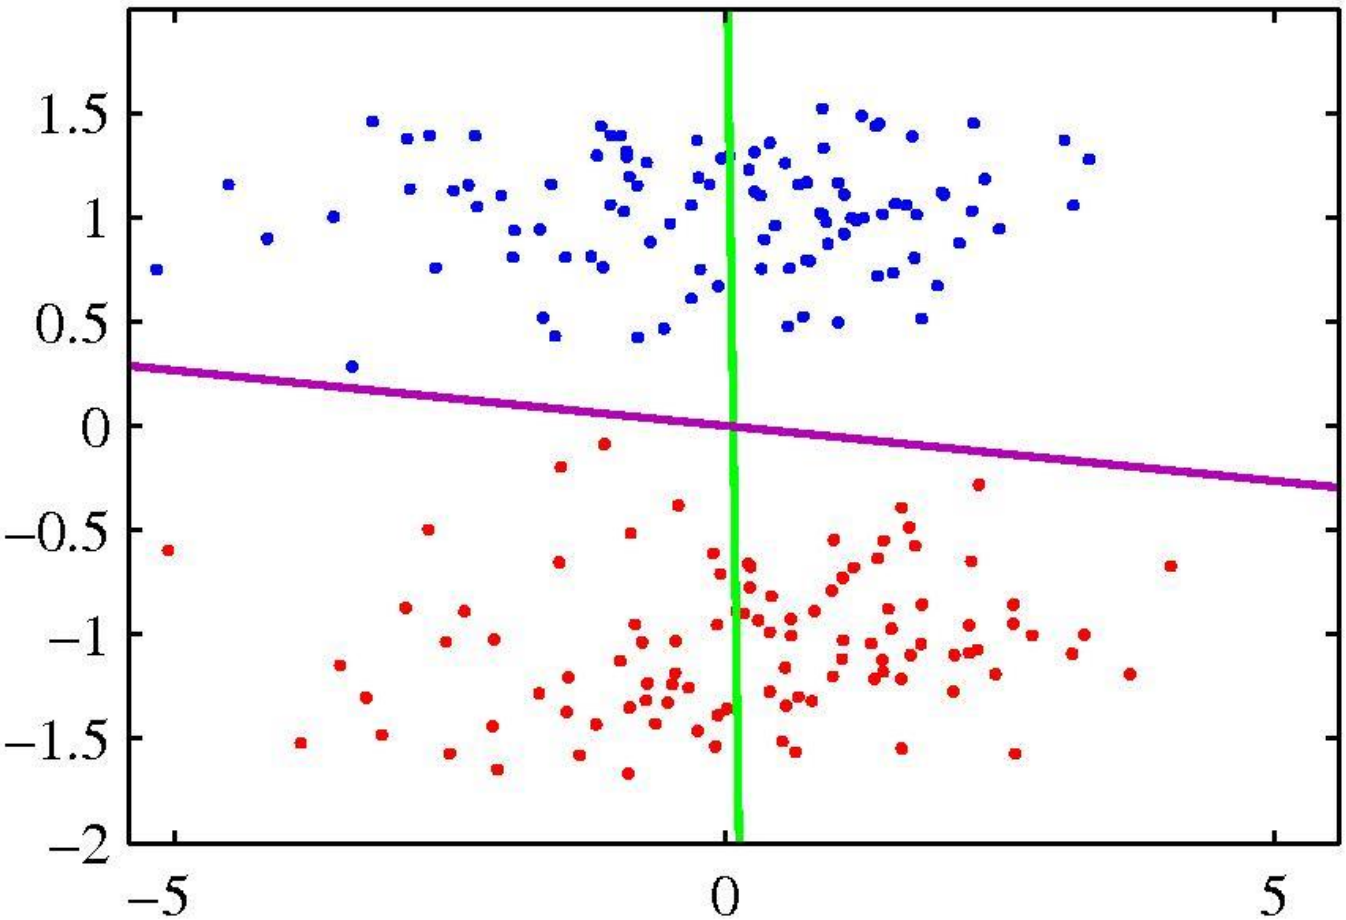

核主成分分析

- **Kernel PCA**

将主成分分析的线性假设一般化使之适应非线性数据

传统PCA：*D*维样本 $\{\mathbf{x}_n\}, n = 1, 2, ..., N$**，** $\sum_n \mathbf{x}_n = \mathbf{0}$

$$\mathbf{S}\mathbf{u}_i = \lambda_i \mathbf{u}_i \quad \mathbf{S} = \frac{1}{N}\sum_{n=1}^{N} \mathbf{x}_n \mathbf{x}_n^{\mathrm{T}} \quad \mathbf{u}_i^T \mathbf{u}_i = 1$$

核PCA：非线性映射 $\phi(\mathbf{x})$**，** $\mathbf{x}_n \longmapsto \phi(\mathbf{x}_n)$**，** $\Sigma_n \phi(\mathbf{x}_n) = 0$

$$\mathbf{C} = \frac{1}{N}\sum_{n=1}^{N} \phi(\mathbf{x}_n)\phi(\mathbf{x}_n)^{\mathrm{T}} \qquad \mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i$$

***C*：*N*个矩阵相加求平均。高维度且*φ*未知，难以直接计算*C*的特征值与特征向量。考虑引入核函数：**

$$k(\mathbf{x}_n, \mathbf{x}_m) = \phi(\mathbf{x}_n)^{\mathrm{T}} \phi(\mathbf{x}_m)$$ **内积！**

核主成分分析

- **Kernel PCA**

矩阵中每一个元素仅由两个（变换空间中的）样本计算得到

核PCA：$K = X^T X$，其中$\boxed{K_{ij} = k(x_i, x_j),}$ $X = [\varphi(x_1), \dots, \varphi(x_n)]$

$$(X^T X)\mu = \lambda\mu$$

$$\longrightarrow \quad X(X^T X)\mu = \lambda X\mu$$

$$(XX^T)X\mu = \lambda X\mu$$

v与μ的关系：

$$v = X\mu$$

由于φ未知，所以X未知

v归一化

$$v = \frac{1}{\|X\mu\|} X\mu = \frac{1}{\sqrt{\mu^T X^T X \mu}} X\mu = \frac{1}{\sqrt{\mu^T \lambda \mu}} X\mu = \boxed{\frac{1}{\sqrt{\lambda}} X\mu}$$

但我们通常仅关注于投影到v 后的坐标，对于新样本x：

$$v^T \varphi(x) = \frac{1}{\sqrt{\lambda}} \mu^T X^T \varphi(x) = \frac{1}{\sqrt{\lambda}} \mu^T \begin{bmatrix} \varphi(x_1)^T \\ \dots \\ \varphi(x_N)^T \end{bmatrix} \varphi(x) = \frac{1}{\sqrt{\lambda}} \mu^T \begin{bmatrix} k(x_1, x) \\ \dots \\ k(x_N, x) \end{bmatrix}$$

核主成分分析

- **Kernel PCA**

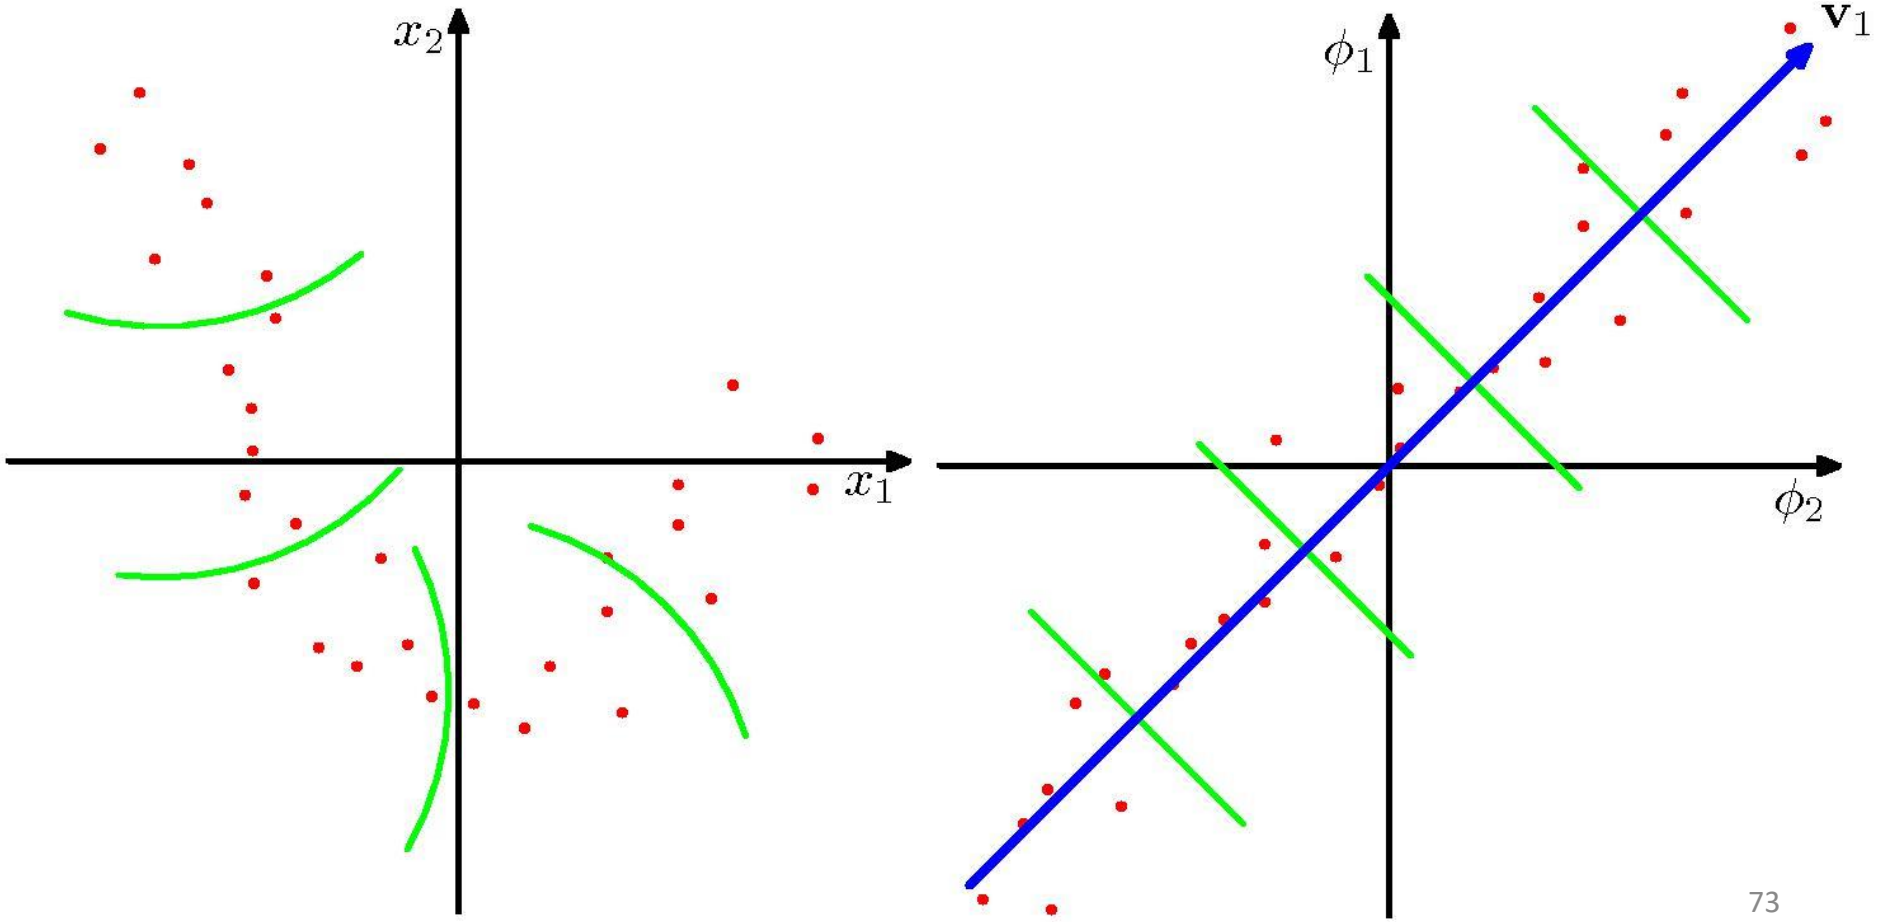

核主成分分析

- **Kernel PCA**

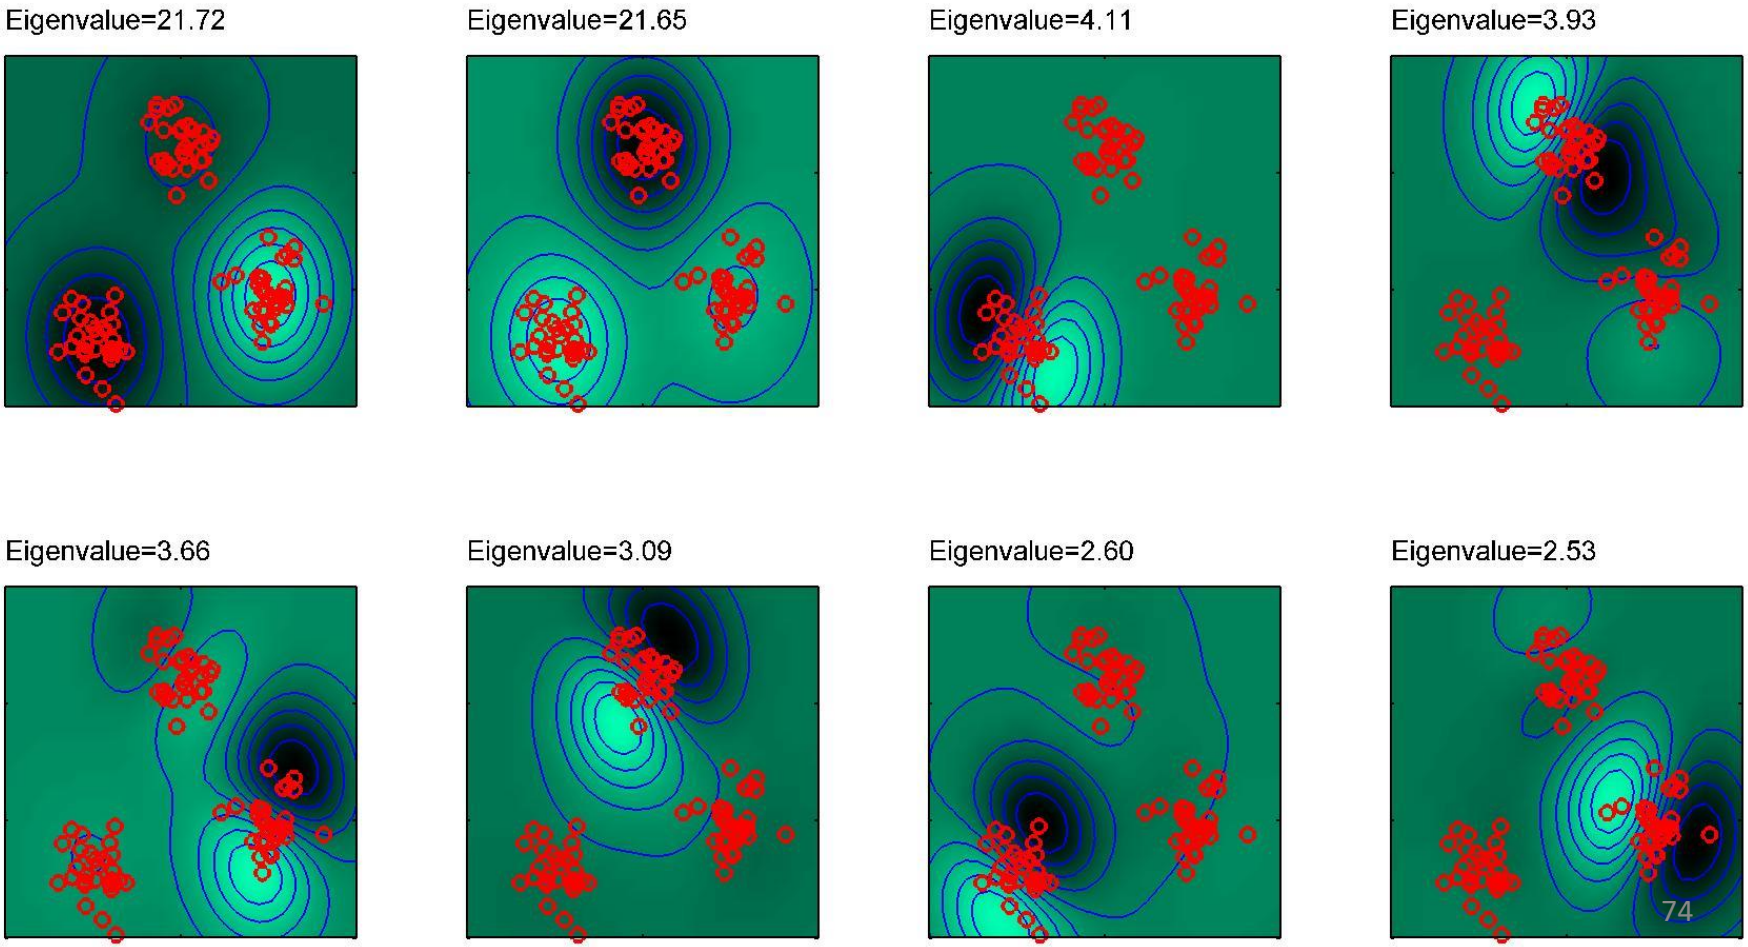

MDS (Multi-dimensional Scaling)
多维尺度分析

MDS的基本背景

- MDS基本出发点：将样本之间的距离关系或不相似关系在低维空间中表示出来。
  - 度量型（定量度量样本间距离）
  - 非度量型（定性度量样本间距离）

  - 古典尺度法：主坐标分析方法。根据两两点之间的距离关系（距离矩阵），确定在空间中的坐标。

距离矩阵

- **距离阵的定义：**

一个$n \times n$ **矩阵** $D = \{d_{ij}\}$ **,如果满足以下条件：**

$$d_{ij} \geq 0, d_{ii} = 0, i, j = 1, \ldots, n$$

d_{ij} **称为第*i*与第*j*个点间的距离**

距离矩阵通常不限于欧式距离。

有了距离矩阵，多维尺度法的目的就是要确定维数*k*，并在*k*维空间 R_k **中求*n*个点** $\{x_1, x_2, x_3, \ldots, x_n\}$ **,使得*n*个点的欧式距离与距离阵中的相应值在某种意义下尽量接近。**

MDS算法推导

- **原始数据矩阵**为样本X的 $n \times q$ 维矩阵，n为样本数，q是原始数据的维度（样本表示成行向量）
- 为了方便计算，对原始数据矩阵进行**中心化**：

$$\sum_{i=1}^{n} x_{ik} = 0, k = 0,1,..,q$$

MDS算法推导

- 我们首先构造一个**内积矩阵** $B = XX^T$ ，B 为 $n \times n$ 的矩阵。

$$B = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1q} \\ . & . & . & . \\ . & . & . & . \\ x_{n1} & x_{n2} & . & x_{nq} \end{bmatrix} \times \begin{bmatrix} x_{11} & . & . & x_{n1} \\ x_{12} & . & . & x_{n2} \\ . & . & . & . \\ x_{1q} & . & . & x_{nq} \end{bmatrix}$$

$$= \begin{bmatrix} x_{11}^2 + x_{12}^2 + \dots + x_{1q}^2 & . & . & x_{11}x_{n1} + x_{12}x_{n2} + \dots + x_{1q}x_{nq} \\ . & . & . & . \\ . & . & . & . \\ x_{n1}x_{11} + x_{n2}x_{12} + \dots + x_{nq}x_{1q} & . & . & x_{n1}^2 + x_{n2}^2 + \dots + x_{nq}^2 \end{bmatrix}_{n \times n}$$

$$b_{ij} = \sum_{k=1}^{q} x_{ik} x_{jk} = x_i x_j$$

MDS算法推导

- 距离矩阵D的计算公式为：

$$d_{ij}^2 = (x_i - x_j)^2 = x_i^2 + x_j^2 - 2x_i x_j$$

- 因为 $b_{ij} = x_i x_j$，
- 所以：$d_{ij}^2 = \sum_{k=1}^{q} x_{ik}^2 + \sum_{k=1}^{q} x_{jk}^2 - 2b_{ij} = b_{ii} + b_{jj} - 2b_{ij}$

MDS算法推导

- 由于进行了中心化处理，所以：

$$\sum_{i=1}^{n} x_{ik} = 0, k = 0,1,..,q$$

- 因此：

$$\sum_{j=1}^{n} b_{ij} = \sum_{j=1}^{n}\sum_{k=1}^{q} x_{ik}x_{jk}$$

$$= \sum_{k=1}^{q}(x_{ik}\sum_{j=1}^{n} x_{jk})$$

$$= 0$$

同理：

$$\sum_{i=1}^{n} b_{ij} = \sum_{i=1}^{n}\sum_{k=1}^{q} x_{ik}x_{jk}$$

$$= \sum_{k=1}^{q}(x_{jk}\sum_{i=1}^{n} x_{ik})$$

$$= 0$$

MDS算法推导

- 那么：

$$\sum_{i=1}^{n} d_{ij}^2 = \sum_{i=1}^{n} b_{ii} + \sum_{i=1}^{n} b_{jj} - 2\sum_{i=1}^{n} b_{ij}$$

$$= \sum_{i=1}^{n} b_{ii} + nb_{jj}$$

$$\boxed{Trace = \sum_{i=1}^{n} b_{ii} = \sum_{j=1}^{n} b_{jj}}$$

$$\sum_{j=1}^{n} d_{ij}^2 = \sum_{j=1}^{n} b_{ii} + \sum_{j=1}^{n} b_{jj} - 2\sum_{j=1}^{n} b_{ij}$$

$$= \sum_{j=1}^{n} b_{jj} + nb_{ii}$$

$$\sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}^2 = \sum_{i=1}^{n}\sum_{j=1}^{n} b_{jj} + \sum_{i=1}^{n} nb_{ii} = n\sum_{j=1}^{n} b_{jj} + n\sum_{i=1}^{n} b_{ii} = 2nT$$

MDS算法推导

- 于是联立以下等式：

$$d_{ij}^2 = \sum_{k=1}^{q} x_{ik}^2 + \sum_{k=1}^{q} x_{jk}^2 - 2b_{ij} = b_{ii} + b_{jj} - 2b_{ij}$$

$$\sum_{i=1}^{n} d_{ij}^2 = T + nb_{jj} \Rightarrow b_{jj} = \frac{T}{n} + \frac{1}{n}\sum_{i=1}^{n} d_{ij}^2$$

$$\sum_{j=1}^{n} d_{ij}^2 = T + nb_{ii} \Rightarrow b_{ii} = \frac{T}{n} + \frac{1}{n}\sum_{i=1}^{n} d_{ij}^2$$

$$\sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}^2 = 2nT \Rightarrow \frac{2T}{n} = \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}^2$$

MDS算法推导

$$b_{ij} = -\frac{1}{2}(d_{ij}^2 - b_{ii} - b_{jj})$$

$$= -\frac{1}{2}(d_{ij}^2 - \frac{1}{n}\sum_{j=1}^{n} d_{ij}^2 - \frac{1}{n}\sum_{i=1}^{n} d_{ij}^2 + \frac{2T}{n})$$

$$= -\frac{1}{2}(d_{ij}^2 - \frac{1}{n}\sum_{j=1}^{n} d_{ij}^2 - \frac{1}{n}\sum_{i=1}^{n} d_{ij}^2 + \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}^2)$$

- **由上述公式，$B = XX^T$ 内积矩阵可以完全由 D 距离阵得出！**
- $\boldsymbol{B = \frac{-1}{2}HSH}$**, 其中** $H = I_n - \frac{1}{N}\mathbf{1}\mathbf{1}^T \quad S(i,j) = D_G^2(i,j)$

MDS推导

- $B = XX^T$ ，可以**对角化**：

$$\boldsymbol{B} = \boldsymbol{V\Lambda V}^{-1} = \boldsymbol{V\Lambda}^{1/2}\boldsymbol{\Lambda}^{1/2}\boldsymbol{V}^{-1} = \boldsymbol{XX}^{\boldsymbol{T}}$$

- 其中， Λ 是由矩阵B的特征向量组成的矩阵，V是由特征向量组成的矩阵。

- 因此如果想通过距离阵还原原始数据，就选择B矩阵的q个向量，**如果想达到降维的目的，就选择$p(p<q)$ 个特征向量**。最终降维的数据X为：

$$\mathrm{X} = V\Lambda^{1/2}$$

等距映射
ISO-Metric Mapping

等距映射

- **ISO-Metric Mapping**

高维空间中直接计算直线距离具有误导性，因为该直线距离在低维嵌入中具有不可达性。

思想：通过局部距离来定义非线性距离度量，在样本较密集的情况下可以实现复杂的非线性距离度量。

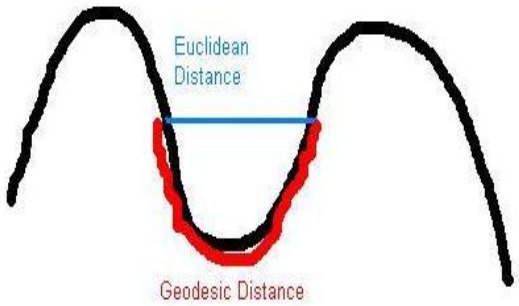

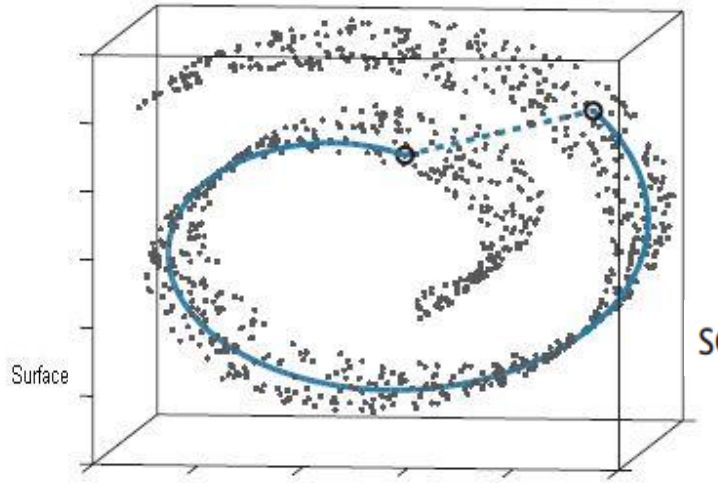

A Global Geometric Framework for Nonlinear Dimensionality Reduction

Joshua B. Tenenbaum,[1*] Vin de Silva,[2] John C. Langford[3]

SCIENCE VOL 290 22 DECEMBER 2000

等距映射

- **ISO-Metric Mapping (ISOMAP)**

保持数据点内在几何性质(测地距离)

对于给定数据 $X = \{x_1, x_2, \ldots, x_N\}$**，构造加权图** $G = \{V, E\}$

***V*是顶点集合，*E*是边的集合**

若 $d(i,j) = dist(x_i, x_j)$

小于某个值 ϵ **(**$\epsilon - \mathrm{ISOMAP}$**)**

或*j*是*i*的*K*近邻($K - \mathrm{ISOMAP}$**)**

则顶点*i*与*j*的边权值设为$d(i,j)$**，否则为0。**

$G = (V, E)$

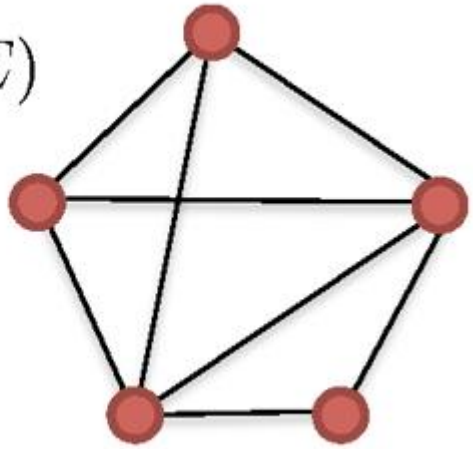

等距映射

- **ISO-Metric Mapping (ISOMAP)**

保持数据点内在几何性质(测地距离)

计算图 $G=\{V,E\}$**中任意两点间的最短距离，得到矩阵** $D_G(i,j)$

- **Dijkstra最短路径算法**
- **Floyd–Warshall算法**

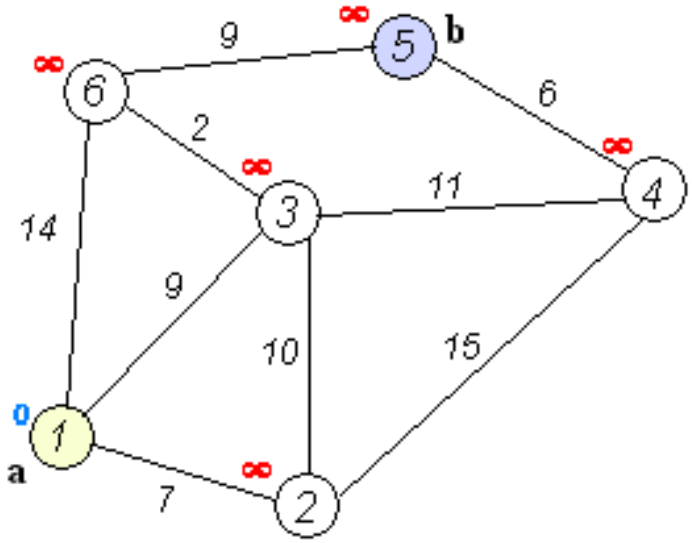

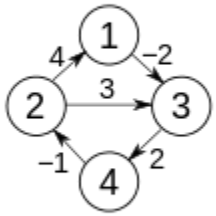

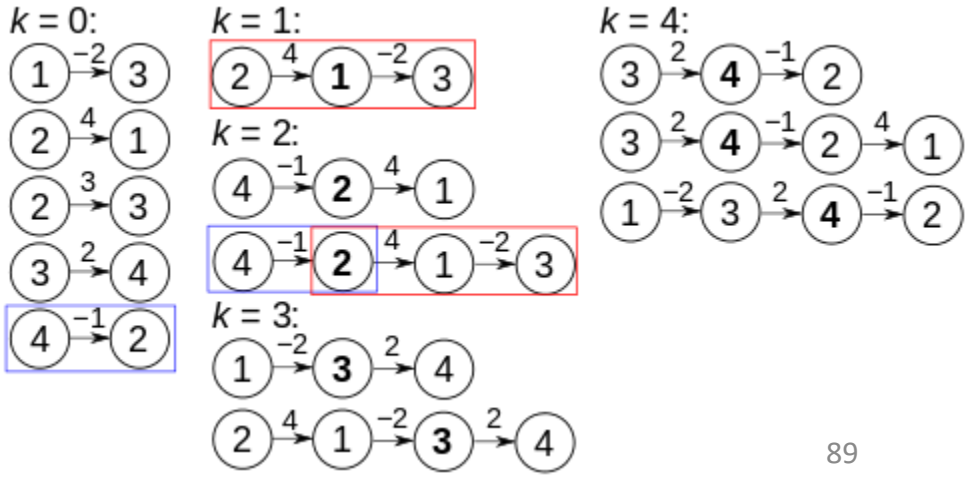

等距映射

- **ISO-Metric Mapping (ISOMAP)**

保持数据点内在几何性质(测地距离)

根据样本间的距离矩阵，可用MDS（多维尺度法）映射到低维空间，具体做法（以古典尺度法为例）：

定义平方距离矩阵 $S(i,j) = D_G^2(i,j)$

并令 $H = I_n - \frac{1}{N}\mathbf{1}\mathbf{1}^T$**(中心矩阵，Centering Matrix)**

并求矩阵$B = \frac{-1}{2}HSH$ **的特征值与特征向量(按特征值降序排列)，**λ_p**为第*p*个特征值，**v_p **为对应的特征向量。**

降维矩阵为$[\sqrt{\lambda_1}v_1, \ldots, \sqrt{\lambda_d}v_d]_{N\times d}$

等距映射

- **ISO-Metric Mapping (ISOMAP)**

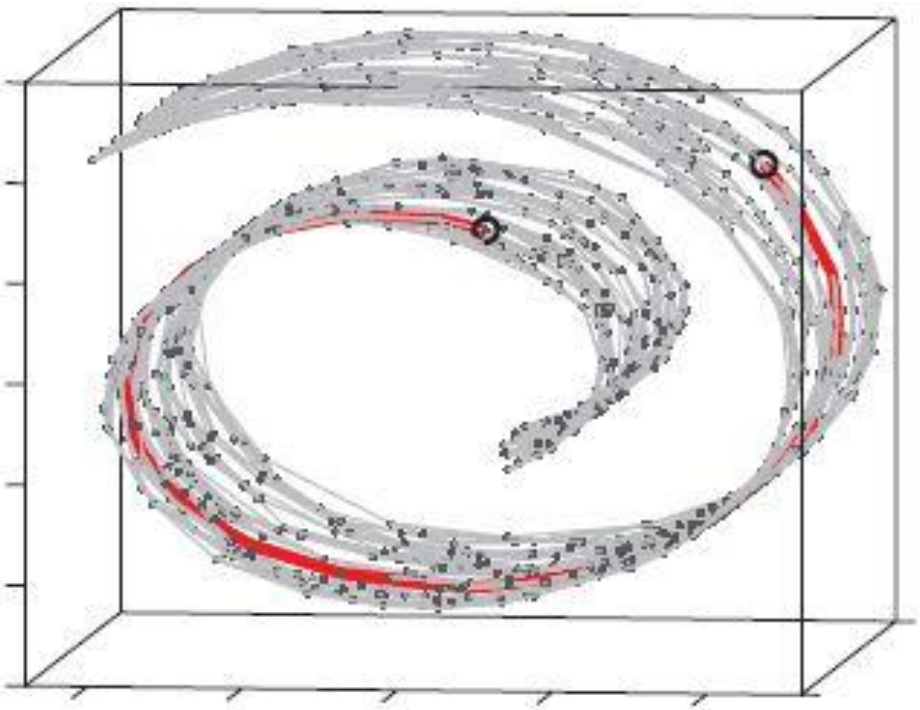

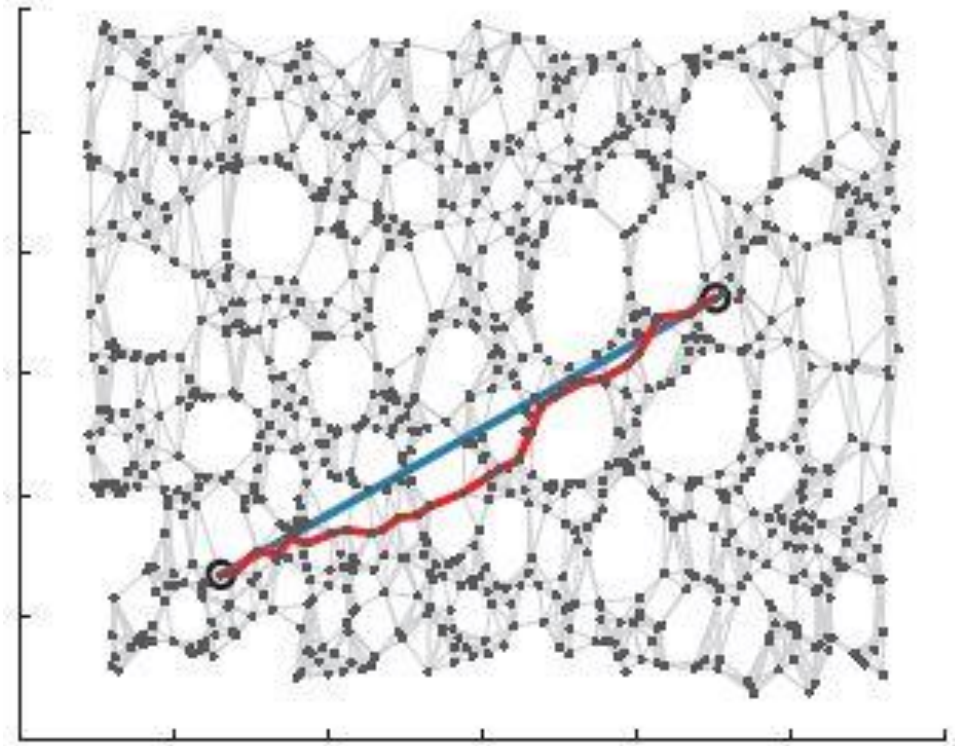

***K*=7（*K*个最近邻点），**
***N*=1000**

等距映射

- 计算步骤

①构造临近关系图

对每一个点，将它与指定半径邻域内所有点相连(或与指定个数最近邻相连)

②计算最短路径

计算临近关系图所有点对之间的最短路径，得到距离矩阵

③多尺度分析

将高维空间中的数据点投影到低维空间，使**投影前后的距离矩阵相似度最大**

等距映射

- **ISOMAP优点和缺点**

非线性

非迭代

全局最优

参数可调节

容易受噪声干扰

在大曲率区域存在短路现象

不适用于非凸参数空间

大样本训练速度慢

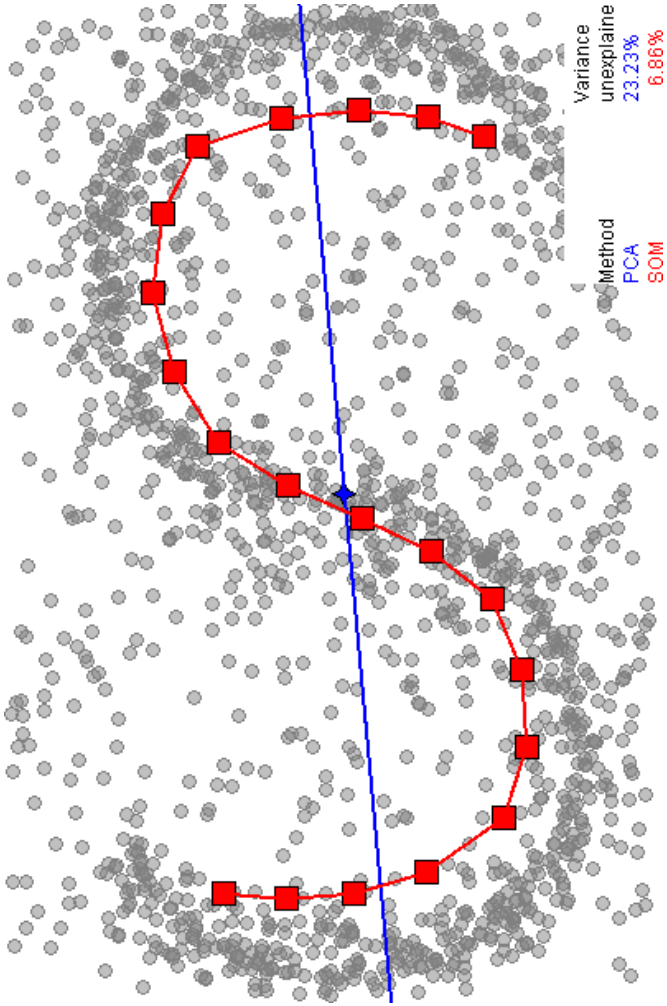

局部线性嵌入

- **Local Linear Embedding (LLE)**

保持数据点的原有流形结构

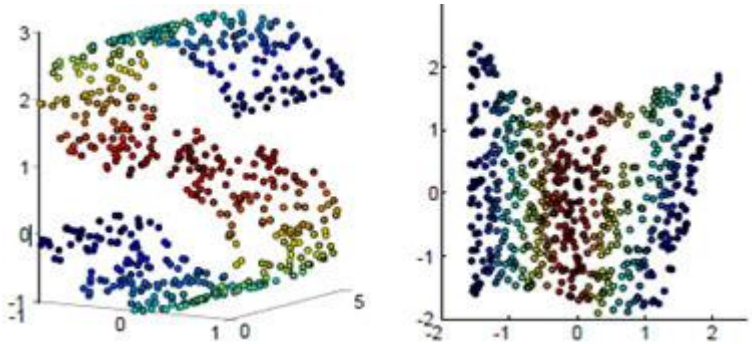

Nonlinear Dimensionality Reduction by Locally Linear Embedding

Sam T. Roweis[1] and Lawrence K. Saul[2]

SCIENCE VOL 290 22 DECEMBER 2000

前提假设：采样数据所在的低维流形在**局部是线性的**，每个采样点可以用它的近邻点线性表示。

学习目标：在低维空间中**保持每个邻域中的权值不变**，即假设嵌入映射在局部是线性的条件下，**最小化重构误差**。

局部线性嵌入

- 计算步骤

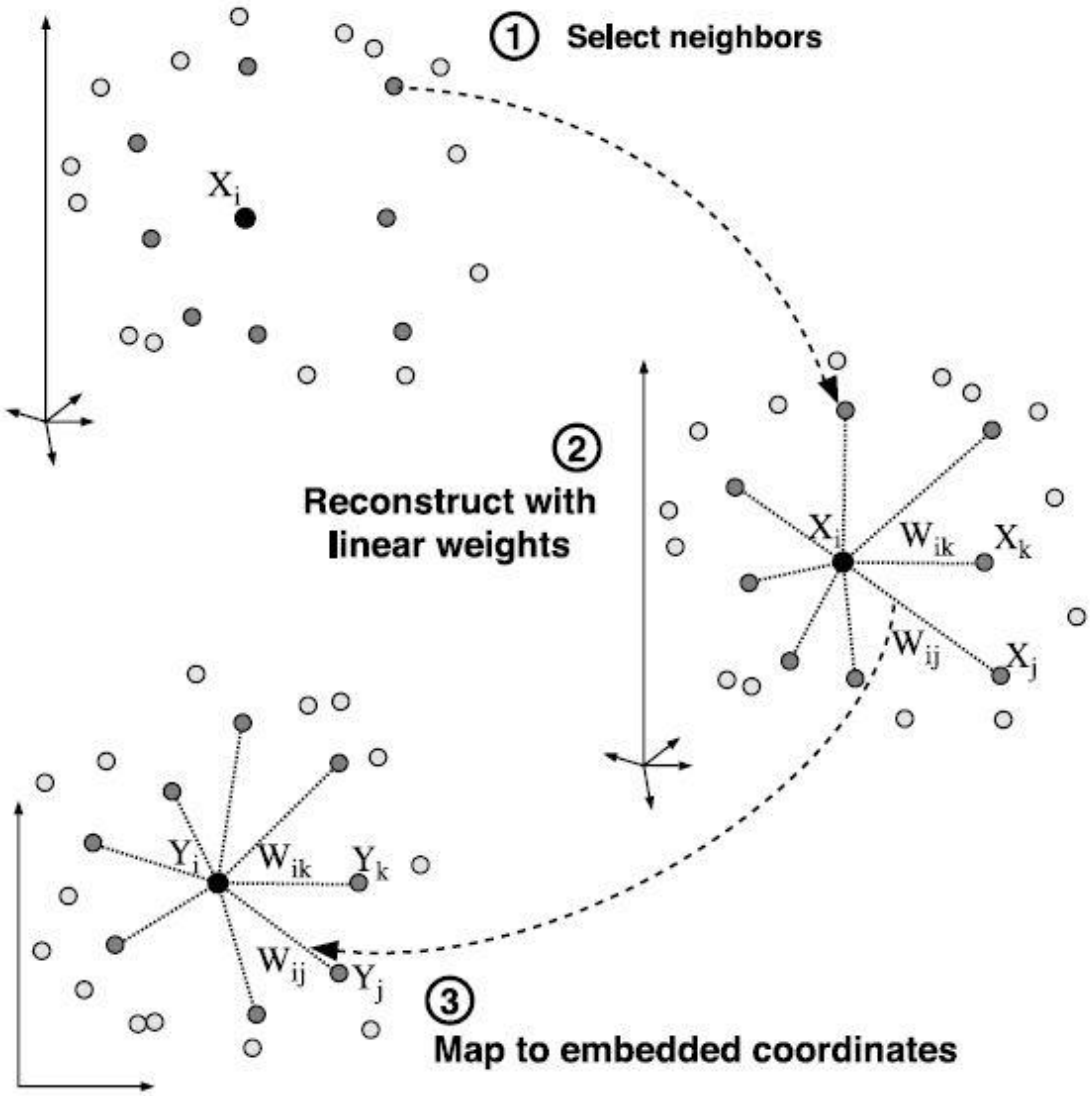
① Select neighbors
X_i
② Reconstruct with linear weights
X_i
W_{ik}
X_k
W_{ij}
X_j
Y_i
W_{ik}
Y_k
W_{ij}
Y_j
③ Map to embedded coordinates

局部线性嵌入

- **Local Linear Embedding (LLE)**

保持数据点的原有流形结构：多个点之间的局部线性关系

寻找每个样本点的*K*近邻 $x_{ij}(j=1,\ldots,k)$

对每个点用*K*个近邻进行重建，即求一组权值 w_{ij}, $\sum_j w_{ij}=1$

使 $\min\sum_i |x_i-\sum_j w_{ij}x_{ij}|^2$ **，即权值描述了局部关系。**

保持相对位置关系，求低维空间中的点集 y_i

使 $\min\sum_i |y_i-\sum_j w_{ij}y_{ij}|^2$

局部线性嵌入

- **Local Linear Embedding (LLE)**

保持数据点的原有流形结构

计算权值，首先构造局部协方差矩阵 C^i

$$C^i_{jk} = (x_i - x_j) \cdot (x_i - x_k)$$

然后，最小化 $\min \sum_i |x_i - \sum_j w_{ij} x_{ij}|^2$

$$s.t. \quad \sum_j w_{ij} = 1$$

最后可求得闭式解: $w_{ij} = \frac{\sum_k (C^i_{jk})^{-1}}{\sum_{jk} (C^i_{jk})^{-1}}$

局部线性嵌入

- **Local Linear Embedding (LLE)**

保持数据点的原有流形结构

计算低维数据，最小化 $\min \sum_i |y_i - \sum_j w_{ij} y_{ij}|^2$

可转化为最小化 $\min \sum_{ij} M_{ij}(y_i \cdot y_j)$

其中， $M = (I - W)^T (I - W)$

- **根据优化目标和约束条件，构造拉格朗日方程，求导置零得到**

求解 $MY = \lambda Y$

取*Y*为*M*的最小*d*个非零特征值所对应的特征向量，最终的输出结果即为*N*×*d*大小的矩阵

局部线性嵌入

- **Local Linear Embedding (LLE)**

Surfaces

N=1000
inputs

k=8
nearest neighbors

D=3
d=2
dimensions

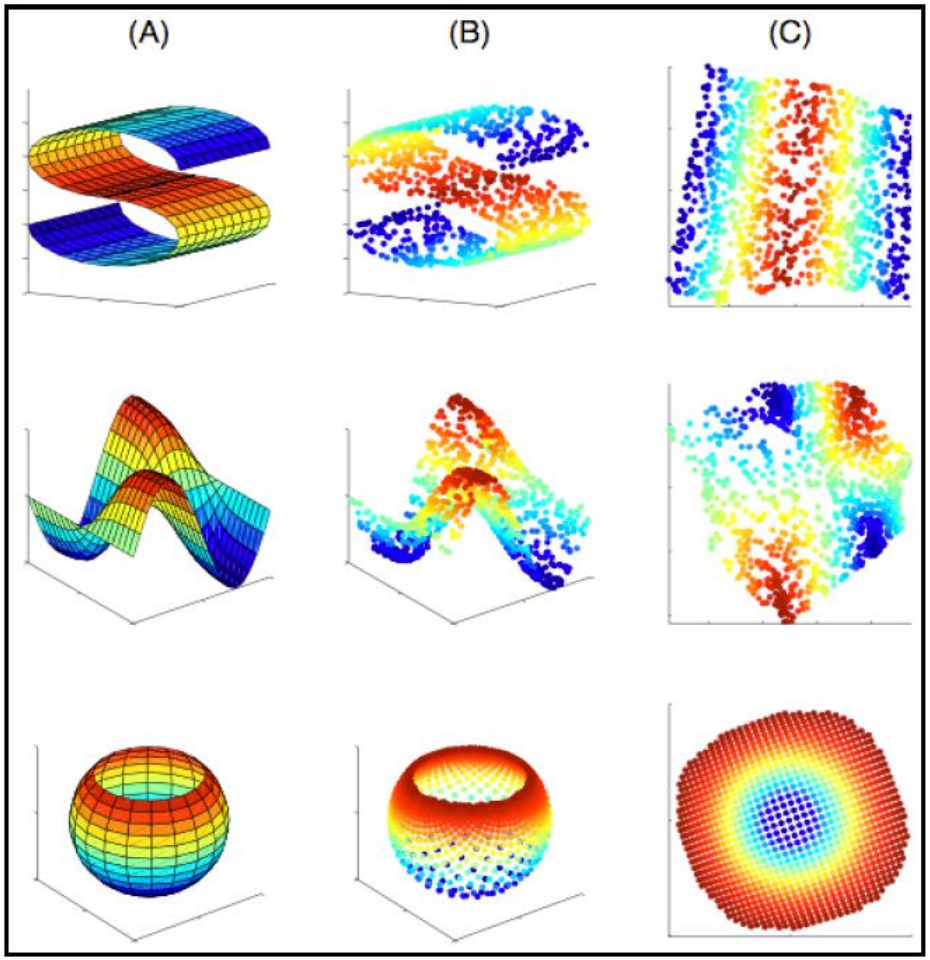

局部线性嵌入

- **Local Linear Embedding (LLE)**

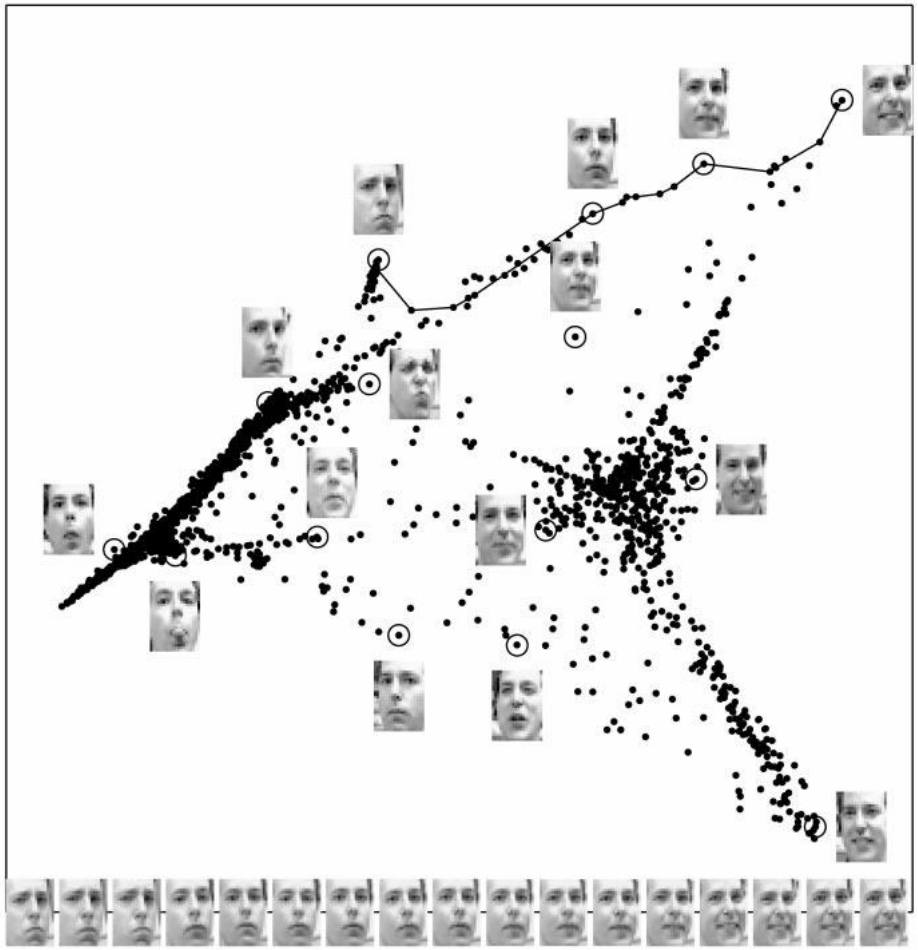

局部线性嵌入

- **Local Linear Embedding (LLE)**

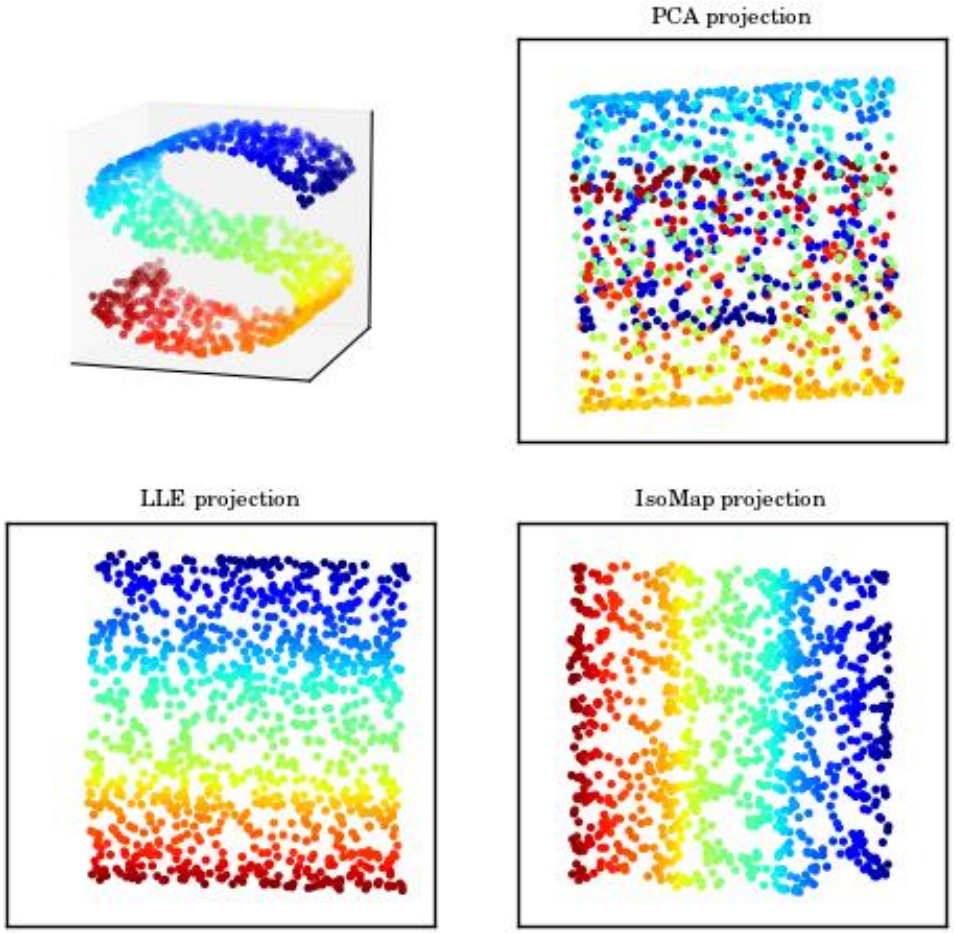

讨论

- 特征选择与特征提取

特征提取和特征选择是降维（Dimension Reduction）的两种方法，针对于维度灾难 (curse of dimensionality)，都可以达到降维的目的。但是这两个有所不同。

特征提取（Feature Extraction）：特征提取后的新特征是原来特征的一个映射。

特征选择（Feature Selection）：特征选择后的特征是原来特征的一个子集。

模式识别

第七章：特征选择与提取

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022