模式识别

第四章：贝叶斯决策理论

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022

内容

- 引言
- 最小错误率贝叶斯决策规则
- 最小风险贝叶斯决策规则
- 正态分布时的统计决策
- 错误率的计算
- 生成式模型与判别式模型

引言

一个简单的例子

- 例：医生要根据病人血液中白细胞的浓度来判断病人是否患血液病。（两分类问题）
- 在没有任何信息的情况下，如何做决策?

引言

基本符号与定义

- 对该问题的数学表示如下：
- 用Ω表示“类别”这一随机变量，ω_1表示正常，ω_2表示患病
- X表示“白细胞浓度”这个随机变量
- x表示浓度值
- 决策：根据观测到的x, 利用先验概率和类条件概率，决定x属于哪一类
- 决策是从样本空间到决策空间的一个映射

引言

一个简单的例子

- 把血液浓度值记为x，患病和健康两类分别记作ω_1和ω_2。 用$P(\omega_1)$和$P(\omega_2)$分别表示两类的**概率**，这一决策规则可以表示为：

  如果$P(\omega_1) > P(\omega_2)$， 则$x \in \omega_1$；反之， $x \in \omega_2$

- 上面所说的概率$P(\omega_1)$和$P(\omega_2)$是在没有对样本进行任何观测情况下的概率，所以叫做**先验概率**（Prior probability）。

引言

- 若此时观测到白细胞的浓度x，考察该情况下属于各类的概率，分别记作$p(\omega_1|x)$和$p(\omega_2|x)$。这种概率叫做**后验概率**（posterior probability）。决策规则为：

  如果$p(\omega_1|x)>p(\omega_2|x)$，则$x\in\omega_1$；反之，$x\in\omega_2$

- 问题是：如果只测了x，如何才能知道$p(\omega_i|x)$，$i=1,2$?

引言

- 根据以往医生的经验知道：
  - 患病的人，白细胞的浓度与正常人不同
  - 一般人群中，患病的人数比例为0.1。
- 医生的先验概率：

$$P(\omega_1) = 0.9$$
$$P(\omega_2) = 0.1$$

- 如果已知一个人的白细胞浓度，医生应该做出怎样的判断?

引言

- 根据概率论中的贝叶斯公式，有：

$$p(\omega_i|x) = \frac{P(x,\omega_i)}{P(x)} = \frac{P(x|\omega_i)P(\omega_i)}{P(x)}, i = 1,2$$

- 其中， $P(\omega_i)$是先验概率； $P(x, \omega_i)$是x与ω_i的联合概率密度；$P(x)$是两类**所有样本的概率密度**，称作**总体密度**。
- 这样，**后验概率就转化成为了先验概率与类条件密度的乘积，再用整体的密度进行归一化**。
- 在比较时，总体密度没有区别，因此只需要比较分子项。决策规则如下：

  如果$P(x|\omega_1)P(\omega_1) > P(x|\omega_2)P(\omega_2)$，则$x \in \omega_1$；反之，$x \in \omega_2$
- 其中，**先验概率**需要根据实际健康人群和患者的总体比例进行估计；类条件密度则需要用一定的属于**本类别的训练样本**来进行估计。

引言

- **贝叶斯决策**：在**类条件概率密度**和**先验已知**（或可以估计）的情况下，通过贝叶斯公式比较样本属于两类的**后验概率**，将类别决策为后验概率大的一类。（这样做的**目的**是使得整体的**错误率最小**）。

- 在只有两类的情况下， $P(\omega_1) + P(\omega_2) = 1$；如果决策$P(\omega_1)$，那么犯错误的概率就是$P(error) = 1 - P(\omega_1) = P(\omega_2)$；反之亦然。

引言

- 贝叶斯决策理论是统计模式识别中最基本的方法，利用此方法进行分类时要求:
  - 各类别总体的概率分布是已知的
  - 待决策分类的类别数是一定的、类条件概率已知
  - 各类别先验概率已知
- 统计决策理论：根据每一类总体的概率分布决定决策边界

引言

基本符号与定义

- 在连续的情况下，假设对要识别的物理对象有d种特征观察量：

$$x_1, x_2, \dots, x_d$$

- 这些特征的所有可能的取值范围构成了d维空间：

$$x = [x_1, x_2, \dots, x_d]^T$$

- 我们又称x为d维特征向量。

引言

基本符号与定义

- 假设要分类的问题有c个类别，各类别状态用ω_i来表示，其中$i = 1, 2, \ldots, c$
- 且对应于各类别的w_i出现的先验概率$P(\omega_i)$及类条件概率密度$p(x|\omega_i)$已知
- 如果在特征空间已经观察到某一个向量x, 所要做的决策就是确定把x分到哪一类。
- Bayes决策是所有识别方法的一个基准
- 评价决策有多种标准，对于同一个问题，采用不同的标准会得到不同意义下“最优”的决策。

引言

基本符号与定义

- Bayes决策两种常用的准则：
  - 最小错误概率准则
  - 最小风险准则

最小错误率准则

基于最小错误概率的贝叶斯决策

- 对于二分类问题，在样本x上错误的概率为：

$$P(e|x)=\begin{cases}P(\omega_2|x)=1-P(\omega_1|x) & \text{若决定}x\in\omega_1\\ P(\omega_1|x)=1-P(\omega_2|x) & \text{若决定}x\in\omega_2\end{cases}$$

- 错误率定义为所有服从同样分布的独立样本上的错误概率的期望。

- 从最小错误率的要求出发，已知先验概率和类条件概率密度，利用贝叶斯公式，就能够求得使错误率最小的分类决策，称为最小错误率贝叶斯决策。即：

$$\min P(e)=\int_{-\infty}^{+\infty}P(e|x)p(x)dx$$

- 上式等价于对于所有的x，最小化$P(e|x)$。等价于使得后验概率最大的决策。
- 其中，后验概率用贝叶斯公式求得：

$$p(\omega_i|x)=\frac{p(x|\omega_i)P(\omega_i)}{P(x)}=\frac{p(x|\omega_i)P(\omega_i)}{\sum_{j=1}^{2}p(x|\omega_j)P(\omega_j)}$$

基于最小错误概率的贝叶斯决策

- **决策规则：**

(1) $P(\omega_i|x) = max_{j=1,2}P(\omega_j|x), x \in \omega_i$

- **其他等价形式：**

(2) $p(x|\omega_i)P(\omega_i) = max_{j=1,2}P(x|\omega_j)P(\omega_j), x \in \omega_i$

(3) 由于先验概率 $P(\omega_i)$是事先确定的，与当前样本x无关，因此，也经常把决策规则整理为下面的形式：

$$若 l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \gtrless \lambda = \frac{P(\omega_2)}{P(\omega_1)}，则 x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

这样，可以事先计算出**似然比**阈值λ，对于每个样本计算$l(x)$，并与λ比较。大于阈值则决策为第一类，否则决策为第二类。概率密度值反映了在ω_i类中特征值x的相对可能性（likelihood），也称为**似然度**，$l(x)$称作**似然比**（likelihood ratio）。

基于最小错误概率的贝叶斯决策

- (4) 很多情况下，用对数形式进行计算更加方便。对上式取**自然对数的负值**，可写为：
  $$\boldsymbol{h}(\boldsymbol{x}) = -\ln\big(\boldsymbol{l}(\boldsymbol{x})\big) = -\ln \mathbf{p}(\boldsymbol{x}|\boldsymbol{\omega}_1) + \ln \mathbf{p}(\boldsymbol{x}|\boldsymbol{\omega}_2)$$
- 那么决策规则可以写作如下形式：

$$\text{若}\boldsymbol{h}(\boldsymbol{x}) \lessgtr \ln\frac{\boldsymbol{P}(\boldsymbol{\omega}_1)}{\boldsymbol{P}(\boldsymbol{\omega}_2)}\text{，则}\boldsymbol{x} \in \begin{cases} \boldsymbol{\omega}_1 \\ \boldsymbol{\omega}_2 \end{cases}$$

基于最小错误概率的贝叶斯决策

- 例题: 前面讲到的白血病检验问题
- 现有一待识别细胞,观察值为x, 从类条件概率密度分布曲线上查得

$$p(x|\omega_1) = 0.2 \quad p(x|\omega_2) = 0.4$$

- 对该细胞进行分类

基于最小错误概率的贝叶斯决策

- 根据医学知识以及以前大量的正常细胞和病症细胞的数据，可以得到两类的类概率密度，如左下图。
- 利用贝叶斯公式，**通过观察x**，把状态的先验概率**转化为后验概率**$P(\omega_i|x)$， $i=1,2$。如右图所示：

$$p(\omega_i|x)=\frac{P(x,\omega_i)}{P(x)}=\frac{P(x|\omega_i)P(\omega_i)}{P(x)},\ i=1,2$$

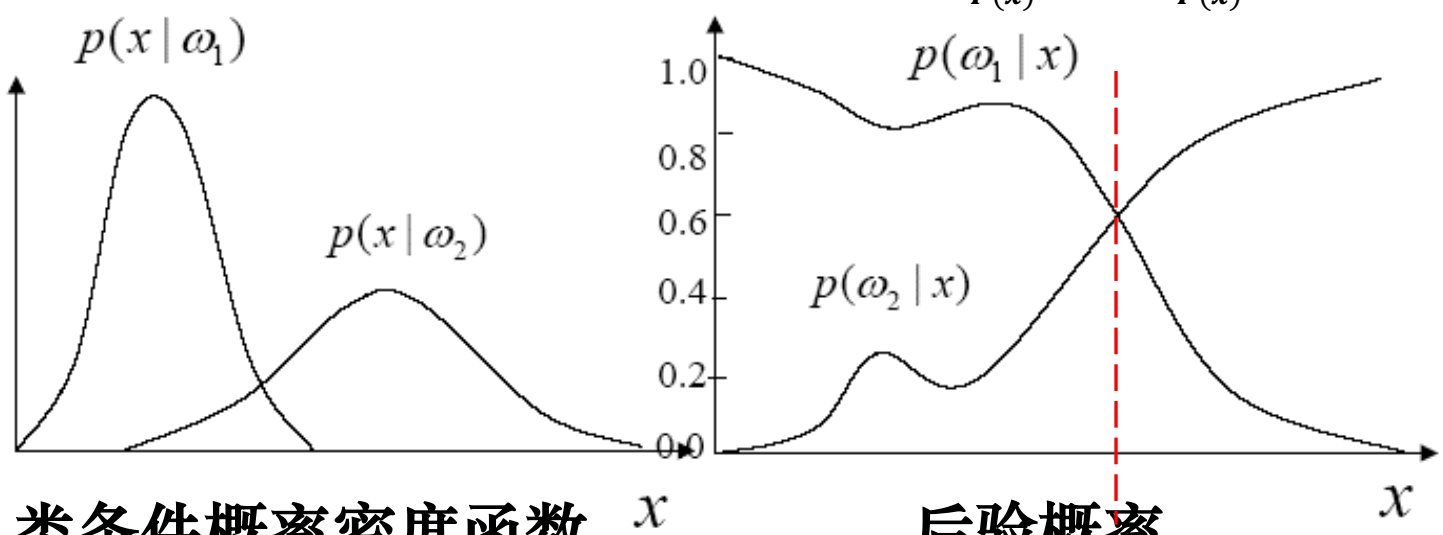

类条件概率密度函数　　后验概率

基于最小错误概率的贝叶斯决策

- 从图中可以看到，这种决策实际的分类线就是图中的虚线位置，被称为**决策边界**或**分类线**。在多维的情况下，称为**决策面**或**分类面**，它把特征空间划分成属于各类的区域。

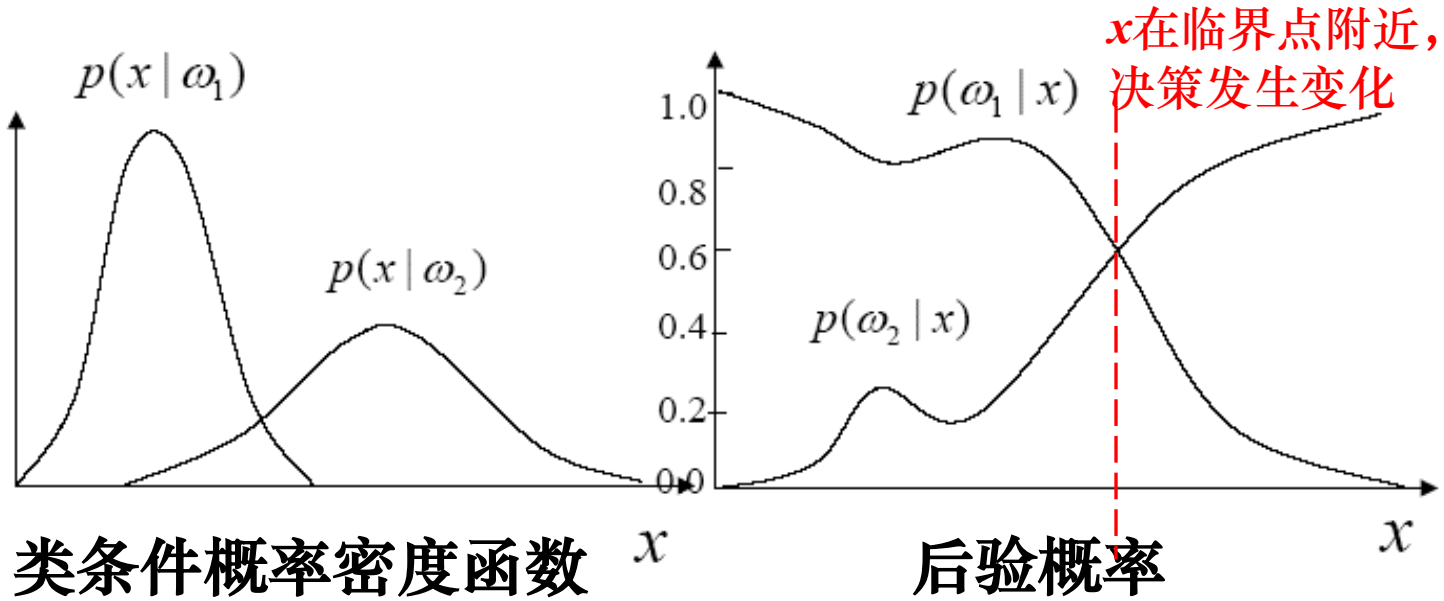

类条件概率密度函数　　后验概率

基于最小错误概率的贝叶斯决策

- 对于该例子，利用贝叶斯公式，分别计算后验概率：

$$P(\omega_1|x) = \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^{2} p(x|\omega_j)P(\omega_j)}$$

$$= \frac{0.2*0.9}{0.2*0.9+0.4*0.1}$$

$$= 0.818$$

$$P(\omega_2|x) = 1 - P(\omega_1|x) = 0.182$$

$$P(\omega_1|x) > P(\omega_2|x)$$

- 所以合理的决策是把x归为正常状态。

基于最小错误概率的贝叶斯决策

- **Bayes最小错误率决策:**
  - 选择**后验概率**$P(\omega_1|x), P(\omega_2|x)$中**大**的$\omega$作为决策，使得在**观测值$x$下的条件错误率最小**。

$$D(x) = \arg\max_i P(\omega_i|x)$$

  - 条件错误率:

$$P(e|x) = 1 - \max_i P(\omega_i|x)$$

  - 错误率:

$$P(e) = E(P(e|x))$$

基于最小错误概率的贝叶斯决策

多类识别问题的Bayes最小错误率决策:

- **决策为:**

$$\boldsymbol{D}(\boldsymbol{x}) = \arg\max_{\boldsymbol{i}} \boldsymbol{P}(\boldsymbol{\omega}_{\boldsymbol{i}}|\boldsymbol{x})$$

- **可以把每一类的后验概率$\boldsymbol{P}(\boldsymbol{\omega}_{\boldsymbol{i}}|\boldsymbol{x})$或$\boldsymbol{p}(\boldsymbol{x}|\boldsymbol{\omega}_{\boldsymbol{i}})\boldsymbol{P}(\boldsymbol{\omega}_{\boldsymbol{i}})$看作是该类的一个判别函数，决策的过程就是比较各类别判别函数的大小。**

基于最小错误概率的贝叶斯决策

- 分析**错误率**：此时，有决策区域$\Re_1$和$\Re_2$。样本在$\Re_1$中，但属于第二类的概率；和样本在$\Re_2$中，但属于第一类的概率就是出现错误的概率。考虑到样本自身的分布后就是平均**错误率**：

$$
\begin{aligned}
p(e) &= p(x \in \Re_1, \omega_2) + p(x \in \Re_2, \omega_1) \\
&= p(x \in \Re_1 | \omega_2) p(\omega_2) + p(x \in \Re_2 | \omega_1) p(\omega_1) \\
&= p(\omega_2) p_2(e) + p(\omega_1) p_1(e)
\end{aligned}
$$

- 其中，

第一类样本决策为第二类的错误率 $p_1(e) = \int_{\Re_2} p(x|\omega_1) dx$

第二类样本决策为第一类的错误率 $p_2(e) = \int_{\Re_1} p(x|\omega_2) dx$

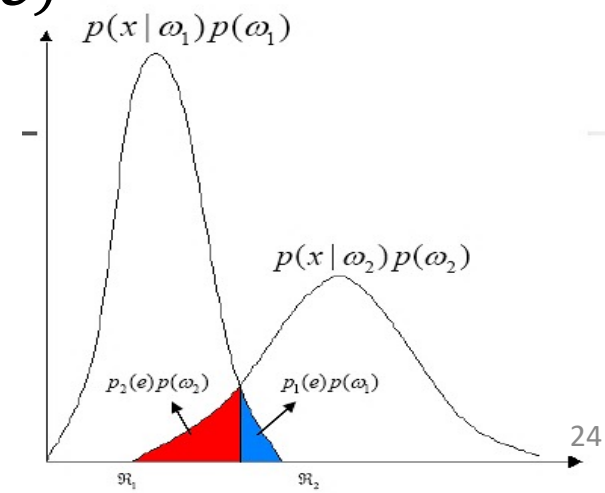

基于最小错误概率的贝叶斯决策

- 在多类决策的过程中，要把特征空间分割成$\Re_1$、$\Re_2$，…，$\Re_c$ 个区域，平均错误率由c(c-1)项组成，即:

$$\left.\begin{aligned}P(e) = {} & [P(\vec{x} \in \Re_2|\omega_1) + P(\vec{x} \in \Re_3|\omega_1) + \cdots + P(\vec{x} \in \Re_c|\omega_1)]P(\omega_1) \\ & +[P(\vec{x} \in \Re_1|\omega_2) + P(\vec{x} \in \Re_3|\omega_2) + \cdots + P(\vec{x} \in \Re_c|\omega_2)]P(\omega_2) \\ & + \cdots \\ & +[P(\vec{x} \in \Re_1|\omega_c) + P(\vec{x} \in \Re_2|\omega_c) + \cdots + P(\vec{x} \in \Re_{c-1}|\omega_c)]P(\omega_c)\end{aligned}\right\} c\text{行}$$

每行c-1项

$$= \sum_{i=1}^{c} \sum_{j=1, j\neq i}^{c} \left[P\left(\vec{x} \in \Re_j|\omega_i\right)\right]P(\omega_i)$$

- 该式计算量较大，可以通过计算平均正确率来计算错误率:

$$P(c) = \sum_{j=1}^{c} P\left(\vec{x} \in \Re_j|\omega_j\right)P(\omega_j) = \sum_{j=1}^{c} \int_{\Re_j} p\left(\vec{x}|\omega_j\right)P(\omega_j)\, d\vec{x}$$

$$P(e) = 1 - P(c)$$

基于最小错误概率的贝叶斯决策

小结：

- Bayes公式计算后验概率$P(\omega_i|x)$：

$$P(\omega_i|x)=\frac{p(x|\omega_i)P(\omega_i)}{p(x)}=\frac{p(x|\omega_i)P(\omega_i)}{\sum_i p(x|\omega_i)P(\omega_i)}$$

- $P(\omega_i)$：先验概率；$p(x|\omega_i)$：类条件概率密度
- Bayes最小错误率决策不仅保证了**错误率(条件错误率的期望）最小**，而且保证**每个观测值下的条件错误率最小**，Bayes决策是**一致最优决策**。

最小风险准则

最小风险贝叶斯决策

- 每个决策的风险是不同的，我们在决策过程中应该考虑决策风险
- 以疾病诊断为例，风险大不相同。在上例中，如果把癌细胞诊断为正常细胞，则损失更大。
- 将两种类型的错误相同对待是不恰当的。
- 如何在决策中考虑风险？引入风险函数（损失函数），通常是决策和自然状态的函数，可用决策表来表示。

最小风险贝叶斯决策

- 最小风险贝叶斯决策，就是考虑各种错误所造成的损失不同时的一种最优决策。以数学形式表示决策问题：
- (1)观察x是d维随机向量

$$x = [x_1, x_2, \dots, x_d]^T$$

- (2)状态空间Ω由c个自然状态组成

$$\Omega = [\omega_1, \omega_2, \dots, \omega_c]^T$$

- (3) 对于随机向量x可能采取的决策构成了空间，k个决策组成

$$A = \{a_1, a_2, \dots, a_k\}$$

- (4) 对于实际状态为ω_j的向量x，采取决策a_i所带来的损失为$\lambda(a_i, \omega_j)$。通常可以用决策表表示：

最小风险贝叶斯决策

基于最小错误概率的贝叶斯决策

- N类问题：$(\lambda_{i,j})_{N*N}$

$$\begin{pmatrix} \lambda_{11} & \lambda_{12} & \lambda_{13} & \lambda_{14} & \cdots & \lambda_{1n} \\ \lambda_{21} & \lambda_{22} & & \cdots & & \lambda_{2n} \\ & & \ddots & & & \\ \vdots & & \lambda_{ij} & & & \vdots \\ \lambda_{(n-1)1} & & & & & \lambda_{(n-1)n} \\ \lambda_{n1} & \lambda_{n2} & & & \cdots & \lambda_{nn} \end{pmatrix}$$

λ_{ij}表示当我们给出的决策为i类，而真实类别为j时的损失值。

最小风险贝叶斯决策

- 在引入损失函数后，对于某一个样本x，它属于各个状态的后验概率是$P(\omega_j|x)$， $j=1,2,\dots,c$，对它采取决策a_i, $i=1,2,\dots,k$，期望损失是：

$$R(a_i|x)=E\left[\lambda(a_i,\omega_j)\right]$$
$$=\sum_{j=1}^{c}\lambda(a_i,\omega_j)P(\omega_j|x), i=1,2,\dots,k$$

最小风险贝叶斯决策

- x是随机变量，采用x不同的观测值，产生的条件风险不同，决策a可以看成是x的函数。我们定义**期望风险**：

$$R(a) = \int R(a(x)|x)p(x)dx$$

- 最小风险贝叶斯决策就是最小化这一期望风险，即：

$$\min R(a)$$

- 在考虑错判带来的损失时，我们希望损失最小。如果在采取每个决策，都使其条件风险最小，则对所有的x作出决策时，其期望风险也必然最小。
- **最小风险贝叶斯决策规则为**：

$$\text{若}\quad R(a_i|x) = \min_{j=1,\ldots,k} R(a_j|x)\text{，则 } a = a_i$$

最小风险贝叶斯决策

- 具体计算步骤如下：
- (1) 计算各个类别的后验概率$P(\omega_j|x)$，这里仍需要先验概率与类条件密度已知。
- (2) 根据决策风险表，计算出采取a_i的条件风险

$$R(a_i|x) = E[\lambda(a_i, \omega_j)] = \sum_{j=1}^{c} \lambda(a_i, \omega_j) P(\omega_j|x),$$

$$i = 1, 2, \ldots, k$$

- (3) 对k个条件风险值进行比较，找出使条件风险最小的决策a

$$a = \arg min_{i=1,\ldots,k} R(a_i|x)$$

最小风险贝叶斯决策

- 以前面例题为例
- 已知：

$$P(\omega_1) = 0.9, P(\omega_2) = 0.1$$
$$P(x|\omega_1) = 0.2, P(x|\omega_2) = 0.4$$
$$\lambda_{11} = 0, \lambda_{12} = 6$$
$$\lambda_{21} = 1, \lambda_{22} = 0$$

λ_{ij}表示当我们给出的决策为i类，而真实类别为j时的损失值。

- 利用贝叶斯公式，分别计算后验概率

$$P(\omega_1|x) = \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^{2} p(x|\omega_j)P(\omega_j)} = \frac{0.2 * 0.9}{0.2 * 0.9 + 0.4 * 0.1}$$
$$= 0.818$$

$$P(\omega_2|x) = 1 - P(\omega_1|x) = 0.182$$
$$P(\omega_1|x) > P(\omega_2|x)$$

最小风险贝叶斯决策

- 引入风险函数后，计算条件风险

$$R(a_1|x) = \sum_{j=1}^{c} \lambda_{1j} P(\omega_j|x) = \lambda_{12} P(\omega_2|x) = 1.092$$

$$R(a_2|x) = \lambda_{21} P(\omega_1|x) = 0.818$$

- 因为 $R(a_1|x) > R(a_2|x)$
- 故选择决策行动a_2 即该细胞为异常

最小风险贝叶斯决策

- 对于两类问题，最小风险贝叶斯决策的等价表示形式?

$$\lambda_{11}P(\omega_1|x)+\lambda_{12}P(\omega_2|x)$$

$$\lesseqgtr \lambda_{21}P(\omega_1|x)+\lambda_{22}P(\omega_2|x)，\text{则}x\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

- 通常，$\lambda_{11}=\lambda_{22}=0$；不失一般性，我们可以假设$\lambda_{11}<\lambda_{21},\lambda_{22}<\lambda_{12}$。
- 1）若$(\lambda_{11}-\lambda_{21})P(\omega_1|x)\le(\lambda_{22}-\lambda_{12})P(\omega_2|x)$，则$x\in\omega_1$，反之$x\in\omega_2$
- 2）若$\frac{P(\omega_1|x)}{P(\omega_2|x)}\gtreqless\frac{\lambda_{22}-\lambda_{12}}{\lambda_{11}-\lambda_{21}}$，则$x\begin{cases}\in\omega_1\\ \in\omega_2\end{cases}$
- 3）若$l(x)=\frac{p(x|\omega_1)}{p(x|\omega_2)}\gtreqless\frac{P(\omega_2)}{P(\omega_1)}\cdot\frac{\lambda_{22}-\lambda_{12}}{\lambda_{11}-\lambda_{21}}$，则$x\begin{cases}\in\omega_1\\ \in\omega_2\end{cases}$

决策表是人为设定的，决策表不同，导致决策结果不同。

分类器的设计（小结）

分类器设计

- 应用最小错误率贝叶斯决策准则设计分类器：
- 分类器设计问题为确定：1）判别函数和 2）决策面
- (1) $P(\omega_i|x) > P(\omega_j|x), j = 1, 2, \ldots, c, j \neq i$，则$x \in \omega_i$
- (2) $p(x \mid \omega_i)P(\omega_i) > p(x \mid \omega_j)P(\omega_j), j = 1, 2, \ldots, c, j \neq i$，则$x \in \omega_i$
- (3) $l(x) = \frac{\mathrm{p}(x|\omega_i)}{\mathrm{p}(x|\omega_j)} > \frac{P(\omega_j)}{P(\omega_i)}, j = 1, 2, \ldots, c, j \neq i$，则$x \in \omega_i$
- (4) $ln\, p(x|\omega_i) + ln\, \mathrm{P}(\omega_i) > ln\, p(x|\omega_j) + ln\, P(\omega_j), j = 1, 2, \ldots, c, j \neq i$，则$x \in \omega_i$

判别函数

- 判别函数：通常定义一组判别函数 $g_i(x), i = 1, 2, \ldots, c$, 用来表示多类决策规则
- 相对应于贝叶斯决策的判别函数：

  (1) $g_i(x) = P(\omega_i|x)$

  (2) $g_i(x) = p(x \mid \omega_i)P(\omega_i)$

  (3) $g_i(x) = \ln \mathrm{p}(x|\omega_i) + \ln \mathrm{P}(\omega_i)$
- 如果使得$g_i(x) > g_j(x)$ 对于一切的$j \neq i$均成立，则将x归于ω_i类。

决策面方程&分类器设计

- 决策面方程：

$$g_i(x) = g_j(x)$$

- 分类器设计原则
  - 选取最大的$g(x)$

- 对于一维空间，决策区域通常有两条决策边界（多类）；
- 对于高维空间，决策区域有复杂的非线性边界。

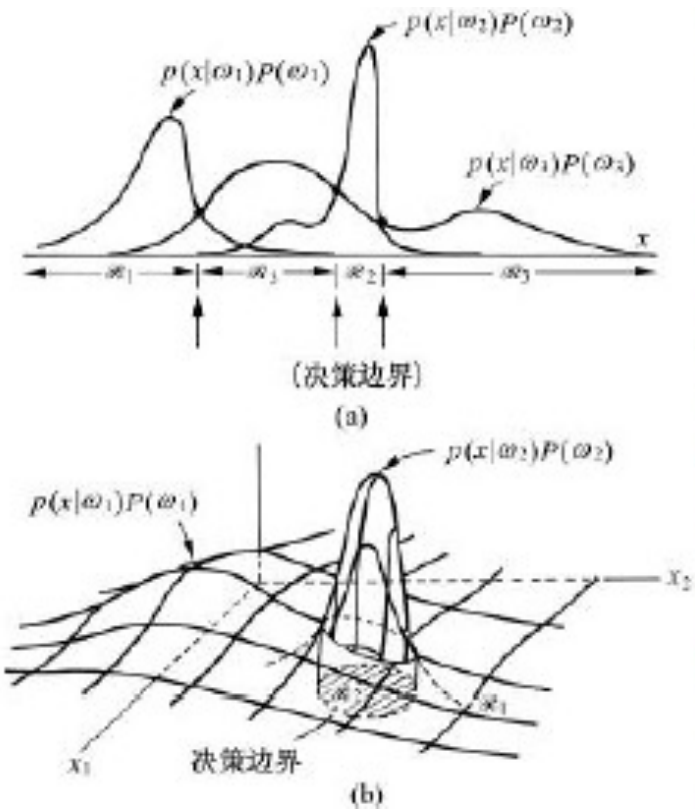

正态分布时的统计决策

正态分布时的统计决策

- 在统计决策分析中，类条件概率密度函数 $p(x \mid \omega_i)$起着重要作用。
- 经常假定正态分布，因为：
  - 物理上的合理性
  - 正态分布的一些性质使在数学上计算简单

- 物理上的合理性示例
  - 人的身高、寿命等
  - 考试成绩
  - 医学参考值
  - 信道噪声

正态分布时的统计决策

正态分布函数定义及性质：

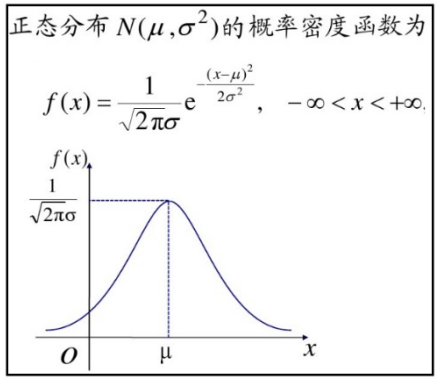

- 单变量正态分布概率密度函数定义为：

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\{\frac{-1}{2}(\frac{x-\mu}{\sigma})^2\}$$

- 式中，μ为随机变量x的**期望**；σ^2为x的方差。

$$\mu=E\{x\}=\int_{-\infty}^{+\infty}xp(x)dx$$

$$\sigma^2=\int_{-\infty}^{+\infty}(x-\mu)^2p(x)dx$$

- 我们常记$p(x)$为$N(\mu,\sigma^2)$。正态分布的样本主要集中于均值附近，其分散程度可以用标准差来表征，σ越大分散度越大。

正态分布时的统计决策

正态分布函数定义及性质：

- 概率密度函数应满足下面关系：

$$p(x) \geq 0(-\infty < x < +\infty)$$

$$\int_{-\infty}^{+\infty} p(x)dx = 1$$

正态分布时的统计决策

正态分布函数定义及性质：

- 多元正态分布的概率密度函数定义为：

$$p(x)=\frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}}exp\{\frac{-1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\}$$

常记为$p(x)$~$N(\mu,\Sigma)$。其中，

- $x=[x_1,x_2,\dots,x_d]^T$是d维列向量，
- $\mu=[\mu_1,\mu_2,\dots,\mu_d]^T$是$d$维均值向量，
- Σ是$d\times d$维的协方差矩阵，Σ^{-1}是它的逆矩阵，$|\Sigma|$是它的行列式。协方差矩阵S是对称的，其中有$d\times(d+1)/2$个独立元素。

正态分布时的统计决策

正态分布函数定义及性质：

- μ, Σ分别是向量x和矩阵$(x-\mu)(x-\mu)^T$的期望：
- 更具体地：

$$\mu = E\{x\},$$

$$\mu_i = E\{x_i\} = \int_{E^d} x_i p(x) dx = \int_{-\infty}^{+\infty} x_i p(x_i) dx_i,$$

其中， $p(x_i)$为边缘分布：

$$p(x_i) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} p(x) dx_1\, dx_2 \dots dx_{i-1} dx_{i+1} \dots dx_d$$

$$\sigma_{ij} = E[(x_i - \mu_i)(x_j - \mu_j)]$$

正态分布时的统计决策

正态分布函数定义及性质：

- 而：$\boldsymbol{\Sigma = E\{(x-\mu)(x-\mu)^T\}}$，

$$\sigma_{ij} = E[(x_i-\mu_i)(x_j-\mu_j)]$$

$$= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}(x_i-\mu_i)(x_j-\mu_j)\cdot p(x_i,x_j)dx_i dx_j$$

- 协方差矩阵总是对称非负定阵，可以表示为：

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \cdots & \sigma_{1d} \\ \sigma_{12} & \sigma_{22} & \cdots & \cdots & \sigma_{2d} \\ \vdots & & & & \vdots \\ \vdots & & & & \vdots \\ \sigma_{1d} & \sigma_{2d} & & & \sigma_{dd} \end{bmatrix}$$

- $\boldsymbol{x_i}$的方差就是对角线上的元素$\boldsymbol{\sigma_{ii} = \sigma_i^2}$，非对角线上的元素$\boldsymbol{\sigma_{ij}}$为$\boldsymbol{x_i}$和$\boldsymbol{x_j}$协方差。

正态分布时的统计决策

- 当d=1时，Σ只是一个1×1的矩阵，也就是只有1个元素的矩阵，退化成一个数值；$|\Sigma|^{1/2}$也就是标准差σ；Σ^{-1} 也就是σ^{-2}，而$(x-\mu)^T(x-\mu)$也变成$(x-\mu)^2$；
- 多元正态分布的概率密度函数中的元就是我们前面说得特征向量的分量数，也就是维数。

正态分布时的统计决策

正态分布函数定义及性质：

- 1）参数μ和 Σ 对分布的决定性：共$d + d(d+1)/2$个参数确定分布；
- 2）等密度点的轨迹为一个超椭球面，它的中心由μ决定，主轴方向由Σ的本征向量所决定，主轴长度与相应的协方差矩阵Σ的本征值成正比，应满足：

$$(\boldsymbol{x}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}) = \gamma^2 = \text{常数c}$$

- 令：式中γ称为x到μ的马氏（Mahalanobis）距离。所以等密度点轨迹是x到μ的马氏距离γ为常数的超椭球面。

正态分布时的统计决策

正态分布函数定义及性质：

- 从下图可以看出，从正态分布总体中抽取的样本大部分落在由μ和Σ所确定的一个区域里，这个区域的**中心**由均值向量μ决定，区域的**大小**由**协方差矩阵**决定。

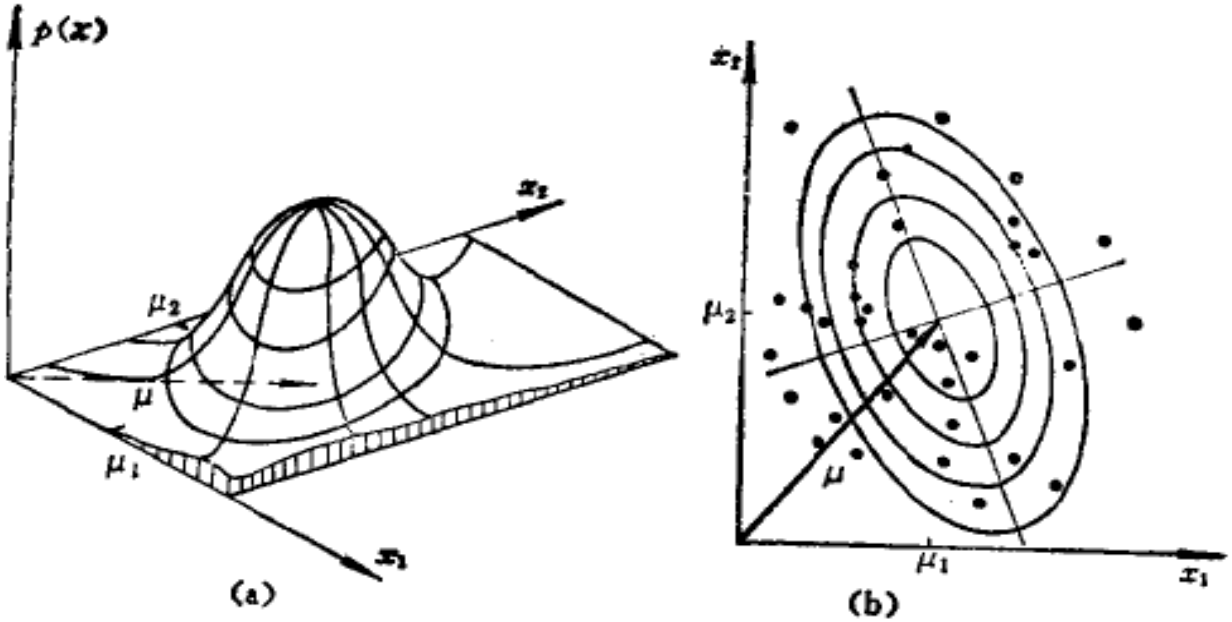

(a) $p(x)$ ($d=2$)；(b) 等密度点轨迹

正态分布时的统计决策

正态分布函数定义及性质：

- 3）不相关性等价于独立性。如果多元正态随机向量 $x = [x_1, x_2, \ldots, x_d]^T$ 的协方差矩阵是对角阵，则x的分量是相互独立的正态分布随机变量。
- 4）边缘分布和条件分布仍然是正态分布。在给定x_1情况下，x_2的条件分布也是正态分布。
- 5）线性变换的正态性：

  若$p(x) \sim N(\mu, \Sigma)$， $y = Ax$，其中A为线性变换矩阵且是非奇异的，则$p(y) \sim N(A\mu, A\Sigma A^T)$
- 6）线性组合的正态性：
- 若$p(x) \sim N(\mu, \Sigma)$， 则线性组合$y = a^T x$是正态随机变量，

$$p(y) \sim N(a^T\mu, a^T\Sigma a)$$

多元正态 - 判别函数和决策面

- 多元正态概率模型下的**最小错误率贝叶斯判别函数（对数形式）**：

$$g_i(x) = ln\, p(x|\omega_i) + ln\, p(\omega_i)$$

- 多元正态分布时，判别函数为：

$$g_i(x) = \frac{-1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i) - \frac{d}{2}\ln 2\pi - \frac{1}{2}\ln|\Sigma_i| + \ln \mathbf{P}(\omega_i)$$

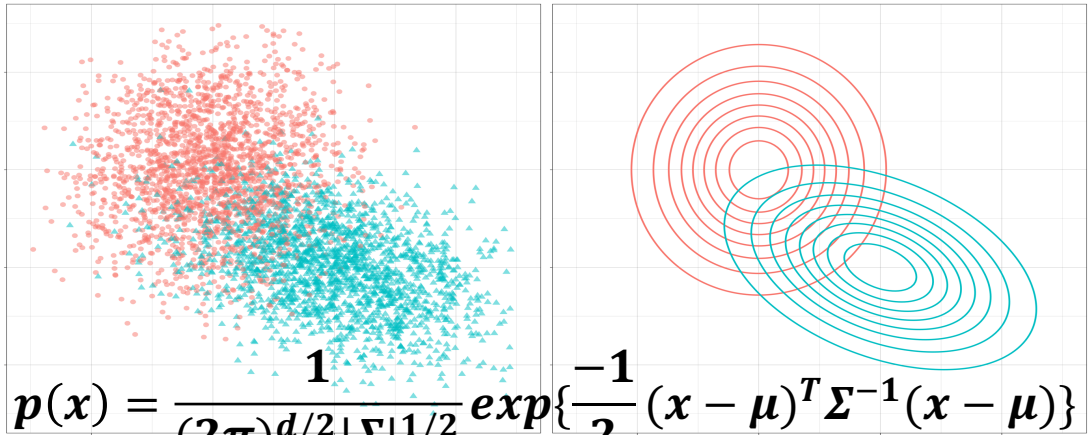

$$p(x) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} exp\{\frac{-1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\}$$

- 二分类问题特征分布示意

多元正态 - 判别函数和决策面

- 决策面方程：

$$g_i(x) = g_j(x)$$

- 即：

$$-\frac{1}{2}[(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i)-(x-\mu_j)^T\Sigma_j^{-1}(x-\mu_j)]$$
$$-\frac{1}{2}ln\frac{|\Sigma_i|}{|\Sigma_j|}+ln\frac{P(\omega_i)}{P(\omega_j)}=0$$

多元正态 - 判别函数和决策面

- 特殊情况①：

$$\boldsymbol{\Sigma}_i = \sigma^2 \boldsymbol{I}, i = 1, 2, \ldots, c$$

- 每类协方差矩阵相等，类内各特征相互独立，方差相等为σ^2。下面再分两种情况讨论：
- 第一种情况，若先验概率$P(\omega_i) \neq P(\omega_j)$，此时各类的协方差矩阵$\boldsymbol{\Sigma}_i$为：

$$\boldsymbol{\Sigma}_i = \begin{bmatrix} \sigma^2 & 0 & \cdots & \cdots & 0 \\ 0 & \sigma^2 & \cdots & \cdots & 0 \\ \vdots & & & & \vdots \\ \vdots & & & & \vdots \\ 0 & 0 & & & \sigma^2 \end{bmatrix} \qquad |\Sigma_i| = \sigma^{2d} \qquad \Sigma_i^{-1} = \frac{1}{\sigma^2} I$$

- 从几何上看，相当于各类样本分布在以$\boldsymbol{\mu}_i$为中心的同样大小的一些超球体内。

多元正态 - 判别函数和决策面

- 判别函数为：

$$g_i(x) = \frac{-1}{2\sigma^2}(x-\mu_i)^T(x-\mu_i) - \frac{d}{2}ln\,2\pi - \frac{1}{2}ln\,\sigma^{2d} + ln\,P(\omega_i)$$

- 由于上式中第2、3项与类别i无关，故可以忽略，$g_i(x)$可以简化为：

$$g_i(x) = \frac{-1}{2\sigma^2}(x-\mu_i)^T(x-\mu_i) + ln\,P(\omega_i)$$

- 式中$(x-\mu_i)^T(x-\mu_i)$ 即为x到类ω_i的均值向量μ_i的欧式距离的平方。

多元正态 - 判别函数和决策面

- $g_i(x)$简化为：

$$g_i(x) = \frac{-1}{2\sigma^2}(x-\mu_i)^T(x-\mu_i) + ln\,P(\omega_i)$$

- 将上式展开后是x的二次函数，但是$x^T x$与类别i无关，因此可忽略，则判别函数为：

$$g_i(x) = \frac{-1}{2\sigma^2}\left(-2\mu_i{}^T x + \mu_i{}^T\mu_i\right) + ln\,P(\omega_i) = \mathrm{w}_i{}^T x + \mathrm{w}_{i0}$$

- 由此可以看出，此时判别函数$g_i(x)$是x的线性函数。这一类分类器也被成为线性分类器。

多元正态 - 判别函数和决策面

- 第二种情况，若先验概率$P(\omega_i) = P(\omega_j)$，则判别函数函数中的$ln\,P(\omega_i)$项可忽略，使得最小错误率贝叶斯决策规则表达得十分简单：

$$g_i(x) = \frac{-1}{2\sigma^2}(x-\mu_i)^T(x-\mu_i)$$

- 决策规则：只需要计算样本x到各类的均值向量μ_i的欧式距离平方，然后把x归为具有最小距离的这一类。这类分类器等价于最小距离分类器。

多元正态 - 判别函数和决策面

- 它的决策面是由线性方程

$$g_i(x) = g_j(x)$$

所确定的一个超平面。

- 在该特殊情况下（即$\Sigma_i = \sigma^2 I, i = 1, 2, \ldots, c$），该判别方程$g_i(x)$ - $g_j(x)$=0可以进一步写为：

$$w^T(x - x_0) = 0$$

其中， $w = \mu_i$ - μ_j，

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} ln \frac{P(\omega_i)}{P(\omega_j)}(\mu_i - \mu_j)$$

- 满足$w^T(x - x_0) = 0$的x的轨迹构成了ω_i和ω_j类间的决策面。

多元正态 - 判别函数和决策面

- 当$P(\omega_i)= P(\omega_j)$时，该**超平面与μ_i与μ_j的连线正交并通过连线中点**。
- 当$P(\omega_i), i = 1, 2, \ldots, c$ 不相等，决策面与先验概率相等时候的决策面平行，向先验概率小的方向偏移，即**先验概率大的一类占据更大的决策空间。**

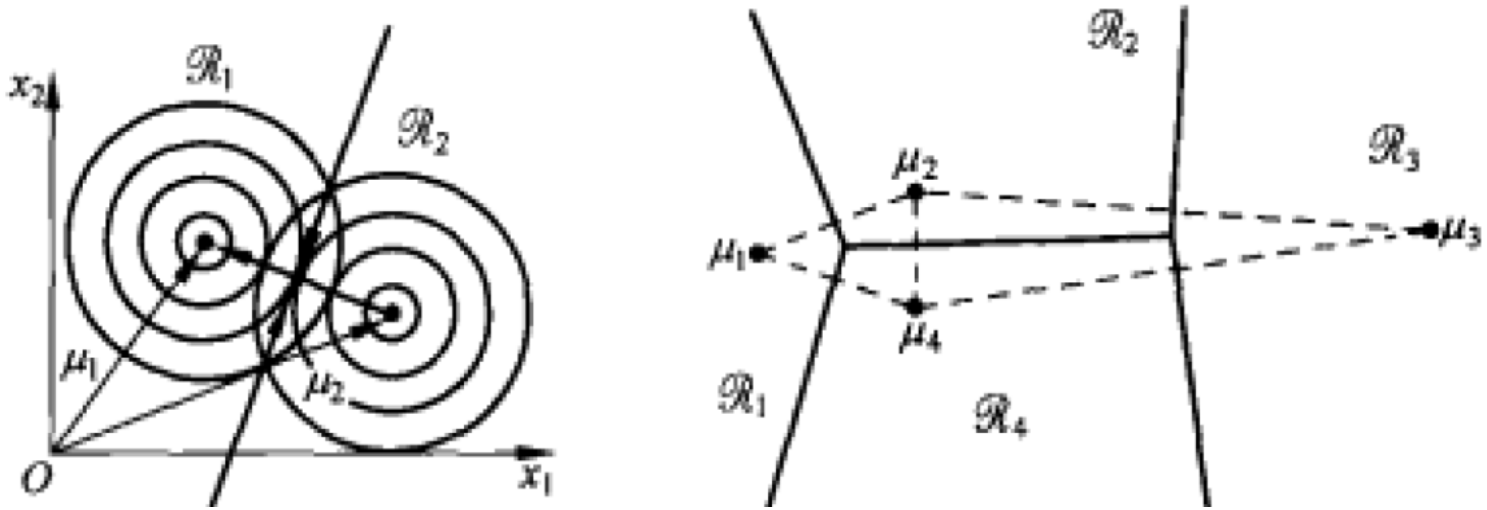

(a) 两类情况　　(b) 多类情况

正态分布且$P(\omega_i)= P(\omega_j)$， $\Sigma_i = \sigma^2 I$时的决策面

多元正态 - 判别函数和决策面

- 当$P(\omega_i)= P(\omega_j)$时，该**超平面与μ_i与μ_j的连线正交并通过连线中点**。
- 当$P(\omega_i), i = 1, 2, \ldots, c$ 不相等，决策面与先验概率相等时候的决策面平行，向先验概率小的方向偏移，即**先验概率大的一类占据更大的决策空间。**

- 两类概率分布等密度点轨迹是两个同心圆，两个圆心就是两类的均值点。

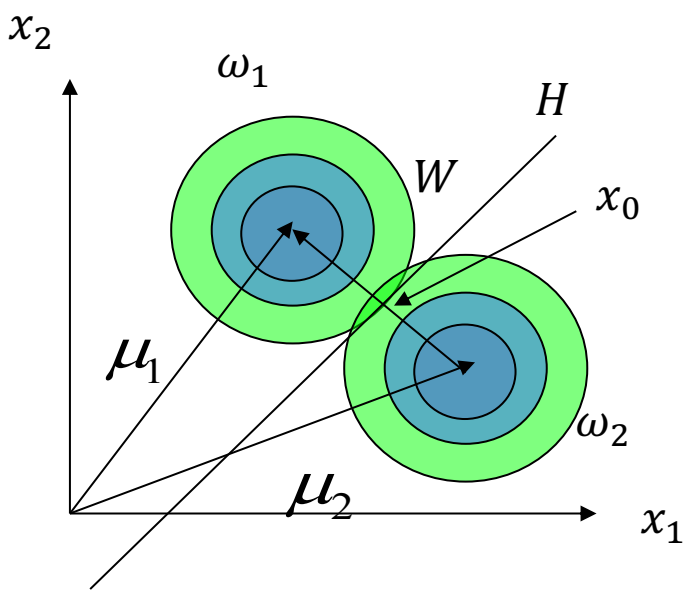

多元正态 - 判别函数和决策面

- 特殊情况②：

$$\Sigma_i = \Sigma, i = 1, 2, \dots, c$$

- 它表示各类的**协方差矩阵都相等**，从几何上看，相当于各类别的样本集中于以该类别均值μ_i为中心的**同样形状**的**超椭球**内。由于Σ_i与i无关，判别函数：

$$g_i(x) = \frac{-1}{2\sigma^2}(x-\mu_i)^T(x-\mu_i) - \frac{d}{2}ln\,2\pi - \frac{1}{2}ln\|\Sigma_i\| + ln\,P(\omega_i)$$

可以简化为：

$$g_i(x) = \frac{-1}{2}(x-\mu_i)^T\Sigma^{-1}(x-\mu_i) + ln\,P(\omega_i)$$

多元正态 - 判别函数和决策面

- 当先验概率相等时， 可以进一步简化为：

$$g_i(x) = \gamma^2 = (x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i)$$

即为马氏距离。

- 决策规则：只需要计算样本x到各类的均值向量μ_i的马氏距离平方，然后把x归为具有最小距离的这一类。
- 该判别函数也可以改写成为线性判别函数的形式，决策面仍然是一个超平面。在一般情况下，决策面方程满足：

$$g_i(x) = g_j(x)$$

多元正态 - 判别函数和决策面

- 即：

$$w^T(x - x_0) = 0$$

其中， $w = \Sigma^{-1}(\mu_i - \mu_j)$，

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{1}{(\mu_i - \mu_j)^T \Sigma^{-1}(\mu_i - \mu_j)} ln \frac{P(\omega_i)}{P(\omega_j)}(\mu_i - \mu_j)$$

- $w = \Sigma^{-1}(\mu_i - \mu_j)$通常不在$(\mu_i - \mu_j)$的方向上，$(x - x_0)$为通过的$x_0$的向量。 w与$(x - x_0)$的点积为0表示$(x - x_0)$与w正交。所以，**超平面通过x_0点，但是不与$(\mu_i - \mu_j)$正交**。

多元正态 - 判别函数和决策面

- 如果各类先验概率相等，则：

$$x_0 = \frac{1}{2}(\mu_i + \mu_j)$$

此时， x_0为$\mu_i + \mu_j$连线的中点，决策面通过该点。

- 当$P(\omega_i), i = 1, 2, \ldots, c$ 不相等，决策面向先验概率小的方向偏移。

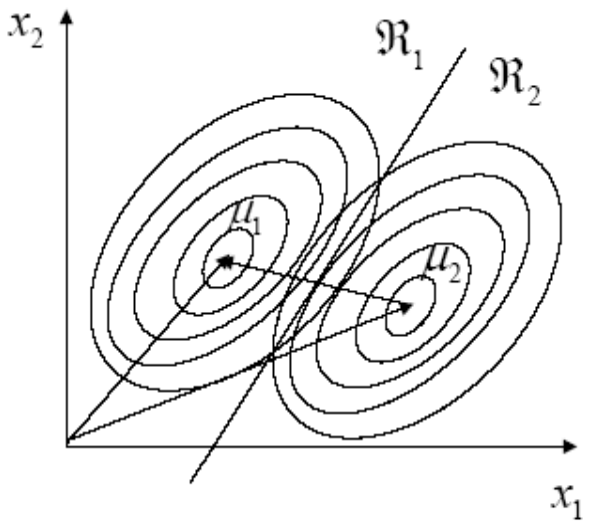

正态分布且$P(\omega_1) = P(\omega_2), \Sigma_1 = \Sigma_2$ 时的决策面

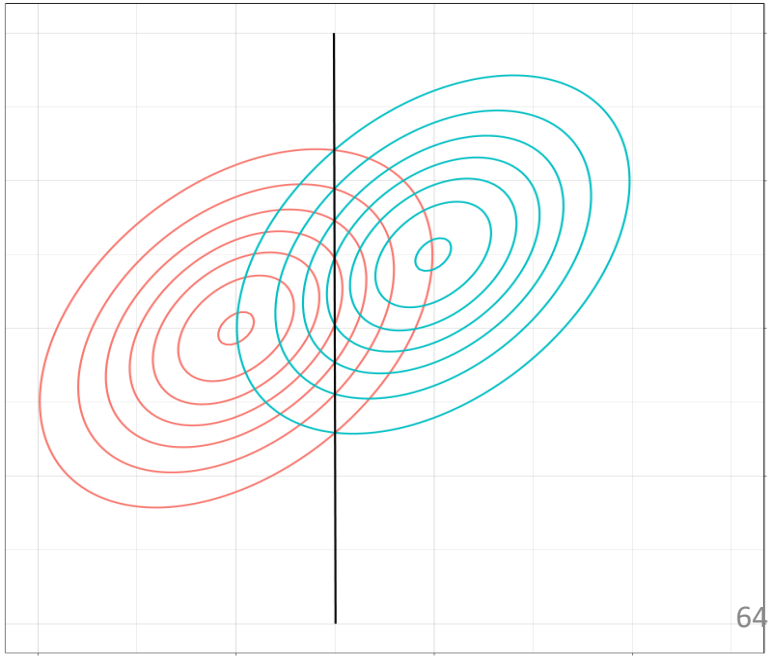

多元正态 - 判别函数和决策面

- 特殊情况③：各类协方差阵不相等

$$\Sigma_i \neq \Sigma_j$$

- 判别函数中只有$\frac{d}{2}\ln 2\pi$与i无关，判别函数可以简化为：

$$g_i(x) = \frac{-1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i) - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$$
$$= x^T W_i x + w_i^T x + w_{i0}$$

- 其中， $W_i = \frac{-1}{2}\Sigma_i^{-1}$ （$d\times d$维）
- $w_i = \Sigma_i^{-1}\mu_i$ （d维）
- $w_{i0} = \frac{-1}{2}\mu_i{}^T\Sigma_i^{-1}\mu_i - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$
- 这时的判别函数为x的二次型。

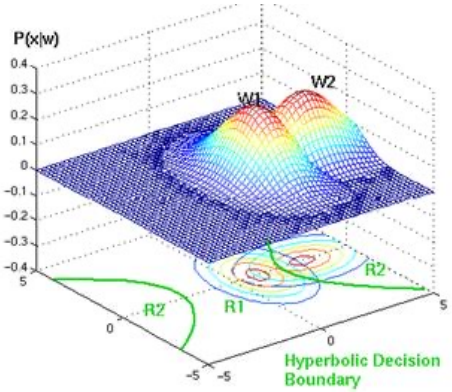

多元正态 - 判别函数和决策面

- 决策面： $g_i(x) - g_j(x) = 0$ 即：

$$x^T(W_i - W_j)x + (w_i - w_j)^T x + \omega_{i0} - \omega_{j0} = 0$$

- 该决策面为超二次曲面。随着Σ_i， μ_i， $P(\omega_i)$的不同而呈现出某种曲面，即超球面、超椭球面、超抛物线面、超双曲面或者超平面。下图呈现的集中情形中x_1与x_1相互独立。

多元正态 - 判别函数和决策面

- 如果假定各先验概率相等，决策面的不同是由于方差项的差异引起的。

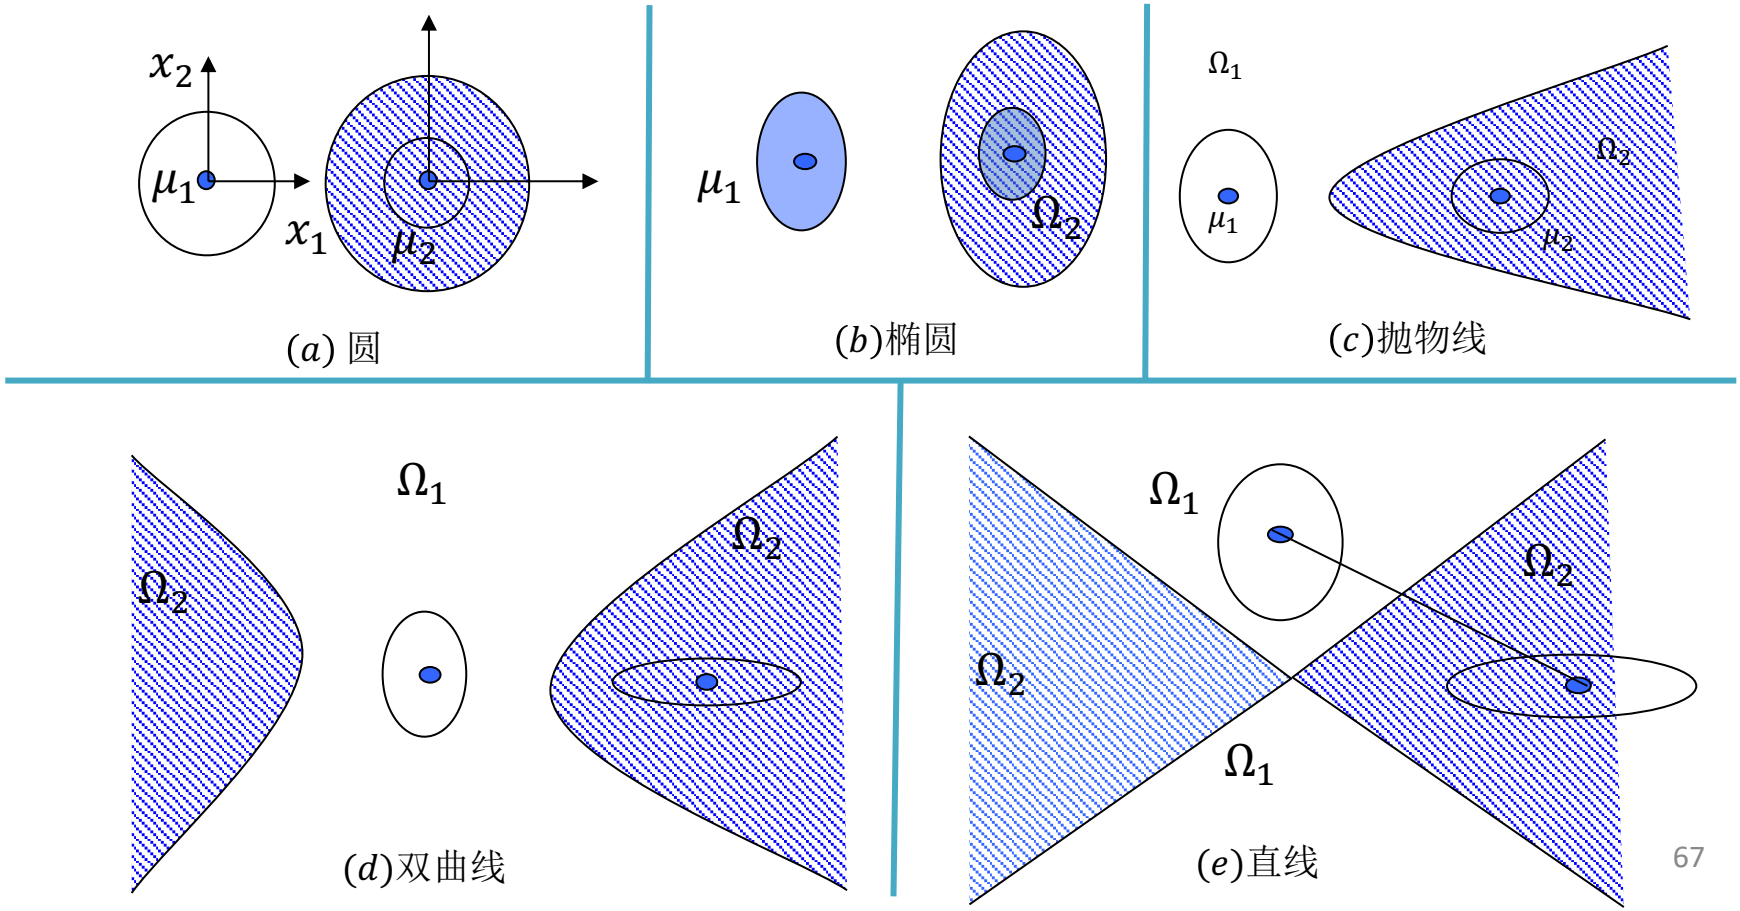

多元正态 - 判别函数和决策面

- 如果假定各先验概率相等，决策面的不同是由于方差项的差异引起的。

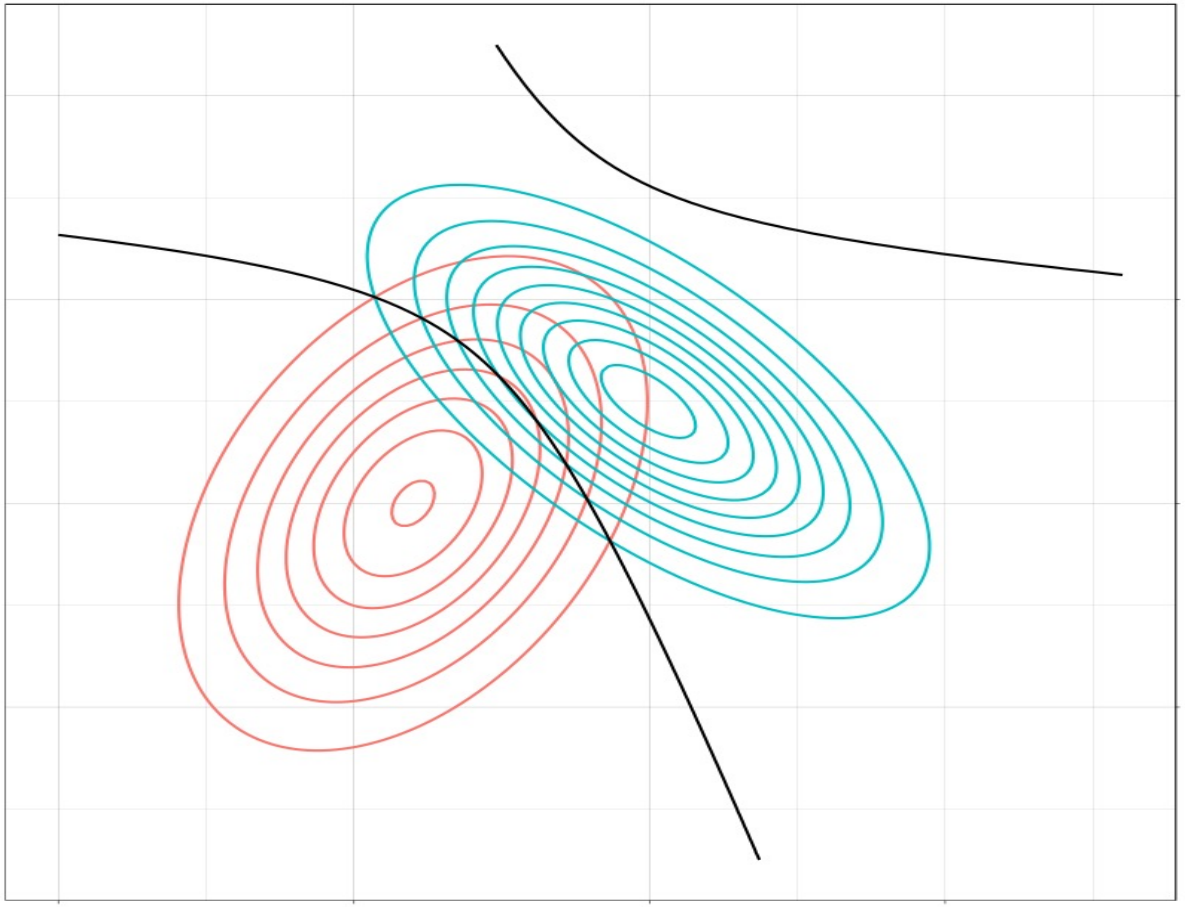

错误率的计算

错误率的计算

- 在分类过程中，任何一种决策规则都有其相应的错误率。
- 当采用指定的决策规则来对类条件概率密度及先验概率均为已知的问题进行分类时，它的错误率是固定的。
- 错误率反映了分类问题固有的复杂性的程度。
- 对同一种问题设计出的多种不同的分类方案，通常总是以错误率大小作为比较方案好坏的标准。
- 因此，错误率是非常重要的参数。

错误率的计算：回顾

- 在两类情况下，最小错误率贝叶斯的错误率为：

$$P(e)=\int_{-\infty}^{t}P(\omega_2|\mathrm{x})\cdot p(\mathrm{x})d\,\mathrm{x}+\int_{t}^{+\infty}P(\omega_1|\mathrm{x})\cdot p(\mathrm{x})d\,\mathrm{x}$$
$$=P(\omega_2)\,\varepsilon_2+P(\omega_1)\,\varepsilon_1$$

- 从上式可以看出当*x*为多维向量的时候，进行积分运算的工作量比较大。
- 因此对于实际问题，对错误率的研究一般从下面三点出发：
- 1、按理论公式研究。
- 2、理论难以计算时，估算错误率上界。
- 3、实验估计。

错误率的计算

- 第①种情况---正态分布且等协方差矩阵 $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}$

- 最小错误率贝叶斯决策的负对数似然比函数：

$$\boldsymbol{h}(\boldsymbol{x}) = -\ln\big(\boldsymbol{l}(\boldsymbol{x})\big) = -\ln \mathbf{p}(\boldsymbol{x}|\boldsymbol{\omega}_1) + \ln \mathbf{p}(\boldsymbol{x}|\boldsymbol{\omega}_2)$$

$$\text{若}\boldsymbol{h}(\boldsymbol{x}) \lessgtr \ln\frac{\boldsymbol{P}(\boldsymbol{\omega}_1)}{\boldsymbol{P}(\boldsymbol{\omega}_2)}\text{，则}\boldsymbol{x} \in \begin{cases} \boldsymbol{\omega}_1 \\ \boldsymbol{\omega}_2 \end{cases}$$

- $h(x)$为随机变量，记它的分布函数为$p(h|\omega_i)$，是一维密度函数。

错误率的计算

- 这样贝叶斯决策的最小错误率形式

$$P_1(e) = \int_{R2} p(x|\omega_1)\ d\,x = \int_t^{\infty} p(h|\omega_1)\,dh$$

$$P_2(e) = \int_{R1} p(x|\omega_2)\ d\,x = \int_{-\infty}^{t} p(h|\omega_2)\,dh$$

- 其中，$t = \ln[P(\omega_1)/P(\omega_2)]$确定决策面。
- 由多维积分转换为一维积分。

错误率的计算

- 我们只考虑x服从正态分布的情况，因此$h(x)$可以写成如下形式：

$$h(x) = -\ln l(x) = -\ln p(x \mid \omega_1) + \ln p(x \mid \omega_2)$$

$$= -[-\frac{1}{2}(x-\mu_1)^T \sum_1^{-1}(x-\mu_1) - \frac{d}{2}\ln 2\pi - \frac{1}{2}\ln\left|\sum_1\right|]$$

$$+[-\frac{1}{2}(x-\mu_2)^T \sum_2^{-1}(x-\mu_2) - \frac{d}{2}\ln 2\pi - \frac{1}{2}\ln\left|\sum_2\right|$$

$$= \frac{1}{2}(x-\mu_1)^T \sum_1^{-1}(x-\mu_1) - \frac{1}{2}(x-\mu_2)^T \sum_2^{-1}(x-\mu_2) + \frac{1}{2}\ln\frac{\left|\sum_1\right|}{\left|\sum_2\right|}$$

错误率的计算

- 上式表明决策面是x的二次型，如果协方差相等，决策面就变成 x 的线性函数，即：

$$h(x)=(\mu_2-\mu_1)^T\sum{}^{-1}x+\frac{1}{2}(\mu_1{}^T\sum{}^{-1}\mu_1-\mu_2{}^T\sum{}^{-1}\mu_2)$$

$$\lessgtr \ \ln\frac{p(\omega_1)}{p(\omega_2)}\rightarrow x\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

- x是d维等协方差正态分布的随机向量，而$h(x)$是一维的随机变量，且是x的线性函数。因此上式可看成是对x的各分量做线性组合$\alpha^T x$，然后再作平移。其中$\alpha^T=(\mu_2-\mu_1)^T\Sigma^{-1}$

错误率的计算

- 根据正态分布的性质，$h(x)$服从一维正态分布。 $p(h|\omega_i)$的参数(η_1, σ_1^2)：

$$\eta_1 = E[h(x)\,|\,\omega_1]$$

$$= (\mu_2 - \mu_1)^T \sum^{-1} \mu_1 + \frac{1}{2}(\mu_1^T \sum^{-1} \mu_1 - \mu_2^T \sum^{-1} \mu_2)$$

$$= -\frac{1}{2}(\mu_1 - \mu_2)^T \sum^{-1} (\mu_1 - \mu_2)$$

- 令：

$$\eta = \frac{1}{2}(\mu_1 - \mu_2)^T \sum^{-1} (\mu_1 - \mu_2)$$

- 则有：

$$\eta_1 = -\eta$$

$$\sigma_1^2 = E\{[h(x) - \eta_1]^2 | \omega_1\}$$
$$= (\mu_1 - \mu_2)^T \boldsymbol{\Sigma}^{-1} (\mu_1 - \mu_2) \quad = 2\eta$$

- 5）线性变换的正态性：
  若$p(x) \sim N(\mu, \Sigma)$， $y = Ax$，其中A为线性变换矩阵且是非奇异的，则$p(y) \sim N(A\mu, A\Sigma A^T)$

错误率的计算

- 同样可以得出$p(h|\omega_2)$的参数(η_2, σ_2^2)：

$$\eta_2 = \frac{1}{2}(\mu_1 - \mu_2)^T \sum^{-1} (\mu_1 - \mu_2) = \eta$$

$$\sigma_2^2 = (\mu_1 - \mu_2)^T \sum^{-1} (\mu_1 - \mu_2) = 2\eta$$

- 因此，可计算出错误率：

$$p_1(e) = \int_t^{\infty} p(h \mid \omega_1) dh$$

$$= \int_t^{\infty} \frac{1}{(2\pi)^{1/2}\sigma} \exp\{-\frac{1}{2}(\frac{h+\eta}{\sigma})^2\} dh$$

错误率的计算

$$=\int_{t}^{\infty}\frac{1}{(2\pi)^{1/2}}\exp\{-\frac{1}{2}(\frac{h+\eta}{\sigma})^{2}\}d(\frac{h+\eta}{\sigma})$$

$$=\int_{(\frac{t+\eta}{\sigma})}^{\infty}\frac{1}{(2\pi)^{1/2}}\exp\{-\frac{1}{2}\xi^{2}\}d\xi$$

$$P_{2}(e)=\int_{-\infty}^{(\frac{t-\eta}{\sigma})}\frac{1}{(2\pi)^{1/2}}\exp\{-\frac{1}{2}\xi^{2}\}d\xi$$

其中，$t=\ln[P(\omega_1)/P(\omega_2)],\sigma=\sqrt{2\eta}$

错误率的计算

- 第②种情况---独立随机变量
- 当d维随机向量x的分量相互独立时，x的密度函数可表示为：

$$p(x \mid \omega_i) = \prod_{l=1}^{d} p(x_l \mid \omega_i), i = 1,2$$

- 因此，负对数似然比$h(x)$为：

$$h(x) = \sum_{l=1}^{d} h(x_l), \text{其中} h(x_l) = -\ln \frac{p(x_l \mid \omega_1)}{p(x_l \mid \omega_2)}$$

错误率的计算

- 也就是说随机变量$h(x)$为d个随机变量$h(x_l)$之和。根据**中心极限定理**，无论$h(x_l)$的密度函数如何，**只要当d大时**， $h(x)$的密度函数总是**趋于正态分布**。这样我们就可以得到均值及方差。
- **均值：**

$$\eta_{\mathrm{i}} = E[h(x)|\omega_i] = E[\sum_{l=1}^{d} h(x_l)\,|\omega_i] = \sum_{l=1}^{d} \eta_{il}$$

错误率的计算

- 方差：

$$\sigma_i^2 = E\{[h(x) - \eta_i]^2 | \omega_i\}$$
$$= E\{\sum_{l=1}^{d}[h(x_l) - \eta_{il}]^2 + \sum_{\substack{l,j=1 \\ l\neq j}}^{d}[h(x_l) - \eta_{il}][h(x_j) - \eta_{ij}] | \omega_i\}$$
$$= \sum_{l=1}^{d} E\{[h(x_l) - \eta_{il}]^2 | \omega_i\} + \sum_{\substack{l,j=1 \\ l\neq j}}^{d} E\{[h(x_l) - \eta_{il}][h(x_j) - \eta_{ij}] | \omega_i\}$$

- 根据独立性假设，上式中第二项必定为零，所以其方差可写为

$$\sigma_i^2 = \sum_{l=1}^{d} \sigma_{il}^2$$

错误率的计算

- 由于η_{il}和σ_{il}^2都是一维随机变量x_l的函数，在大多数情况下，计算这些参数相对比较容易，即使非正态情况亦是如此。所以，我们可以把$(h(x)|\omega_i)$近似看成是服从$N(\eta_i, \sigma_i^2)$的一维正态分布的随机变量，再近似算出错误率。
- 应当指出，这种计算须在维数d较大时使用，否则中心极限定理不成立。

贝叶斯决策理论小结

贝叶斯决策

- **样本(Sample)** $\mathbf{x} \in R^d$
- **状态(State) 第一类:** $w = w_1$ **第二类:** $w = w_2$
- **先验概率(A Priori Probability or Prior)** $P(w_1)$ $P(w_2)$
- **样本分布密度(Sample Distribution Density)** $p(\mathbf{x})$
- **类条件概率密度(Class-Conditional Probability Density)**

$$p(\mathbf{x}|w_1) \qquad p(\mathbf{x}|w_2)$$

贝叶斯决策

- **后验概率(A Posteriori Probability or Posterior)**

$$P(w_1|\mathbf{x}), P(w_2|\mathbf{x})$$

- **错误概率(Probability of Error)**

$$P(e|\mathbf{x}) \begin{cases} P(w_2|\mathbf{x}) \text{ if } \mathbf{x} \text{ is assigned to } w_1 \\ P(w_1|\mathbf{x}) \text{ if } \mathbf{x} \text{ is assigned to } w_2 \end{cases}$$

- **平均错误率(Average Probability of Error)**

$$P(e) = \int P(e|\mathbf{x})p(\mathbf{x})d\mathbf{x}$$

- **正确率(Probability of Correctness)** $P(c)$

基于最小错误率的决策

$$\min \quad P(e) = \int P(e|x)p(x)dx$$

因为 $P(e|\mathbf{x}) \geq 0,\ p(x) \geq 0$

$$\longrightarrow \quad \min P(e|\mathbf{x}) \text{ for all } x$$

而 $$P(e|\mathbf{x}) \begin{cases} P(w_2|\mathbf{x}), & \text{if } P(w_1|\mathbf{x}) > P(w_2|\mathbf{x}) \\ P(w_1|\mathbf{x}), & \text{if } P(w_2|\mathbf{x}) > P(w_1|\mathbf{x}) \end{cases}$$

$$\text{if } P(w_1|\mathbf{x}) \begin{matrix} > \\ < \end{matrix} P(w_2|\mathbf{x}) \text{ assign } \begin{matrix} x \in w_1 \\ x \in w_2 \end{matrix}$$

$$P(w|\mathbf{x}) = \max_{j=1,\ldots,c} P(w_j|\mathbf{x})$$

基于最小风险的决策

条件期望损失：对于特定的*x*采取决策 α_i 的期望损失：

$$R(\alpha_i|x) = E[\lambda(\alpha_i, w_j)|x] = \sum_{j=1}^{c} \lambda(\alpha_i, w_j) P(w_j|x), \ i = 1, 2, ..., k$$

期望风险：对所有可能的*x*采取决策 $\alpha(x)$ 所造成的期望损失之和

$$R(\alpha) = \int R(\alpha(x)|x) p(x) dx$$

也称平均风险($R(\alpha)$**表示**R**依赖于决策规则**$\alpha(\cdot)$**)**

对所有*x*，使 $R(\alpha(x)|x)$ **最小，则可以使** $R(\alpha)$ **最小**

最小风险贝叶斯决策规则：

$$\text{if } R(\alpha_t|x) = \min_{j=1...k} R(\alpha_j|x), \text{then } \alpha = \alpha_t$$

示例-基于最小错误率

- 假设在某个局部区域细胞中正常(w_1)和异常(w_2)两类的先验概率分别为：正常状态 $P(w_1)=0.9$, 异常状态 $P(w_2)=0.1$。现有一待识别细胞，其观察值为x，从类条件概率密度曲线上查得 $p(x|w_1)=0.2$，$p(x|w_2)=0.4$。试对该细胞x进行分类。

解：利用贝叶斯公式计算w_1和w_2的后验概率

$$P(w_1|x)=\frac{p(x|w_1)P(w_1)}{\sum_{j=1}^{2}p(x|w_j)P(w_j)}=\frac{0.2\times0.9}{0.2\times0.9+0.4\times0.1}=0.818$$

$$P(w_2|x)=1-P(w_1|x)=0.182$$

根据贝叶斯决策规则有

$$P(w_1|x)=0.818>P(w_2|x)=0.182$$

把x归类于正常细胞。

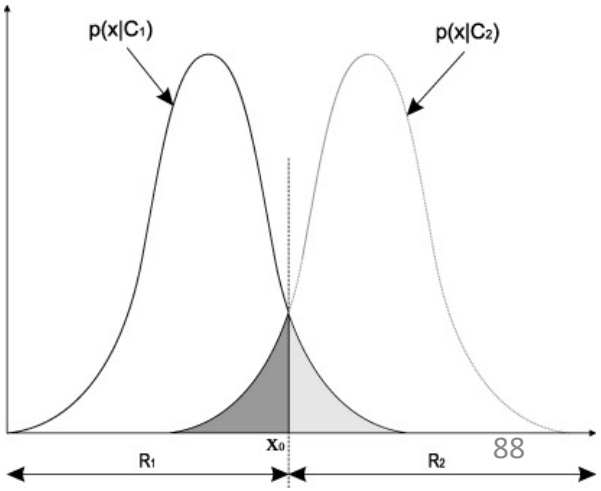

示例-基于最小风险

- **决策表**

决策 \ 损失 \ 状态	w_1	w_2
α_1	0	6
α_2	1	0

解： $\lambda_{11}=0, \lambda_{12}=6, \lambda_{21}=1, \lambda_{22}=0$ $P(w_1|x)=0.818$ $P(w_2|x)=0.182$

计算条件风险 $R(\alpha_1|x)=\sum_{j=1}^{2}\lambda_{1j}P(w_j|x)=\lambda_{12}P(w_2|x)=1.092$

$$R(\alpha_2|x)=\lambda_{21}P(w_1|x)=0.818$$

由于 $R(\alpha_1|x)>R(\alpha_2|x)$

把*x*归类于异常细胞。

小结

- 已知类条件概率密度 $p(\mathbf{x}|w_i)$ 和先验概率 $P(w_i)$，计算后验概率 $P(w_i|\mathbf{x})$ 进行决策

若类条件概率密度参数未知?

- 已知类条件概率密度 $p(\mathbf{x}|w_i)$ 的参数表达式，利用样本估计 $p(\mathbf{x}|w_i)$ 的未知参数，再利用贝叶斯定理将其转化成后验概率 $P(w_i|\mathbf{x})$ 进行决策

若类条件概率密度形式难以确定?

- 非参数方法估计

需要大量样本…

模式识别

第四章：贝叶斯决策理论

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022