模式识别

第五章：概率密度函数的估计

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022

课程回顾

贝叶斯决策理论

- 贝叶斯决策：在类条件概率密度和先验已知（或可以估计）的情况下，通过贝叶斯公式比较样本属于两类的后验概率，将类别决策为后验概率大的一类，这样做的目的是使得整体的错误率最小。
- 贝叶斯决策理论是统计模式识别中最基本的方法，利用此方法进行分类时要求:
  - 各类别总体的概率分布是已知的
  - 待决策分类的类别数是一定的、类条件概率已知
  - 各类别先验概率已知
- 统计决策理论——根据每一类总体的概率分布决定决策边界

基于最小错误概率的贝叶斯决策

- **决策规则：**

(1) $P(\omega_i|x) = max_{j=1,2}P(\omega_j|x), x \in \omega_i$

- **其他等价形式：**

(2) $p(x|\omega_i)P(\omega_i) = max_{j=1,2}P(x|\omega_j)P(\omega_i)$

(3) 由于先验概率 $P(\omega_i)$是事先确定的，与当前样本x无关，因此，也经常把决策规则整理为下面的形式：

$$若 l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \gtrless \frac{P(\omega_2)}{P(\omega_1)}，则 x \begin{cases} \in \omega_1 \\ \in \omega_2 \end{cases}$$

这样，可以事先计算出似然比阈值λ，对于每个样本计算$l(x)$，并与λ比较。大于阈值则决策为第一类，否则决策为第二类。概率密度值反映了在ω_i类中特征值x的相对可能性（likelihood），也称为似然度，$l(x)$称作似然比（likelihood ratio）。

基于最小错误概率的贝叶斯决策

- (4) 很多情况下，用对数形式进行计算更加方便。对上式取**自然对数的负值**，可写为：
  $$\boldsymbol{h}(\boldsymbol{x}) = -\ln\big(\boldsymbol{l}(\boldsymbol{x})\big) = -\ln \mathbf{p}(\boldsymbol{x}|\boldsymbol{\omega}_1) + \ln \mathbf{p}(\boldsymbol{x}|\boldsymbol{\omega}_2)$$
- 那么决策规则可以写作如下形式：

$$\text{若}\boldsymbol{h}(\boldsymbol{x}) \lessgtr \ln\frac{\boldsymbol{P}(\boldsymbol{\omega}_1)}{\boldsymbol{P}(\boldsymbol{\omega}_2)}\text{，则}\boldsymbol{x} \in \begin{cases} \boldsymbol{\omega}_1 \\ \boldsymbol{\omega}_2 \end{cases}$$

基于最小错误概率的贝叶斯决策

多类识别问题的Bayes最小错误率决策:

- **决策为:**

$$\boldsymbol{D}(\boldsymbol{x}) = \arg\max_{\boldsymbol{i}} \boldsymbol{P}(\boldsymbol{\omega}_{\boldsymbol{i}}|\boldsymbol{x})$$

- **可以把每一类的后验概率$\boldsymbol{P}(\boldsymbol{\omega}_{\boldsymbol{i}}|\boldsymbol{x})$或$\boldsymbol{p}(\boldsymbol{x}|\boldsymbol{\omega}_{\boldsymbol{i}})\boldsymbol{P}(\boldsymbol{\omega}_{\boldsymbol{i}})$看作是该类的一个判别函数，决策的过程就是比较各类别判别函数的大小。**

最小风险贝叶斯决策

- 对于两类问题，最小风险贝叶斯决策的**等价表示形式**?

$$\lambda_{11}P(\omega_1|x)+\lambda_{12}P(\omega_2|x)$$

$$\lessgtr \lambda_{21}P(\omega_1|x)+\lambda_{22}P(\omega_2|x)，\text{则}x\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

- 通常，$\lambda_{11}=\lambda_{22}=0$；不失一般性，我们可以假设$\lambda_{11}<\lambda_{21},\lambda_{22}<\lambda_{12}$。
- 1）若$(\lambda_{11}-\lambda_{21})P(\omega_1|x)\le(\lambda_{22}-\lambda_{12})P(\omega_2|x)$，则$x\in\omega_1$，反之$x\in\omega_2$
- 2）若$\frac{P(\omega_1|x)}{P(\omega_2|x)}\gtrless\frac{\lambda_{22}-\lambda_{12}}{\lambda_{11}-\lambda_{21}}$，则$x\begin{cases}\in\omega_1\\ \in\omega_2\end{cases}$
- 3）若$l(x)=\frac{p(x|\omega_1)}{p(x|\omega_2)}\gtrless\frac{P(\omega_2)}{P(\omega_1)}\cdot\frac{\lambda_{22}-\lambda_{12}}{\lambda_{11}-\lambda_{21}}$，则$x\begin{cases}\in\omega_1\\ \in\omega_2\end{cases}$

决策表是人为设定的，决策表不同，导致决策结果不同。

多类情况的贝叶斯决策规则

- 应用**最小错误率**贝叶斯决策准则设计分类器：
- 分类器设计问题为确定：1）**判别函数**，和 2）**决策面**
- (1) $P(\omega_i|x) > P(\omega_j|x), j = 1, 2, \dots, c, j \neq i$，则$x \in \omega_i$
- (2) $p(x \mid \omega_i)P(\omega_i) > p(x \mid \omega_j)P(\omega_j), j = 1, 2, \dots, c, j \neq i$，则$x \in \omega_i$
- (3) $l(x) = \frac{\mathrm{p}(x|\omega_i)}{\mathrm{p}(x|\omega_j)} > \frac{P(\omega_j)}{P(\omega_i)}, j = 1, 2, \dots, c, j \neq i$，则$x \in \omega_i$
- (4) $ln\, p(x|\omega_i) + ln\, \mathrm{P}(\omega_i) > ln\, p(x|\omega_j) + ln\, P(\omega_j), j = 1, 2, \dots, c, j \neq i$，则$x \in \omega_i$

多元正态 - 判别函数和决策面

- 特殊情况①：

$$\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$$

- 每类协方差矩阵相等，类内各特征相互独立，方差相等为σ^2。下面再分两种情况讨论：
- 第一种情况，若先验概率$P(\omega_i) \neq P(\omega_j)$，$g_i(x)$可以简化为：

$$g_i(x) = \frac{-1}{2\sigma^2}(x - \mu_i)^T(x - \mu_i) + ln\, P(\omega_i)$$

- 式中$(x - \mu_i)^T(x - \mu_i)$ 即为x到类ω_i的均值向量μ_i的欧式距离的平方。
- 判别函数还可以写为：

$$g_i(x) = \frac{-1}{2\sigma^2}\left(-2\mu_i{}^T x + \mu_i{}^T \mu_i\right) + ln\, P(\omega_i) = \mathbf{w}_i{}^T x + \mathbf{w}_{i0}$$

- 由此可以看出，此时判别函数$g_i(x)$是x的线性函数。这一类分类器也被成为线性分类器。

多元正态 - 判别函数和决策面

- 第二种情况，若先验概率$P(\omega_i) = P(\omega_j)$，则判别函数函数中的$ln\,P(\omega_i)$项可忽略，使得最小错误率贝叶斯决策规则表达得十分简单：

$$g_i(x) = \frac{-1}{2\sigma^2}(x-\mu_i)^T(x-\mu_i)$$

- 决策规则：只需要计算样本x到各类的均值向量μ_i的欧式距离平方，然后把x归为具有最小距离的这一类。这类分类器等价于最小距离分类器。

多元正态 - 判别函数和决策面

- 它的决策面是由线性方程

$$g_i(x) = g_j(x)$$

所确定的一个超平面。

- 在该特殊情况下（即$\Sigma_i = \sigma^2 I, i = 1, 2, \ldots, c$），该判别方程可以进一步写为：

$$w^T(x - x_0) = 0$$

其中， $w = \mu_i - \mu_j$，

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} ln \frac{P(\omega_i)}{P(\omega_j)}(\mu_i - \mu_j)$$

- 满足$w^T(x - x_0) = 0$的x的轨迹构成了ω_i和ω_j类间的决策面。

多元正态 - 判别函数和决策面

- 当$P(\omega_i)= P(\omega_j)$时，该**超平面通过μ_i与μ_j的连线中点，并与连线正交**。
- 当$P(\omega_i), i = 1, 2, \ldots, c$ 不相等，决策面与先验概率相等时候的决策面平行，向先验概率小的方向偏移，即**先验概率大的一类占据更大的决策空间。**

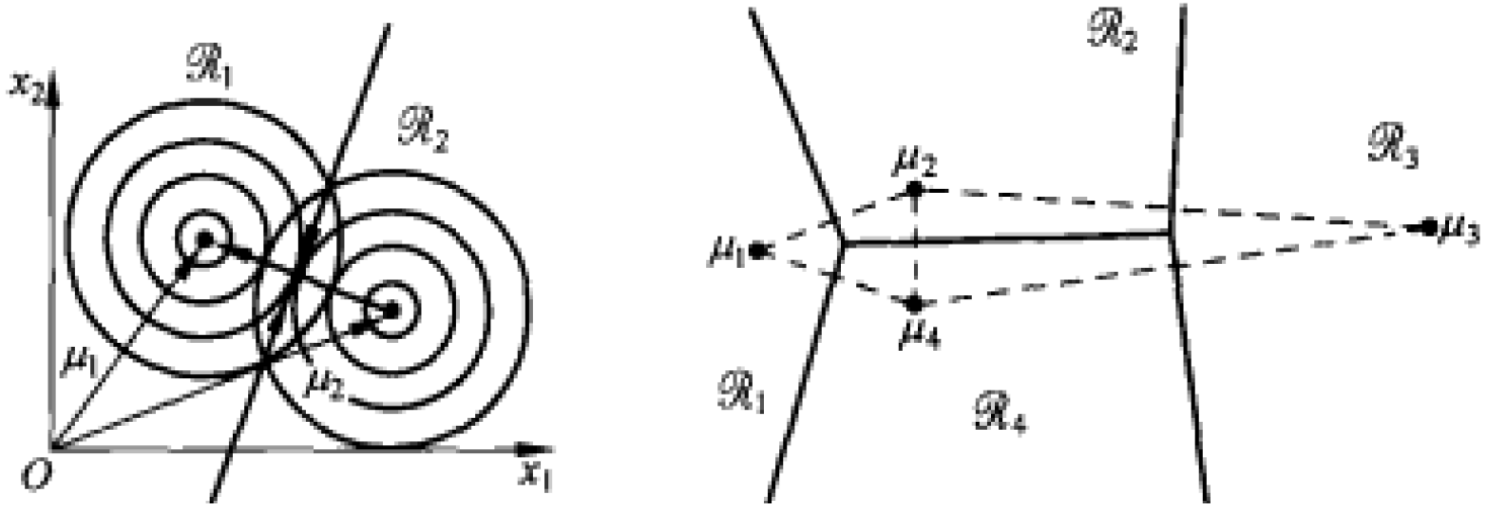

(a) 两类情况　　(b) 多类情况

正态分布且$P(\omega_i)= P(\omega_j)$，$\Sigma_i = \sigma^2 I$时的决策面

多元正态 - 判别函数和决策面

- 特殊情况②:

$$\Sigma_i = \Sigma, i = 1, 2, \dots, c$$

- 它表示各类的**协方差矩阵都相等**，从几何上看，相当于各类别的样本集中于以该类别均值μ_i为中心的**同样形状**的超椭球内。由于Σ_i与i无关，判别函数

$$g_i(x) = \frac{-1}{2}(x-\mu_i)^T\Sigma^{-1}(x-\mu_i) - \frac{d}{2}ln\,2\pi - \frac{1}{2}ln\|\Sigma_i\| + ln\,P(\omega_i)$$

可以简化为:

$$g_i(x) = \frac{-1}{2}(x-\mu_i)^T\Sigma^{-1}(x-\mu_i) + ln\,P(\omega_i)$$

多元正态 - 判别函数和决策面

- 当**先验概率相等**时， 可以进一步简化为：

$$g_i(x) = \gamma^2 = (x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i)$$

即为马氏距离。

- **决策规则**：只需要计算样本x到各类的均值向量μ_i的马氏距离平方，然后把x归为具有最小距离的这一类。
- 该判别函数也可以改写成为线性判别函数的形式，决策面仍然是一个超平面。在一般情况下，**决策面方程满足**：

$$g_i(x) = g_j(x)$$

多元正态 - 判别函数和决策面

- 即：

$$w^T(x - x_0) = 0$$

其中， $w = \Sigma^{-1}(\mu_i - \mu_j)$，

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{1}{(\mu_i - \mu_j)^T \Sigma^{-1}(\mu_i - \mu_j)} ln \frac{P(\omega_i)}{P(\omega_j)}(\mu_i - \mu_j)$$

- $w = \Sigma^{-1}(\mu_i - \mu_j)$通常不在$(\mu_i - \mu_j)$的方向上。
- $(x - x_0)$为通过x_0点的向量。 w与$(x - x_0)$的点积为0表示$(x - x_0)$与w正交。所以，超平面通过x_0点，但是不与$(\mu_i - \mu_j)$正交。

多元正态 - 判别函数和决策面

- 如果**各类先验概率相等**，则：

$$x_0 = \frac{1}{2}(\mu_i + \mu_j)$$

此时， x_0为$\mu_i + \mu_j$连线的**中点**，决策面通过该点。

- 当$P(\omega_i), i = 1, 2, \ldots, c$ 不相等，决策面向**先验概率小**的方向偏移。

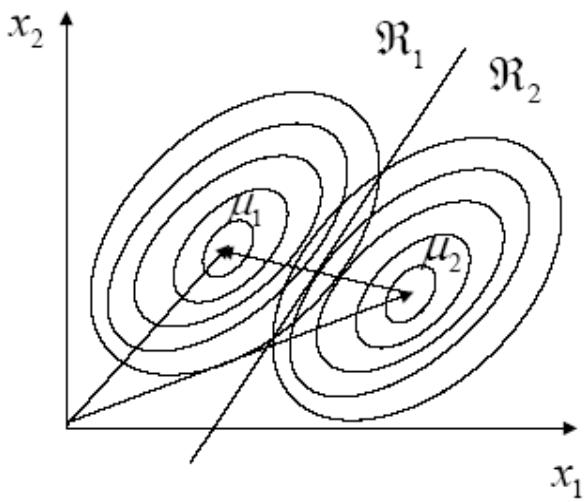

正态分布且$P(\omega_1) = P(\omega_2), \Sigma_1 = \Sigma_2$ 时的决策面

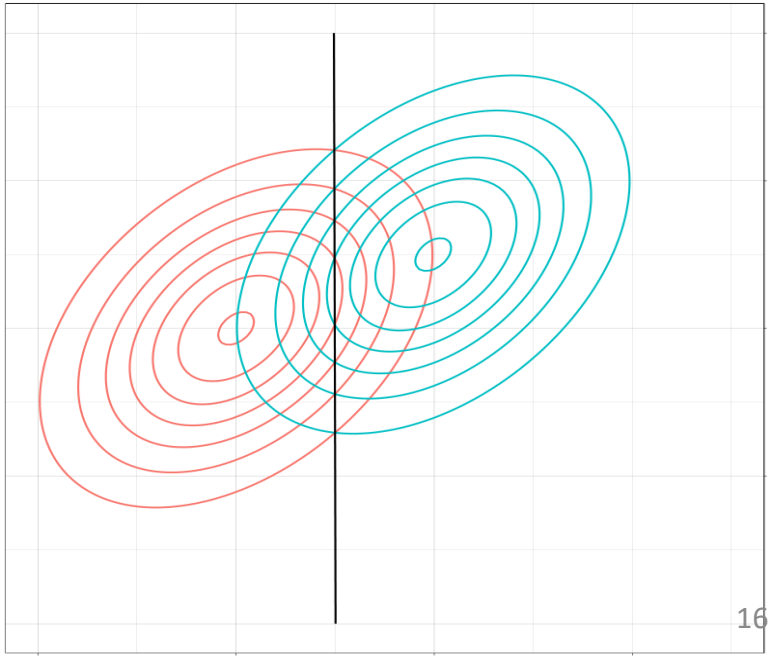

多元正态 - 判别函数和决策面

- 特殊情况③：各类协方差阵不相等

$$\Sigma_i \neq \Sigma_j$$

- 判别函数中只有$\frac{d}{2}\ln 2\pi$与i无关，判别函数可以简化为：

$$g_i(x) = \frac{-1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i) - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$$
$$= x^T W_i x + w_i^T x + w_{i0}$$

- 其中，$W_i = \frac{-1}{2}\Sigma_i^{-1}$ （$d\times d$维）
- $w_i = \Sigma_i^{-1}\mu_i$ （d维）
- $w_{i0} = \frac{-1}{2}\mu_i{}^T\Sigma_i^{-1}\mu_i - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$
- 这时的判别函数为x的二次型。

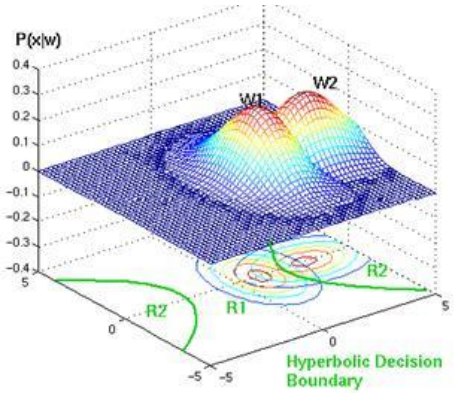

多元正态 - 判别函数和决策面

- 决策面： $g_i(x) - g_j(x) = 0$ 即：

$$x^T(W_i - W_j)x + (w_i - w_j)^T x + w_{i0} - w_{j0} = 0$$

- 该决策面为超二次曲面。随着Σ_i， μ_i， $P(\omega_i)$的不同而呈现出某种曲面，即超球面、超椭球面、超抛物线面、超双曲面或者超平面。

贝叶斯决策的实际使用

- 计算贝叶斯后验概率进行决策如何实现?

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{\sum_{j=1}^{2} p(x|\omega_j)P(\omega_j)}$$

- 实现中有问题吗? 能直接计算吗?

贝叶斯决策的实际使用

- 以上一章中医生诊病为例：

$$P(\omega_1), P(\omega_2)$$

$$P(x|\omega_1), P(x|\omega_2)$$

- 先验概率未知，医生可大致估计
- 类条件概率密度呢?
- 贝叶斯决策的基础是概率密度的估计，即根据一定的训练样本来估计统计决策中用到的先验概率$P(\omega_i)$和类条件概率密度$P(x|\omega_i)$

基于样本的两步贝叶斯决策

- 第一步：利用样本集估计$P(\omega_i)$和$P(x|\omega_i)$得到$\widehat{P}(\omega_i)$和$\widehat{P}(x|\omega_i)$
- 第二步：将估计量带入贝叶斯决策规则中得到决策结果

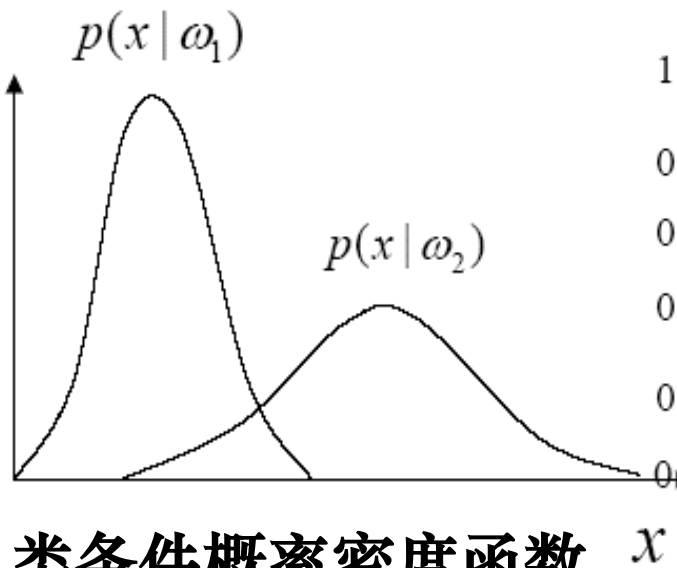

类条件概率密度函数

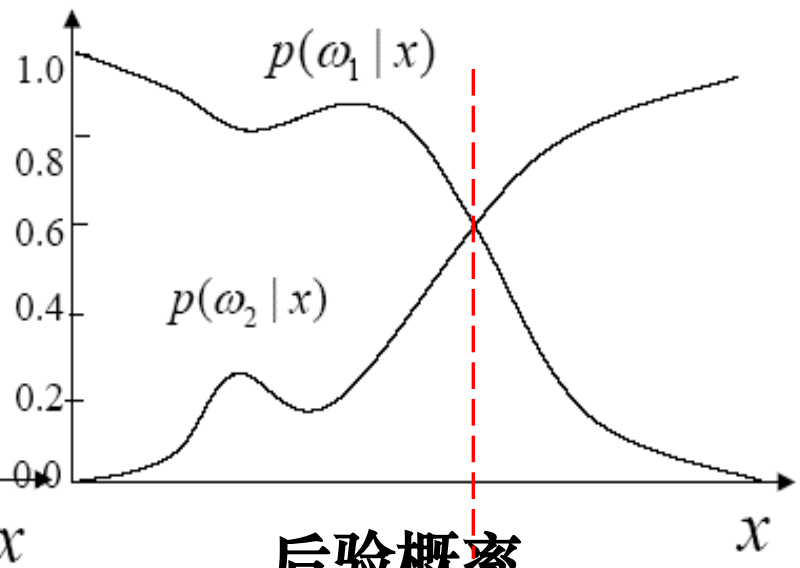

后验概率

基于样本的两步贝叶斯决策

- 通过训练样本进行估计
  - 先验概率估计 – 训练样本分布情况/根据领域知识认定
  - 类条件概率密度估计难，本章重点
- 统计决策进行类别判定
- 注意！与上一章的贝叶斯决策有区别，什么区别?

基于样本的两步贝叶斯决策

- 训练样本有限，难以涵盖所有情况
- 当训练样本无限多，**基于样本的两步贝叶斯决策**可无限**趋近**第二章中的**理论贝叶斯决策**，即：

当$N \to \infty$

$$\widehat{P}(\omega_i) \to P(\omega_i)$$
$$\widehat{P}(x|\omega_i) \to P(x|\omega_i)$$

概率密度估计方法

- 由训练样本集估计总体概率密度的方法可分为:
  - 监督参数估计: 样本所属类别及类条件概率密度函数形式已知，表征概率密度函数的某些参数未知。
  - 注意：在监督学习中，用同一类样本来估计本类的类条件概率密度。在后续除特殊说明，一概假定所有样本来自同一类，不再标出类别标号。
  - 非监督参数估计: 已知总体概率密度函数形式但未知样本所属类别，要求推断出概率密度函数的某些参数。
  - 非参数估计: 已知样本所属类别，总体概率密度函数形式未知，直接推断概率密度函数本身。

参数估计的基本概念

- 1）**统计量**：样本中包含着总体的信息，针对不同要求构造出样本的某种函数，这种函数在统计学中称统计量。

- 2）**参数空间**：假设总体概率密度函数形式已知，未知分布中的参数θ，θ的全部可容许值组成的集合称为参数空间，记为Θ

参数估计的基本概念

- 3）点估计：点估计问题就是要构造一个统计量$d(x_1, x_2, \dots, x_N)$作为参数θ的估计$\hat{\theta}$。
- 估计量：$\hat{\theta}$被称为θ的估计量。
- 估计值：如果$x_1^i, x_2^i, \dots, x_N^i$是属于类别$\omega_i$的样本的观察值，代入统计量$d$就得到对于第$i$类的$\hat{\theta}$的具体数值，这一数值被称为$\theta$的估计值。

参数估计的基本概念

- 4）区间估计: 估计出区间(d_1, d_2)作为θ可能的取值范围，这个区间叫**置信区间**，这类问题称为**区间估计**。

- 本章所涉及的是估计总体分布的**具体参数**，是点估计问题。

概率密度估计的评估

- 如何评估概率密度估计的好坏?
- 单次抽样得到的估计值与真实值的偏差?
- 基于平均和方差进行评估较为公平!
- 常用标准:
  - 无偏性
  - 有效性
  - 一致性

概率密度估计的评估

- **无偏性**：θ的估计量$\hat{\theta}(x_1, x_2, \ldots, x_N)$的数学期望是$\theta$
- **渐进无偏**：N趋于无穷时估计才具有无偏性
- **有效性**：一种估计比另一种的**方差小**，此种估计更有效
- 对于任意正数ε，有

$$\lim_{n\to\infty} P\left(\left|\hat{\theta}_n - \theta\right| > \varepsilon\right) = 0$$

  则$\hat{\theta}$是θ的**一致**估计。
- 无偏性、有效性都是说明对于**多次估计**来说，估计量能以较小的方差平均地表示其真实值，不能保证具体的一次估计的性能；一致性保证**当样本无穷多时**，每一次的估计量都在概率意义上任意地接近其真实值。

概率密度估计的评估

- 参数估计主要方法包括两类:
  - 最大似然估计
  - 贝叶斯估计

- 统计学中的典型分布不能拟合所有的真实数据分布，因此需直接利用样本非参数地估计概率密度
  - 直方图法
  - k_N近邻法
  - Parzen窗法

最大似然估计

似然函数的定义

- 似然函数示例：
- 假设$N=1$， x为一维的且均值为6，方差为1的正态分布。那么，最可能出现的样本? $x_1'=6$
- 此时，似然函数为：

$$l(\theta)=p(x_1'|6,1)=\max_x p(x|6,1)$$

- 反之，假定θ未知，我们从一次抽样中得到一组样本$x_1,x_2,\dots,x_N$，来自哪个密度函数的可能性最大（θ取什么值）？

最大似然估计

基本假设：

- **Maximum Likelihood Estimation.**
- **1）参数θ是确定（非随机）的而未知的量。**
- **2）按类别把样本集分开，X_i类中的每个样本都是独立地从概率密度为$p(x|\omega_i)$的总体中独立地抽取出来的 – 独立同分布。**

最大似然估计

基本假设：

- 3）类条件概率密度$p(x|\omega_j)$为某种确定的分布形式，参数未知。对于不同类别的参数，可以记作θ_j。为了强调待估计的参数，可以写作：

$$p(x|\omega_j) \rightarrow p(x|\omega_j, \boldsymbol{\theta_j})$$

- 4）假设X_i中不包含关于$\theta_j (j \neq i)$的信息，即不同类别的参数在函数上是独立的，可以分别对每一类进行单独估计。

最大似然估计

似然函数的定义

- 基于上述假设，在每一类中独立抽取样本集来估计未知参数。
- 假设某类样本集中包含有 N个样本：

$$X = \{x_1, x_2, \dots, x_N\}$$

- 因样本独立地从$P(x|\theta)$中抽取，获得样本集X的概率为各个样本的联合概率：

$$l(\theta) = P(X|\theta) = p(x_1, x_2, \dots, x_N|\theta) = \prod_{i=1}^{N} p(x_i|\theta)$$

最大似然估计

似然函数的定义

- 这个概率反映了在概率密度函数的参数为θ时，得到这组样本的概率。
- 该函数为θ的函数，反映了不同参数取值下获得当前样本集的可能性。
- 因此，$P(X|\theta)$也被称为参数θ相对于样本集X的似然函数(likelihood function)
- 似然函数的定义：

$$l(\theta) = p(x_1, x_2, \dots, x_N|\theta)$$
$$= p(x_1|\theta)\, p(x_2|\theta) \dots p(x_N|\theta)$$

最大似然估计

最大似然估计量

- 即：要在参数空间中找到一个θ值（可用 $\hat{\theta}$ 表示），能够使得$l(\theta)$极大化。
- 使得**似然函数的值最大**的$\hat{\theta}$是**样本$x_1, x_2, \dots, x_N$的函数**，记为：

$$\hat{\theta} = d(X) = d(x_1, x_2, \dots, x_N)$$

- 则称$\hat{\theta}$是θ的**最大似然估计量**
- **定义**：$\hat{\theta}$是参数空间中能使似然函数$l(\theta) = p(x_1, x_2, \dots, x_N|\theta)$**最大化**的$\theta$，记作

$$\hat{\theta} = \arg\max l(\theta)$$

最大似然估计

最大似然估计的求解

- **求解：** 为了便于后续分析，可以对N个训练样本出现概率的乘积取对数，最优解不变：

$$H(\theta) = \ln l(\theta) = \ln \prod_{i=1}^{N} p(x_i|\theta) = \sum_{i=1}^{N} \ln p(x_i|\theta)$$

最大似然估计的求解

- 当p的形式已知，X确定时，未知量只有θ
- 在似然函数满足连续可微的条件下，如果θ是一维变量，即只有一个带估计的参数，其**最大似然估计量**就是如下微分方程的解：

$$\frac{\mathrm{d}\, l(\theta)}{\mathrm{d}\,\theta} = 0 \text{ 或 } \frac{\mathrm{d}\, H(\theta)}{\mathrm{d}\,\theta} = 0$$

- 更一般地，当$\theta = (\theta_1, \dots, \theta_s)^T$是由多个未知的参数组成的向量时，就需要**对$\theta$的每一维求偏导**，即使用下面的梯度算子$\nabla_\theta = (\frac{\partial}{\partial\theta_1}, \dots, \frac{\partial}{\partial\theta_s})^T$对似然函数求梯度，并**令其等于0**：

$$\begin{bmatrix} \frac{\partial}{\partial\theta_1} \\ \cdots \\ \frac{\partial}{\partial\theta_s} \end{bmatrix} \sum_{i=1}^{N} \ln p(x_i|\theta) = 0$$

最大似然估计的求解

- 进一步有：

$$\sum_{i=1}^{N} \frac{\partial}{\partial \theta_1} \ln P(x_i|\theta) = 0$$

$$\cdots$$

$$\sum_{i=1}^{N} \frac{\partial}{\partial \theta_s} \ln P(x_i|\theta) = 0$$

- 方程组的解就是对数似然函数的极值点。
- 注意，某些情况下可能有多个极值，此时上述方程组可能有多个解，其中**使得似然函数最大的解是最大似然估计量**。

最大似然估计的求解

- 利用上式可以求出θ的估值$\hat{\theta}$
- 则$\theta = \hat{\theta}$
- 注意：有时上式是多解的
- 例：此图有5个解,只有一个解最大

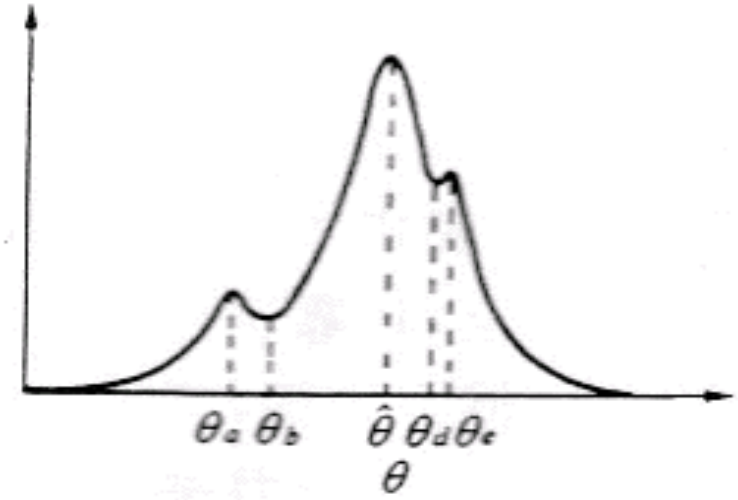

单变量正态分布的最大似然估计

- 样本集$X = \{x_1, x_2, \dots, x_N\}$服从正态分布形式：

$$p(x|\theta) = \frac{1}{\sqrt{2\pi}\sigma}\exp\{\frac{-1}{2}(\frac{x-\mu}{\sigma})^2\}$$

- 其中均值 μ和方差σ^2未知，$\theta = [\theta_1, \theta_2]^{\mathrm{T}} = [\mu, \sigma^2]^{\mathrm{T}}$
- 求解方程

$$\sum_{i=1}^{N} \nabla_\theta \ln p(x_i|\theta) = 0$$

多维正态分布的最大似然估计

- 由正态分布公式可以得到：

$$\ln p(x_k|\theta) = -\frac{1}{2}\ln 2\pi\theta_2 - \frac{1}{2\theta_2}(x_k - \theta_1)^2$$

- 分别对两个未知参数求偏导，最大似然估计应该是以下方程组的解：

$$\sum_{k=1}^{N}\frac{1}{\widehat{\theta_2}}(x_k - \widehat{\theta_1}) = 0$$

$$-\sum_{k=1}^{N}\frac{1}{\widehat{\theta_2}} + \sum_{k=1}^{N}\frac{(x_k - \widehat{\theta_1})^2}{\widehat{\theta_2}^2} = 0$$

- 可以求得$\hat{\mu} = \widehat{\theta_1} = \frac{1}{N}\sum_{k=1}^{N} x_k$；$\hat{\sigma}^2 = \widehat{\theta_2} = \frac{1}{N}\sum_{k=1}^{N}(x_k - \hat{\mu})^2$
- 以上是对**正态分布样本的均值和方差的最大似然估计**

多维正态分布的最大似然估计

- 多维正态分布时，情况①：Σ已知，μ未知：

$$p(x_k|\mu) = -\frac{1}{2}\ln\left[(2\pi)^d|\Sigma|\right] - \frac{1}{2}(x_k-\mu)^T\Sigma^{-1}(x_k-\mu)$$

- 对其求偏导：

$$\Sigma^{-1}\sum_{k=1}^{N}(x_k - N\mu) = 0$$

$$\mu = \hat{\mu} = \frac{1}{N}\sum_{k=1}^{N} x_k$$

- 说明未知均值的最大似然估计正好是训练样本的算术平均

多维正态分布的最大似然估计

- 情况②：Σ，μ均未知
- 估计值：

$$\hat{\mu} = \hat{\theta}_1 = \frac{1}{N}\sum_{k=1}^{N} x_k$$

$$\hat{\Sigma} = \hat{\theta}_2 = \frac{1}{N}\sum_{k=1}^{N}(x_k - \hat{\mu})(x_k - \hat{\mu})^T$$

多维正态分布的最大似然估计

- 结论：
  - 正态总体均值μ的最大似然估计即为训练样本的算术平均
  - 协方差矩阵Σ的最大似然估计为N个矩阵 $(x_k-\hat{\mu})(x_k-\hat{\mu})^T$的算术平均。
  - 正态总体方差的最大似然估计与样本的方差不同(一个是算术平均，一个是期望值），当N较大的时候，二者的差别不大。
- 注意，这两个也正是人们经常使用的对于均值和方差的估计！

最大似然估计

多维正态分布的最大似然估计

- 这两个估计是否为无偏的估计量?

- θ_1，即μ为无偏估计量
- θ_2，即Σ并不是无偏的
- 小作业：无偏的θ_2的估计量是什么?

贝叶斯估计和贝叶斯学习

- Bayesian Estimation
- 把概率密度函数的参数估计看做是一个贝叶斯决策问题，将贝叶斯估计的原理用于直接从数据对概率密度函数进行迭代估计；
- 贝叶斯估计实质：贝叶斯决策来决策参数的取值。要决策的不是离散的类别，而是在**连续的空间中做决策**。

- 对比最大似然估计方法的**区别**：
  - 最大似然估计把待估计的参数当作**未知但固定的量**
  - 贝叶斯估计**把待估计的参数也看为随机变量**
- 相同：结果多数情况下与最大似然估计相同

贝叶斯估计

最小风险贝叶斯决策回顾

- 回顾在分类问题中，最小风险贝叶斯决策：

$$R(a_i|x) = E\left[\lambda\left(a_i, \omega_j\right)\right]$$

$$= \sum_{j=1}^{c} \lambda\left(a_i, \omega_j\right) P\left(\omega_j|x\right), i = 1, 2, \ldots, a$$

- 最小风险贝叶斯决策：

若 $R(a_i|x) = \min_{j=1,\ldots,k} R\left(a_j|x\right)$，则 $a = a_i$

贝叶斯估计

损失函数

- 在分类的贝叶斯决策中，最优的条件可以是最小错误率或最小风险。注意：贝叶斯估计也有不同的优化准则！
- 决策分类时我们往往需要事先定义决策风险表即损失表。
- 这里，对于连续变量θ，假设它的估计$\hat{\theta}$带来的损失为$\lambda(\hat{\theta},\theta)$，也称为损失函数。
- 损失函数有许多种，最常见的损失函数为平方误差损失函数：

$$\lambda(\hat{\theta},\theta)=(\hat{\theta}-\theta)^2$$

- 此外，也有误差绝对值代价函数等。

贝叶斯估计和贝叶斯学习

贝叶斯估计量

- $R(\hat{\theta}|x)$为给定x条件下估计量$\hat{\theta}$的期望损失，也称为条件风险，写作：

$$R(\hat{\theta}|x) = \int_{\Theta}^{\infty} \lambda(\hat{\theta}, \theta) p(\theta|x) d\theta$$

- 如果θ的估计量$\hat{\theta}$使得条件风险最小，则称$\hat{\theta}$是θ的贝叶斯估计量
- 设样本的取值空间为E^d，那么用$\hat{\theta}$来作为估计时的总期望风险为：

$$R = \int_{E^d} R(\hat{\theta}|x) p(x) dx$$

贝叶斯估计

- 此时的优化目标是对**期望风险求最小**。与贝叶斯决策相似，这里的期望风险也是在**所有可能的x的情况下**的条件风险的积分。
- 对于样本集合$X=(x_1,x_2,\dots,x_N)$，对所有的样本求**条件**风险最小，即：

$$\theta^* = \arg\min_{\hat{\theta}} R(\hat{\theta}|x) = \int_{\Theta} \lambda(\hat{\theta},\theta) p(\theta|X) d\theta$$

- **思想**：最小化**期望**损失；**多模型求平均；避免过拟合**（**集成学习**的思想）。

贝叶斯估计

- 定理（不难推导出）：
- 对于连续变量θ，如果损失函数为平方误差损失函数：

$$\lambda(\hat{\theta},\theta)=(\hat{\theta}-\theta)^2$$

- 则θ的贝叶斯估计量θ^*（使得条件风险最小），为在给定x时θ的条件期望：

$$\theta^*=E[\theta|x]=\int_{\Theta}^{\infty}\theta p(\theta|x)d\theta$$

- 同样，在给定样本集X下，θ的贝叶斯估计量是：

$$\theta^*=E[\theta|X]=\int_{\Theta}^{\infty}\theta p(\theta|X)d\theta$$

贝叶斯估计

- **贝叶斯估计**：假设有一个样本集X，要求我们找出估计量$\hat{\theta}$用来估计X所属的**总体分布**的**某个真实参数θ**使得带来的**贝叶斯风险最小**，这就是贝叶斯估计。

似然项　先验项

$$P(\theta|X)=\frac{\boxed{P(X|\theta)}\boxed{P(\theta)}}{\boxed{\int_{\Theta}P(X|\theta)P(\theta)d\theta}}$$

归一化项

贝叶斯估计

在最小平方误差损失函数下，贝叶斯估计具体步骤：

求解目标：$\theta^* = E[\theta|X] = \int_{\Theta}^{\infty} \theta p(\theta|X) d\theta$

- ①确定θ的先验分布$P(\theta)$，待估参数为随机变量
- ②用第i类样本$X = (x_1, x_2, \dots, x_N)$求出样本的联合概率密度分布$P(X|\theta)$，它是$\theta$的函数：

$$P(X|\theta) = \boxed{\prod_{i=1}^{N} p(x_i|\theta)}$$

似然

- ③利用贝叶斯公式，求θ的后验概率

$$P(\theta|X) = \frac{P(X|\theta)P(\theta)}{\int_{\Theta} P(X|\theta)P(\theta)d\theta}$$

- ④最后推断，求贝叶斯估计

$$\theta^* = \int_{\Theta} \theta P(\theta|X) d\theta$$

贝叶斯估计

- 最大似然估计是把待估的参数看作固定的未知量，而贝叶斯估计则是把待估的参数作为具有某种先验分布的随机变量
- 通过对第i类训练样本X^i的观察，使得概率密度分布$P(X^i|\theta)$转化为后验概率$P(\theta|X^i)$，再求贝叶斯估计
- 在贝叶斯估计中，概率密度函数$p(x|\theta)$的形式是已知的，先验分布$p(\theta)$只有在某些特殊形式下才会使得后验概率方便计算。
- 如果先验分布$p(\theta)$能够使得参数的后验分布$p(\theta|X)$具有与$p(x|\theta)$相同的形式，则这样的先验密度函数形式称作与概率模型$p(x|\theta)$共轭。为了计算方便！
- $p(x|\theta)$为正态分布时， $p(\theta)$也为正态分布。计算方便！

贝叶斯估计--正态分布的均值估计

- 样本x服从一维正态分布
- 模型的方差σ^2已知，估计均值μ

- 求解过程：假设概率密度服从正态分布：$p(x|\mu)\sim N(\mu,\sigma^2)$，即：

$$p(x|\mu)=\frac{1}{\sqrt{2\pi}\sigma}\exp\{\frac{-1}{2}(\frac{x-\mu}{\sigma})^2\}$$

- 假定均值 μ 的先验分布也是正态分布，$P(\mu)\sim N(\mu_0,\sigma_0^2)$ （先验，可以来自既往数据）
- 现有第i类样本$X=(x_1,x_2,\dots,x_N)$
- 利用贝叶斯公式求μ的后验概率：

似然项　先验项

$$P(\mu|X)=\frac{\boxed{P(X|\mu)}\boxed{P(\mu)}}{\boxed{\int P(X|\mu)P(\mu)d\mu}}$$

归一化的常数项

贝叶斯估计--正态分布的均值估计

- 因为N个样本是独立抽取的：

$$P(\mu|X) = a\prod_{k=1}^{N} P(x_k|\mu)P(\mu)$$

其中，a为比例因子，只与x有关，与μ无关

$$a = \frac{1}{\int P(X|\mu)P(\mu)d\mu}$$

贝叶斯估计--正态分布的均值估计

- 由于

$$P(X|\mu) = N(\mu, \sigma^2)$$
$$P(\mu) = N(\mu_0, \sigma_0^2)$$

- 则

$$P(\mu|X) = a\prod_{k=1}^{N}\frac{1}{\sqrt{2\pi}\sigma}exp\left\{-\frac{1}{2}\left(\frac{x_k-\mu}{\sigma}\right)^2\frac{1}{\sqrt{2\pi}\sigma}exp[-\frac{1}{2}(\frac{\mu-\mu_0}{\sigma_0})^2]\right\}$$

$$= a'exp\left\{-\frac{1}{2}\left[\sum_{k=1}^{N}\left(\frac{x_k-\mu}{\sigma}\right)^2+\left(\frac{\mu-\mu_0}{\sigma_0}\right)^2\right]\right\}$$

$$= a''exp\{-\frac{1}{2}[\left(\frac{N}{\sigma^2}+\frac{1}{\sigma_0^2}\right)\mu^2-2(\frac{1}{\sigma^2}\sum_{k=1}^{N}x_k+\frac{\mu_0}{\sigma_0^2})\mu]\}$$

其中a', a''包含了所有与μ无关的因子

贝叶斯估计--正态分布的均值估计

- $P(\mu|X)$是μ的二次函数的指数函数
- $P(\mu|X)$仍然是一个正态函数，$P(\mu|X) = N(\mu_N, \sigma_N^2)$
- 整理后，后验概率可以直接写成正态形式：

$$\boxed{P(\mu|X) = \frac{1}{\sqrt{2\pi}\sigma_N}\exp[-\frac{1}{2}(\frac{\mu-\mu_N}{\sigma_N})^2]}$$

是否可以
直接使用?

- 比较以上两个式子,对应的系数应该相等

$$\frac{1}{\sigma_N^2} = \frac{N}{\sigma^2} + \frac{1}{\sigma_0^2}$$

$$\frac{\mu_N}{\sigma_N^2} = \frac{1}{\sigma^2}\sum_{k=1}^{N} x_k + \frac{\mu_0}{\sigma_0^2}$$

贝叶斯估计--正态分布的均值估计

- 进一步整理，可得：

$$\mu_N = \underbrace{\boxed{\frac{\sigma_0^2}{N\sigma_0^2+\sigma^2}\sum_{k=1}^{N} x_k}}_{\text{样本的算术平均}} + \underbrace{\boxed{\frac{\sigma^2}{N\sigma_0^2+\sigma^2}\mu_0}}_{\text{对均值的先验认识}}$$

$$\sigma_N^2 = \frac{\sigma_0^2\sigma^2}{N\sigma_0^2+\sigma^2}$$

- 当**样本趋于无穷大**时，第一项系数趋近于1，而第二项系数趋近于0。即：**估计的均值就是样本的算术平均**，与最大似然估计是**一致**的。
- 当**样本数量很小**时，估计**主要由先验知识确定**。
- 一般情况下，均值的贝叶斯估计就是样本的算术平均与先验分布的均值之间**进行加权平均**。

贝叶斯估计--正态分布的均值估计

- 将μ_N和σ_N^2代入$P(\mu|X)$可以得到μ的**后验概率**，再用$\widehat{\theta}=\int_{\Theta}\theta P(\theta|X)d\theta$求$\mu$的**贝叶斯估计值**：

$$\widehat{\mu}=\int \mu P\left(\mu|X^i\right)d\mu=\mu_N \quad \text{（因为正态分布）}$$

$$\widehat{\mu_N}=\mu_N=\frac{\sigma_0^2}{N\sigma_0^2+\sigma^2}\sum_{k=1}^{N}x_k+\frac{\sigma^2}{N\sigma_0^2+\sigma^2}\mu_0$$

贝叶斯估计

- 注意，我们本来的目的并不是估计概率密度参数，而是估计样本的概率密度函数$p(x|X)$本身。
- 实际上，在贝叶斯估计的框架下，得到了参数的后验概率$p(\theta|X)$后就可以不必求对参数的估计，而是直接代入下式得到样本的概率密度函数：

$$p(x|X) = \int_{\Theta} p(x|\theta)p(\theta|X)d\theta$$

- 直观理解：要估计的概率密度$p(x|X)$是所有可能的参数取值下的样本概率密度函数的加权平均。这个加权，就是在观测样本下估计出参数θ的后验概率。

贝叶斯估计--正态分布的均值估计

- 在贝叶斯估计的框架下，得到了参数的后验概率$p(\theta|X)$后就可以不必求对参数的估计，而是直接代入下式得到样本的概率密度函数：

$$p(x|X) = \int_{\Theta} p(x|\theta)p(\theta|X)d\theta$$

- 对于前面说到的正态分布，整理后可以得到：

$$p(x|X) = \frac{1}{\sqrt{2\pi}\sqrt{\sigma^2+\sigma_N^2}}\exp\left[-\frac{1}{2}\left(\frac{x-\mu_N}{\sqrt{\sigma^2+\sigma_N^2}}\right)^2\right] \sim N(\mu_N, \sigma^2+\sigma_N^2)$$

- 可以看到，虽然我们的已知条件是样本的方差为σ^2，但是由于均值是估计值μ_N，贝叶斯估计得到的分布密度函数方差增加了，变成了$\sigma^2+\sigma_N^2$，而所增加的σ_N^2项在样本数趋于无穷大时，趋于零。

贝叶斯估计--小结

- **步骤：**
- 确定θ的先验分布$P(\theta)$,待估参数为随机变量
- 用第i类样本$X=(X_1,X_2,\dots,X_N)$求出样本的联合概率密度分布$P(X|\theta)$，它是θ的函数
- 利用贝叶斯公式，求θ的后验概率

$$P(\theta|X)=\frac{P(X|\theta)P(\theta)}{\int_{\Theta}P(X|\theta)P(\theta)d\theta}$$

- 最后求贝叶斯估计

$$\hat{\theta}=\int_{\Theta}\theta P(\theta|X)d\theta$$

贝叶斯估计--小结

- 在贝叶斯公式求取θ的后验分布的公式中：

$$P(\theta|X) = \frac{P(X|\theta)P(\theta)}{\int_{\Theta} P(X|\theta)P(\theta)d\theta}$$

- 分母只是归一化因子，$P(\theta|X)$ 由分子两项决定。
- 其中，$P(X|\theta)$为似然函数，反映不同参数值下观测到样本的可能性，另一项是先验概率$P(\theta)$，反映了对参数分布的先验知识或者是主观猜测。
- 贝叶斯估计的优势：不但使用样本中提供的信息进行估计，而且能够很好地把关于待估计参数的先验知识融合进来，并且能够根据样本的数量和先验知识的确定程度来调和两部分信息的相对贡献。

贝叶斯估计--小结

- 若完全没有先验，$P(\theta)$为平均分布，这里就是把所有的可能的参数值的似然函数作为加权，来平均出对参数的估计（不同于极大似然估计，没有直接把使得似然函数值最大的值当做估计）。
- 另一极端，先验非常强，$P(\theta)$为脉冲函数，则最后的估计就是该特定取值点θ_0。
- 通常情况下，似然函数和先验概率共同作用。一种常见情况是，似然函数在其极大值附近有一个尖峰，而先验概率在最大似然估计处不为0且变化较为平缓，则参数的后验概率集中在似然极大值取值附近，此时贝叶斯估计与最大似然估计接近。

最大似然估计与贝叶斯估计

- **最大似然估计**：把待估的参数看做是确定性的量，只是其取值未知。最佳估计就是使得**产生已观测到的样本的概率最大的那个值**。

- **贝叶斯估计**：把待估计的参数看成是符合某种先验概率分布的**随机变量**。对样本进行观测的过程，就是把先验概率密度转化为后验概率密度，这样就**利用样本的信息修正了对参数的初始估计值**。

贝叶斯学习

贝叶斯学习

- 如何在估计样本的概率密度函数的参数时，反映出样本的数目？
- 为了反映样本数目，把样本集重新记作$X^N = (x_1, x_2, \dots, x_N)$
- 贝叶斯估计公式重新写作

$$\theta^* = \int_{\Theta} \theta P(\theta|X^N) d\theta$$

- 其中，$P(\theta|X^N) = \frac{P(X^N|\theta)P(\theta)}{\int_{\Theta} P(X^N|\theta)P(\theta)d\theta}$
- 当N＞1时，有：

$$P(X^N|\theta) = P(x_N|\theta)P(X^{N-1}|\theta)$$

贝叶斯学习

- 代入可得如下递推公式：

$$P\left(\theta|X^N\right)=\frac{P\left(x^N|\theta\right)P\left(\theta|X^{N-1}\right)}{\int_\Theta P(x^N|\theta)P\left(\theta|X^{N-1}\right)d\theta}$$

- 为了统一形式，把先验概率记作$P\left(\theta|X^0\right)=P(\theta)$
- 随着样本数量的增加，可以得到一系列对于概率密度函数参数的估计，称为**递推的贝叶斯估计**。
- **贝叶斯学习：**如果随着样本数的增加，后验概率序列逐渐变得尖锐，逐步地趋向于以θ的真实值为中心的一个尖峰，当样本数无穷多时收敛于在参数真实值上的脉冲函数，则这一过程称作贝叶斯学习。
- 此时，样本的概率密度函数也逼近真实的密度函数：

$$p\left(x|X^{N\to\infty}\right)=p(x)$$

朴素贝叶斯分类器

朴素贝叶斯分类器

- 基于贝叶斯公式来估计后验概率$P(\omega|x)$的主要困难在于：**类条件概率**$P(x|\omega)$是所有属性上的**联合概率分布，难以从有限的训练样本直接估计而得**。
- 为避开这个障碍，**朴素贝叶斯分类器(naive Bayes classifier)采用了“属性条件独立性假设”，即：对已知类别，假设所有属性之间相互独立。**

$$p(x_l x_k|\omega_i) = p(x_l|\omega_i)p(x_k|\omega_i), l, k = 1, \dots, d, k \neq l$$

- 在该假设下，需要求解的**联合概率**可以分解为：

$$p(x_1, \dots, x_d|\omega_i) = p(x_1|\omega_i) \dots p(x_d|\omega_i)p(\omega_i)$$

朴素贝叶斯分类器

- 对于各类别的先验概率，可以通过统计训练样本中第i类样本占总训练样本的比率来进行统计。

$$P(Y=\omega_i)=\frac{\sum_{j=1}^{N} I(y_j=\omega_i)}{N}$$

- 对于每个属性的条件概率，可以通过第i类样本在该特征上的取值进行估计。对于离散取值的特征：

$$p(x_k=v_l|Y=\omega_i)=\frac{\sum_{j=1}^{N} I(x_k^{(j)}=v_l, y_j=\omega_i)}{\sum_{j=1}^{N} I(y_j=\omega_i)}$$

- 其中$x_k^{(j)}$表示第j个样本的第k个特征的取值。
- 当训练样本较少时或某些特征取值的概率较低时，可能会出现$\sum_{j=1}^{N} I(x_k^{(j)}=v_l, y_j=\omega_i)=0$的情况。

朴素贝叶斯分类器

- 此时，如果将$\hat{p}(x_k = v_l | Y = \omega_i)$直接设置为0可能会不合理。
- 为了避免由于训练样本的局限，导致某些概率的估计值过低，通常会在估计概率分布时，**引入伪计数来对概率值进行平滑矫正，也被成为拉普拉斯平滑**。例如：

$$P(Y = \omega_i) = \frac{\sum_{j=1}^{N} I(y_j = \omega_i) + 1}{N + C}$$

$$p(x_k = v_l | Y = \omega_i) = \frac{\sum_{j=1}^{N} I(x_k^{(j)} = v_l, y_j = \omega_i) + 1}{\sum_{j=1}^{N} I(y_j = \omega_i) + S_k}$$

其中，C为类别数；S_k为第k维的特征可能的取值数量。

- 拉普拉斯修正避免了因训练样本不充分而导致概率估值为零的问题，并且在训练集变大时，修正过程所引入的先验的影响也会**逐渐变得可忽略**。

非参数估计方法

概率密度函数的估计

非参数估计方法

- 最大似然方法和贝叶斯方法都属于**参数化的估计方法**。
- 多数情况下我们对样本的分布没有充分的了解，**无法给出密度函数形式**，部分样本情况**难以用简单的函数来描述**。
- 需要非参数估计，即不对密度函数进行假设，直接利用样本估计整个函数。
- 只有数值形式，无封闭函数形式。
- 不同于参数化估计方法只从一类函数中选择一个函数对未知函数进行估计，非参数化估计方法从所有可能的函数中进行一种选择。

非参数估计方法

- 几种常见的非参数设计
  - 直方图方法
  - K_N近邻估计方法
  - Parzen窗法

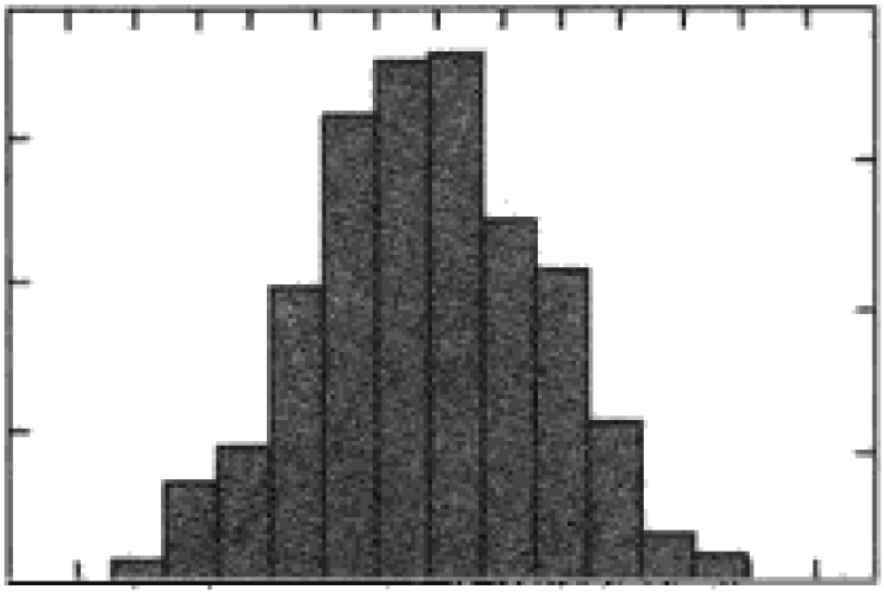

非参数估计方法-直方图估计

- 直方图方法为日常人们常用之方法
- 过程：
  - 将样本x的每个分量在其取值范围内分割成k个等间隔小窗。如果x是d维向量，则这种分割会得到k^d个小舱，每个小舱体积为V
  - 统计落入每个小舱内的样本数目q_i
  - 把每个小舱的概率密度看为常数，并用$\frac{q_i}{NV}$作为其估计值，N为样本总数。

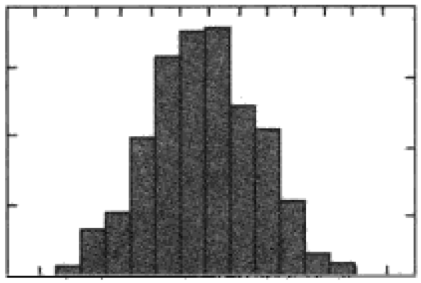

非参数估计方法-直方图估计

- 小舱的选择与估计效果息息相关
- 过宽：$p(x)$在小窗内为常数的假设非常粗糙，导致最终估计的概率密度函数非常粗糙。
- 过窄：某些小窗内样本过少或没有，估计出的概率密度函数不连续。

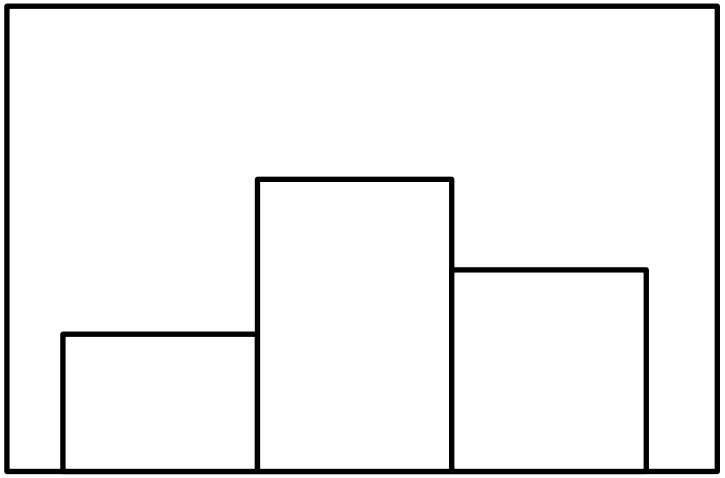

(a)小窗过宽

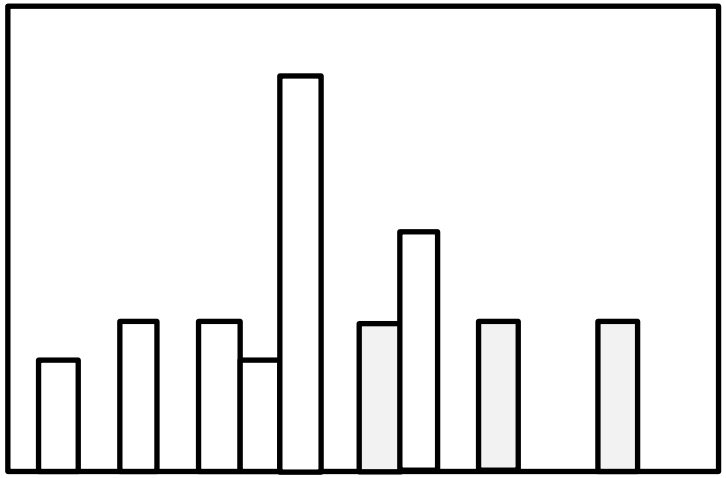

(b)小窗过窄

非参数估计方法- K_N近邻估计

- K_N 近邻估计就是一种采用可变大小的小舱的密度估计方法。
- 基本做法是:
- 1）根据总样本确定一个参数k_N，即在总样本数量为N时每个小舱内的样本个数。
- 2）在求x处的密度估计$\hat{p}(x)$时，调整包含x的小舱的体积，直到小舱内恰好落入k_N个样本，并用下式来估算$\hat{p}(x)$，即:

$$\hat{p}(x) = \frac{k_N}{NV}$$

- 能够自动地根据样本密度调整小舱的体积，较好地兼顾高密度区域估计的分辨率和低密度区域估计的连续性。

非参数估计方法- *Parzen*窗法

- 假定 $\Re_N$ 是d 维超立方体，h_N 是 $\Re_N$的侧棱的长度，则该超立方体的体积为：

$$V_N = h_N^d$$

方窗函数

$$\varphi(u) = \begin{cases} 1, & 当 |u_j| \le \frac{1}{2}, j = 1, 2, \cdots, \\ 0, & 其它 \end{cases}$$

- 当某一个 $\mathbf{x}_i$ 落在以 $\mathbf{x}$ 为中心的体积为V_N的超立方体内时，有：

$$\varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right) = 1$$ 否则为0。

$$\Rightarrow \quad k_N = \sum_{i=1}^{N} \varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right)$$

$$\Rightarrow \quad \boxed{p_N(\mathbf{x}) = \frac{k_N / N}{V_N} = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{V_N}\varphi\left(\frac{\mathbf{x}-\mathbf{x}_i}{h_N}\right)}$$

(补)：生成式模型和判别式模型

Generative Model and Discriminative Model

生成式模型和判别式模型

- **生成式模型(Generative Model)--源头导向**

分别对各类的**类条件密度** $p(\mathbf{x}|C_k)$ 和**先验概率** $p(\mathcal{C}_k)$进行建模，之后利用贝叶斯定理计算**后验概率**

$$p(\mathcal{C}_k|\mathbf{x}) = \frac{p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)}{\sum_j p(\mathbf{x}|\mathcal{C}_j)p(\mathcal{C}_j)}$$

或者直接对**联合分布** $p(\mathbf{x}, C_k)$建模得到后验概率

- **判别式模型(Discriminative Model)--结果导向**

直接对**后验概率** $p(\mathcal{C}_k|\mathbf{x})$建模

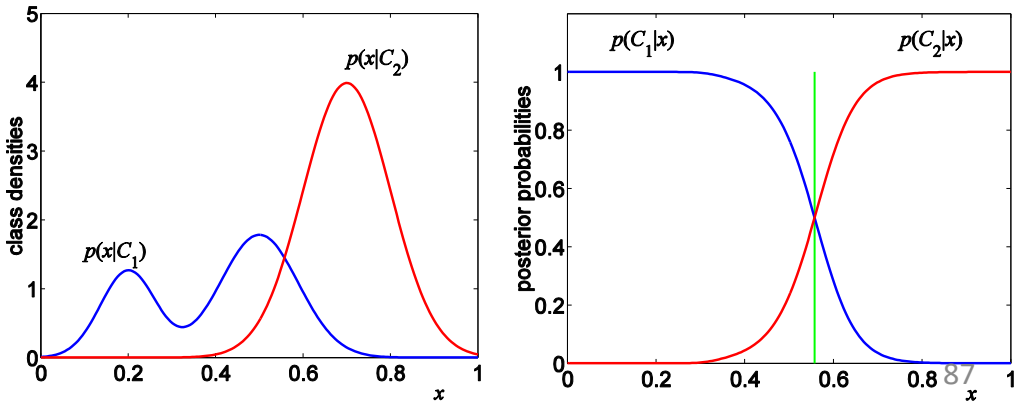

逻辑回归(Logistic Regression)

- **将回归问题转为分类问题**

逻辑回归是概率型非线性回归，但其本质是线性回归，只是在特征到结果的映射中加入了一层函数映射，即先把特征线性求和，然后使用函数σ(z) 来预测。

$$p(C_1|\mathbf{x}) = \frac{p(\mathbf{x}|C_1)p(c_1)}{p(\mathbf{x}|C_1)p(c_1)+p(\mathbf{x}|C_2)p(c_2)} = \sigma(w^T x) \quad \sigma(a) = \frac{1}{1+\exp(-a)}$$

Sigmoid函数性质：

①可以将连续值映射到0和1区间上

②对称性 $\sigma(-a) = 1 - \sigma(a)$

③反转性 $a = ln(\frac{\sigma}{1-\sigma}) = ln\frac{p(C_1|x)}{p(C_2|x)}$

④可导性 $\frac{d\sigma}{da} = \sigma(1-\sigma)$

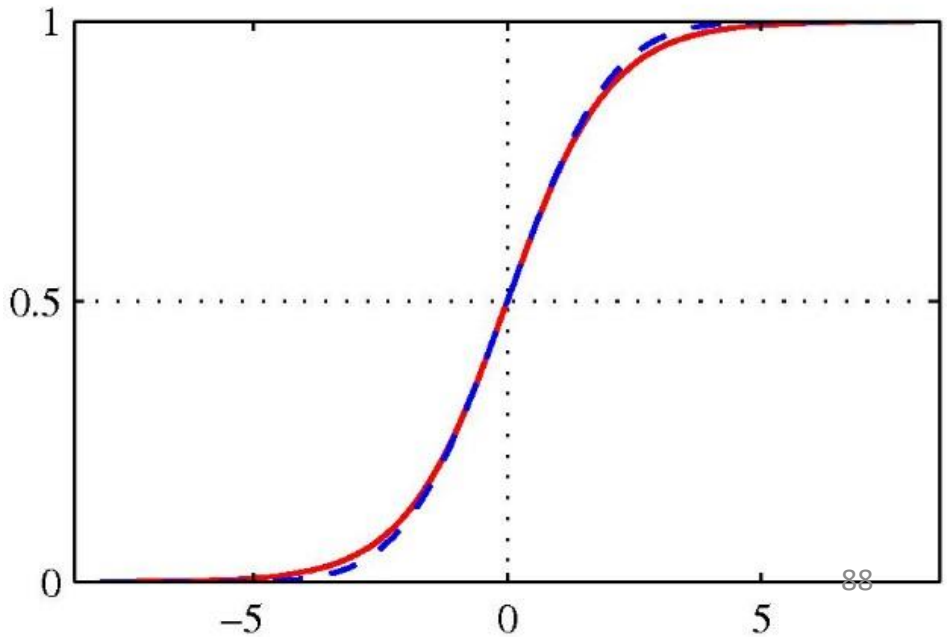

生成式模型和判别式模型

$$p(C_1|\mathbf{x}) = \frac{p(\mathbf{x}|C_1)p(c_1)}{p(\mathbf{x}|C_1)p(c_1)+p(\mathbf{x}|C_2)p(c_2)} = \frac{1}{1+exp(-a)} = \sigma(a)$$

$$a = ln\frac{p(C_1|x)}{p(C_2|x)} = ln\frac{p(x|C_1)p(C_1)}{p(x|C_2)p(C_2)}$$

- **生成式模型(Generative Model)**

估计类条件密度并计算*a*

- **判别式模型(Discriminative Model)**

把*a*视为线性函数 $a = w^T x$ 直接估计

生成式模型

- **连续型输入变量**

假设类条件密度函数符合高斯分布，并且各类的协方差矩阵相同，表达式为：

$$p(\mathbf{x}|C_k) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp\{-\frac{1}{2}(x-\mu_k)^T \Sigma^{-1} (x-\mu_k)\}$$

$$p(C_1|\mathbf{x}) = \sigma(w^T x + w_0)$$

$$w = \Sigma^{-1}(\mu_1 - \mu_2)$$

$$w_0 = -\frac{1}{2}\mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2}\mu_2^T \Sigma^{-1} \mu_2 + \ln \frac{p(C_1)}{p(C_2)}$$

未知数

μ_1, μ_2, Σ, $p(c_1)$和$p(c_2)$

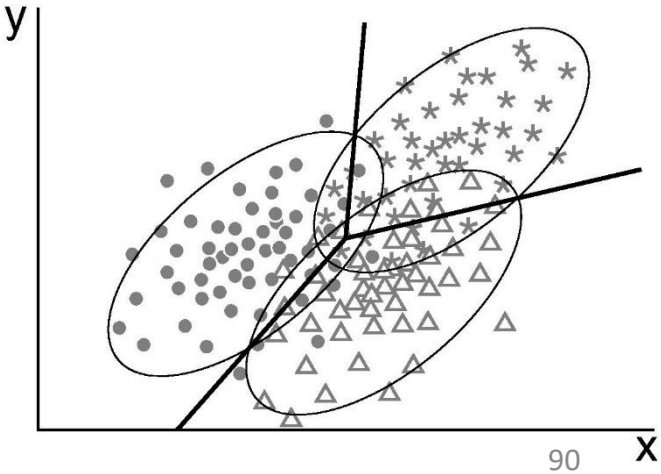

生成式模型

- **最大似然解**

数据集 $\{X_n, t_n\}, n = 1, 2, ..., N$， $t_n = 1, x \in C_1; t_n = 0, x \in C_2,$

先验概率 $p(C_1) = \pi, p(C_2) = 1 - \pi$

对于第一类样本 $t_n = 1$， $p(x_n, C_1) = p(C_1)p(x_n|C_1) = \pi\mathcal{N}(x_n|\mu_1, \Sigma)$

对于第二类样本 $t_n = 0$， $p(x_n, C_2) = p(C_2)p(x_n|C_2) = (1 - \pi)\mathcal{N}(x_n|\mu_2, \Sigma)$

似然函数 $p(t, X|\pi, \mu_1, \mu_1, \Sigma) = \prod^{N} [\pi\mathcal{N}(x_n|\mu_1, \Sigma)]^{t_n}[(1 - \pi)\mathcal{N}(x_n|\mu_2, \Sigma)]^{1-t_n}$

对变量求导得到解: $\pi = \frac{1}{N}\sum_{n=1}^{N} t_n = \frac{N_1}{N} = \frac{N_1}{N_1+N_2}$

$$\mu_1 = \frac{1}{N_1}\sum_{n=1}^{N} t_n x_n, \mu_2 = \frac{1}{N_2}\sum_{n=1}^{N}(1 - t_n)x_n, \quad S = \frac{N1}{N}S_1 + \frac{N_2}{N}S_2$$

$$S_1 = \frac{1}{N_1}\sum_{n\in C_1}(x_n - \mu_1)(x_n - \mu_1)^T, S_2 = \frac{1}{N_2}\sum_{n\in C_2}(x_n - \mu_2)(x_n - \mu_2)^T$$

生成式模型

● 离散型输入变量

D个输入样本 $x_i \in \{0,1\}$，假设它们彼此独立(满足朴素贝叶斯)，类条件分布表达式为：

$$p(\mathbf{x}|C_k) = \prod_{i=1}^{D} \mu_{ki}^{x_i}(1-\mu_{ki})^{1-x_i}$$

每类包含***D***个独立参数，代入 $a_k = \ln p(\mathbf{x}|C_k)p(c_k)$，

$$a_k(x) = \sum_{i=1}^{D}\{x_i ln\mu_{ki} + (1-x_i)ln(1-\mu_{ki})\} + lnp(C_k)$$

是输入样本 x_i 的线性函数。

判别式模型

● 广义线性模型

将后验概率表示为作用于特征向量 ϕ 的线性函数的Logistic Sigmoid

$$p(C_1|\phi) = y(\phi) = \sigma(w^T\phi)$$
$$p(C_2|\phi) = 1 - p(C_1|\phi)$$

数据集 $\{\phi_n, t_n\}$, $t_n \in \{0,1\}, \phi_n = \phi(x_n),\ n = 1, 2, ..., N$

似然函数 $p(t|w) = \prod_{n=1}^{N} y_n^{t_n}\{1-y_n\}^{1-t_n}, \quad t = (t_1, ..., t_N)^T, y_n = p(C_1|\phi_n)$

误差函数 $E(w) = -\ln p(t|w) = -\sum_{n=1}^{N}\{t_n \ln y_n + (1-t_n)\ln(1-y_n)\}$

$y_n = \sigma(a_n), a_n = w^T\phi_n$ **交叉熵(Cross-Entropy)误差函数**

$$\boxed{\frac{d\sigma}{da} = \sigma(1-\sigma)} \qquad \nabla E(w) = \sum_{n=1}^{N}\{y_n - t_n)\phi_n$$

$$\nabla_{\mathbf{w}} \ln p(\mathbf{t}|\mathbf{w}, \beta) = \beta \sum_{n=1}^{N} \{t_n - \mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}(\mathbf{x}_n)\}\, \boldsymbol{\phi}(\mathbf{x}_n)^{\mathrm{T}} = \mathbf{0}.$$

生成式模型和判别式模型

● 生成式模型

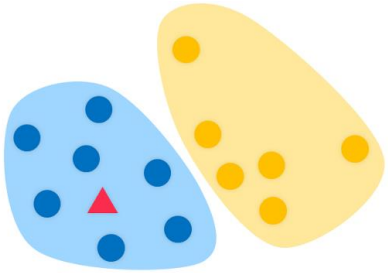

优点：

- 信息丰富
- 单类问题灵活性强
- 增量学习
- 合成缺失数据

缺点：

- 学习过程复杂
- 为分布牺牲分类性能

● 判别式模型

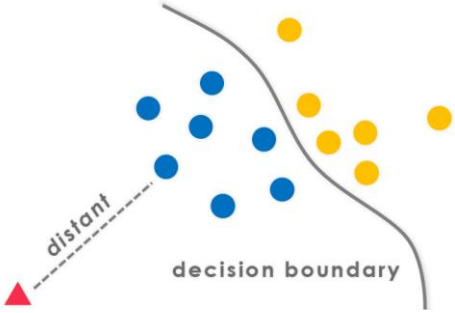

优点：

- 类间差异清晰
- 分类边界灵活
- 学习简单
- 性能较好

缺点：

- 不能反应数据特性
- 需要全部数据进行学习

由生成模型可以得到判别模型，
但由判别模型得不到生成模型。

生成式模型和判别式模型

- **生成式模型**

代表算法：

- Naive Bayes
- Mixtures of Gaussians
- Hidden Markov Models
- Bayesian Networks
- Deep Belief Network

- **判别式模型**

代表算法：

- Linear & Logistic Regression
- Support Vector Machine
- Nearest Neighbor
- Conditional Random Fields
- Boosting

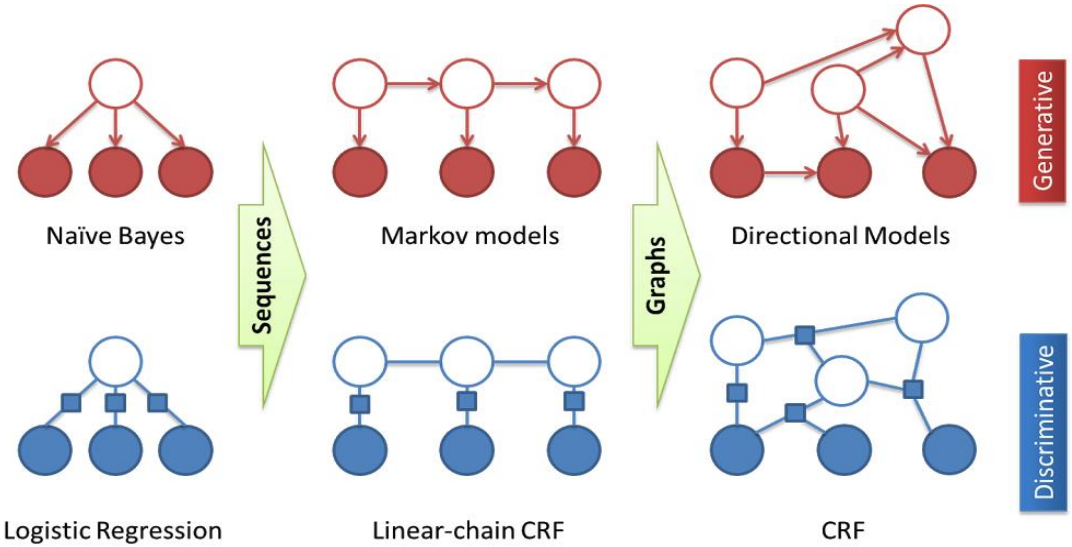

模式识别

第五章：概率密度函数的估计

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022