模式识别

第六章：支持向量机

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022

回顾

- 线性判别函数的基本概念
- Fisher线性判别函数
- 感知准则函数
- 最小平方误差准则函数
- 多类问题

一些问题

- 已知类条件概率密度 $p(\mathbf{x}|w_i)$ 和先验概率 $P(w_i)$，计算后验概率 $P(w_i|\mathbf{x})$ 进行决策

若类条件概率密度参数未知?

- 已知类条件概率密度 $p(\mathbf{x}|w_i)$ 的参数表达式，利用样本估计 $p(\mathbf{x}|w_i)$ 的未知参数，再利用贝叶斯定理将其转化成后验概率 $P(w_i|\mathbf{x})$ 进行决策

若类条件概率密度形式难以确定?

- 非参数方法估计

需要大量样本…

回顾 – 线性分类器设计

- 利用训练样本建立线性判别函数

$$g(x) = \boxed{w^T}x + \boxed{w_0}$$

$$g(x) = w_0 + \sum_{i=1}^{d} w_i x_i = \sum_{i=1}^{d} a_i y_i = \boxed{a^T}y$$

最好的结果一般出现在准则函数的极值点上，所以将分类器设计问题转化为求准则函数极值w^*, w_0^*或a^*的问题。

步骤1：具有类别标志的样本集$\mathcal{X} = \{x_1, x_2, \dots x_N\}$或其增广样本集$\mathcal{Y}$。

步骤2：确定准则函数$\mathcal{J}$，满足①$\mathcal{J}$是样本集和w, w_0或a的函数；②$\mathcal{J}$的值反应分类器的性能，其极值对应“最好”的决策。

步骤3：优化求解准则函数极值w^*, w_0^*或 a^* 。

最终得到线性判别函数： $g(x) = w^{*T}x + w_0^*$或 $g(x) = a^{*T}y$。对于未知类别样本x_k，计算$g(x_k)$并通过决策规则判断其类别。

准则函数

- **Fisher准则**

$$J_F(w) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

$$w^* = S_w^{-1}(m_1 - m_2)$$

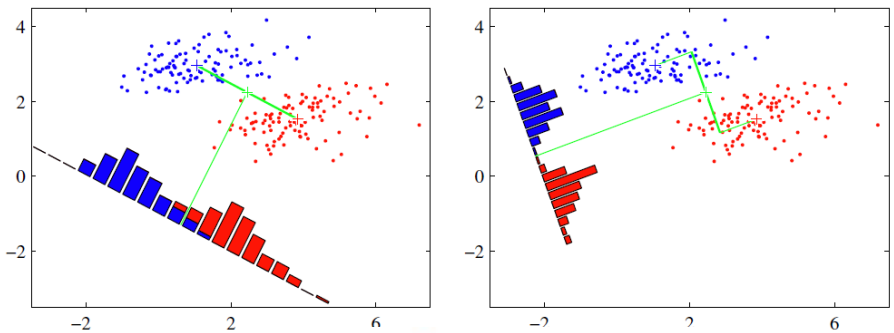

- **感知机准则**

$$J_P(a) = \sum_{y \in \eta^k} (-a^T y)$$

$$a(k+1) = a(k) + \rho_k \nabla \sum_{y \in \eta^k} y$$

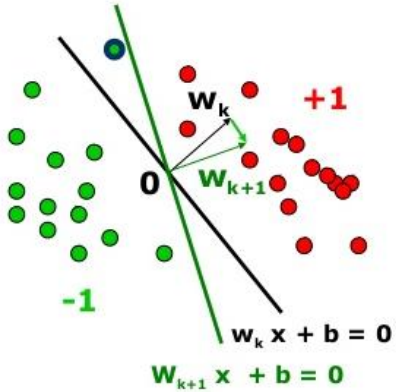

- **最小平方误差准则**

$$J_S(a) = \|e\|^2 = \|Ya - b\|^2 = \sum_{n-1}^{N} (a^T y_n - b_n)^2$$

$$a^* = (Y^T Y)^{-}1 Y^T b = Y^+ b$$

$$a(k+1) = a(k) - \rho_k Y^T (Ya - b)$$

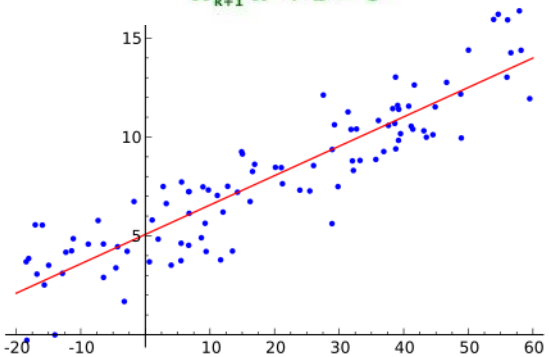

线性判别函数的基本概念

- 两类问题的线性分类可采用如下**决策规则**:

$$\text{如果}\begin{cases} g(x) > 0\text{，则决策}x \in \omega_1 \\ g(x) < 0\text{，则决策}x \in \omega_2 \\ g(x) = 0\text{，可将其任意分类或拒绝} \end{cases}$$

- $g(x) = 0$ 定义了一个决策面，把两类实例分开。如果$g(x)$是**线性**的，则决策面是一个**超平面**。

- 如果x_1和x_2都在决策面上，则:

$$w^T x_1 + w_0 = w^T x_2 + w_0$$

- 或:

$$w^T(x_1 - x_2) = 0$$

线性判别函数的基本概念

- 对于超平面H上的点x_1和x_2，有：

$$w^T(x_1 - x_2) = 0$$

- 说明w与超平面上任一向量正交，即：**w是H的法向量**
- 一般来说H将空间分成两个**决策域**R_1和R_2。当x在R_1中，g(x)>0, 法向量是指向R_1的。有时称R_1中所有的x在H的**正侧**，相应地R_2中的x在H的**负侧**。

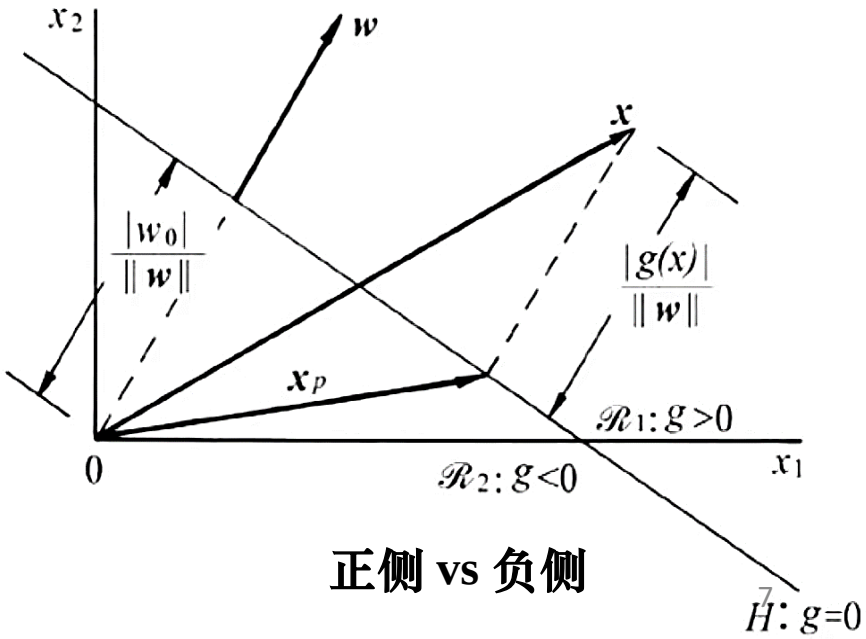

正侧 vs 负侧

线性判别函数的基本概念

- 判别函数$g(x)$也可以**看作是特征空间中某个点x到超平面距离的一种代数度量**。若把x表示为：

$$x = x_p + r\frac{w}{||w||}$$

- 其中，x_p是x到H的射影向量，r是x到H的垂直距离，$\frac{w}{||w||}$是**w方向上**的单位向量。

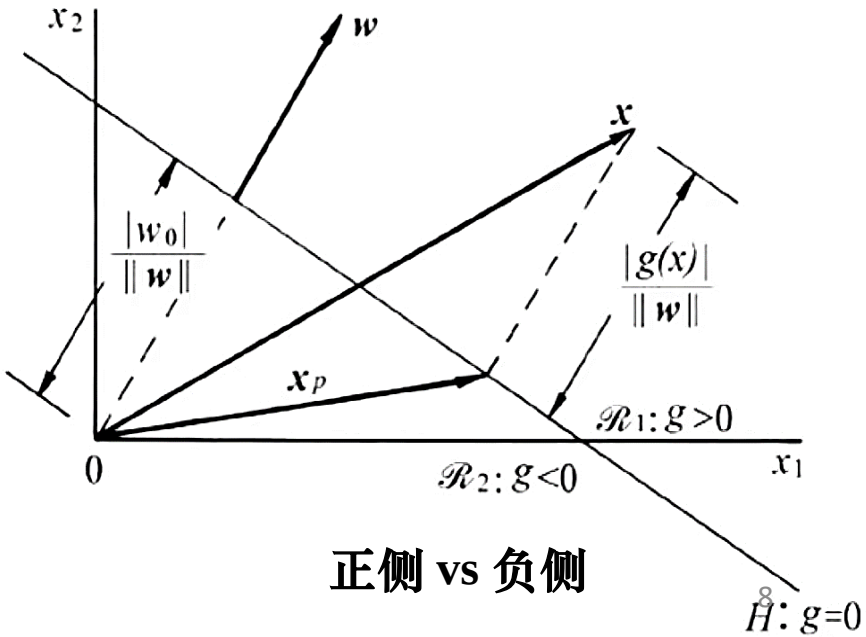

正侧 vs 负侧

线性判别函数的基本概念

- 可进一步写为：

$$g(x) = w^T\left(x_p + r\frac{w}{||w||}\right) + \omega_0 = w^T x_p + \omega_0 + r\frac{w^T w}{||w||}$$
$$= r||w||$$

- 可进一步写为： $r = \frac{g(x)}{||w||}$
- 若x为原点，则$g(x) = \omega_0$
- 原点到超平面H的距离可以写作： $r_0 = \frac{\omega_0}{||w||}$

回顾 – 多分类问题

- **1 *vs.* (N-1) or 1 *vs.* 1**

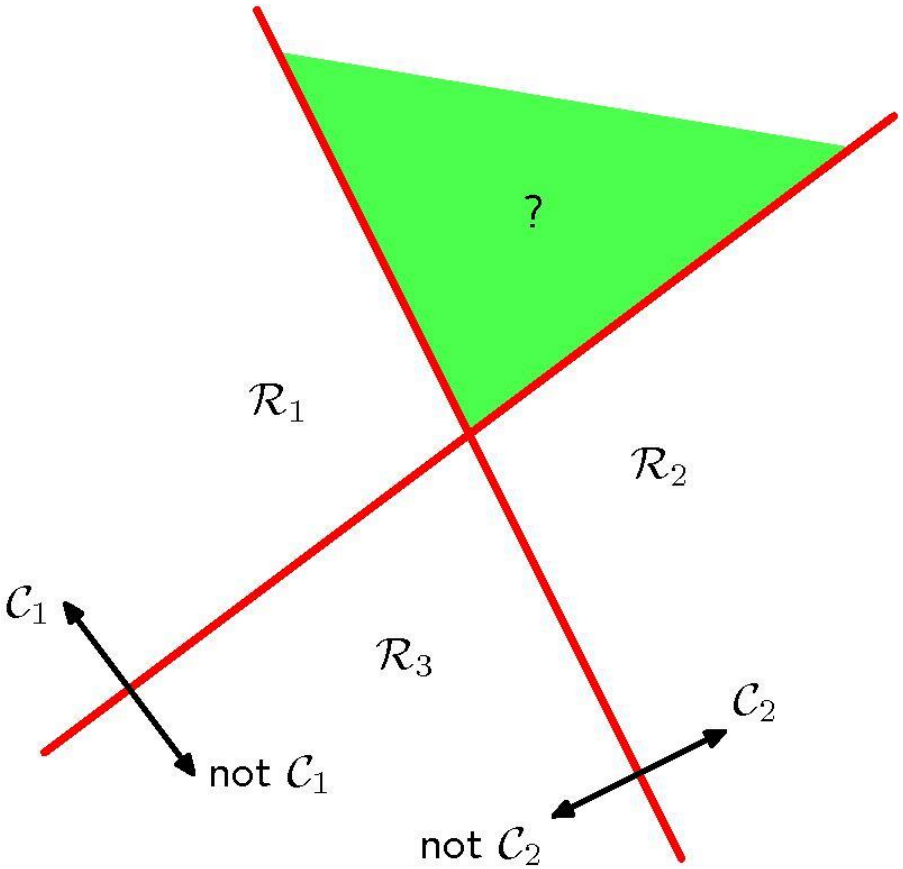

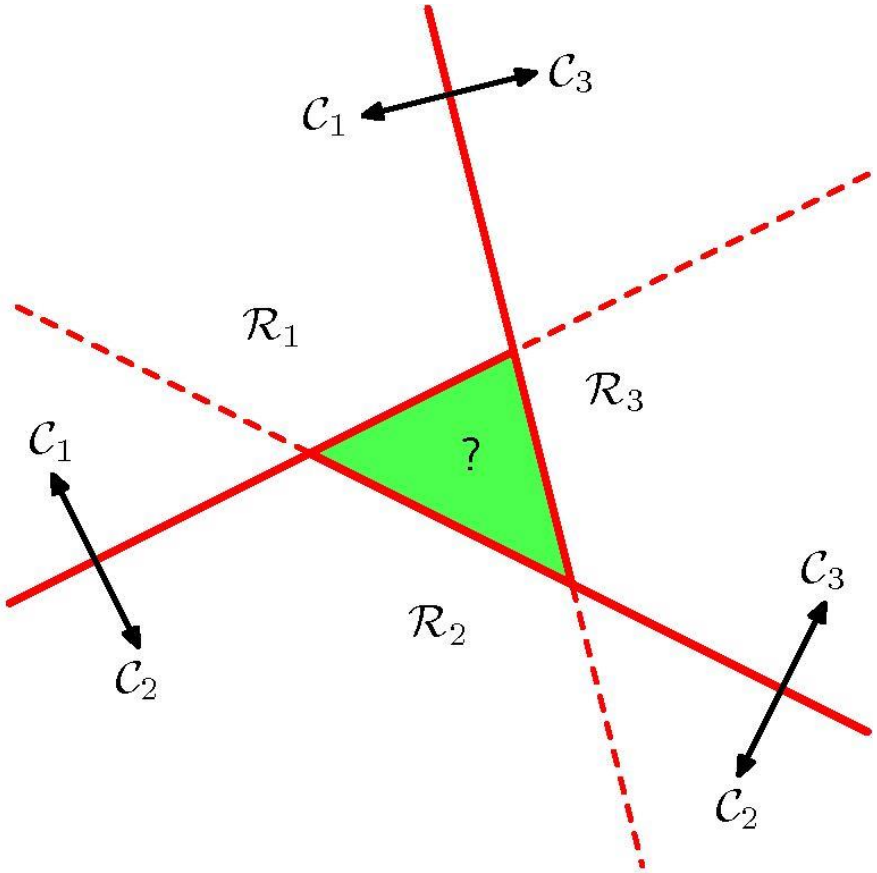

引言

- 两类样本的线性分类模型:
- $y(x) = w^T x + b$

- 问题:
- 如果存在一个线性模型（存在一个超平面）可以将两类样本分开，那么是否存在无数条线可以将两类样本分开?
- 如果存在无数条线，那么哪条最优?
- 如何明确定义“最优”？

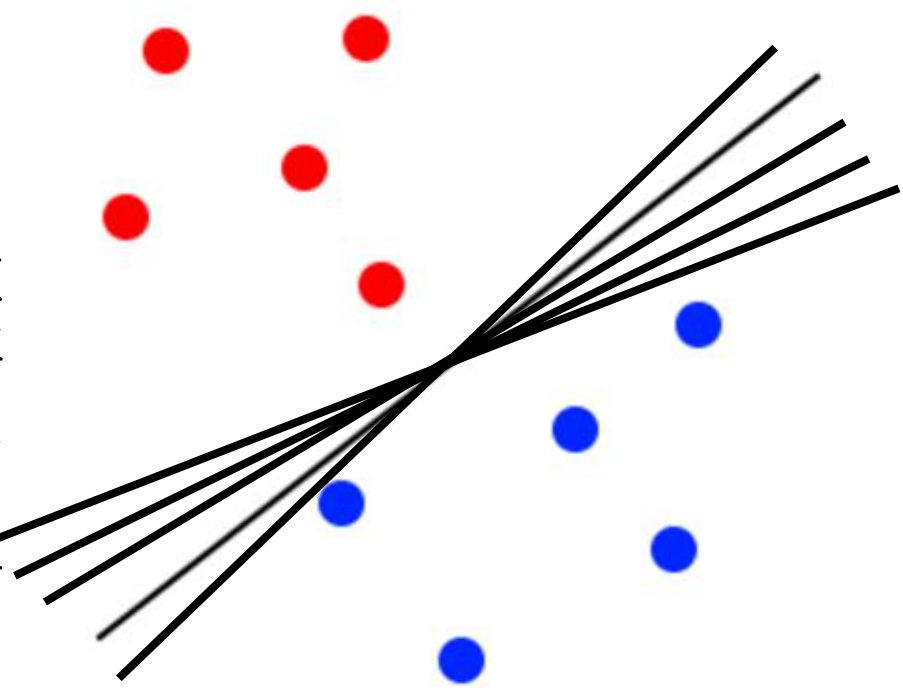

线性可分样本集:
多解性

SVM：解决最优超平面的问题

内容

- 引言
- 线性支持向量机
  - 对于线性可分样本集如何找出最优分类超平面
- 非线性支持向量机
  - SVM如何推广?

引言

- C. Cortes和V. Vapnik (1995年发表)
- 支持向量机(Support Vector Machine)是基于统计学习理论(Statistical Learning Theory, SLT)发展起来的一种新的机器学习的方法。直接掀起了统计学习在2000前后的发展高潮。
- 统计学习理论主要创立者是Vladimir N. Vapnik。

引言

- **Vladimir N. Vapnik**

1936年 出生于苏联

1958年 乌兹别克国立大学 硕士
1964年 莫斯科控制科学学院 博士

1964-1990年 莫斯科控制科学学院
曾担任计算机科学与研究系主任
1991-2001年 美国AT&T贝尔实验室
发明支持向量机理论
2002-2014年 NEC实验室(美国)
从事机器学习研究
2014年至今 美国Facebook公司
从事人工智能研究

1995年和**2003年**，他分别被伦敦大学皇家霍洛威学院和美国哥伦比亚大学聘为计算机专业的教授。
2006年，他成为美国国家工程院院士。

概述

- **V. Vapnik对于统计机器学习的贡献**

1963年，Vapnik提出了支持向量的概念。

1968年，Vapnik和Chervonenkis提出了VC熵和VC维的概念，这些是统计学习理论的核心概念。同时，他们发现了泛函空间的大数定理，得到了关于收敛速度的非渐进界的主要结论。

1974年，Vapnik和Chervonenkis提出了结构风险最小化归纳原则。

1989年，Vapnik和Chervonenkis发现了经验风险最小化归纳原则和最大似然方法一致性的充分必要条件，完成了对经验风险最小化归纳推理的分析。

90年代中期，有限样本情况下的机器学习理论研究逐渐成熟起来，形成了较完善的理论体系—统计学习理论。

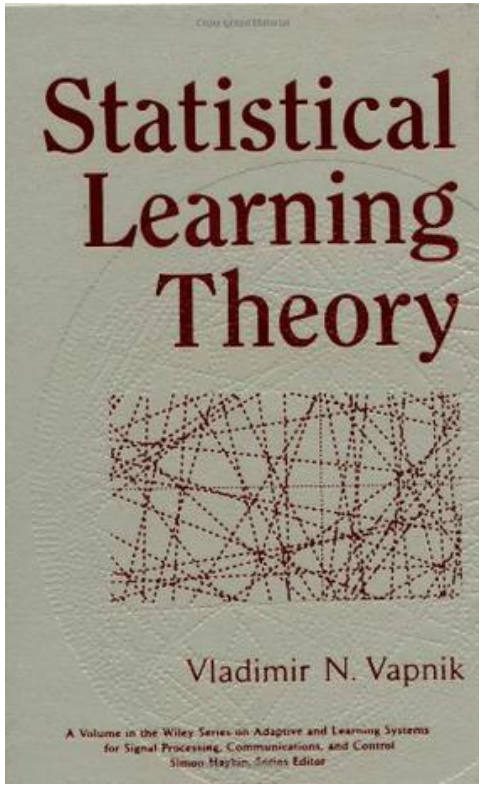

支持向量机

- **SVM从线性可分情况下的最优分类面发展而来。**

最优分类面就是要求分类线不但能将两类正确分开(训练错误率为0)，且使分类间隔最大。SVM考虑寻找一个满足分类要求的超平面，并且使训练集里的点距离分类面尽可能的远，也就是寻找一个分类面使它两侧的空白区域(Margin)最大。

要点：①定义一种距离，每个分类面都能够衡量出该性能指标；②最优分类面在该性能指标上最优。

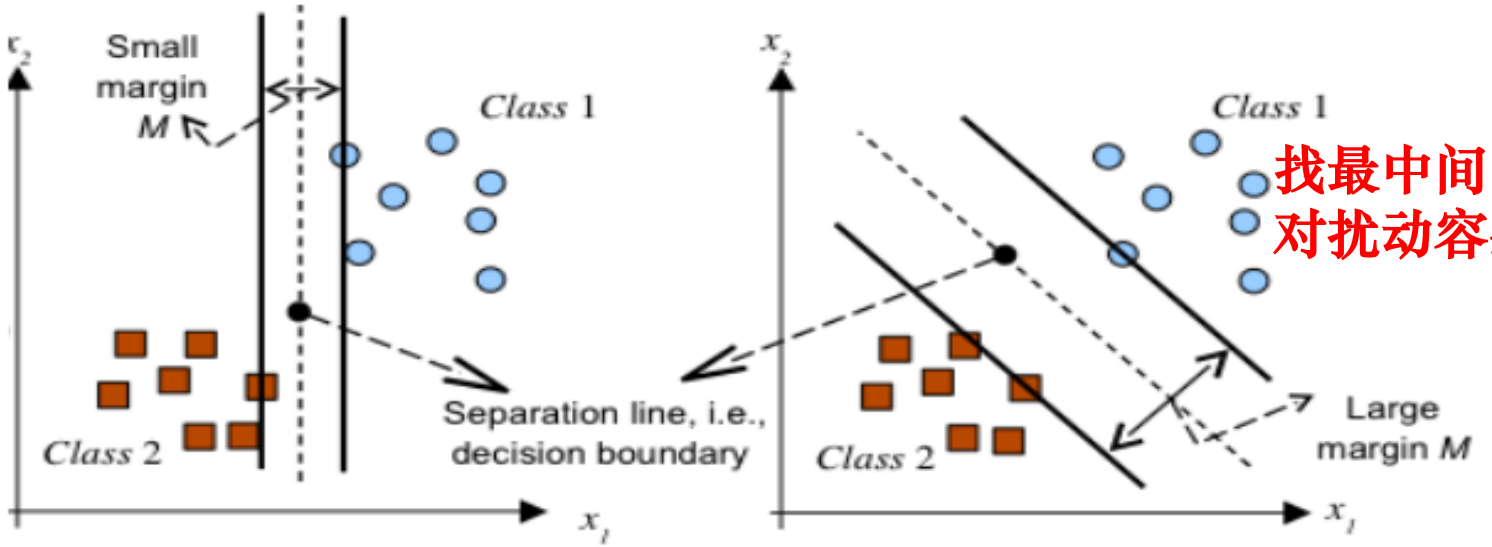

找最中间的位置：对扰动容忍性最好

线性支持向量机

- ①样本集$\{x_n, t_n\}, n = 1, 2, \ldots, N,\ x_n \in \mathcal{R}^d; t_n \in \{-1, 1\}$
- ②线性模型：分类器定义为 $y(x) = w^T x + b$，可学习。
- ③线性可分的定义：

$$t_n = \begin{cases} 1, & y(x_n) > 0 \ \ if\ x_n \in w_1 \\ -1, & y(x_n) < 0 \ \ if\ x_n \in w_2 \end{cases} \Rightarrow \quad t_n y(x_n) > 0$$

- 最优超平面定义的分类决策函数可以表示为：

$$f(\mathbf{x}) = \mathrm{sgn}(\mathbf{w} \cdot \mathbf{x} + b)$$

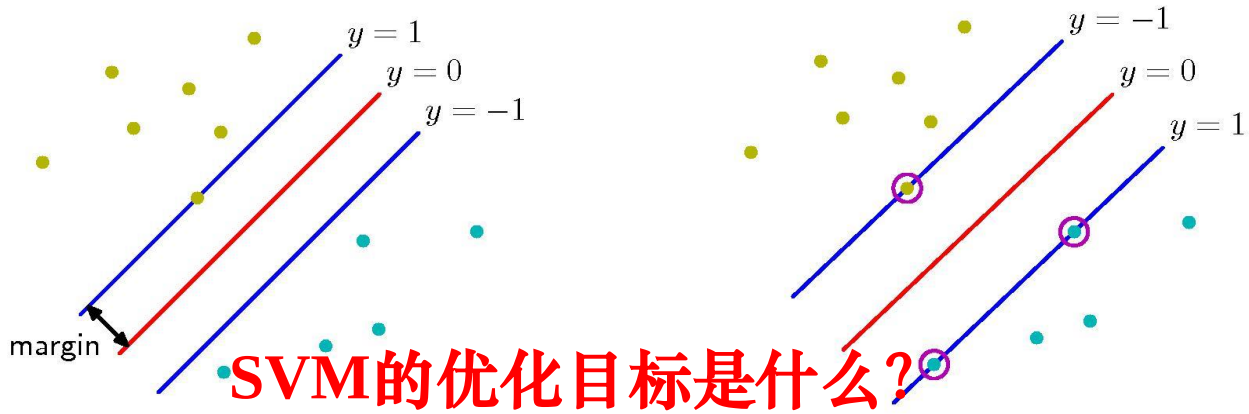

SVM的优化目标是什么？

线性支持向量机

- 事实①：样本集任意一点x_n到分类面(满足 $t_n y(x_n) > 0$)的距离为$\frac{|g(x)|}{\|w\|}$，即：

$$\frac{t_n y(x_n)}{\|w\|} = \frac{t_n(w^T x_n + b)}{\|w\|}$$

$$x = x_p + r\frac{w}{||w||}$$

$$g(x) = w^T\left(x_p + r\frac{w}{||w||}\right) + \omega_0$$

$$= w^T x_p + \omega_0 + r\frac{w^T w}{||w||} = r||w||$$

优化w和b使**Margin**最大

$$\arg\max_{w,b}\left\{\frac{1}{\|w\|}\min_n\left[t_n(w^T x_n + b)\right]\right\}$$

求解复杂

事实②：无数等价解：$w \to kw, b \to kb$

确定尺度：对于离超平面最近的点$t_n(w^T x_n + b) = 1$

那么对于所有点满足$t_n(w^T x_n + b) \geq 1$

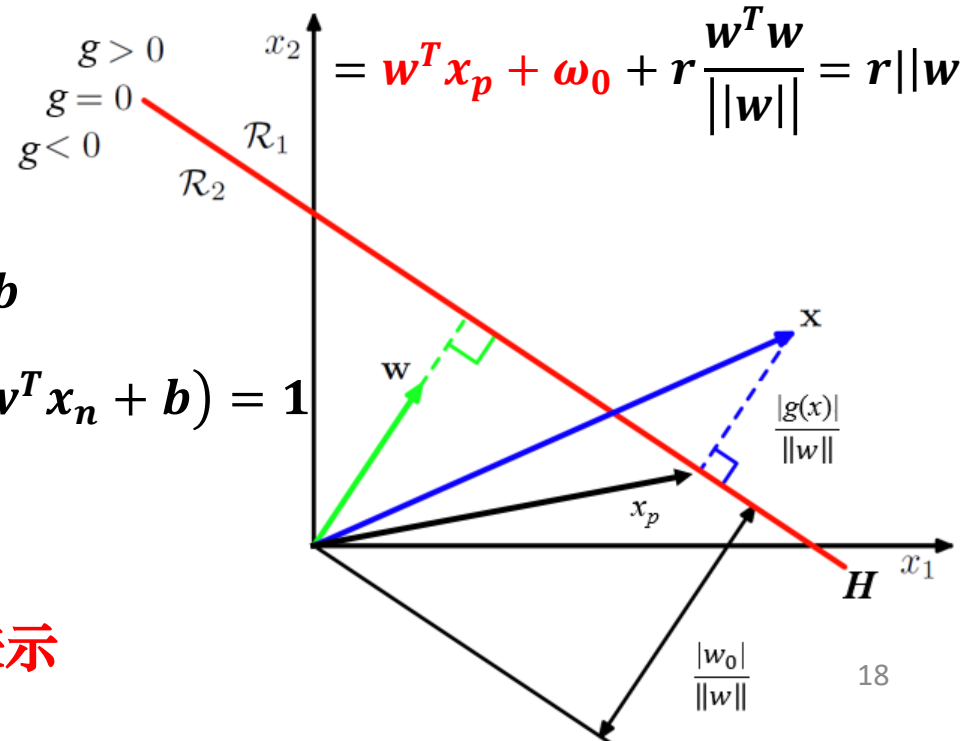

对于决策超平面的标准（规范化）表示

Canonical Representation

线性支持向量机

- 问题转化为最大化$\|w\|^{-1}$，等价于 **支持向量机的基本型！**

$$\arg\min_{w,b} \frac{1}{2}\|w\|^2 \quad s.t. \quad t_n\left(w^T x_n + b\right) \geq 1$$ 凸二次规划问题

- **凸函数**：极小值也是最小值
- **凸二次规划**：要么无解，要么唯一解。
- 可以直接用优化计算包求解，也可以有更加高效的方法。
- 不等式约束下的优化问题，可以用拉格朗日乘子法求解极值：

$$\min_{w,b} \max_{a} L(w,b,a)$$

$$L(w,b,a) = \frac{1}{2}\|w\|^2 - \sum_{n=1}^{N} a_n\left\{t_n\left(w^T x_n + b\right) - 1\right\}, a_n \geq 0$$

- 其中，$L(w,b,a)$为拉格朗日泛函，a_n为**对每一个样本**引入的拉格朗日系数。

线性支持向量机

- 上述最小、最大问题，最优解在鞍点处求得。
- 最优解处偏导数为零：

$$\frac{\partial L(w,b,a)}{\partial w} = w - \sum_{n=1}^{N} a_n t_n x_n = 0$$

$$\frac{\partial L(w,b,a)}{\partial b} = \sum_{n=1}^{N} a_n t_n = 0$$

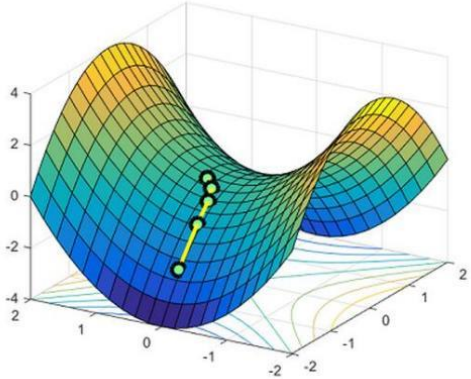

- 代入L拉格朗日泛函，消去w和b，得到对偶形式（max）：

$$\tilde{L}(a) = \sum_{n=1}^{N} a_n - \frac{1}{2}\sum_{n=1}^{N}\sum_{m=1}^{N} a_n a_m t_n t_m {x_n}^T x_m$$

$$s.t.\ a_n \geq 0, n = 1, \dots, N, \sum_{n=1}^{N} a_n t_n = 0$$

对a_n的二次规划问题，称作最优超平面的对偶问题

线性支持向量机

- 通过对偶问题的解 a_n^* ，$n = 1,2,\ldots, N$，可以求解出原问题的解：

$$\boldsymbol{w}^* = \sum_{n=1}^{N} a_n^* t_n x_n$$

即：最优平面的权值向量等于训练样本以一定的系数加权后进行线性组合。

- 测试时：$f(\mathbf{x}) = \mathrm{sgn}(\boldsymbol{w}^* \boldsymbol{x} + \boldsymbol{b}^*)$

线性支持向量机－拉格朗日对偶

拉格朗日对偶性：

- 存在**等式约束**的函数极值问题，可用拉格朗日乘子法求解：

$$\min_w \ f(w)$$
$$s.t.\ h_i(w) = 0, i = 1, \dots, l.$$

$$\Rightarrow \quad L(w, \beta) = f(w) + \sum_{i=1}^{l} \beta_i h_i(w)$$

- 存在**不等式约束**的函数极值问题（**原问题**）

$$\min_w \ f(w)$$
$$s.t.\ g_i(w) \le 0, i = 1, \dots, k.$$
$$h_i(w) = 0, i = 1, \dots, l.$$

这里的$f(w)$、$g_i(w)$都是通用的表示方式

$$\Rightarrow \quad \boxed{L(w, \alpha, \beta)} = f(w) + \sum_{i=1}^{k} \alpha_i g_i(w) + \sum_{i=1}^{l} \beta_i h_i(w)$$

在满足约束的条件下，可以对$L(w,\alpha,\beta)$求最大

线性支持向量机－拉格朗日对偶

- 求L极小值，但如果 $g_i(w) \neq 0$ ，当 $\alpha_i \to +\infty$ ， $L \to -\infty$，无意义

- 定义$\theta_P(w) = \max_{\alpha,\beta;\alpha_i \geq 0} L(w,\alpha,\beta)$ ，只有当满足约束条件，才有最大值。

$$\Rightarrow \quad \theta_P(w) = \begin{cases} f(w), & \text{if } w \text{ satisfies primal constraints} \\ +\infty, & \text{otherwise} \end{cases}$$

线性支持向量机 – 拉格朗日对偶

拉格朗日对偶性：

把所有的约束都融合在一起，
即转化为求无不等式约束的
min max问题

- 原问题$\min_w f(w)$转化为：

$$\min_w \theta_P(w) = \boxed{\min_w \max_{\alpha,\beta;\alpha_i \geq 0} L(w,\alpha,\beta)},$$

记为p^*（等价，原始问题）

- 直接求解不容易，进而转向另一个问题 $\theta_D(\alpha,\beta) = \min_w L(w,\alpha,\beta)$。

- 先固定α,β，求拉格朗日函数关于w的最小值，之后再求$\theta_D(\alpha,\beta)$的最大值，即：

$$\max_{\alpha,\beta;\alpha_i \geq 0} \theta_D(\alpha,\beta) = \max_{\alpha,\beta;\alpha_i \geq 0} \min_w L(w,\alpha,\beta)$$

为原问题的对偶问题，记为d^*。和原问题的关系：

$$\boxed{d^* = \max_{\alpha,\beta;\alpha_i \geq 0} \min_w L(w,\alpha,\beta) \leq \min_w \max_{\alpha,\beta;\alpha_i \geq 0} L(w,\alpha,\beta) = p^*}$$

弱对偶性

线性支持向量机 – 拉格朗日对偶

拉格朗日对偶性：

$$\boldsymbol{d}^* = \max_{\boldsymbol{\alpha},\boldsymbol{\beta};\boldsymbol{\alpha}_i \geq 0} \min_{\boldsymbol{w}} \boldsymbol{L}(\boldsymbol{w},\boldsymbol{\alpha},\boldsymbol{\beta}) \leq \min_{\boldsymbol{w}} \max_{\boldsymbol{\alpha},\boldsymbol{\beta};\boldsymbol{\alpha}_i \geq 0} \boldsymbol{L}(\boldsymbol{w},\boldsymbol{\alpha},\boldsymbol{\beta}) = \boldsymbol{p}^*$$

弱对偶性

证明：

$$D(\alpha,\beta) = \min_{x} L(x,\alpha,\beta) \leq L(x,\alpha,\beta) \leq \max_{\alpha,\beta,\beta_i \geq 0} L(x,\alpha,\beta) = f(x)$$

$$d^* = \max_{\alpha,\beta;\beta_i \geq 0} D(\alpha,\beta) \leq \min_{x} f(x) = p^*$$

求最大、最小同时成立的时候，上式取等。

线性支持向量机 – 拉格朗日对偶

- 对偶间隔： $p^* - d^*$
- 在强对偶成立的情况下，可以通过求解对偶问题来得到原始问题的解（SVM利用强对偶求解）；
- 即：在(α^*, β^*)确定时候，w^*恰好使得$L(w, \alpha, \beta)$最小
- 根据最优化理论，假设 f 和 g 都是凸函数，h是仿射的(Affine，线性函数的一般形式)，且对于所有的i，$g_i(w) < 0$，那么一定存在w^*, α^*, β^*，使w^*是原问题的解，α^*, β^*是对偶问题的解，
- 即$d^* = p^* = L(w^*, \alpha^*, \beta^*)$，且$w^*, \alpha^*, \beta^*$满足KKT条件。

线性支持向量机 – KKT条件

- KKT(Karush-Kuhn-Tucker)条件

$$\frac{\partial}{\partial w_i} L(w^*, \alpha^*, \beta^*) = 0, i = 1, \dots, n$$

$$\frac{\partial}{\partial \beta_i} L(w^*, \alpha^*, \beta^*) = 0, i = 1, \dots, l$$

$$\boxed{\alpha_i^* g_i(w^*) = 0, i = 1, \dots, k}$$ KKT对偶互补条件

$$g_i(w^*) \leq 0, i = 1, \dots, k$$

$$\alpha_i^* \geq 0, i = 1, \dots, k$$

- 如果w^*, α^*, β^*满足KKT条件，那么它们就是原问题和对偶问题的解。

- 补充条件隐含如果 $\alpha^* > 0$，那么$g_i(w^*) = 0$，即w处于可行域的边界上，是起作用的(Active)约束。

线性支持向量机 – KKT条件

- 根据最优化理论中的KKT(Karush-Kuhn-Tucker)条件，式

$$L(w,b,a)=\frac{1}{2}\|w\|^2-\sum_{n=1}^{N}a_n\{t_n(w^Tx_n+b)-1\},a_n\geq 0$$

在拉格朗日泛函的鞍点处满足：

KKT对偶互补条件

$$\boxed{\alpha_i\{t_i[(w\cdot x_n)+b]-1\}=0,i=1,\dots,n}$$

- 对于满足目标函数$t_n(w^Tx_n+b)\geq 1$中大于号的样本，必定有$\alpha_i=0$。
- 只有使$t_n(w^Tx_n+b)\geq 1$中等号成立的样本对应的$\alpha_i>0$。这些样本就是离分类面最近的样本，决定了最终的最优超平面的位置。
- 上述条件隐含着，如果$\alpha_i^*>0$，那么$g_i(w^*)=0$，即w处于可行域的边界上，是起作用的约束（往往只是训练样本中的一小部分，决定超平面位置）；而位于可行域内部的点都是不起作用的约束，其$\alpha^*=0$。

线性支持向量机

- **KKT条件：**

$$a_n \geq 0$$
$$t_n y(x_n) - 1 \geq 0$$
$$a_n\{t_n y(x_n) - 1\} = 0$$

- **支持向量：**

$$t_n(w^T x + b) = 1, a_n > 0$$

可以根据已经求得的w^*，用支持向量求解b^*

- **非支持向量：**

$$t_n(w^T x + b) > 1, a_n = 0$$

$$y(x) = \sum_{n=1}^{N} a_n t_n x^T x_n + b$$

$$b = \frac{1}{N_s}\sum_{n\in S}(t_n - \sum_{m\in S} a_m t_m x_n^T x_m)$$

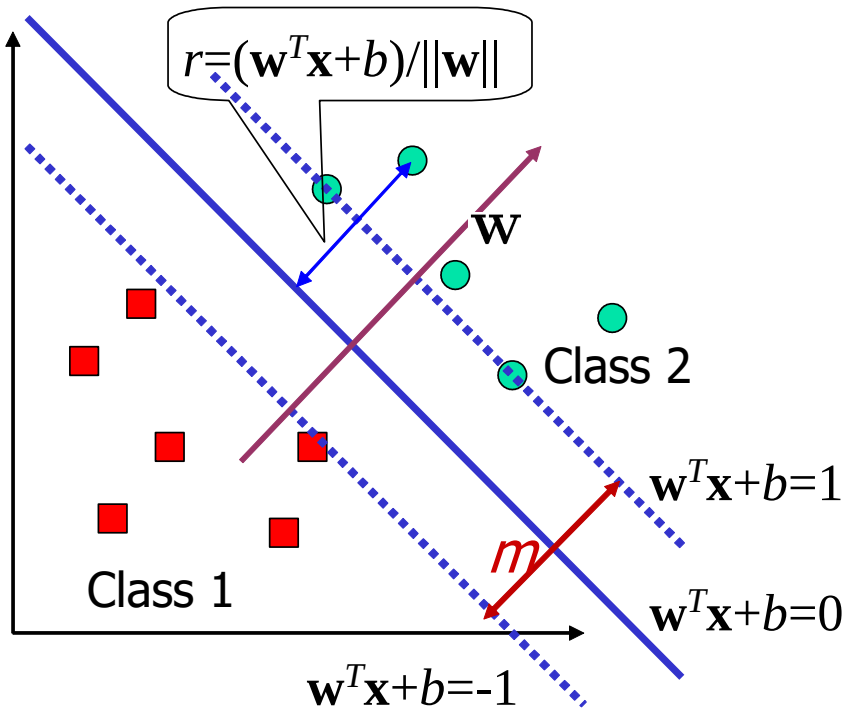

超平面法向量是支持向量的线性组合

由于最优超平面的解完全由支持向量决定，这种方法被称为支持向量机。

线性支持向量机

●处理噪声和离群点

① 如何处理线性不可分?
② 求解最优分类面的时间代价大，还可能导致受噪声影响泛化性能差。因此，对于分布有交集的数据需要有一定范围内的“错分”，又有较大分界区域的广义最优分类面。

准确性

泛化性

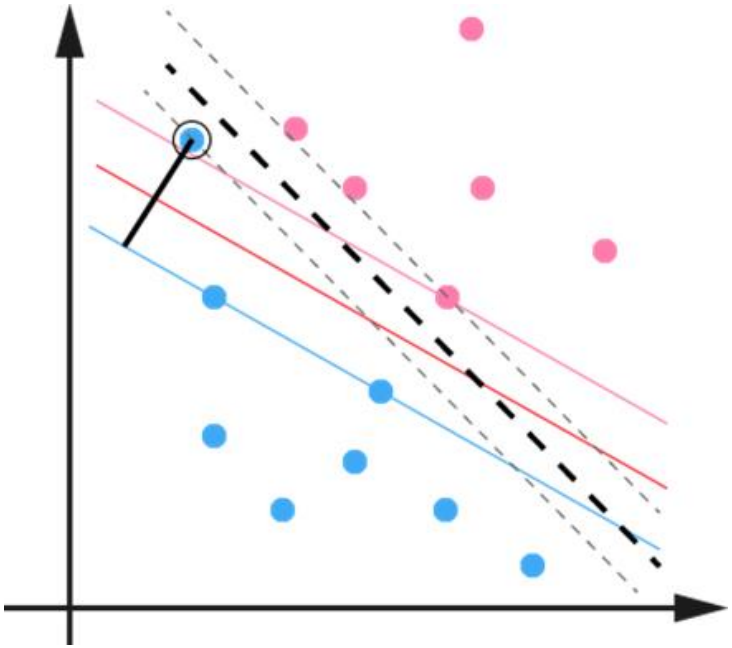

线性支持向量机

- 处理噪声和离群点

引入松弛变量$\xi_n \geq 0$

$\xi_n = 0$

$\boxed{\xi_n = |t_n - y(x_n)|}$

$\xi_n = 1$

$0 < \xi_n \leq 1$

$\xi_n > 1$

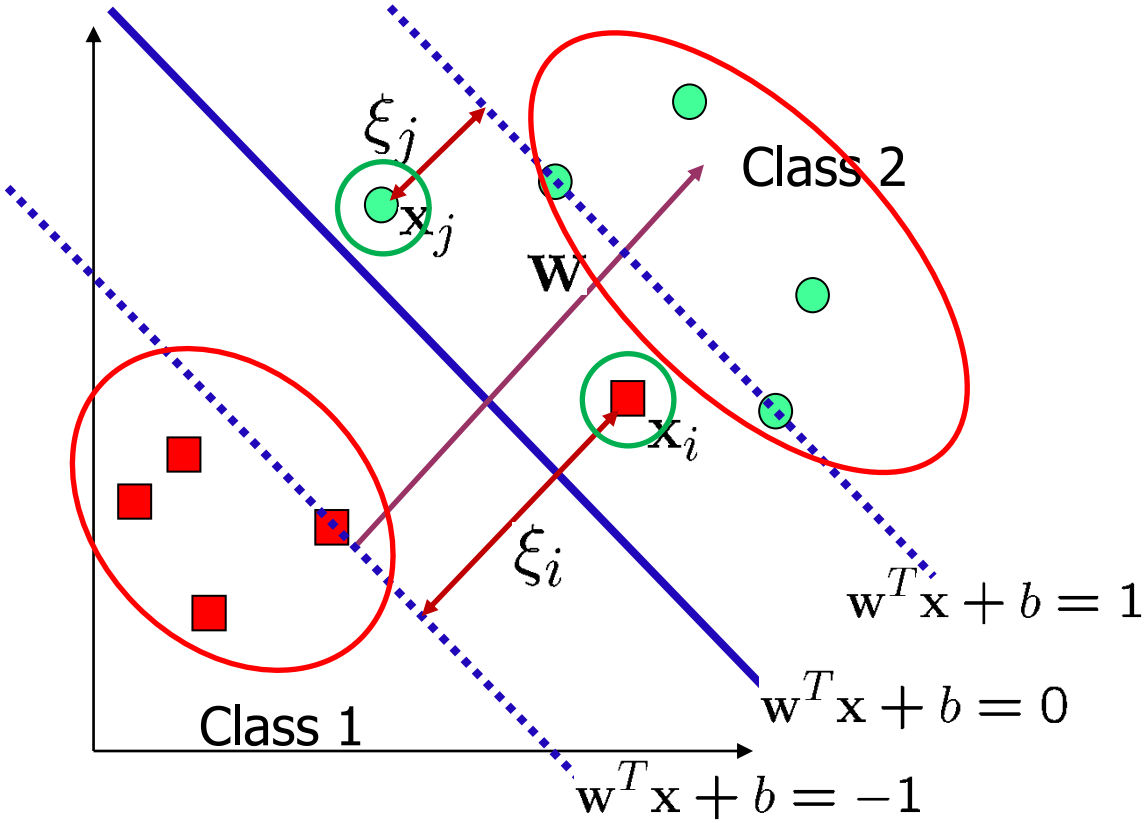

原有约束$t_n y(x_n) \geq 1$ ➡ $t_n y(x_n) \geq 1 - \xi_n$

线性支持向量机

●处理噪声和离群点

这种处理方式也被视为是从硬间隔(Hard Margin)向软间隔(Soft Margin)的转变。

硬间隔

$$\min_{w,b} \frac{1}{\|w\|^2}$$

$$s.t.\ t_n\left(w^T x_n + b\right) \geq 1, n = 1, \dots, N$$

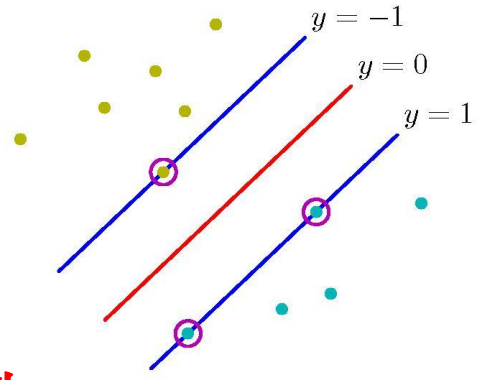

分类间隔

软间隔

$$\boxed{\min_{w,b,\xi} \frac{1}{\|w\|^2}} + \boxed{C \sum_{n=1}^{N} \xi_n}$$

正则项，反应在整个训练样本集上的错分程度；希望尽可能小

$$s.t.\ t_n\left(w^T x_n + b\right) \geq 1 - \xi_n, n = 1, \dots, N$$

$$\xi_n \geq 0$$

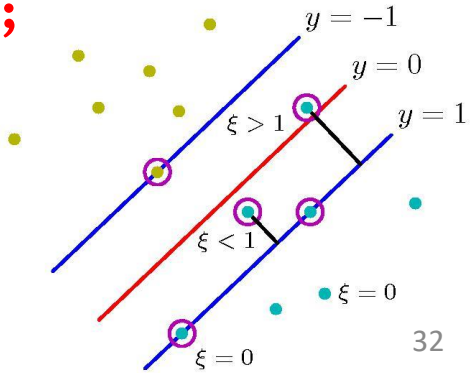

线性支持向量机

处理噪声和离群点

- 利用拉格朗日乘子法求解：

$$\min_{\boldsymbol{w},\boldsymbol{b},\xi}\max_{a} L(w,b,\xi,a,\gamma)=\frac{1}{2}\|w\|^2+C\sum_{n=1}^{N}\xi_n-\sum_{n=1}^{N}a_n\{t_n y(x_n)-1+\xi_n\}-\sum_{n=1}^{N}\gamma_n\xi_n$$

$a_n \geq 0; \gamma_n \geq 0$

- KKT条件：

$a_n \geq 0$

$t_n y(x_n)-1+\xi_n \geq 0$

$a_n(t_n y(x_n)-1+\xi_n)=0$

$\gamma_n \geq 0$

$\xi_n \geq 0$

$\boldsymbol{\gamma_n \xi_n = 0}$

- 同样地，对L求导优化$w, b, \{\xi_n\}$

$$\frac{\partial L}{\partial w}=0 \Rightarrow w=\sum_{n=1}^{N}a_n t_n x_n$$

$$\frac{\partial L}{\partial b}=0 \Rightarrow \sum_{n=1}^{N}a_n t_n=0$$

$$\frac{\partial L}{\partial \xi_n}=0 \Rightarrow \boldsymbol{a_n = C-\gamma_n}$$

- 代入L化简得到对偶优化问题（max）：

$$\tilde{L}(a)=\sum_{n=1}^{N}a_n-\frac{1}{2}\sum_{n=1}^{N}\sum_{m=1}^{N}a_n a_m t_n t_m x_n^T x_m$$

线性支持向量机

- **处理噪声和离群点**

得到广义最优分类面的对偶形式： 二次规划问题

$$\max_{a} \sum_{n=1}^{N} a_n - \frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{N} a_n a_m t_n t_m x_n{}^T x_m$$

$$s.t. \quad \sum_{n=1}^{N} a_n t_n = 0$$

并且：

$$0 \le a_n \le C, n = 1,2,\dots,N$$

原问题中的解向量满足：

$$w^* = \sum_{n=1}^{N} a_n^* t_n x_n$$

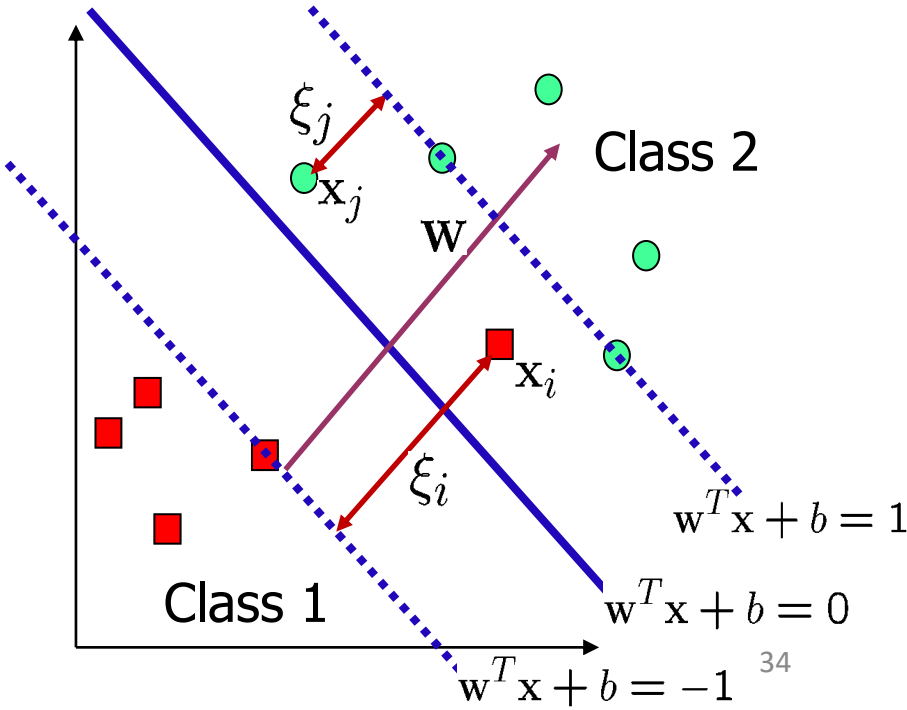

线性支持向量机

- **处理噪声和离群点**

代入$\mathrm{sgn}(\boldsymbol{w}^T\boldsymbol{x}+\boldsymbol{b})$，得到对于新样本预测的分类器：

$$y(x)=\sum_{n=1}^{N} a_n\, t_n x^T x_n + b$$

$$b=\frac{1}{N_{\mathcal{M}}}\sum_{n\in\mathcal{M}}\left(t_n-\sum_{m\in S} a_m t_m x_n{}^T x_m\right)$$

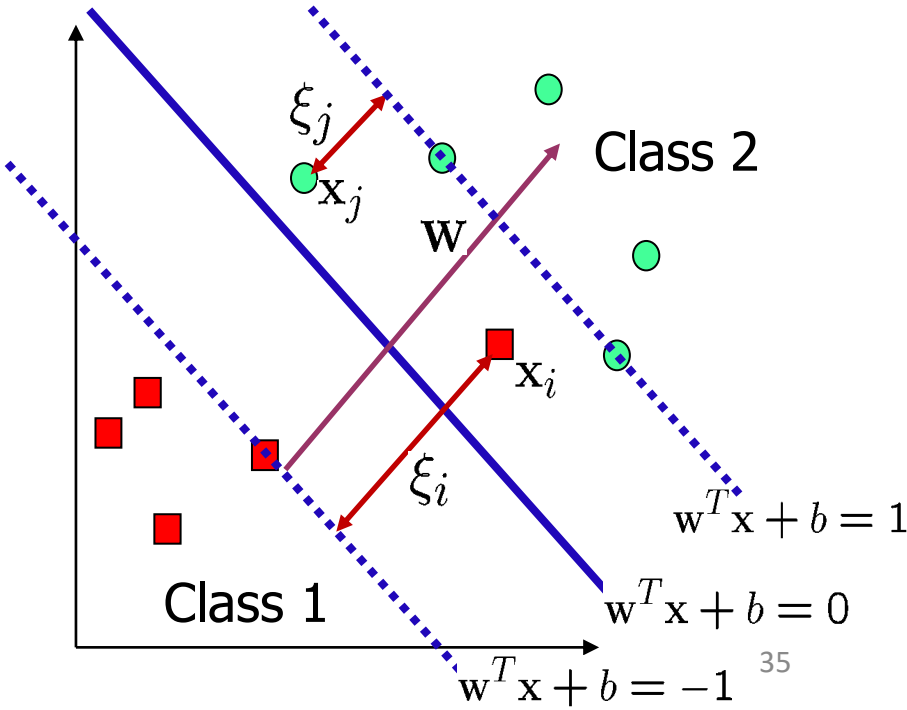

线性支持向量机

● 处理噪声和离群点

根据KTT条件，式：

$$\min_{\boldsymbol{w},\boldsymbol{b},\xi}\max_{a} L(w,b,\xi,a,\gamma)=\frac{1}{2}\|w\|^2+C\sum_{n=1}^{N}\xi_n-\sum_{n=1}^{N}a_n\{t_n y(x_n)-1+\xi_n\}-\sum_{n=1}^{N}\gamma_n\xi_n$$

在鞍点满足以下两个条件：

$$a_n\{t_n[\boldsymbol{w}^T\boldsymbol{x_n}+b]-1+\xi_n\}=0$$

且： $\gamma_n\xi_n=(C-a_n)\xi_n=0$

多数的$a_n=0$**，只有使得**$t_n[\boldsymbol{w}^T\boldsymbol{x_n}+b]-1+\xi_n$ **=0的样本，才会使得**$a_n>0$**。这些样本分为两类，决定着支持向量：**

①分类正确但处于分界面上的样本， $0<a_n<C$**，** $\xi_n=0$

②分类错误的样本$a_n=C$**，** $\xi_n>0$**。**

从上式可见，只有对拉格朗日乘子达到上界$a_n=C$**的样本才有**$\xi_n>0$**，它们是被错分的样本，其余样本对应的**$\xi_n=0$**。**

非线性支持向量机

非线性支持向量机

- 线性模型在解决复杂分类问题时适应性较差。而对于非线性可分的数据样本，可能通过适当的函数变换，将其在高维空间中转化为线性可分。

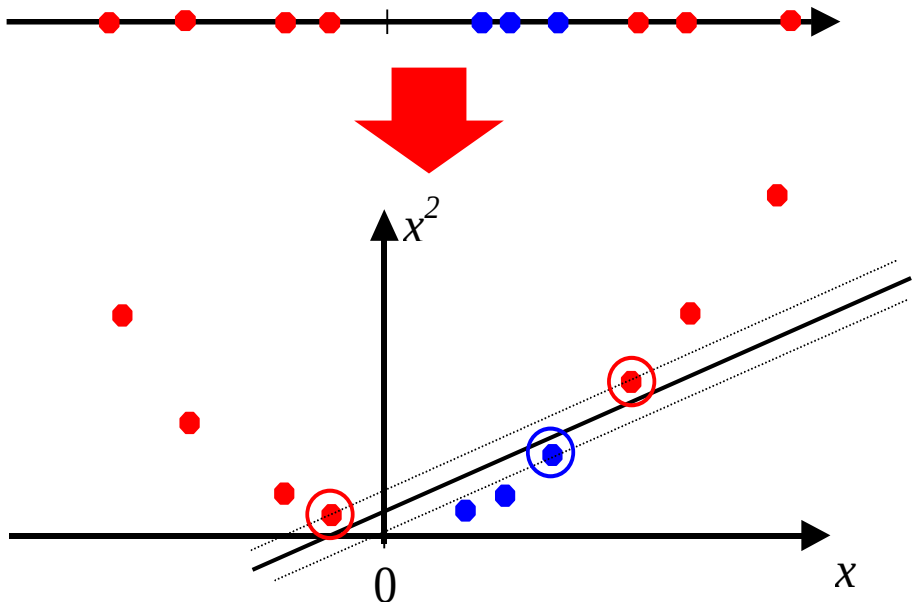

非线性支持向量机

- 如果原始空间是有限维，一定存在一个这样的高维空间使得样本可分；
- 非线性支持向量机可以把样本x映射到某个高维特征空间 $\phi(x)$ ，并在其中使用线性分类器。

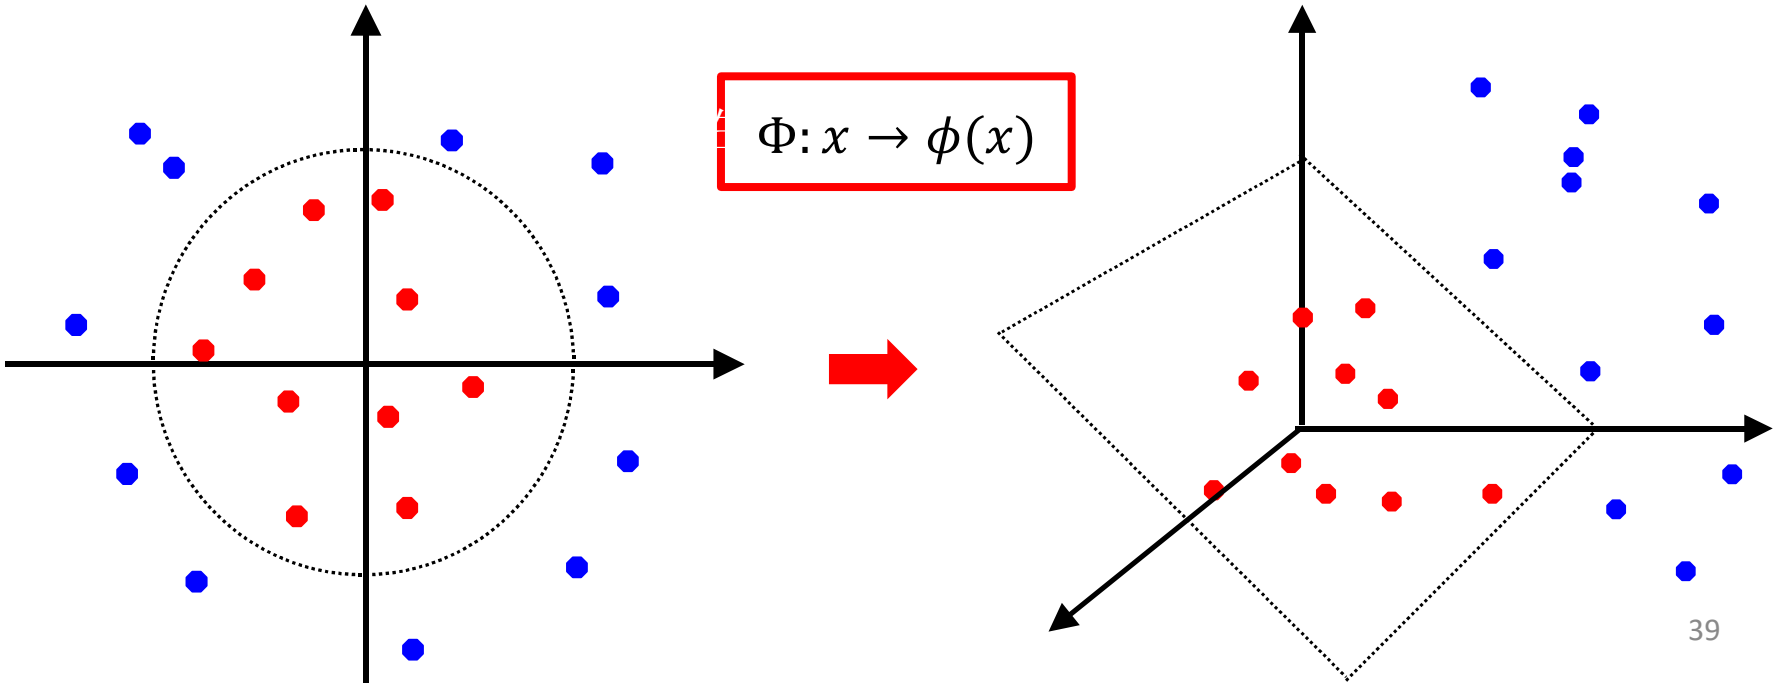

非线性支持向量机 - XOR问题

- **XOR问题（二维空间中最简单的非线性问题）**

二维样本集 $x = (x_1, x_2)$

第一类(0, 0)和 (1, 1)，第二类(1, 0)和 (0, 1)

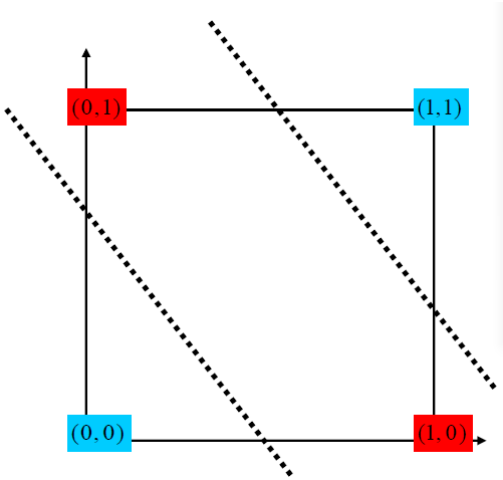

将二维数据映射到三维

映射函数$\phi(x) = (x_1, x_2, x_1 x_2)$

$$\boxed{\begin{array}{c} (0,0) \rightarrow (0,0,0) \\ (1,1) \rightarrow (1,1,1) \end{array}}$$

$$\boxed{\begin{array}{c} (0,1) \rightarrow (0,1,0) \\ (1,0) \rightarrow (1,0,0) \end{array}}$$

线性不可分 线性可分

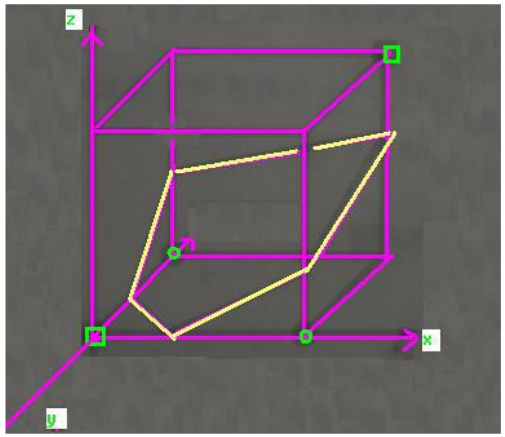

其他变换：$\phi(x) = ({x_1}^2, {x_2}^2, x_1, x_2, x_1 x_2)$

非线性支持向量机

- 利用一个固定的非线性映射$\phi(x)$将数据映射到特征空间学习的线性分类器等，价于基于原始数据学习的非线性分类器。

$$y(x) = w^T x + b \quad \Rightarrow \quad y(x) = w^T \phi(x) + b$$

如何把无限维运算准换为有限维?

- 决策时：

$$y(x) = \sum_{n=1}^{N} a_n t_n x^T x_n + b \quad \Rightarrow \quad y(x) = \sum_{n=1}^{N} a_n t_n \boxed{\phi(x)^T \phi(x_n)} + b$$

$$\boxed{k(x, x_n) = \phi(x)^T \phi(x_n)} \longrightarrow \text{核函数}$$

- 不论$\phi(x)$所生成的变换空间的维数有多高、具体形式如何，高维特征空间里的内积都可以在原空间通过函数$k(x, x_n)$计算得到。避免高维空间运算。大大简化了计算过程。

非线性支持向量机

- 利用一个固定的非线性映射将数据映射到特征空间学习的线性分类器，等价于基于原始数据学习的非线性分类器。

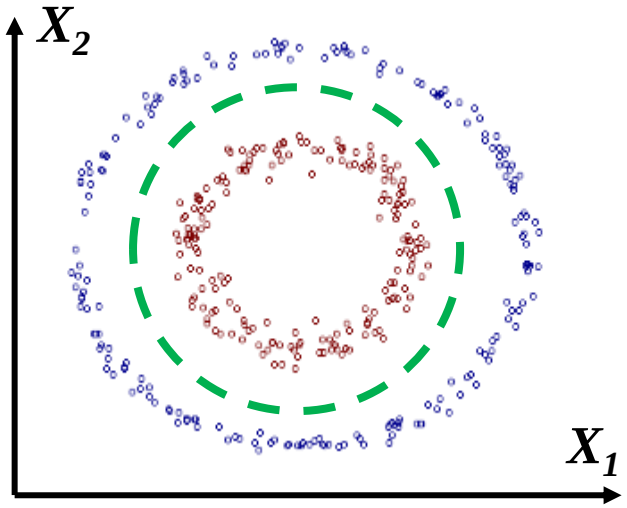

$$a_1X_1 + a_2{X_1}^2 + a_3X_2 + a_4{X_2}^2 + a_5X_1X_2 + a_6 = 0$$

$$Z_1 = X_1; Z_2 = {X_1}^2; Z_3 = X_2; Z_4 = {X_2}^2; Z_5 = X_1X_2$$

$$\sum_{i=1}^{5} a_iZ_i + a_6 = 0 \qquad \phi: \mathbb{R}^2 \to \mathbb{R}^5$$

$$a_1{X_1}^2 + a_2(X_2 - c)^2 + a_3 = 0$$

$$Z_1 = {X_1}^2; Z_2 = {X_2}^2; Z_3 = X_2$$

$$\phi: \mathbb{R}^2 \to \mathbb{R}^3$$

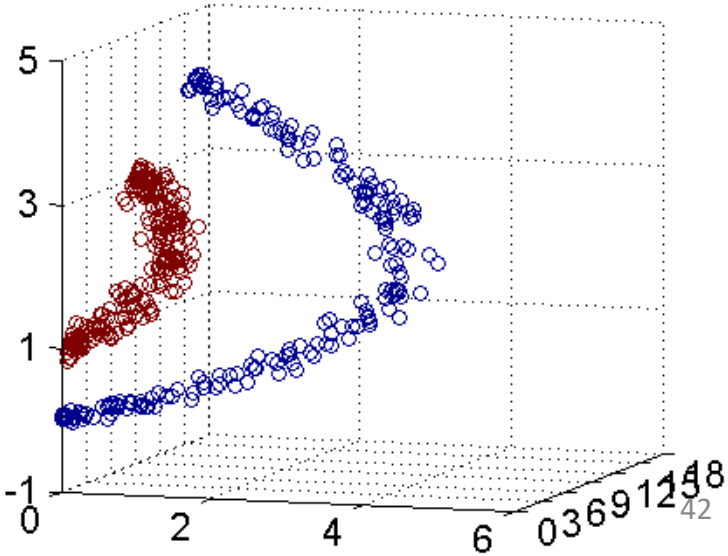

非线性支持向量机

- **非线性支持向量机**

利用一个固定的非线性映射将数据映射到特征空间学习的线性分类器等价于基于原始数据学习的非线性分类器。

$$a_1X_1 + a_2X_1^2 + a_3X_2 + a_4X_2^2 + a_5X_1X_2 + a_6 = 0 \quad \phi : \mathbb{R}^2 \to \mathbb{R}^5$$

原始样本增加到三维

$$a_1X_1^3 + a_2X_2^3 + a_3X_3^3 + a_4X_1^2X_2 + a_5X_1^2X_3 + a_6X_2^2X_1 + a_7X_2^2X_3 + a_8X_3^2X_1 + a_9X_3^2X_2 + a_{10}X_1X_2X_3 + a_{11}X_1^2 + a_{12}X_2^2 + a_{13}X_3^2 + a_{14}X_1X_2 + a_{15}X_2X_3 + a_{16}X_1X_3 + a_{17}X_1 + a_{18}X_2 + a_{19}X_3 + a_{20} = 0 \quad \phi : \mathbb{R}^3 \to \mathbb{R}^{19}$$

维数大大增加
计算变得非常困难

$$k(x_1, x_2) = (< x_1, x_2 > +1)^2$$

要找到能够构成某一变换空间里的核函数。利用核函数直接在原来的低维空间中进行计算，不需要显式地写出映射后的结果，避免了先映射到高维空间中然后再根据内积的公式进行计算

非线性支持向量机

- **非线性支持向量机**

根据问题和数据的不同，选择带有不同的核函数。

一些常用的核函数:

线性核: $k(x_1, x_2) = x_1^T x_2$

多项式核: $k(x_1, x_2) = (< x_1, x_2 > + R)^d$

高斯核: $k(x_1, x_2) = \exp\{-\frac{\|x_1 - x_2\|^2}{2\sigma^2}\}$

Sigmoid核: $k(x_1, x_2) = \tanh(\beta_0 x_1^T x_2 + \beta_1)$

如何判断一个函数是否可以作为核函数?

Mercer定理:
$\mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$**上的映射*k*是一个有效核函数(也称Mercer核函数)当且仅当对于训练样本其相应的核函数矩阵是对称 半正定的,即对于任何平方可积函数*g*(*x*)有**$\int\int k(x,y)g(x)g(y)dxdy \geq 0$ 。

支持向量机--小结

- 支持向量机的基本思想（间隔、对偶、核技巧）：
  1）通过非线性变换将输入空间变换到一个高维空间
  2）在这个新空间中求最优分类面即最大间隔分类面

- 线性支持向量机就是采用欧式空间中的内积作为相似性度量
- 非线性变换通过定义适当的内积核函数实现。
- 选择不同的核函数，可看作是选择不同的相似性度量

非线性支持向量机 - SVM工具

- LibSVM: http://www.csie.ntu.edu.tw/~cjlin/libsvm/

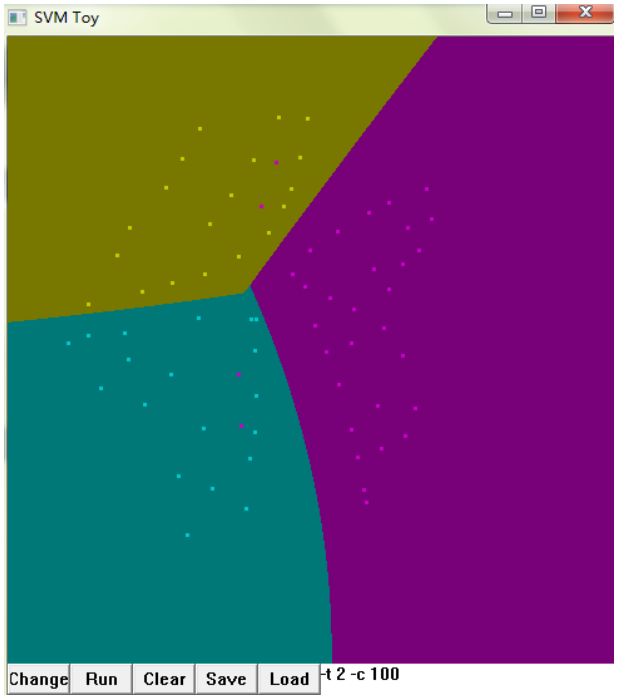

VC维
Vapnik-Chervonenkis Dimension

- 1971年，V. Vapnik 和A. Chervonenkis在论文“On the uniform convergence of relative frequencies of events to their probabilities”中提出VC维的概念。
- VC维用于衡量假设空间的复杂度，为机器学习提供了坚实的理论基础。

V. Vapnik

VC维

- **SLT中衡量函数集性能的指标**

为了研究经验风险最小化函数集的学习一致收敛速度和推广性，统计学力理论定义了一些指标来衡量函数集的性能，其中最重要的就是VC维(Vapnik-Chervonenkis Dimension)

VC维定义：

对于一个指示函数(即只有0和1两种取值的函数)集，如果存在h个样本能够被函数集里的函数按照所有可能的2^h种形式分开，则称函数集能够把h个样本打散，函数集的VC维就是能够打散的最大样本数目。

VC维

打散（shattering）

- 无论假设空间中包含多少假设，对D中示例赋予标记的可能结果数是有限的。即，对m个示例最多有2^m种可能结果。每种结果都称为D的一种“对分”。如果假设空间能实现D上所有对分，则称示例集D能被假设空间打散。

- 例如，二维平面上大小为3的示例集可以被直线打散，但大小为4的示例集不能被直线打散。因此二维平面上线性划分构成的假设空间的VC维为3。

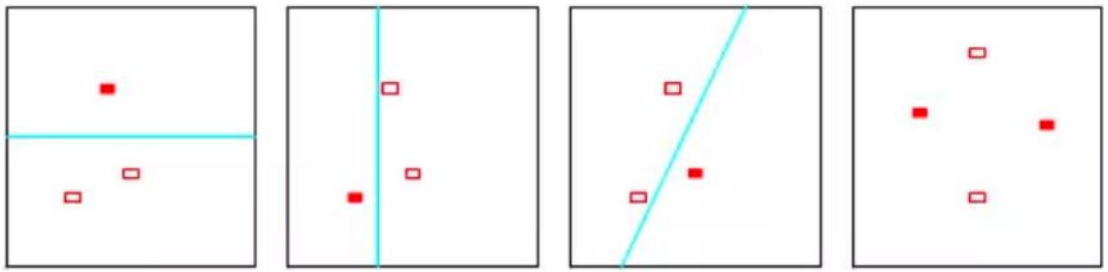

VC维

- 一般来说,对于***n*维空间的线性分类面函数**

$$y = w_0 + w_1 x_1 + \ldots + w_n x_n$$

的**VC维为*n*+1**。

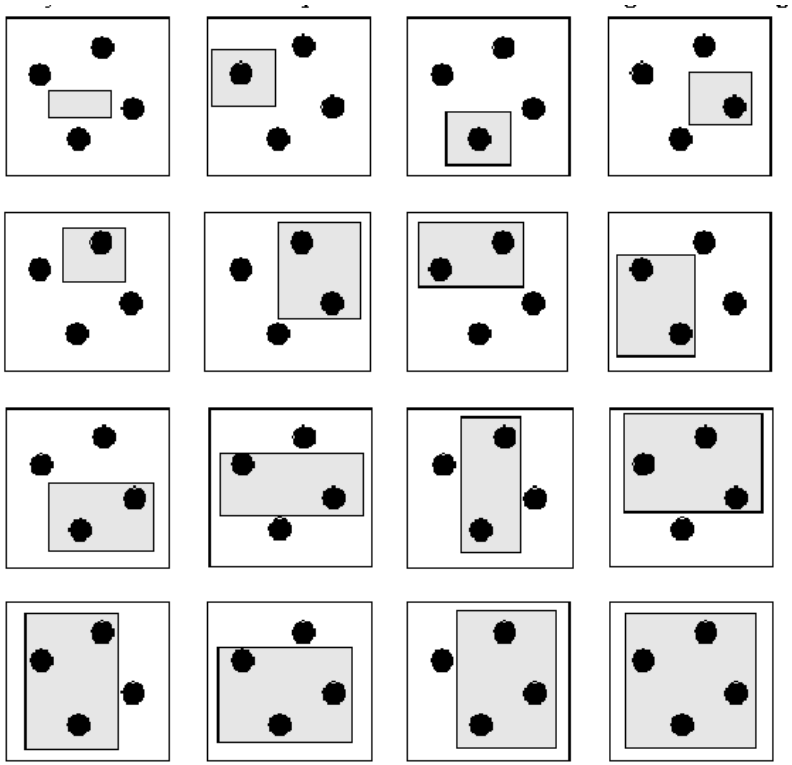

VC维

- **SLT中衡量函数集性能的指标**

一般而言，VC维反映了函数集的学习能力，VC维越大则学习机器越复杂，学习内容量就越大。

目前没有通用的关于任意函数集VC维计算的理论，只对一些特殊的函数集知道其函数维。

- **在n维实数空间中线性分类器和线性实函数的VC维是$n+1$**
- **而$f(x, a)=\sin(ax)$的VC维则为无穷大**

如何用理论和试验的方法计算其VC维是当前SLT中一个待研究的问题。

模式识别

第六章：支持向量机

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022