模式识别

第八章：图像特征提取

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022

引言

- 计算机不认识图像，只认识数字

提取有用的数据或信息，得到图像的“非图像” 的表示或描述

12	11	10	9	23	…	8	28	34	93	12
9	20	13	35	2	…	9	23	53	29	10
11	13	17	9	23	…	11	80	23	23	12
…	…	…	…	…	…	…	…	…	…	…
11	11	10	9	23	…	8	27	23	13	12
9	20	13	35	2	…	97	63	53	27	15
12	11	10	9	23	…	95	23	23	33	11

R
G
B

数值、向量和符号等

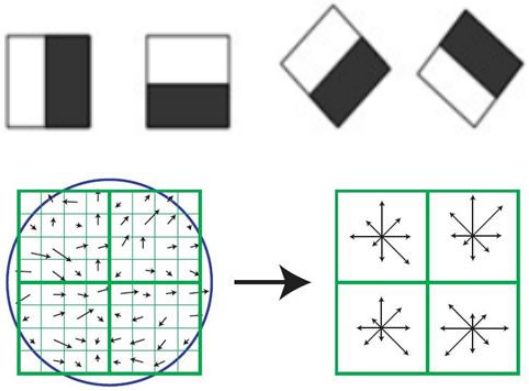

引言

- **图像特征的定义**

图像特征可以定义为某一张或一类图像区别于其他图像的相应本质特点或特性的表示及描述，以及这些描述的集合。

- **特征提取的一般原则**

为了识别出某图像所属的类别，选取的特征不仅要能够很好地描述图像， 更重要的是还能够很好地区分不同类别的图像。

我们希望选择那些在同类图像之间差异较小（较小的类内距），在不同类别的图像之间差异较大（较大的类间距）的图像特征。

引言

耳朵　胡须　爪子

（1，1，1）

耳朵　胡须　爪子

（1，1，1）

耳朵　胡须　爪子

（1，0，1）

常见的图像底层特征提取算法

- 颜色特征：如颜色直方图、颜色集、颜色矩、颜色聚合向量等；
- 纹理特征：如Tamura纹理特征、自回归纹理模型、Gabor变换、小波变换、MPEG7边缘直方图等；
- 形状特征：如傅立叶形状描述符、不变矩、小波轮廓描述符等；

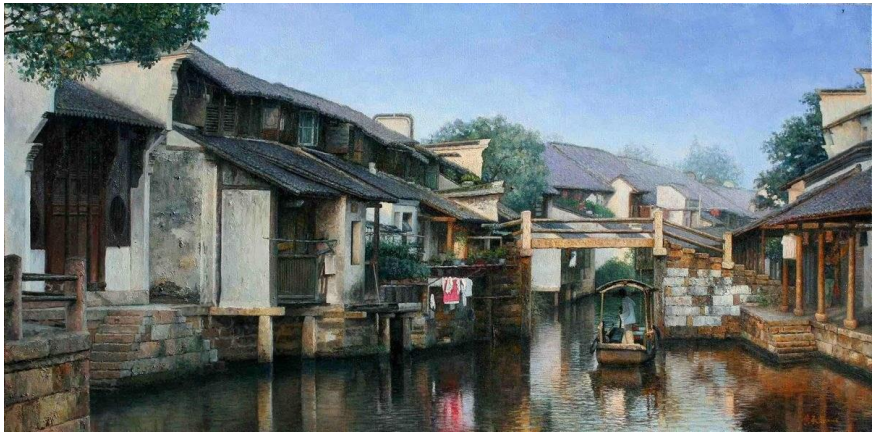

常见的图像底层特征提取算法

（a）色织物图像

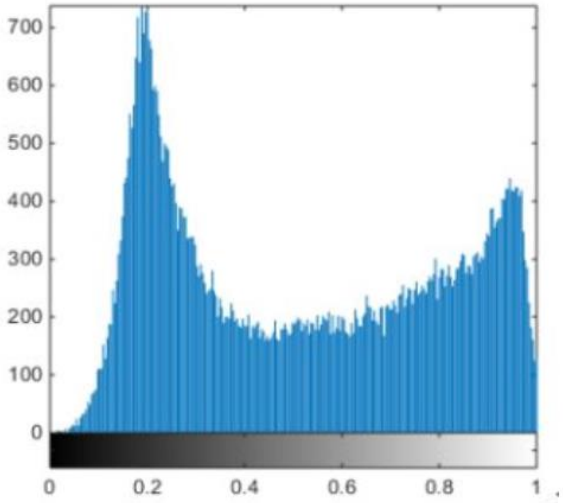

（b）对应直方图

颜色直方图（不足：维度高；量化；忽略空间分布）

- 以颜色特征为例：如颜色直方图、颜色集、颜色矩、颜色聚合向量等；
- 《数字图像处理》 拉斐尔C.冈萨雷斯，理查德 E.伍兹
- Gonzalez R C, Woods R E. Digital image processing[J]. 2012.

常见图像应用特征提取算法

- LBP（Local Binary Patterns, 局部二值模式）

  -- 纹理分类、人脸分析
- LDA （Linear Discriminant Analysis）
- HOG（Histogram of Oriented Gradient, 方向梯度直方图）

  -- 行人检测、DPM（目标检测算法）
- Haar-like 特征

  -- 人脸表示、人脸检测

局部二值模式
(Local Binary Patterns, LBP)

- 原始的LBP算子定义为在3×3的窗口内，以窗口**中心像素**为阈值，将相邻的8个像素的灰度值与其进行比较，若周围像素值大于中心像素值，则该像素点的位置被标记为1，否则为0。
- 这样，3×3邻域内的8个点经比较可产生**8位二进制数**（通常**转换为十进制数**即LBP码，共256种），即得到该窗口中心像素点的LBP值，并用这个值来反映该区域的**纹理**信息。

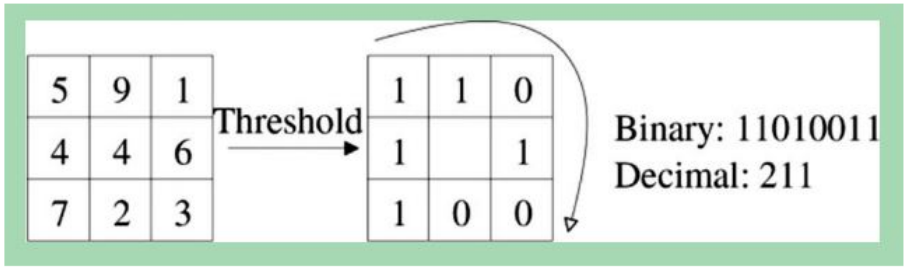

Multiresolution gray-scale and rotation invariant texture classification with local binary patterns
T Ojala, M Pietikainen… - … on pattern analysis and …, 2002 - ieeexplore.ieee.org
… range of rotated textures efficiently. Extending our earlier work [27], [28], [29], we present a gray-scale and rotation invariant texture operator based on local binary patterns. Starting from …
引用 被引用次数：17271 相关文章 所有 17 个版本

局部二值模式（LBP）

6	5	2
7	6	1
9	8	7

LBP →

1	0	0
1		0
1	1	1

Pattern=11110001

56	55	52
57	56	51
59	58	57

LBP →

1	0	0
1		0
1	1	1

Pattern=11110001

LBP码

$$LBP(x_c, y_c) = \sum_{p=0}^{P-1} 2^p s(i_p - i_c)$$

LBP的主要思想

- 以某一点与其邻域像素的相对灰度作为响应，这种**相对机制**使 LBP算子**对单调的灰度变化具有不变性**。
- 人脸图像常常会受到**光照因素**的影响而产生**灰度变化**。但在局部区域内，这种变化可以被视为是**单调的**，因此LBP对**光照不均人脸识别也取得了很好效果**。

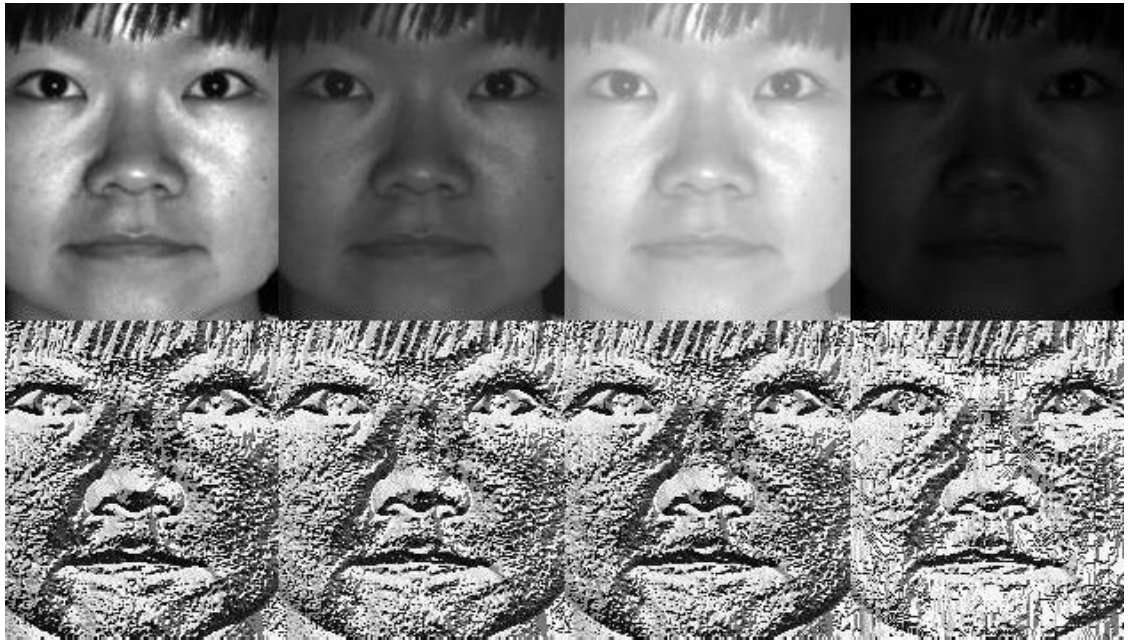

LBP的改进版本 -圆形LBP算子

- 不足：基本的 LBP算子的最大缺陷在于它只覆盖了一个固定半径范围内的小区域，这显然不能满足不同尺寸和频率纹理的需要。
- 为了适应不同尺度的纹理特征，同时达到灰度和旋转不变性的要求，研究人员用圆形邻域代替了正方形邻域，改进后的LBP算子允许在半径为R的圆形邻域内有P个采样点。
- 不在像素中心位置的点通过双线性插值确定其值。

LBP的改进版本 -圆形LBP算子

- Extended LBP，也叫Circular LBP。使用可变半径的圆对近邻像素进行编码

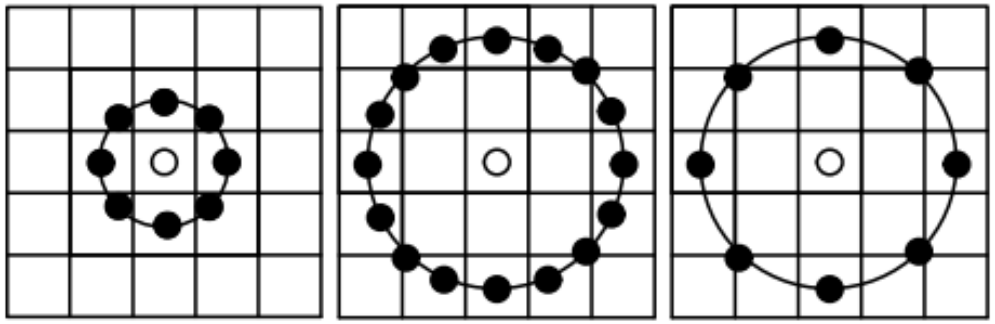

$LBP_{8,1}$ $LBP_{16,2}$ $LBP_{8,2}$

原图

初始LBP算子

圆形LBP算子

LBP的改进版本 - 旋转不变模式

- 从LBP的定义可以看出，LBP算子是灰度不变的，但却不是旋转不变的。图像的旋转就会得到不同的LBP值。
- 研究人员又将LBP算子进行了扩展，提出了具有旋转不变性的LBP算子，即不断旋转圆形邻域得到一系列初始定义的 LBP值，取其最小值作为该邻域的 LBP 值。

LBP的改进版本 - 旋转不变模式

- 图中算子下方的数字表示该算子对应的LBP值，图中所示的8种LBP模式，经过旋转不变的处理，最终得到的具有旋转不变性的LBP值为15。也就是说，图中的8种LBP模式对应的旋转不变的LBP模式都是00001111。

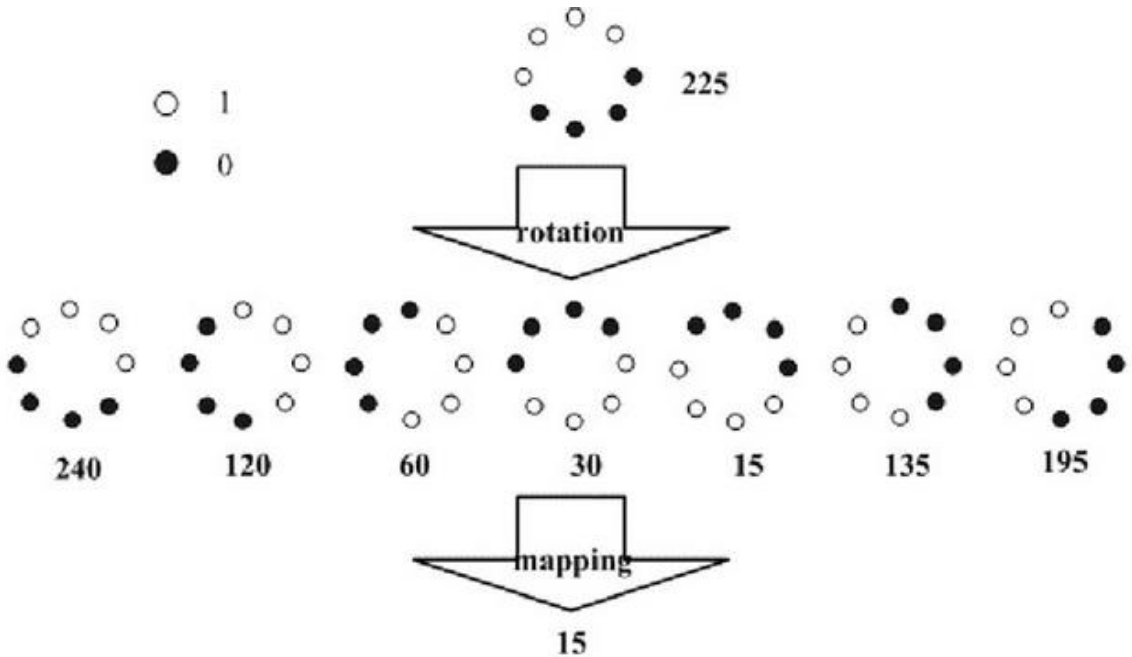

LBP统一模式/等价模式

- 目的：LBP等价模式目的即为对LBP算子进行降维。LBP算子可以产生非常多二进制模式，例如：5×5 邻域有 p=24 个采样点，则可得到2^24=16777216种二进制模式。
- 过多的二进制模式种类、直方图过于稀疏！需要对原始的LBP模式进行降维。
- 定义：某个局部二进制模式所对应的循环二进制数从0→1或从1→0，最多有两次跳变，该局部二进制模式所对应的二进制就成为一个统一模式（Uniform Pattern）。

LBP统一模式

- 做法：当小于两次跳变时，该类型保留；当超过2次时，该类型删除。
- 举例：如00000000（0次跳变），00000111（只含一次从0到1的跳变），10001111（先由1跳到0，再由0跳到1，共两次跳变）。
- 效果：**特征维数减少**，而基本上不会丢失信息，模式种类由原来的2^p减少为p×(p-1)+2种；**减少高频噪声带来的影响。**

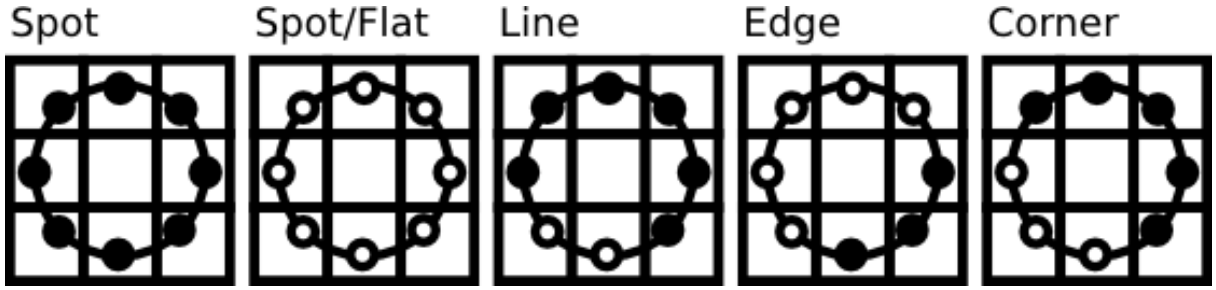

几种等价模式的示意图

LBP特征应用

- LBP的应用中，如纹理分类、人脸分析等，一般都不将LBP图谱作为特征向量用于分类识别，而是采用LBP特征谱的统计直方图（LBPH，Local Binary Patterns Histograms）作为特征向量用于分类识别。
- 进一步：LBP特征与空间信息结合，划分（有重叠的）区域进行统计。
- 采用各类相似性度量函数判断图像之间的相似性。

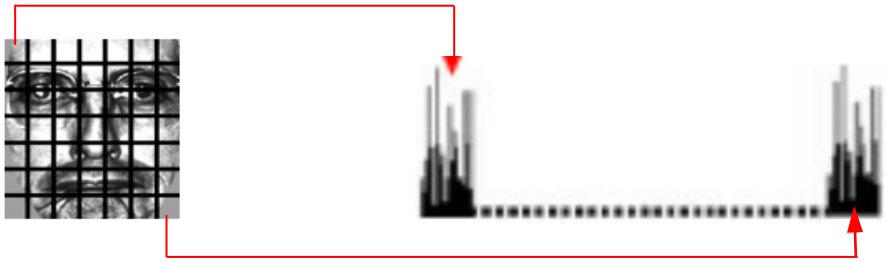

LBP特征转换直方图流程

LBP特征应用

- LBP的应用中，如纹理分类、人脸分析等，一般都不将LBP图谱作为特征向量用于分类识别，而是采用LBP特征谱的统计直方图（LBPH，Local Binary Patterns Histograms）作为特征向量用于分类识别。

基于LBP特征的图像分类流程

LBP特征向三维扩展：LBP-TOP

- **LBP-TOP：Local Binary Patterns from Three Orthogonal Planes**
- **是一种向时间维度扩展的视频描述子。**

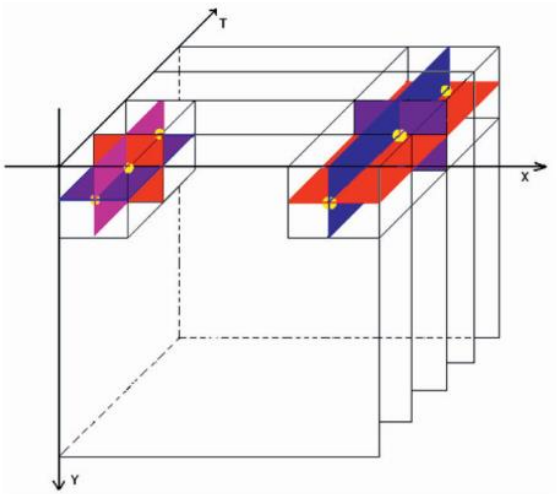

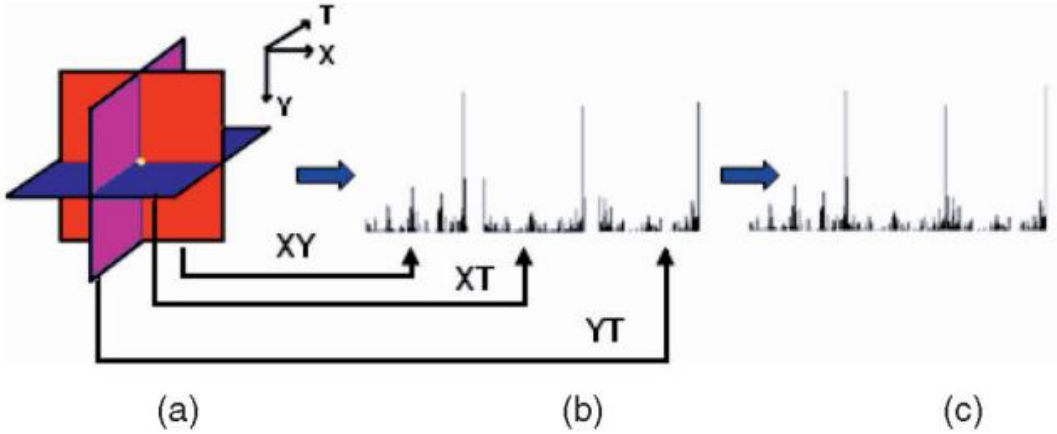

Fig. 5. (a) Three planes in DT. (b) LBP histogram from each plane. (c) Concatenated feature histogram.

方向梯度直方图
（Histogram of Oriented Gradient, HOG）

- HOG特征通过计算和统计图像局部区域的梯度方向直方图来构成特征。HOG特征结合SVM分类器已经被广泛应用于图像识别中，尤其在行人检测中获得了极大的成功。
- 主要思想：在一幅图像中，局部目标的表观和形状能够被梯度或边缘的方向密度分布很好地描述。（本质：梯度的统计信息，而梯度主要存在于边缘、拐点的地方）。
- 实现方法：首先将图像分成小的连通区域，我们把它叫细胞单元（cell）。然后采集细胞单元中各像素点的梯度或边缘的方向构建直方图。最后把这些直方图组合起来就可以构成特征描述器。

方向梯度直方图（HOG）

- **HOG示例**

Input image

Histogram of Oriented Gradients

HOG特征提取实现过程

- HOG特征提取方法就是将一个图像（你要检测的目标或者扫描窗口）：

1）剪裁、缩放、灰度化，归一化（降低光照变化的影响）；

2）计算图像每个像素的梯度（包括大小和方向）；

3）将图像划分成小Cells（例如，6×6像素/cell）；

4）统计每个Cell的梯度直方图（不同梯度的个数），即可形成每个Cell的描述特征（紧凑、更鲁棒）；

5）将每几个Cell组成一个Block（例如，3×3个cell/block），一个Block内所有Cell的特征串联起来便得到该块的HOG特征。

6）将图像内的所有块的HOG特征串联起来就可以得到该图像的HOG特征。

HOG - 计算图像梯度

- 图像中像素点(x, y)的梯度为：

$$G_x(x, y) = H(x+1, y) - H(x-1, y)$$

$$G_y(x, y) = H(x, y+1) - H(x, y-1)$$

- **注：梯度求取方式多，可使用其他求取方式**

	32	
20	A	30
	64	

- 对于像素点A:
- 水平梯度 G_x(A) = 30-20 = 10；
- 竖直梯度 G_y(A) = 64-32 = 32。

HOG - 计算图像梯度

- 其中$G_x(x,y)$和$G_y(x,y)$分别表示输入图像中像素点(x,y)的水平方向梯度和垂直方向梯度。$H(x,y)$表示像素值。再以此计算出梯度的大小和方向：

$$G(x,y)=\sqrt{G_x(x,y)^2+G_y(x,y)^2}$$

$$\alpha(x,y)=arctan\frac{G_x(x,y)}{G_y(x,y)}$$

- 梯度方向将会取绝对值，因此梯度方向的范围是0-180度，两个完全相反的方向被认为是相同的。
- x方向梯度图会强化垂直边缘特征，y方向梯度图会强化水平边缘特征。这就使得有用的特征（轮廓）得到保留，无关不重要的信息被去除。

HOG - 计算图像梯度

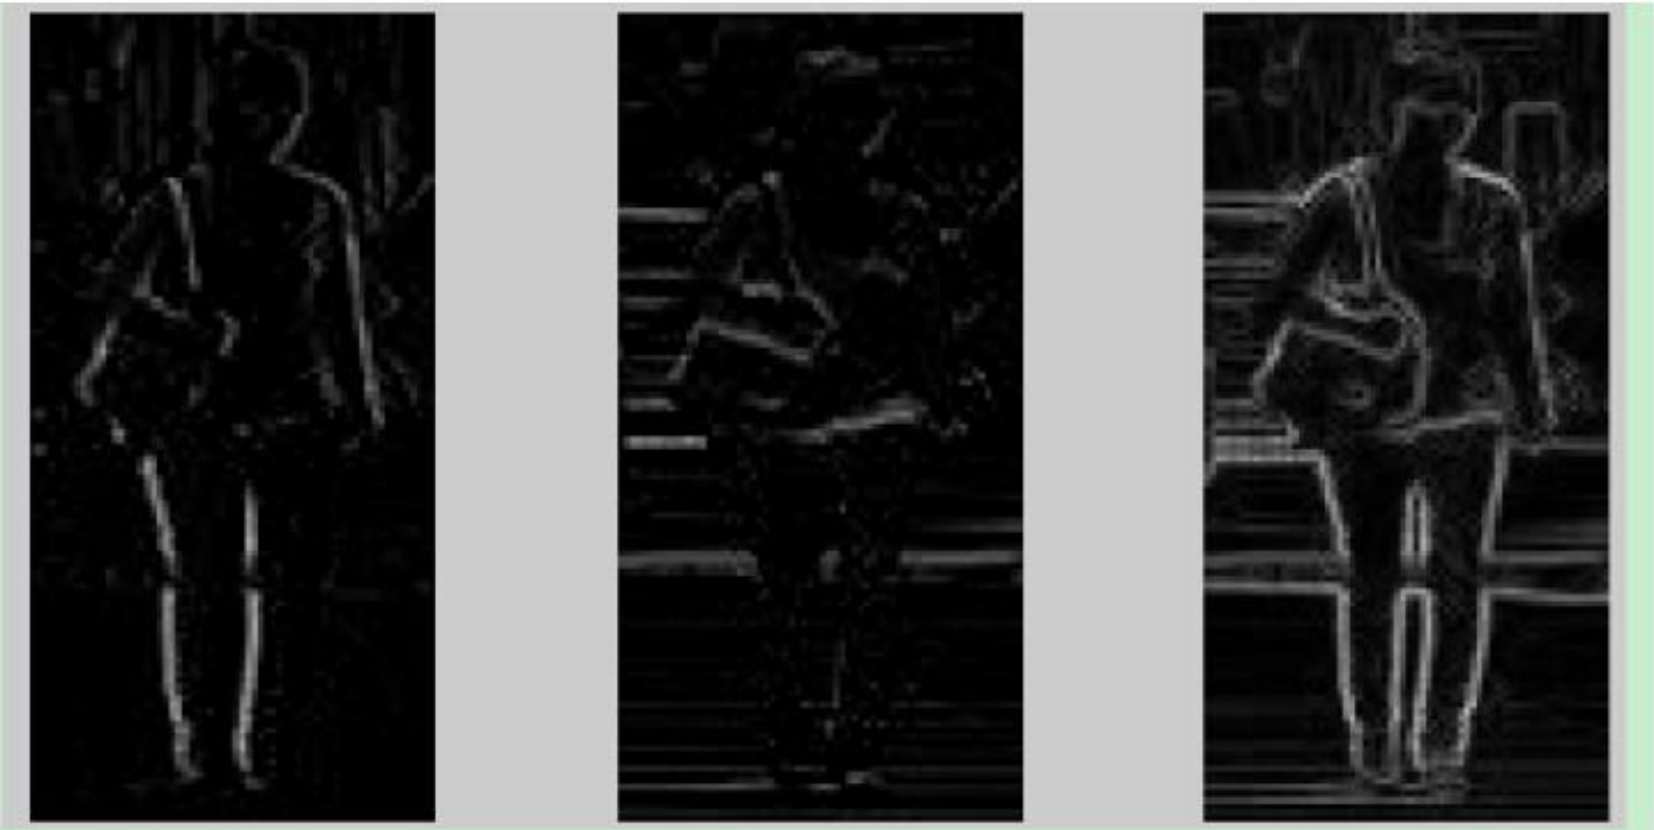

从左到右分别是水平方向梯度图，垂直方向梯度图和梯度幅值图

HOG - 构建梯度直方图

- 一整张梯度图，其中的有效特征是非常稀疏的，不但运算量大，而且效果可能还不好。
- 构建梯度直方图：假设采用9个bin的直方图来统计每个细胞单元的梯度信息。如图所示：如果这个像素的梯度方向是20-40度，直方图第2个bin的计数就加对应梯度大小的权值。对细胞单元内每个像素映射到固定的角度范围，就可以得到该细胞单元的梯度方向直方图，对应的是9维特征向量（因为有9个bin）。紧凑，抗噪！

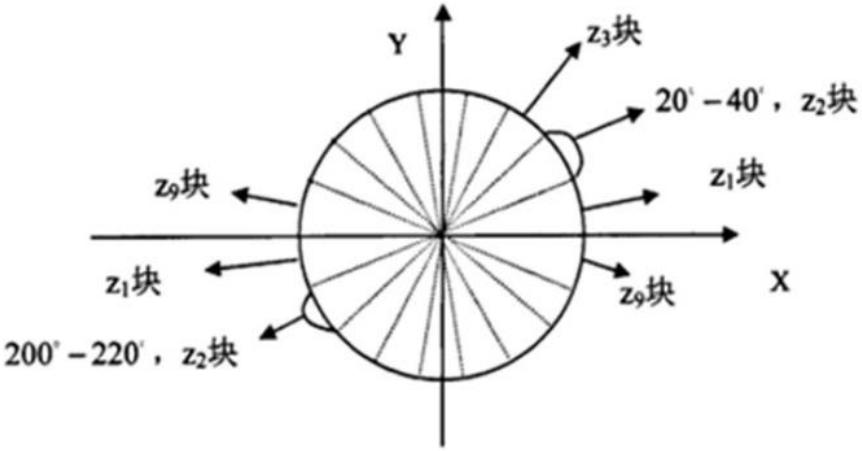

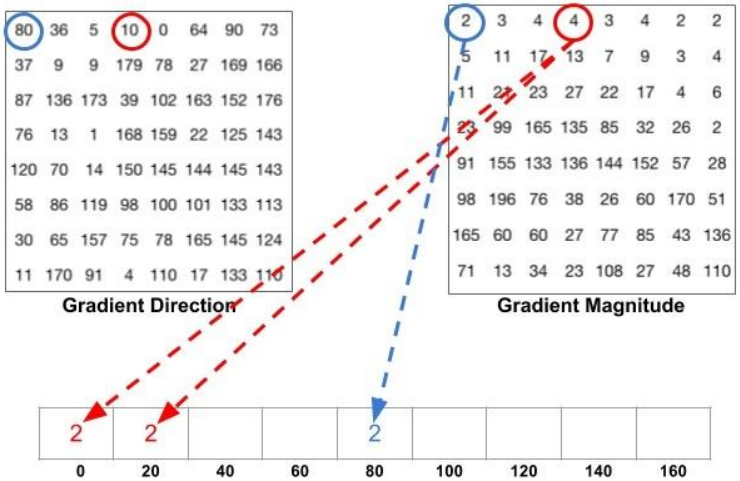

HOG - 归一化梯度直方图

- 由于**局部光照的变化**以及前景-背景**对比度的变化**，使得**梯度强度的变化范围非常大**。
- 这就需要对梯度强度做归一化。归一化能够进一步地对光照、阴影和边缘的变化进行压缩。

常用归一化函数

(a) $L2-norm, v \leftarrow \frac{v}{\sqrt{\|v\|_2{}^2+\varepsilon^2}}$ (ε是一个极小的常数，避免分母为0)

(b) $L2-Hys$ (方法同上，只是限制v的最大值到0.2)

(c) $L1-sqrt, v \leftarrow \frac{v}{\sqrt{\|v\|_1+\varepsilon}}$

HOG - 归一化梯度直方图

- 把多个细胞单元组合成较大的、空间上连通的块（Block）。
- 以Cell的尺寸为步长，以Block为大小，在图像上扫描，得到每一个Block的特征；并在Block内进行归一化。
- 把所有Block特征串联得到图像最终的HOG特征。
- 由于扫描的Block之间是互有重叠的，这意味着每一个细胞单元的特征会以不同的结果多次出现在最后的特征向量中。

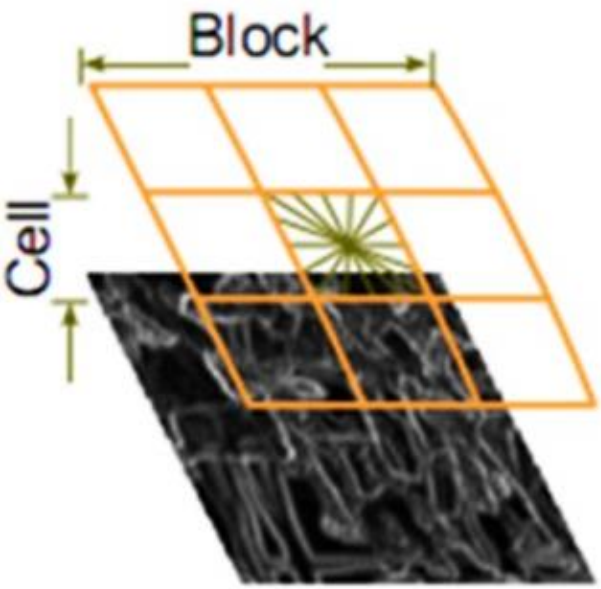

HOG的可视化

- 所检测的局部物体外形能够被HOG较好地捕捉和描述。

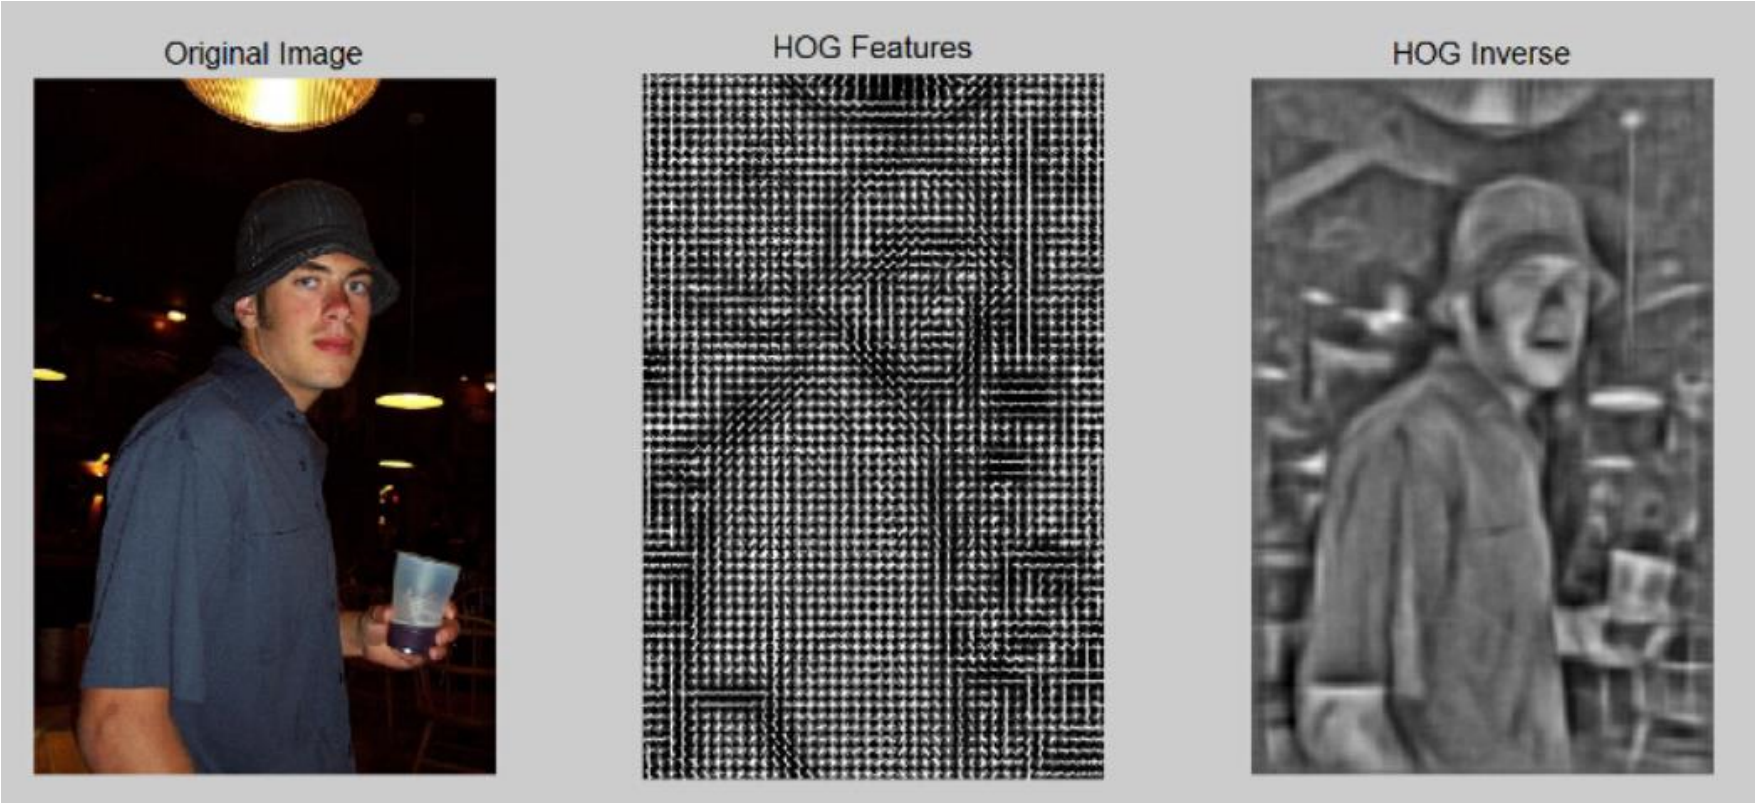

HOG的优点

- 核心思想是所检测的局部物体外形能够被梯度或边缘方向的分布所描述，HOG能较好地捕捉局部形状信息，对几何和光学变化都有很好的不变性；
- HOG是在密集采样的图像块中求取的，在计算得到的HOG特征向量中隐含了该块与检测窗口之间的空间位置关系。

HOG的缺陷

- 很难处理遮挡问题，人体姿势动作幅度过大或物体方向改变也不易检测（这个问题后来在DPM中采用可变形部件模型的方法得到了改善）；
- HOG没有选取主方向，也没有旋转梯度方向直方图，因而本身不具有旋转不变性（较大的方向变化），其旋转不变性是通过采用不同旋转方向的训练样本来实现的；
- HOG本身不具有尺度不变性，其尺度不变性是通过缩放检测窗口图像的大小来实现的；
- 此外，由于梯度的性质，HOG对噪点相当敏感，在实际应用中，在Block和Cell划分之后，对于得到各个图像区域，有时候还会做一次高斯平滑去除噪点。

Haar-like 特征

- 一个Haar特征可以定义为矩形中几个区域的像素和的差值（卷积模板），这个值反映了图像的灰度变化情况。
- 例如：脸部的一些特征能由矩形特征简单的描述，如：眼睛要比脸颊颜色要深，鼻梁两侧比鼻梁颜色要深，嘴巴比周围颜色要深等。
- 但矩形特征只对一些简单的图形结构，如边缘、线段较敏感，只能描述特定走向（水平、垂直、对角）的结构，对于人脸检测应用有很好的表现。

Haar-like 特征

- 定义了四个基本特征结构，如图所示。
- 用黑色部分的所有的像素值的和减去白色部分所有像素值的和，得到的就是一个特征值。
- 可以将它们理解成为一个窗口，这个窗口将在图像中做步长为1的滑动。最终遍历整个图像。

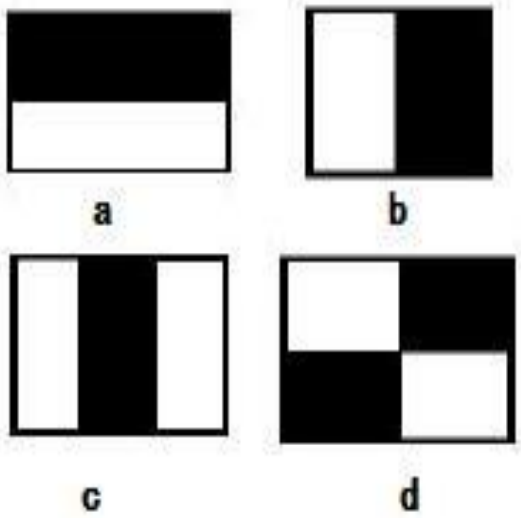

Haar-like 特征的计算-积分图

- 在工程中需要进行快速计算某个矩形内的像素值的和，这就需要引入积分图的概念。
- 积分图是一种能够描述全局信息的矩阵表示方法。积分图的构造方式是位置(x, y)处的值$ii(x, y)$是原图像(x, y)左上角方向所有像素的和：

$$ii(x, y) = \sum_{x' \le x, y' \le y} i(x', y')$$

- 当要计算某个区域的像素和时可以直接从数组中索引，不需要重新计算这个区域的像素和。空间换时间！

Haar-like 特征的计算-积分图

- 积分图构建算法：

1. 用$s(x,y)$表示行方向的累加和，初始化$s(x,-1)=0$;
2. 用$ii(x,y)$表示积分图，初始化$ii(-1,y)=0$;
3. 逐行扫描图像，递归计算每个像素的$s(x,y)$和$ii(x,y)$

$$s(x,y)=s(x,y-1)+i(x,y)$$
$$ii(x,y)=ii(x-1,y)+s(x,y)$$

4. 扫描图像一遍，当到达图像右下角像素时，积分图像就构造好了。

Haar特征构造

- 设D的四个顶点分别为1、2、3、4，则D的像素和可以表示为：

$$D_{sum} = ii(1) + ii(4) - (ii(2) + ii(3))$$

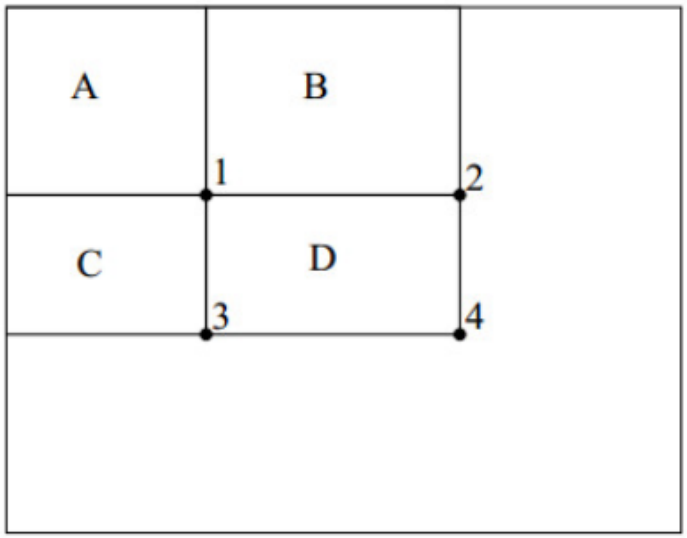

Haar特征构造

- Haar特征构造具体步骤：
- 1、对于某特定大小的特征，在图像内通过窗口滑动的方式计算。例如特征大小为2×1，对于24×24的图像，水平可滑动23步，垂直滑动24步，所以共有23×24个特征。
- 2、对于一个特征，特征本身沿水平、竖直方向分别缩放。例如，还假设特征窗口大小为2×1，则沿水平方向可放大为：4×1，6×1，8×1，…，24×1；竖直方向可放大为：2×1，2×2，2×3，…，2×24。
- 检测窗口通过平移+缩放可以产生一系列Haar特征，这些特征由于位置和大小不同，分类效果也不同。
- 高维特征需要降维！

Haar-like 矩形特征拓展

- 后续研究对Haar-like矩形特征库作了进一步扩展，加入了旋转45°角的矩形特征。扩展后的特征大致分为：边缘特征、线性特征、中心环绕特征和对角线特征等。

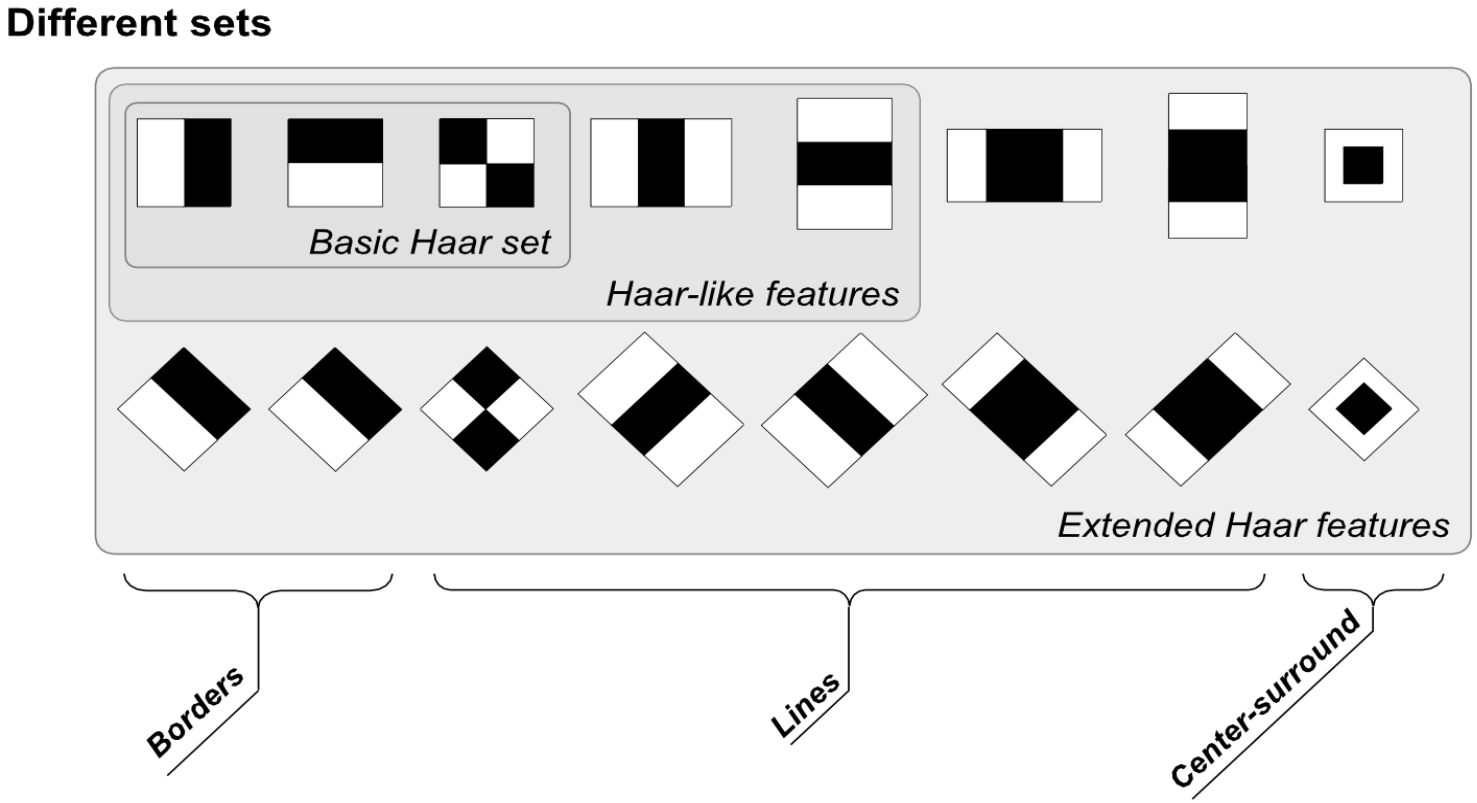

Haar-like 特征应用

- **人脸检测：**

Face detection

*The simplest detection procedure consists in scanning the input image **I** with **S** windows and using a face model **M** (e.g., **K** Haar features) to classify each window*

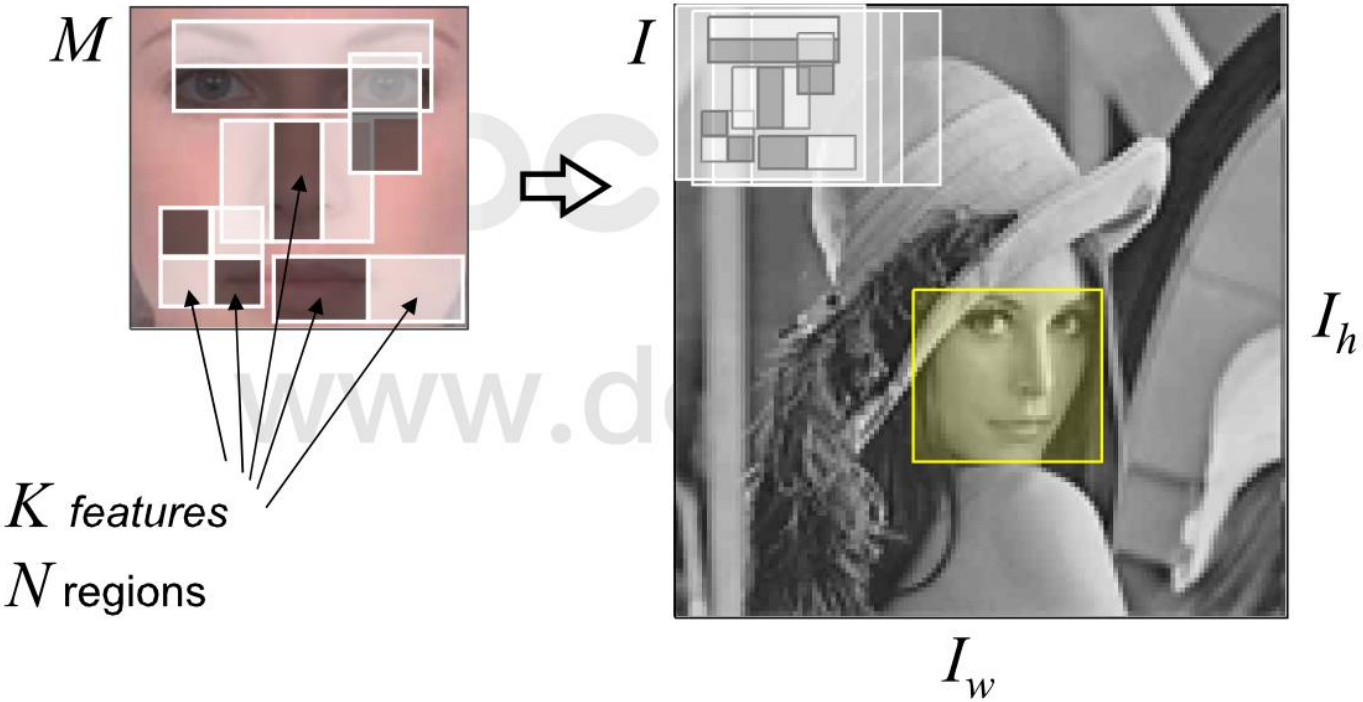

图像特征 *v.s.* 图像局部特征点

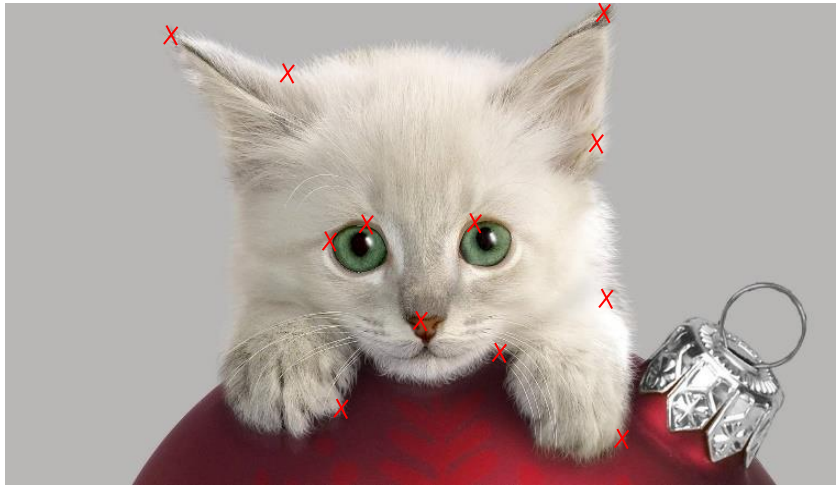

- **图像特征：LBP、HOG、Haar…**

反应了全局的纹理特征、主要物体形状等，容易受到光照、旋转、噪声等影响

识别、分类、检测任务

- **局部特征点**

图像中蕴含数量丰富 ，反应图像上的特殊局部性（线条交叉、明暗变化的结构），受干扰较少

图像匹配、检索等任务

常见图像局部描述子

- SIFT（Scale-Invariant Feature Transform）描述子
- SURF（Speeded Up Robust Features）描述子
- DAISY 描述子
- ……

SIFT尺度不变特征变换（Scale-invariant feature transform）

- 在诸多的局部图像特征描述子中，SIFT是其中应用最广的，它在1999年首次提出（ICCV），至2004年得到完善（IJCV）。
- SIFT的提出是局部图像特征描述子研究领域一项里程碑式的工作。
- 由于SIFT对尺度、旋转以及一定视角和光照变化等图像变化都具有不变性，可扩展，并且SIFT具有很强的可区分性，自它提出以来，很快在物体识别、宽基线图像匹配、三维重建、图像检索中得到了应用。
- 最广泛使用的一种图像描述子，许多人对SIFT进行了改进，诞生了SIFT的一系列变种。
- 局部图像特征描述子在计算机视觉领域内也得到了更加广泛的关注，涌现了一大批各具特色的局部图像特征描述子。

不列颠哥伦比亚大学

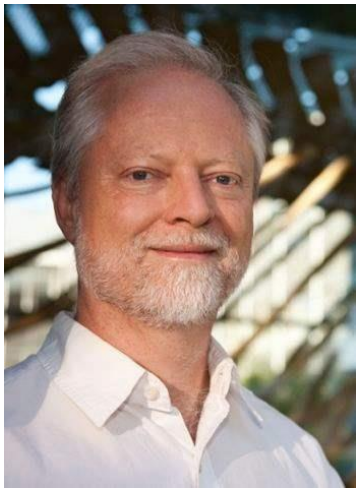

David Lowe

SIFT 算法的步骤

（1）构造高斯差分尺度空间

（2）检测尺度空间极值点，获得尺度不变性

（3）精确定位极值点，过滤不好的特征点

（4）给特征点赋值一个128维的方向参数。每个关键点都包含三个信息：位置、尺度和方向。

（5）关键点描述子的生成

SIFT 算法的步骤

- ① 尺度空间的生成
  - 尺度空间的目的是模拟图像数据的多尺度特性，一幅二维图形的尺度空间定义为：

$$L(x,y,\sigma) = G(x,y,\sigma) * I(x,y)$$

  - 其中$G(x,y,\sigma)$是尺度可变高斯函数$G(x,y,\sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}$，$(x,y)$是空间坐标，$\sigma$是尺度坐标，决定图像的平滑程度，大的 σ 值对应大尺度低分辨率。

SIFT 算法的步骤

- 高斯金字塔的构建
  - 在对图像做不同尺度的高斯模糊后，再对图像做降采样并由大到小，从下到上构成塔状模型（分组、分层）。

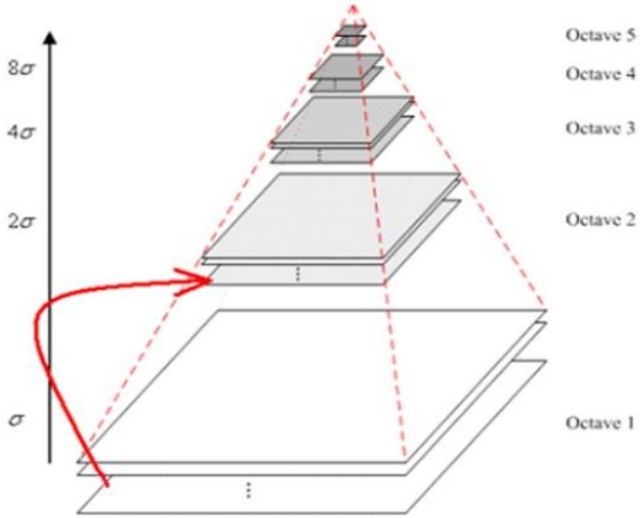

高斯金字塔

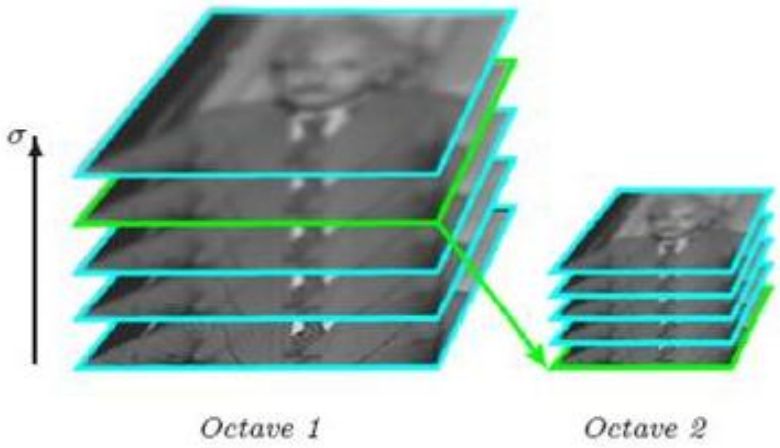

高斯金字塔的另一种表示

$$O = [\log_2 \min(M, N)] - 3$$

SIFT 算法的步骤

- 从0开始记录组数或层数，计算公式如下：

$$\sigma(o,r) = \sigma_0 2^{o+\frac{r}{n}}$$
$$o \in [0,1,\ldots,O-1], r \in [0,1,\ldots,n+2]$$

- *o* 为组索引序号，*r* 为层索引序号，σ (o, r) 为对应的图像的高斯模糊系数。
- 创建好图像高斯金字塔后，每一组内的相邻层相减所可以得到高斯差分金字塔(DoG, Difference of Gaussian)，是后期检测图像极值点的前提。

SIFT 算法的步骤

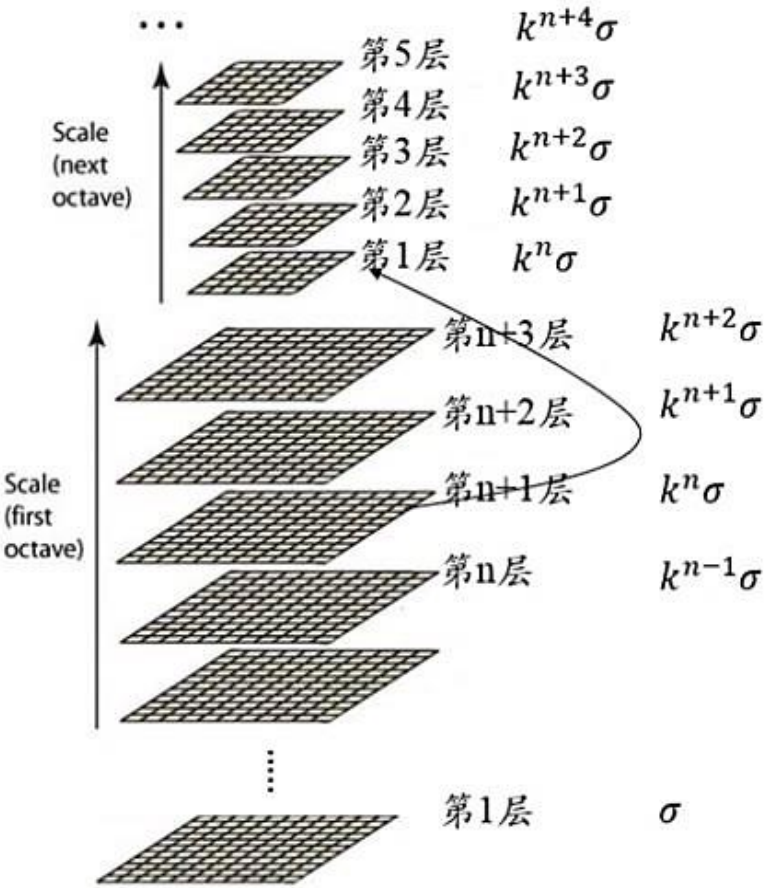

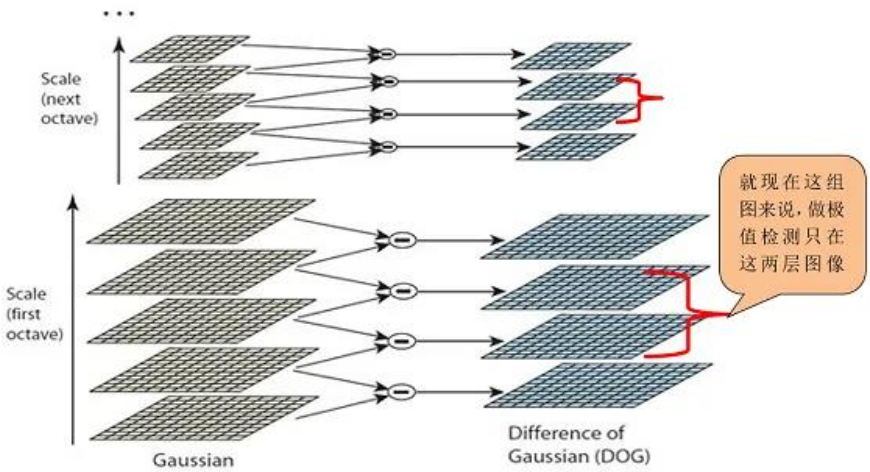

$$k = 2^{\frac{1}{n}}$$

$$\boxed{\sigma_0 = \sqrt{1.6^2 - 0.5^2} = 1.52}$$

下一组的第0层为上一组倒数第3层**降采样**所得，保证**尺度连续性**！

SIFT 算法的步骤

- 高斯差分金字塔
  - 构建尺度空间的目的是为了检测出在不同的尺度下都存在的特征点，而检测特征点较好的算子是$\Delta^2 G$（高斯拉普拉斯，LoG），其中$\Delta^2 = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}$。
  - 为了减少计算量，通常使用DoG（高斯差分）来近似计算，设k为相邻两个高斯尺度空间的比例因子，则高斯差分尺度空间定义如下：

$$\begin{aligned} D(x,y,\sigma) &= [G(x,y,k\sigma) - G(x,y,\sigma)] * I(x,y) \\ &= L(x,y,k\sigma) - L(x,y,\sigma) \end{aligned}$$

  - 其中$L(x,y,\sigma)$是图像的高斯尺度空间
  - 理解：在灰度变化不剧烈的地区，一个像素值的大小和周围像素值得大小基本相等，所以尽管模糊尺度的参数有变化，得到的加权结果其实是相似的，所以做差分之后这种区域的差分值会很小。灰度变化剧烈的地区则反之，差分值会很大。

SIFT 算法的步骤

- ② 检测DoG尺度空间极值点
  - 阈值化 abs(val)>0.5×T/n　T = 0.04
  - 为寻找尺度空间的极值点，每一个采样点要和它同尺度的8个相邻点、上下相邻尺度对应的9×2个点，共26个点比较，以确保在尺度空间和二维图像空间都检测到极值点。
  - 一个点如果在DoG尺度空间本层以及上下两层的26个领域中是最大或最小值时，就认为该点是图像在该尺度下的一个特征点，如图所示。

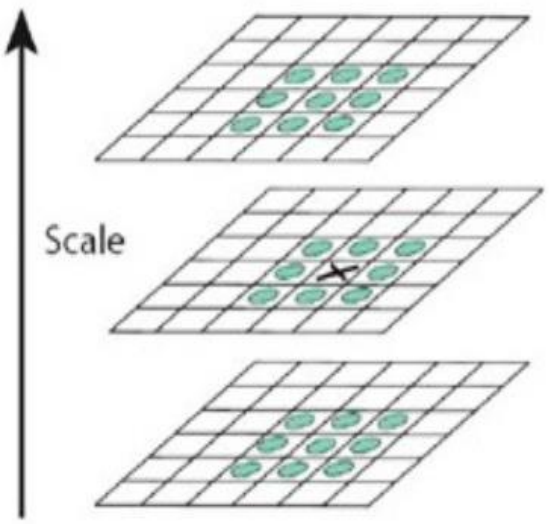

SIFT 算法的步骤

- ③ 精确定位极值点
  - 离散空间的极值点并不是真正的极值点，下图显示了二维函数离散空间得到的极值点与连续空间极值点的差别。利用已知的离散空间点插值得到的连续空间极值点的方法叫做子像素插值（Sub-pixel Interpolation）。
  - 泰勒展开!

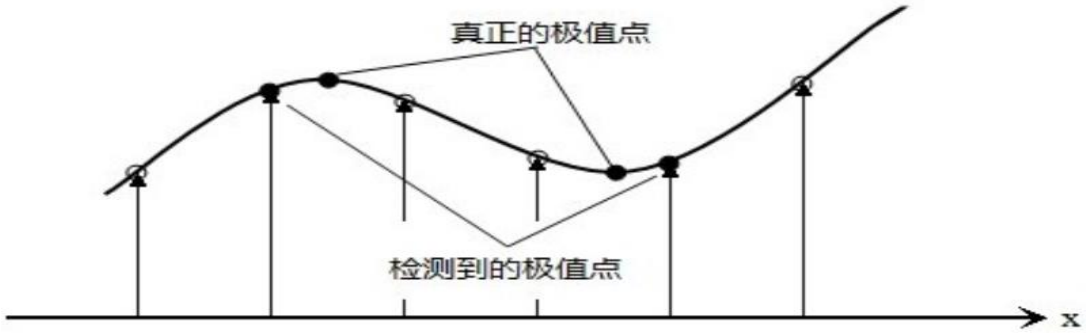

SIFT 算法的步骤

- 精确定位极值点
  - 首先，通过对尺度空间DoG函数曲线拟合以精确确定关键点的位置和尺度（达到亚像素精度）
  - DoG函数在尺度空间的三元二阶Taylor展开式（拟合函数）为$D(X) = D + \frac{\partial D^T}{\partial X} X + \frac{1}{2} X^T \frac{\partial^2 D}{\partial X^2} X$，
  - 其中$X = (x, y, \sigma)^T$。$D(X)$求导并令其为0，得到精确的位置$\hat{x} = -\frac{\partial^2 D^{-1}}{\partial x^2} \frac{\partial D}{\partial x}$。（$\hat{x}$是相对于原检测点的位移量）
  - 上述求解的结束标志：达到一定的迭代次数。

补充：简单回顾，将一个一元函数f(x)在x_0处进行泰勒展开，可以得到以下公式：

$$f(x_0 + \Delta x) = f(x_0) + \Delta x * f'(x_0) + \frac{1}{2!} \Delta x^2 * f''(x_0) + \cdots$$

SIFT 算法的步骤

- **补充：在检测到的极值点X_0处做三元二阶Taylor展开**

$$f\left(\begin{bmatrix} x \\ y \\ \sigma \end{bmatrix}\right) = f\left(\begin{bmatrix} x_0 \\ y_0 \\ \sigma_0 \end{bmatrix}\right) + \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial \sigma}\right]\left(\begin{bmatrix} x \\ y \\ \sigma \end{bmatrix} - \begin{bmatrix} x_0 \\ y_0 \\ \sigma_0 \end{bmatrix}\right)$$

$$+\frac{1}{2}\left(\begin{bmatrix} x \\ y \\ \sigma \end{bmatrix} - \begin{bmatrix} x_0 \\ y_0 \\ \sigma_0 \end{bmatrix}\right)^{\mathrm{T}} \begin{bmatrix} \boxed{\begin{matrix} \frac{\partial^2 f}{\partial x \partial x}, & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial x \partial y}, & \frac{\partial^2 f}{\partial y \partial y} \end{matrix}} & \begin{matrix} \frac{\partial^2 f}{\partial x \partial \sigma} \\ \frac{\partial^2 f}{\partial y \partial \sigma} \end{matrix} \\ \begin{matrix} , \frac{\partial^2 f}{\partial x \partial \sigma}, & \frac{\partial^2 f}{\partial y \partial \sigma}, \end{matrix} & \frac{\partial^2 f}{\partial \sigma \partial \sigma} \end{bmatrix} \left(\begin{bmatrix} x \\ y \\ \sigma \end{bmatrix} - \begin{bmatrix} x_0 \\ y_0 \\ \sigma_0 \end{bmatrix}\right)$$

$H(x,y)$

二阶导数越大，灰度梯度变化得越大。在某个方向上的二阶导数越大，这个方向上的灰度梯度变化就越大，该方向上的亮度突变越大。反之亦然。

矢量形式：$f(X) = f(x_0) + \frac{\partial f^{\mathrm{T}}}{\partial X}\hat{X} + \frac{1}{2}\hat{X}^{\mathrm{T}}\frac{\partial^2 f}{\partial X^2}\hat{X}$

SIFT 算法的步骤

- 精确定位极值点
  - 然后， 在已检测到的特征点中，要去掉低对比度的特征点。
  - $|D(\hat{x})|$过小的点易受噪声的干扰而变得不稳定，带入 $\hat{x} = -\frac{\partial^2 D^{-1}}{\partial x^2}\frac{\partial D}{\partial x}$，得到：

$$D(\hat{x}) = D(x, y, \sigma) + \frac{1}{2}\frac{\partial D^T}{\partial x}\hat{x}。$$

  - 若$|D(\hat{x})| \geq 0.03$或(T/n)，该特征点保留，否则对比度太低则丢弃。

SIFT 算法的步骤

- 精确定位极值点
  - 最后，消除边缘响应。
  - Hessian矩阵通过其特征值的绝对值大小表示图像中局部灰度的变化，特征向量表示该局部灰度变化的方向。
  - 一个定义不好的高斯差分算子的极值在横跨边缘的地方有较大的主曲率，而在垂直边缘的方向有较小的主曲率。主曲率通过一个2×2 的Hessian矩阵H求出：

$$H = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{xy} & D_{yy} \end{bmatrix}$$

  - 二阶导数可以通过图像与二阶高斯模板的卷积获得：

$$I_{xx} = I_{i+1,j} - 2 * I_{i,j} + I_{i-1,j}$$
$$I_{yy} = I_{i,j+1} - 2 * I_{i,j} + I_{i,j-1}$$
$$I_{xy} = I_{i+1,j+1} - I_{i,j+1} - I_{i+1,j} + I_{i,j}$$

$$I_{xx} = \frac{\partial^2 G(x,y)}{\partial x^2} * I(x,y) \qquad I_{yy} = \frac{\partial^2 G(x,y)}{\partial y^2} * I(x,y)$$

$$I_{xy} = \frac{\partial^2 G(x,y)}{\partial x \partial y} * I(x,y) \qquad G(x,y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}$$

SIFT 算法的步

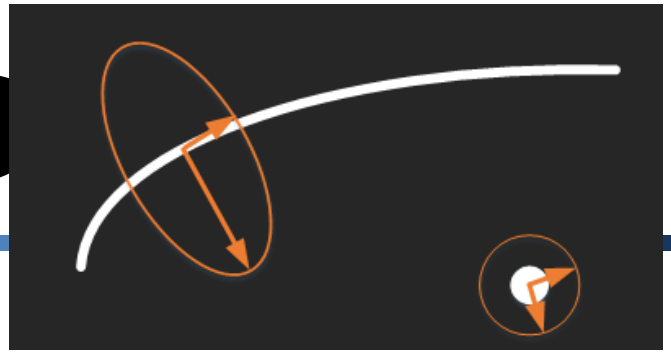

- 精确定位极值点
  - 具体而言，*H*的特征值与*D*的主曲率成比例。设α为最大量级的特征值，β为最小量级的特征值，则：

$$Tr(H) = D_{xx} + D_{yy} = \alpha + \beta$$

$$Det(H) = D_{xx} + D_{yy} - D_{xy}^2 = \alpha \cdot \beta$$

  - 其中$Tr(H)$为矩阵H的迹，$Det(H)$为行列式。设$\alpha=\gamma\beta$，则：

$$\frac{Tr(H)^2}{Det(H)} = \frac{(\alpha+\beta)^2}{\alpha\beta} = \frac{(\gamma\beta+\beta)^2}{\gamma\beta^2} = \frac{(\gamma+1)^2}{\gamma}$$

  - 看主曲率是否高于某个阈值T_γ

$$\frac{Tr(H)^2}{Det(H)} > \frac{(T_\gamma+1)^2}{T_\gamma}$$

  - 如果上式成立，则剔除特征点，否则保留（原文中取T_γ =10）。

SIFT 算法的步骤

- ④ 求取特征点主方向
  - 为了使描述符具有旋转不变性，需要利用图像的局部特征给每一个关键点分配一个基准方向。使用图像梯度的方法求取局部结构的稳定方向。
  - 梯度的模值和方向如下：

$$m(x,y)=\sqrt{[L(x+1,y)-L(x-1,y)]^2+[L(x,y+1)-L(x,y-1)]^2}$$

$$\theta(x,y)=\tan^{-1}\frac{L(x,y+1)-L(x,y-1)}{L(x+1,y)-L(x-1,y)}$$

SIFT 算法的步骤

- 求取特征点主方向
  - 在完成关键点的梯度计算后，使用直方图统计邻域内（以特征点为圆心，以该特征点所在的高斯图像的尺度的1.5倍为半径的圆内）像素的梯度和方向。如图所示，直方图的峰值方向代表了关键点的主方向，其他达到最大值80%的可作为辅助方向(为了简化，图中只画了八个方向的直方图)。

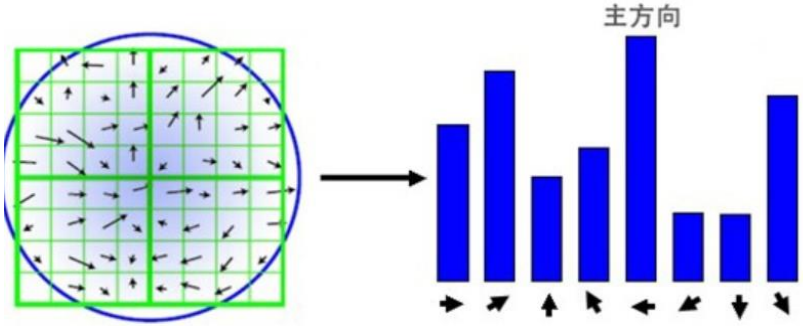

SIFT 算法的步骤

- 求取特征点主方向

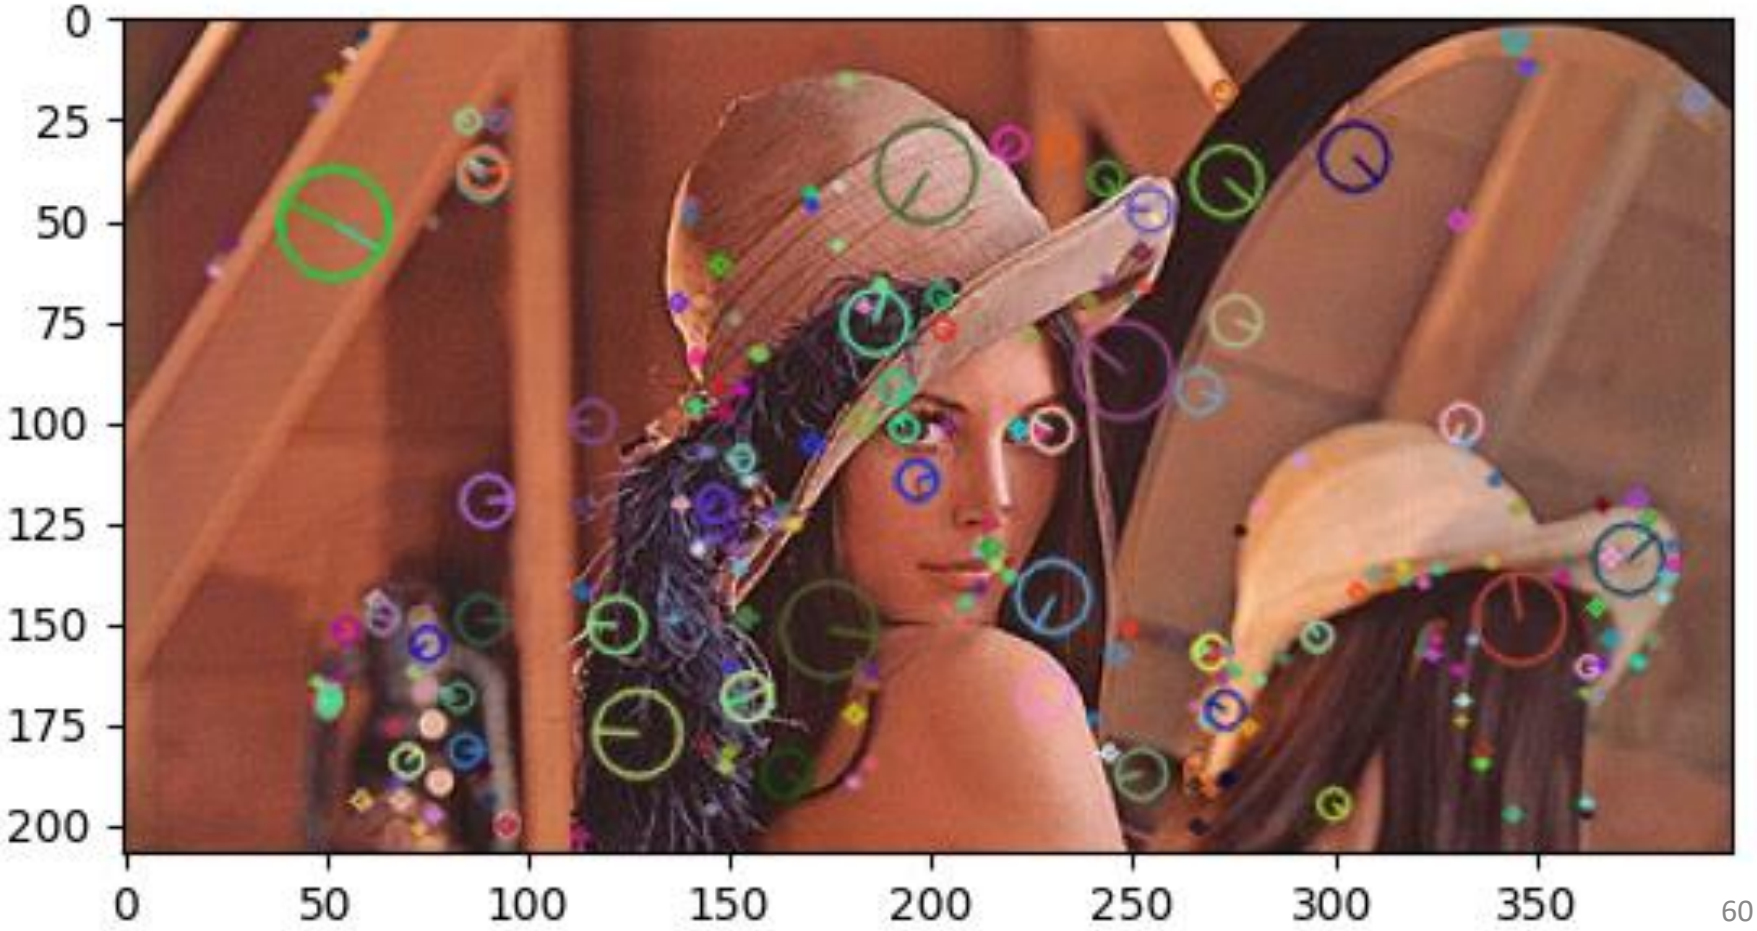

SIFT 算法的步骤

- ⑤ 关键点描述子生成
  - 通过以上的步骤已找到SIFT特征点位置（x，y）、尺度和方向信息，下面就需要使用一组向量来描述关键点也就是生成特征点描述子，这个描述符不只包含特征点，也含有特征点周围对其有贡献的像素点。
  - 描述子应具有较高的独立性，以保证匹配率。
    特征描述符的生成大致有三个步骤：

1) 校正旋转主方向，确保旋转不变性。

2) 生成描述子，最终形成一个128维的特征向量。

3) 归一化处理，将特征向量长度进行归一化处理，进一步去除光照的影响。

SIFT 算法的步骤

- 关键点描述子生成
  - 为了保证特征矢量的旋转不变性，要以特征点为中心，在附近邻域内将坐标轴旋转$\boldsymbol{\theta}$（特征点主方向）角度，旋转后的邻域内像素的新坐标为

$$\begin{bmatrix} \boldsymbol{x}' \\ \boldsymbol{y}' \end{bmatrix} = \begin{bmatrix} \cos\boldsymbol{\theta} & -\sin\boldsymbol{\theta} \\ \sin\boldsymbol{\theta} & \cos\boldsymbol{\theta} \end{bmatrix} \begin{bmatrix} \boldsymbol{x} \\ \boldsymbol{y} \end{bmatrix}$$

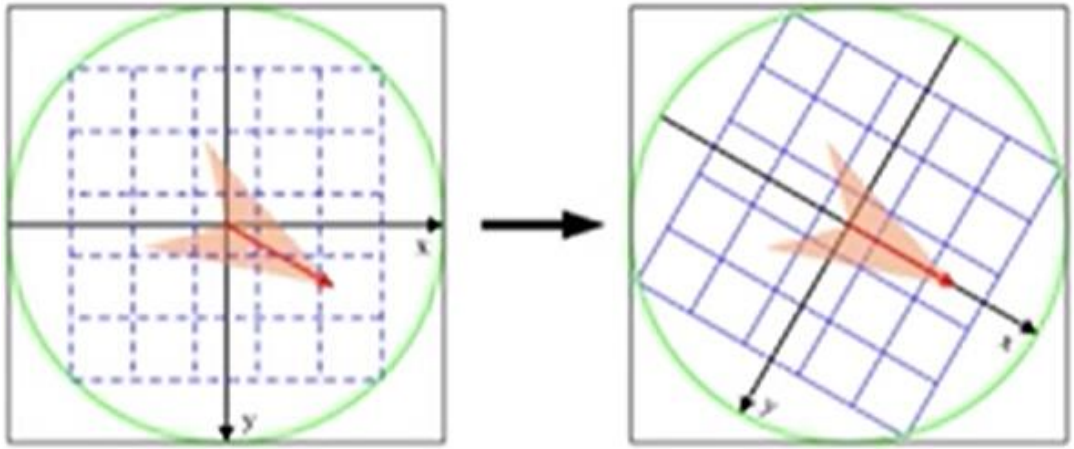

SIFT 算法的步骤

- 关键点描述子生成
  - 旋转后**以特征点为中心**取16×16的邻域为采样窗口，将采样点与特征点的相对方向通过高斯加权后归入针对每个4×4小块的**包含8个方向的直方图**，获得（4×4）×8 = 128维特征向量

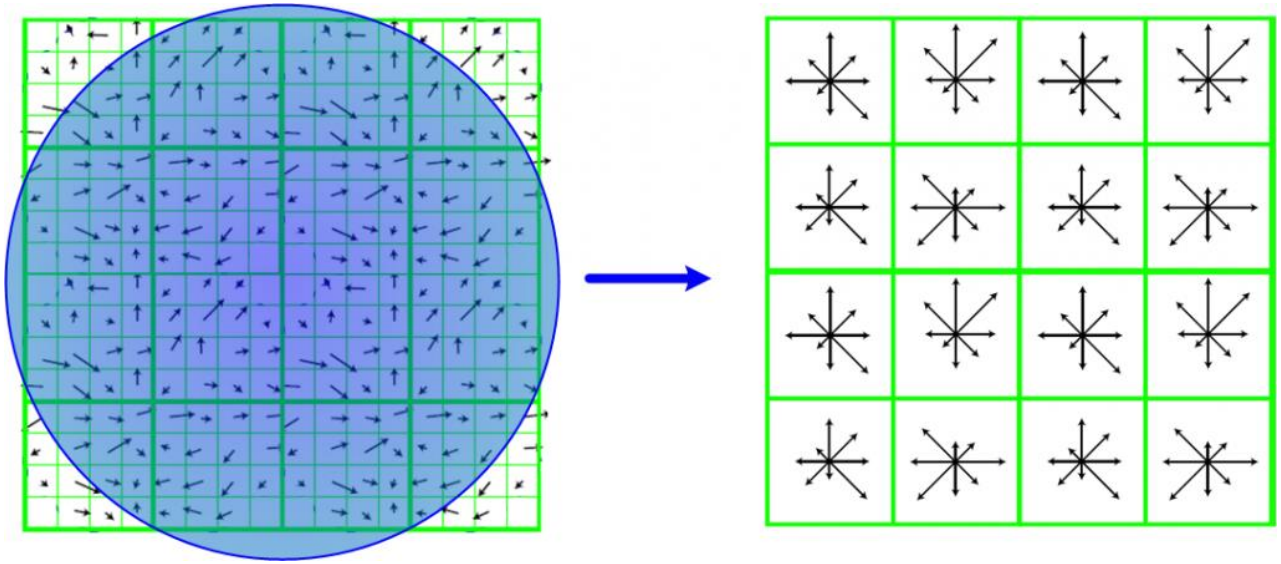

SIFT 算法结果

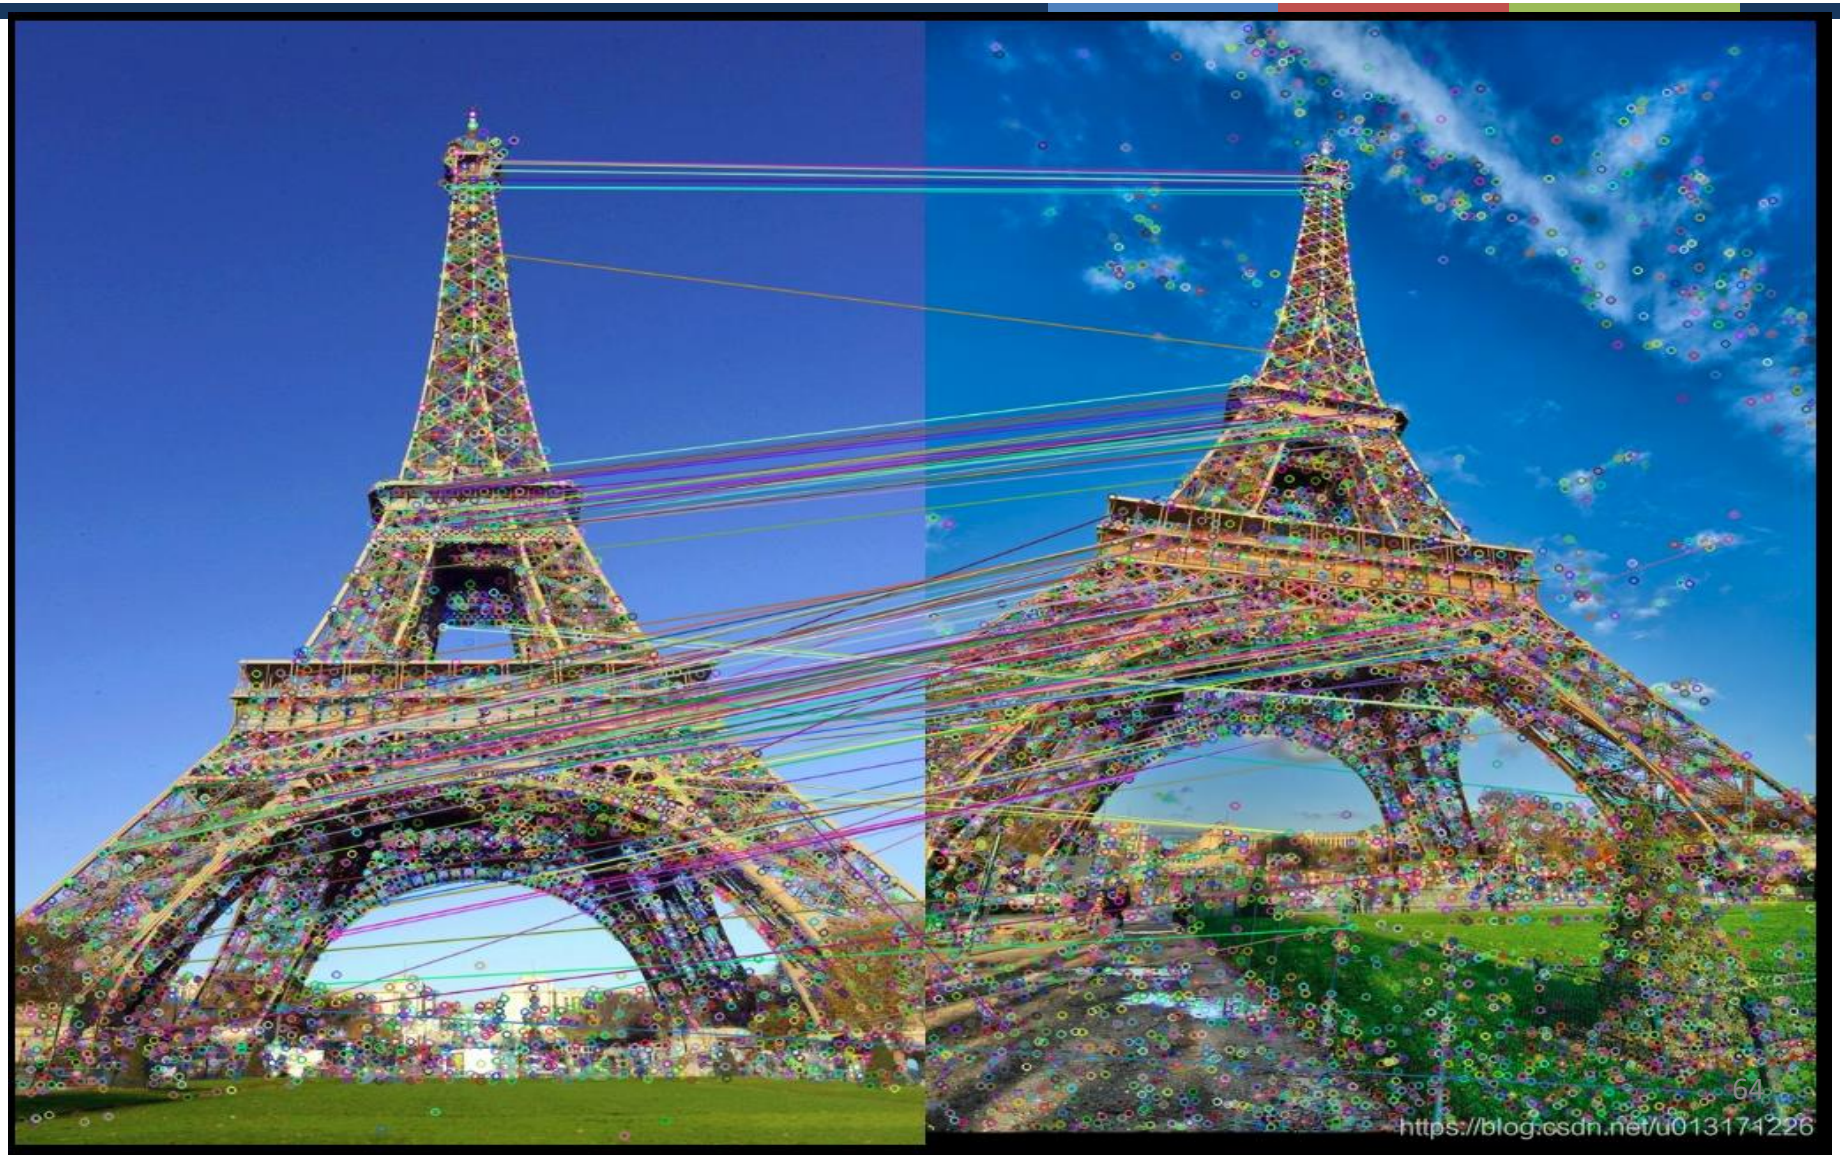

SURF特征

- 经典的SIFT算法比较稳定，检测到的特征点也比较多，其最大的缺点之一是计算复杂度较高。
- SURF（Speeded-up Robust Feature）是SIFT角点检测算法的改进版，主要体现在速度上。
- 发表于2006年ECCV

SURF特征

- 算法的基本流程和SIFT一样，但是在特征提取、尺度空间、特征点主方向和描述子方面会有不同。
- 不同于SIFT的**高斯差分**，SURF中采用**Hessian矩阵行列式构造尺度空间（DoH）**，盒式滤波器来替代高斯滤波器，可采用积分图计算，加快了速度。

$$Det(H) = L_{xx} * L_{yy} - (0.9 * L_{xy})^2$$

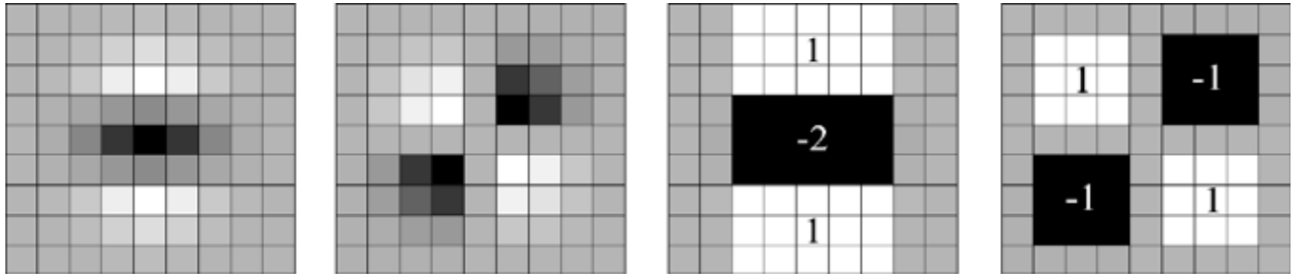

Fig. 2. Left to right: The (discretised and cropped) Gaussian second order partial derivative in y- (L_{yy}) and xy-direction (L_{xy}), respectively; our approximation for the second order Gaussian partial derivative in y- (D_{yy}) and xy-direction (D_{xy}). The grey regions are equal to zero.

SURF特征

- SIFT使用高斯差分金字塔DoG构建尺度空间，每组依次降采样，组内使用不同的高斯模糊系数；
- SURF每组间的尺寸一样，但不同组间使用的盒式滤波器的模板尺寸逐渐增大；组内不同层使用相同尺寸的滤波器，但滤波器的模糊系数逐渐增大。

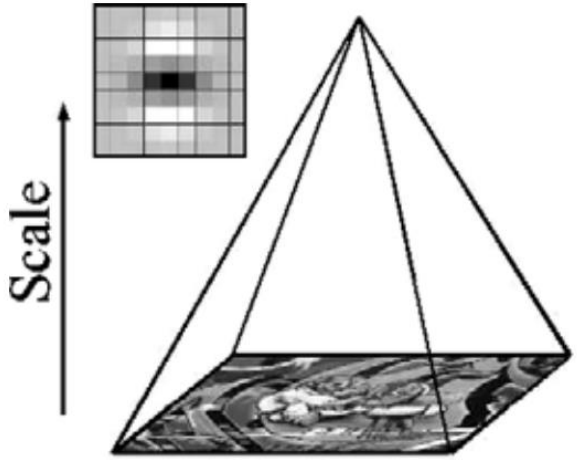

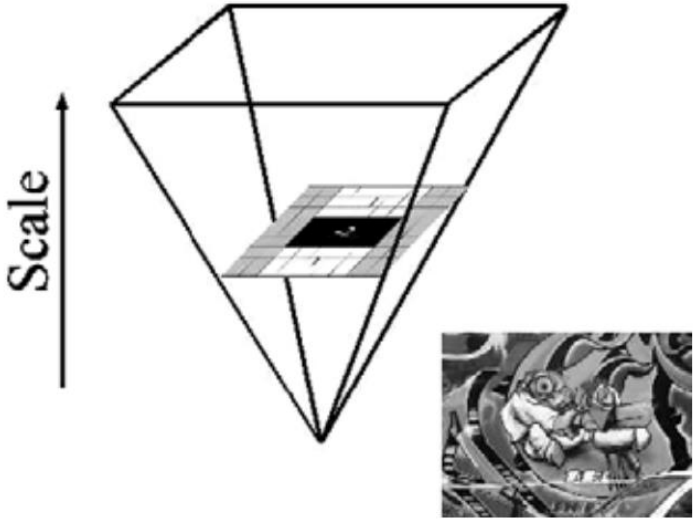

SURF特征

- 统计Haar小波特征选取特征点主方向
  - 在特征点的邻域内，统计60°扇形内所有点的Haar小波特征在水平和垂直方向的响应总和，Haar小波的尺寸变长为4σ（σ是所检测到该特征点所在的尺度），这样一个扇形得到了一个值。
  - 60°扇形以一定间隔进行旋转，最后将最大值扇形的方向作为该特征点的主方向。

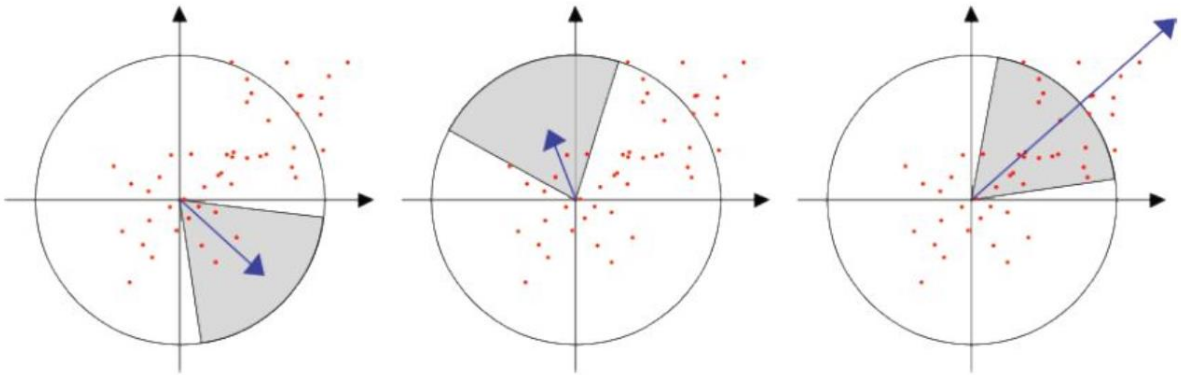

SURF特征

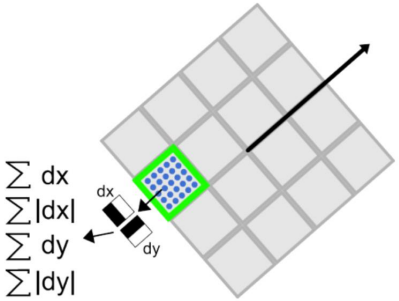

- 采用统计Haar小波特征来**生成描述算子**
  - 在SURF中，也是在特征点周围取一个正方形框，框的边长为20σ（σ是所检测到该特征点所在的尺度）。该框方向为主方向。
  - 然后把该框分为16个子区域，每个子区域统计25个像素的水平方向和垂直方向的**Haar小波特征**，这里的水平和垂直方向都是相对主方向而言的。
  - 该Haar小波特征为：水平方向值之和，水平方向绝对值之和，垂直方向之和，垂直方向绝对值之和。
  - 维度：4×16，相比SIFT减小一半。

SURF特征

- 采用统计Haar小波特征来生成描述算子
  - 该过程的示意图如下所示

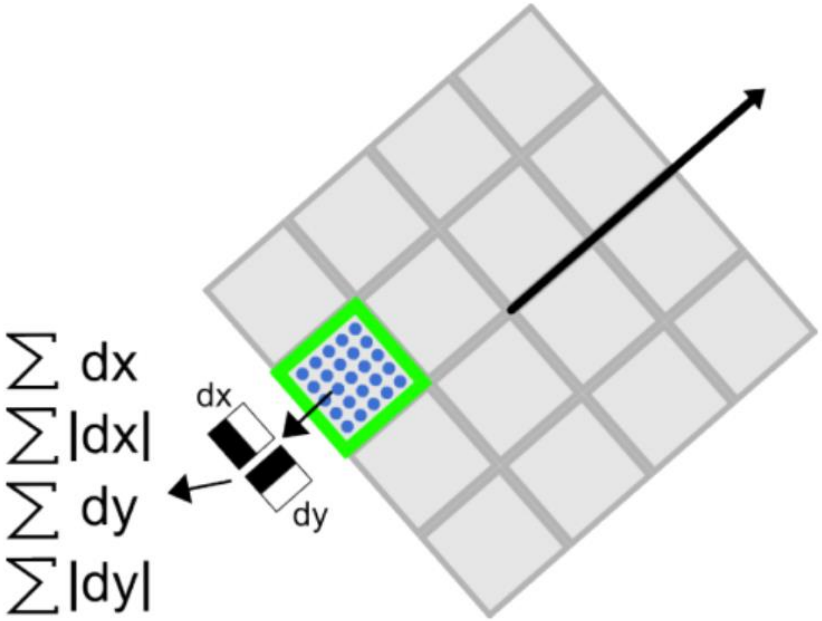

这样每个小区域就有4个值，所以每个特征点就是16×4=64维的向量。相比SIFT而言，少了一半，这在特征匹配过程中会大大加快匹配速度

模式识别

第八章：图像特征提取

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022