Pattern-recognition-LDA

两种模式识别方法

概率密度函数方法

已知概率密度函数的形式，通过样本来估计密度函数的参数

判别函数方法

✓线性判别分析

非线性判别

问题求解

- 问题：如何选择模型中的参数 $\mathbf{w}^T$
- 基本思想：在训练集中, 预测 f 与真正的输出 y 的差异要最小
- 因此 目标函数 (又叫成本函数Cost function) 定义为:

$$J(\mathbf{w}) = \frac{1}{2}\sum_{i=1}^{N}\left(f\left(\mathbf{x}_i\right) - y_i\right)^2 \tag{1}$$

进一步:

$$\hat{\mathbf{w}} = \arg\min_{\mathbf{w}} J(\mathbf{w}) = \arg\min_{\mathbf{w}}\left[\frac{1}{2}\sum_{i=1}^{N}\left(f\left(\mathbf{x}_i\right) - y_i\right)^2\right] \tag{2}$$

(回归)方法

(批处理）梯度下降

- 给定初始值w^0
- 更新w使得 $J(\mathbf{w})$ 越来越小

- $$\begin{aligned} \frac{\partial}{\partial w_j} J(\mathbf{w}) &= \sum_{i=1}^{N} \left(f\left(\mathbf{x}_i\right) - y_i\right) \cdot \mathbf{x}_{i,j} \\ w_j^t &= w_j^{t-1} - \alpha \frac{\partial}{\partial w_j} J(\mathbf{w}) \end{aligned} \tag{3}$$
- 同时更新 $\mathbf{w}$ 的各维 $f\left(\mathbf{x}_i\right) = \left[\mathbf{w}^{t-1}\right]^T \mathbf{x}_i$
- α 为学习率 (Learning rate) 或更新步长
- 迭代速度较慢

随机梯度下降

- 每次只用一个 $(\mathbf{x}_r, y_r)$ 或一些样本
- $$w_j^t = w_j^{t-1} - \alpha \left(f\left(\mathbf{x}_r\right) - y_r\right) \cdot \mathbf{x}_{r,j} \tag{4}$$
  - 收敛速度较快
  - 不太容易陷入局部极值
  - 对大样本数据较有效
- 又叫在线学习 (Online learning)
  - 数据集可以随时进行增加，不需要预先了解所有的数据集
  - 可离线学习, 对所有样本循环使用多次 (一次循环称为一个 epoch)
  - 每次可以看一些样本 (mini-batch)

正规方程组(Normal Equations)

思想

直接令导数为零，而非用梯度下降迭代得出

具体计算

$$\begin{aligned} \frac{\partial}{\partial \mathbf{w}} J(\mathbf{w}) &= \frac{\partial}{\partial \mathbf{w}} (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) \\ &= 2X^T (X\mathbf{w} - \mathbf{y}) = 0 \\ \Rightarrow X^T X\mathbf{w} &= X^T \mathbf{y} \end{aligned} \tag{5}$$

得到模型的参数估计为：$\hat{\mathbf{w}} = \left(X^T X\right)^{-1} X^T \mathbf{y}$

其中：$\left(X^T X\right)^{-1} X^T$为X的伪逆矩阵

线性判别函数（用于分类）

形式

d 维空间中的线性判别函数（决策面）的一般形式:

$$\mathrm{g}(\mathrm{x}) = w^T x + w_0 \tag{6}$$

其中：x 是样本向量-样本在 d 维特征空间中的描述, w 是权 向量, w_0 是一个常数(阈值权):

$$\begin{aligned} x &= [x_1, x_2, \ldots, x_d]^T \\ w &= [w_1, w_2, \ldots, w_d]^T \end{aligned} \tag{7}$$

决策规则

两类问题的线性分类可采用如下决策规则:

$$\text{如果} \begin{cases} \mathbf{g}(\mathbf{x}) > \mathbf{0}, \text{ 则决策 } \mathbf{x} \in \omega_1 \\ \mathbf{g}(\mathbf{x}) < \mathbf{0}, \text{ 则决策 } \mathbf{x} \in \omega_2 \\ \mathbf{g}(\mathbf{x}) = \mathbf{0}, \text{ 可将其任意分类或拒绝} \end{cases} \tag{8}$$

$\mathbf{g}(\mathbf{x}) = \mathbf{0}$ 定义了一个决策面, 把两类实例分开。如果 $\mathbf{g}(\mathbf{x})$ 是线性的, 则决策面是一个超平面。

如果 x_1 和 x_2 都在决策面上, 则：

对于超平面 H 上的点 x_1 和 x_2, 有:

$$\begin{aligned} w^T x_1 + w_0 &= w^T x_2 + w_0 \\ w^T (x_1 - x_2) &= 0 \end{aligned} \tag{9}$$

说明w是H的法向量

$g(x)$的意义

判别函数 $g(x)$ 也可以看作是特征空间中某个点 x 到超平面距离的一种代数度量。若把 x 表示为:

$$x = x_p + r\frac{w}{\|w\|} \tag{10}$$

$$\text{其中} \begin{cases} x_p\text{是}x\text{到}H\text{的射影向量} \\ r\text{是}x\text{到}H\text{的垂直距离} \\ \frac{w}{\|w\|}\text{是}w\text{方向上的单位向量} \end{cases} \tag{11}$$

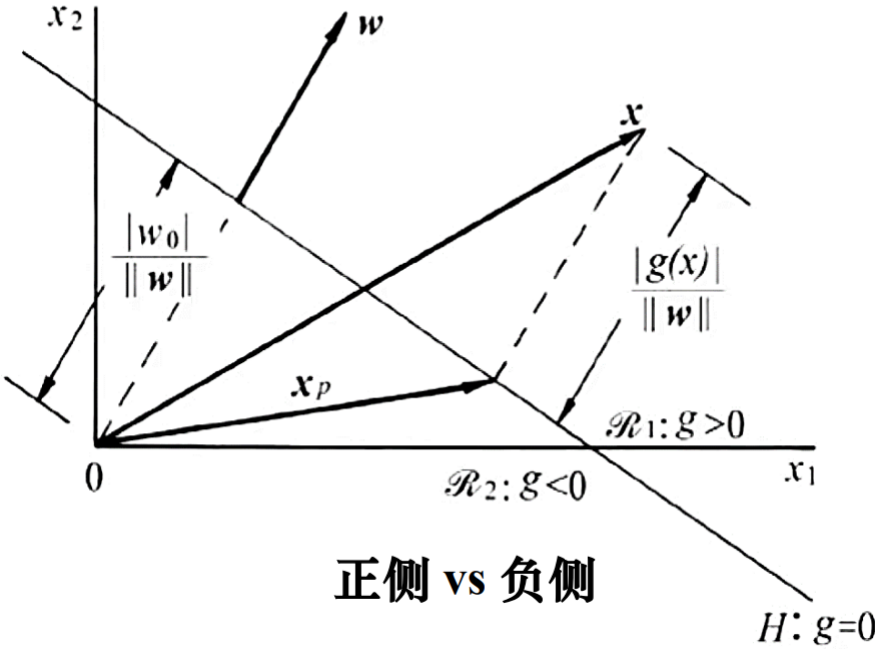

$g(x)$可进一步写为:

$$
\begin{aligned}
g(x) &= w^T\left(x_p + r\frac{w}{\|w\|}\right) + w_0 \\
&= w^T x_p + \omega_0 + r\frac{w^T w}{\|w\|} \\
&= r\|w\|
\end{aligned}
\tag{12}
$$

$$
r = \frac{g(x)}{\|w\|}
$$

例如

- 若 x 为原点, 则 $\mathrm{g(x)} = \omega_0$
- 原点到超平面 H 的距离可以写作: $r_0 = \frac{\omega_0}{\|w\|}$

增广数据与齐次化

增广数据

称$y = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} 1 \\ x \end{bmatrix}$ 为增广样本向量；称 $a = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} w_0 \\ w \end{bmatrix}$ 为增广权向量

增广空间维数 $\hat{d} = d + 1$

方程 $a^T y = 0$ 在增广空间 Y 确定了一个通过原点的超平面 $\hat{H}$, 它对 d 维子空间的划分与原决策面 $w^T x + w_0 = 0$ 对原 X 空间的划分完全相同。 Y 空间中任意一点 y 到 $\hat{H}$ 的距离: $r = \frac{g(x)}{\|a\|} = \frac{a^T y}{\|a\|}$

线性判别函数齐次化

线性判别函数

$$g(x) = w^T x + w_0 \tag{13}$$

改写成

$$g(x) = w_0 + \sum_{i=1}^{d} w_i x_i = \sum_{i=1}^{d} a_i y_i = a^T y \tag{14}$$

称为线性判别函数的齐次化

准则函数

引入

上文讲述了线性判别函数的决策规则，下文讲解的准则函数则是在这样的决策规则下给出的一个利益准则/目标函数，通过最大化利益准则可以使我们达到不同的分类效果

Fisher准则

基本思想

希望投影后的一维数据满足：

1. 两类 之间 的距离尽可能 远
2. 每一类 自身 尽可能 紧凑

基本思想的数学描述（建模）

(1)各类样本的均值向量 $m_i = \frac{1}{N_i} \sum_{x \in x_i} x, i = 1, 2$

(2)原始空间内样本类内离散度矩阵 S_i 和总类内离散度矩阵 S_w

$$S_i = \sum_{x \in \chi_i} (x - m_i)(x - m_i)^T, i = 1, 2$$

$$or \tag{15}$$

$\bar{S_1} = \frac{1}{|X_1|}\sum_{x\in X_1}(x-m_1)(x-m_1)^T$?

$$S_w = S_1 + S_2 \quad S_w = P(w_1)\boxed{S_1} + P(w_2)S_2$$

(3)样本类间离散度矩阵 S_b

$$\begin{gathered} S_b = (m_1 - m_2)(m_1 - m_2)^T \\ or \\ S_b = P(w_1)P(w_2)(m_1 - m_2)(m_1 - m_2)^T \end{gathered} \tag{16}$$

目标准则的数学描述（建模）

在投影以后的一维 Y 空间 $y_n = w^T x_n$

(1)各类样本均值 $\tilde{m}_i = \frac{1}{N_i}\sum_{y\in\eta_i} y, i = 1, 2$

(2)样本类内离散度 $\widetilde{S_i^2}$ 和总类内离散度 $\widetilde{S_w}$

$$\begin{gathered} \tilde{S}_i^2 = \sum_{y\in\eta_i}(y - \tilde{m}_i)^2, i = 1, 2 \\ \tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2 \end{gathered} \tag{17}$$

(3)而类间离散度 $\widetilde{S}_{\mathrm{b}}$ 就成为了两类均值差的平方 $(\widetilde{m_1} - \widetilde{m}_2)^2$ 。

注：这是投影后空间上的离散度（距离)表征(也正是我们的目标准则所要求的)，

在给定w的情况下S和$\tilde{S}$的本质是相同的[1]，例如：

$$\begin{aligned} \tilde{S}_i^2 &= \sum_{y\in\eta_i}(y - \tilde{m}_i)^2 \\ &= \sum_{x\in\chi_i}\left(w^T x - w^T m_i\right)^2 \\ &= \sum_{x\in\chi_i}\left(w^T x - w^T m_i\right)\left(w^T x - w^T m_i\right) \\ &= \sum_{x\in\chi_i} w^T (x - m_i)(x - m_i)^T w \\ &= w^T S_i w \end{aligned} \tag{18}$$

故目标准则可以形式化成问题

$$\begin{aligned} \arg\max_w \quad J_F(w) \quad &= \frac{(\widetilde{m_1} - \widetilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2} \\ &= \frac{w^T S_b w}{w^T S_w w} \end{aligned} \tag{19}$$

若考虑两类样本类内散度矩阵的不对称性（即考虑他们的先验概率），则[2]

$$
\begin{aligned}
J_F(w) &= \frac{w^T S_b w}{w^T S_w w} \\
&= \frac{w^T P(w_1) P(w_2)(m_1 - m_2)(m_1 - m_2)^T w}{w^T P(w_2) S_1 w + w^T P(w_1) S_2 w} \\
&= \frac{w^T (m_1 - m_2)(m_1 - m_2)^T w}{w^T \frac{S_1}{P(w_1)} w + w^T \frac{S_2}{P(w_2)} w}
\end{aligned} \tag{20}
$$

投影方向w求解

$J_F(w)$ 只与投影方向有关, 与 w 的大小无关。即若 w 是一个最优解, kw 也是最优解，其中 k 是任何不为零的常数。

因此, 在求解时, 可以假定分母项为非零的常数而最大化分子部分, 可以转化为如下问题：

$$
\begin{aligned}
&\arg\max_{w} \quad w^T S_b w \\
&s.t. \quad w^T S_w w = c \neq 0
\end{aligned} \tag{21}
$$

假定 S_{w} 是非奇异的, 可以得到:

$$
S_w^{-1} S_b w^* = \lambda w^* \tag{22}
$$

也就是说, w^* 是 $S_w^{-1} S_b$ 的特征向量。把 S_b 代入, 可进一步写为：

$$
\lambda w^* = S_w^{-1} (m_1 - m_2)(m_1 - m_2)^T w^* \tag{23}
$$

应该注意, $(m_1 - m_2)^T w^*$ 是标量, 不影响 w^* 的方向, w^* 的方向是由 $S_w^{-1}(m_1 - m_2)$ 决定的, 因此可取:

$$
w^* = S_w^{-1}(m_1 - m_2) = (S_1 + S_2)^{-1}(m_1 - m_2) \tag{24}
$$

这就是Fisher判别准则下的最优投影方向

分类阈值b求解

上文只给出了投影方向, 却没给出分类面（缺少截距），所以要在投影之后的方向上确定分类阈值

分类阈值的两种确定方法

- 两类均值的中点(先验概率相同)

$$
b = \frac{\mu_1 + \mu_2}{2} \tag{25}
$$

- 投影后数据的 调和 均值 (先验概率相同)

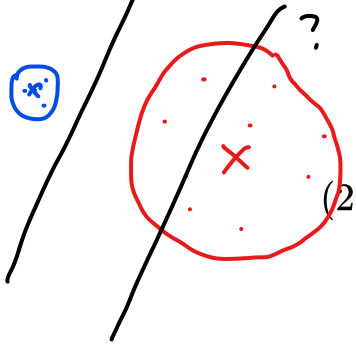

$$b = \frac{n_1\mu_1 + n_2\mu_2}{n_1 + n_2} \tag{26}$$

（在先验概率不同时, 分界点向先验概率小的一侧偏移）

其中，n_1, n_2 是两类样本的个数，$\mu_i = \tilde{m}_i = \frac{1}{N_i}\sum_{x\in x_i} w^T x = \frac{1}{N_i}\sum_{y\in\eta_i} y, i = 1, 2$

注意这里μ_i的求解与**b**无关，也就是不妨取$b_0 = 0$，求完调和平均后才能真正的确定能用来分类的b

直观来说，用**0**将1个**-1**和3个**3**调和分开，和用**100**将1个**99**和3个**103**调和分开是一样的

Fisher准则就是要解决
如何根据实际情况找到这条最好的、最易于分类的投影线的问题

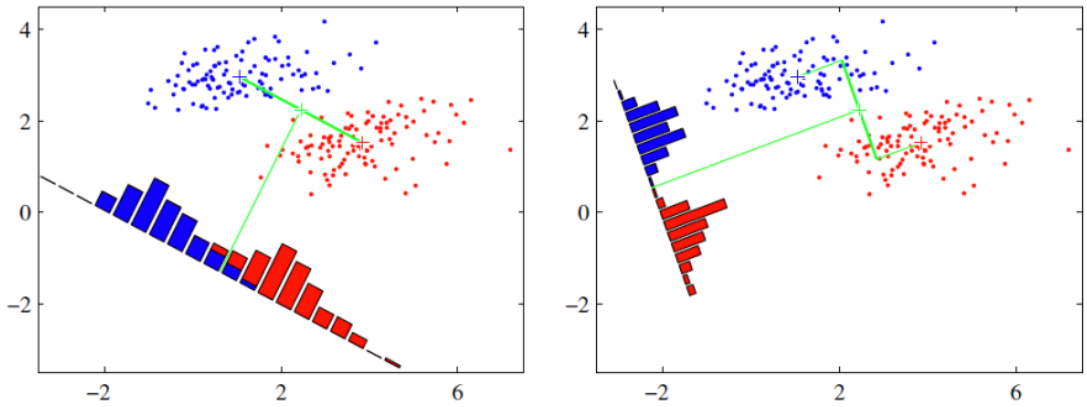

故最后的Fisher准则下的分类器为

$$\mathrm{g(x)} = w^T x + w_0$$

$$\text{其中} \quad w = S_w^{-1}(m_1 - m_2) = (S_1 + S_2)^{-1}(m_1 - m_2) \tag{27}$$

$$w_0 = -b = -\frac{\mu_1 + \mu_2}{2} \quad or \quad -\frac{n_2\mu_1 + n_1\mu_2}{n_1 + n_2}$$

感知机准则

思想

感知准则是一种自学习判别函数的生成方法, 由于 Rosenblatt试图将其用于脑模型感知器, 因此得名。

该方法对随意给定的判别函数初始值, 通过样本分类训练过程逐步对其修正直至最终确定。

基本概念

H5 线性可分性

一组容量为 N 的样本集 $y_1, y_2, \ldots y_N$, 其中 y_n 为 d 维增广样本向量, 分别来自 w_I 类和 w_2 类, 如果存在权向量 a, 使得对于任何 $y \in w_1$, 都有 $a^T y > 0$, 而对于任何 $y \in w_2$, 都有 $a^T y < 0$, 则称这组样本为线性可分的。

H5 样本的规范化

原问题是

$$\begin{cases} a^T y_i > 0, y_i \in w_1 \\ a^T y_j < 0, y_j \in w_2 \end{cases} \tag{28}$$

通过规范化样本增广向量

$$y_n' = \begin{cases} y_i > 0, y_i \in w_1 \\ -y_j < 0, y_j \in w_2 \end{cases} \tag{29}$$

使得

$$a^T y_n' > 0, n = 1, 2, \ldots, N \tag{30}$$

线性可分的条件: 存在向量 a^*, 使得上式成立; a^*为解向量

H5 解向量：存在向量**a***，使得上式成立

H5 解区：在权值空间内所有的解向量组成的区域

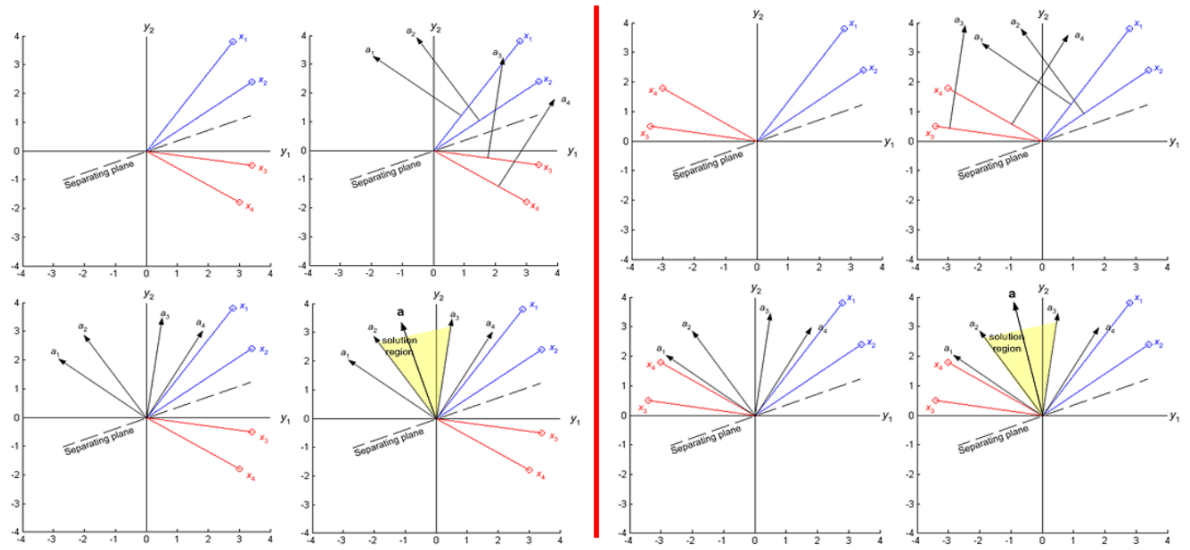

考虑到噪声、误差的存在，应为解区留有余量，即$a^T y_n \geq b > 0$

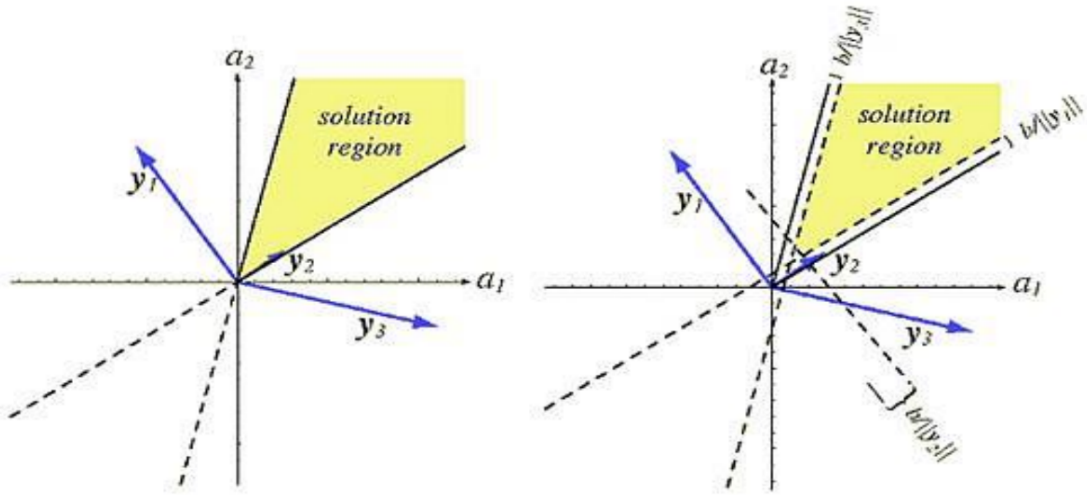

目标准则的数学描述（建模）

寻找解向量 a^*，使得对于一组样本 $y_1, y_2, \ldots y_N$：

$$a^T y_n > 0, n = 1, 2, \ldots, N \tag{31}$$

其中 y_n 是规范化增广样本向量

算法思想

对于线性可分问题, 构造准则函数 $J_P(a) = \sum_{y \in \eta^k} (-a^T y)$
其中 η^k 是被权向量 a 错分的样本集合, 即当 y 被错分时, 就有 $a^T y_n \leq 0$
因此 $J_P(a) \geq 0$, 仅当 a 为解向量或在解区边界时 $J_P(a) = 0$
也就是说, 当且仅当 η^k 为空集时 $J_P^*(a) = \min J_P(a) = 0$，此时无错分样本, 这时的 a 就是解向量 a^* 。

算法——梯度下降法

求使 $J_P(a)$ 达到最小值的 a^*, 采用梯度下降法求解:

$$\begin{aligned} J_P(a) &= \sum_{y \in \eta^k} (-a^T y) \\ \nabla J_P(a) &= \frac{\partial J_P(a)}{\partial a} = \sum_{y \in \eta^k} (-y) \\ a(k+1) &= a(k) - \rho_k \nabla J \\ a(k+1) &= a(k) + \rho_k \sum_{y \in \eta^k} y \end{aligned} \tag{32}$$

具体步骤

初值：任意给定一向量初始值 $a(0)$

迭代: 第 $k+1$ 次迭代时的权向量 $a(k+1)$ 等于第 k 次的权向量 $a(k)$ 加上被错分类的所有样本之和与 r_k 的乘积

终止: 对所有样本正确分类。

算法**Tricks**

- 固定增量法与可变增量法(ρ_k的变化与否)
- 批量样本修正法与单样本修正法
  - 单样本修正法: 样本集视为不断重复出现的序列, 逐个样本检查, 修正权向量✓
  - 批量样本修正法: 样本 成批 或 全部 检查后, 修正权向量

注意

1. 只要 解区间存在 , 那么经过 有限的步骤 后可以得到一个解向量。
2. 如果不是线性可分，迭代的过程中总会出现 新的被错误分类 的样本 y，算法 不会终止 [3]

---

1. S_w和S_b在w确定的情况下可以用来评估类内距离和类间距离 ↩
2. 这里的$P(w_i)$为不同类别的先验概率，也即不同类别样本的比例 ↩
3. 需要注意，这里必须保证样本是线性可分的，否则算法迭代不会结束 ↩