模式识别

第二章：线性判别函数

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022

内容

- 引言
- 线性判别函数的基本概念
- Fisher线性判别函数
- 感知准则函数
- 最小平方误差准则函数
- 多类线性分类器

课前回顾

模式识别系统

- 有已知样本情况：监督模式识别

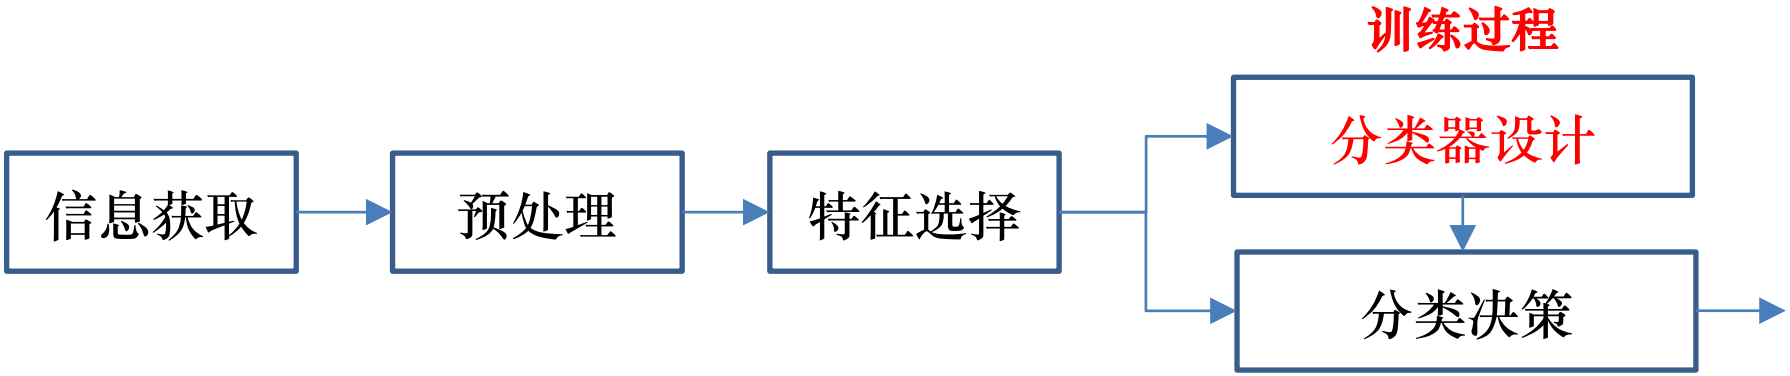

- 无已知样本情况：非监督模式识别

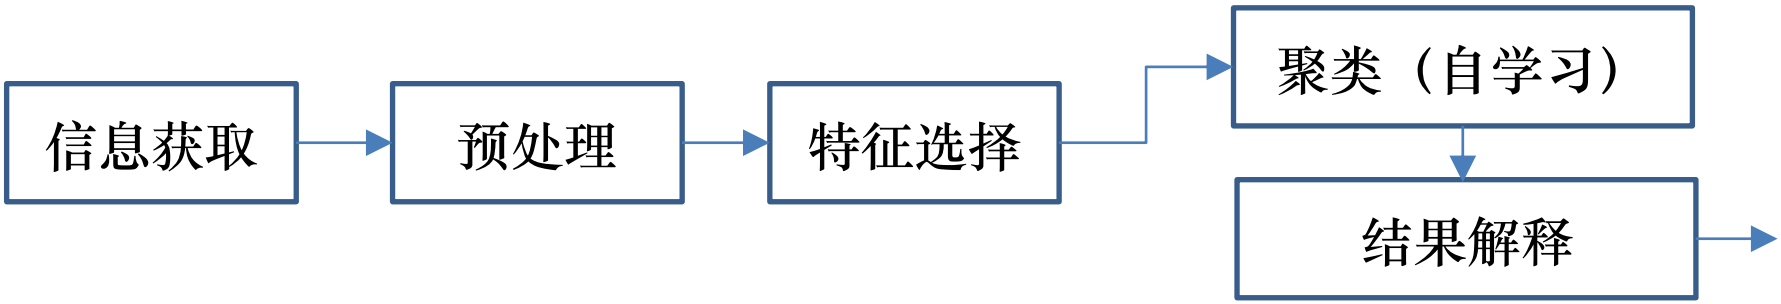

引言

Pattern Recognition

- **Based on class-conditional p.d.f (probability density function)**
  - 参数化方法
    - **Assume a model of the p.d.f. and estimate parameters**
      - Gaussian density
      - Mixture densities
    - **No model assumptions: 'non-parametric'**
      - histogram methods
      - k-nearest neighbours
      - kernel method
- **Based on Discriminant function**
  - **Linear discriminant function.**
    - Perceptron
    - Fisher Discriminant
    - Logistic Discriminant
    - Support vector machine
  - **Non-linear discriminant function.**
- **Based on similarity with stored sample**

引言

- 参数化方法--概率密度函数的估计
  - Underlying p.d.fs are known.
  - Training samples used to estimate p.d.f parameters
- 线性判别函数
  - Forms of discriminant functions are known similar to non-parametric techniques.
  - Sub-optimal, but simple to use

引言

- 模式识别（分类）的目的是在特征空间中找到分类面
- 分类器的设计初步思想：根据对样本/问题的理解直接设定判别函数形式，直接求解
  - 线性
  - 非线性
- 模式识别还有更多方法！

引言

- 基于样本直接设计分类器的三个要素：
  - 1）分类器，即判别函数，的类型。
  - 2）分类器设计的目标或准则，通过选择该准则下的最优函数，来确定某些待定参数。
  - 3）如何利用样本数据，求解出最优的函数参数。形式化表示：确定参数$\boldsymbol{\alpha}^*$，使得准则函数$L(\boldsymbol{\alpha})$最小（或最大），即：

$$L(\boldsymbol{\alpha}^*) = \min L(\boldsymbol{\alpha})$$

引言

- **基于样本的直接确定判别函数方法：**
  - 针对各种不同的情况，使用不同的准则函数，设计出满足这些不同准则要求的分类器。
  - 这些准则的“最优”并不一定与错误率最小相一致：次优分类器。
  - 实例：正态分布最小错误率贝叶斯分类器在特殊情况下，是线性判别函数 $g(x) = w^T x$ （决策面是超平面），能否基于样本直接确定w?

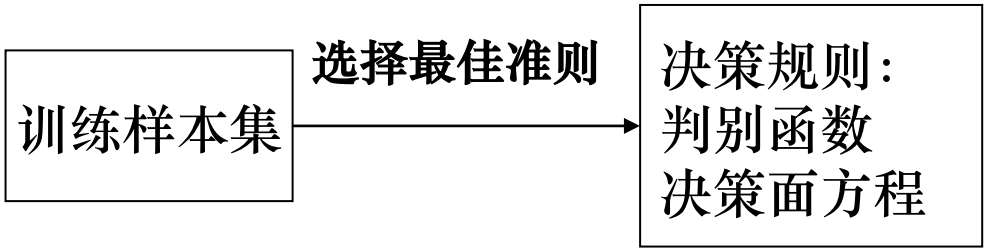

“回归”起源

- Francis Galton，英国生物学家，他研究了父母身高与子女身高之间关系后得出，若父母身高高于平均大众身高，则其子女身高倾向于倒退生长，即会比其父母身高矮一些而更接近于大众平均身高。若父母身高小于平均身高，则其子女身高倾向于向上生长，以更接近于大众平均身高。此现象，被Galton称之为回归现象，即regression.

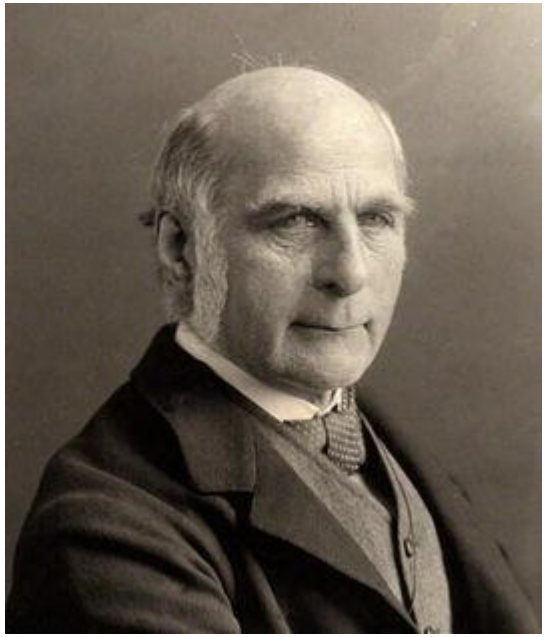

弗朗西斯·高尔顿（Francis Galton，1822年2月16日—1911年1月17日）

“回归”起源

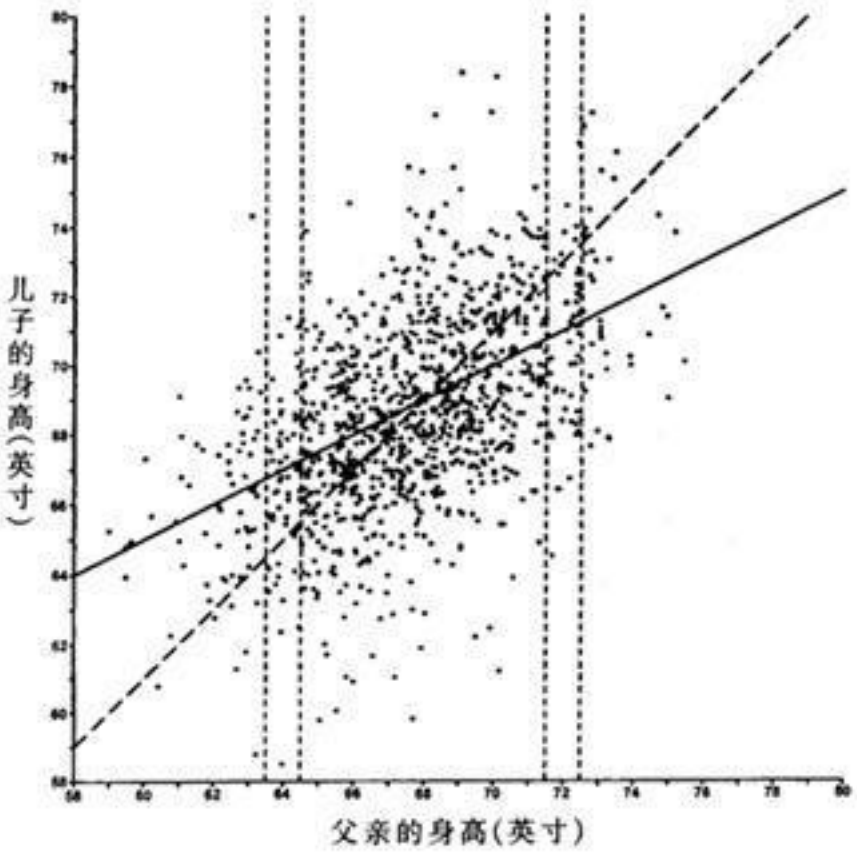

从左图中可以看到，后代的身高倾向于“回归”到一个平均值。

回归问题举例

- 例：房价估计

Size (feet²)	Number of bedrooms	Number of floors	Age of home (years)	Price ($1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
…	…	…	…	…

Size (feet²)	Number of bedrooms	Number of floors	Age of home (years)	Price ($1000)
1500	3	2	30	?

测试样本

回归问题举例

- 例：房价估计

训练样本

Size (feet²) x_1	Number of bedrooms x_2	Number of floors x_3	Age of home (years) x_4	Price ($1000) y
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
…	…	…	…	…

N

监督学习

回归问题

N：训练样本个数

x：输入变量/“特征”

y：输出变量/目标变量

模型建立

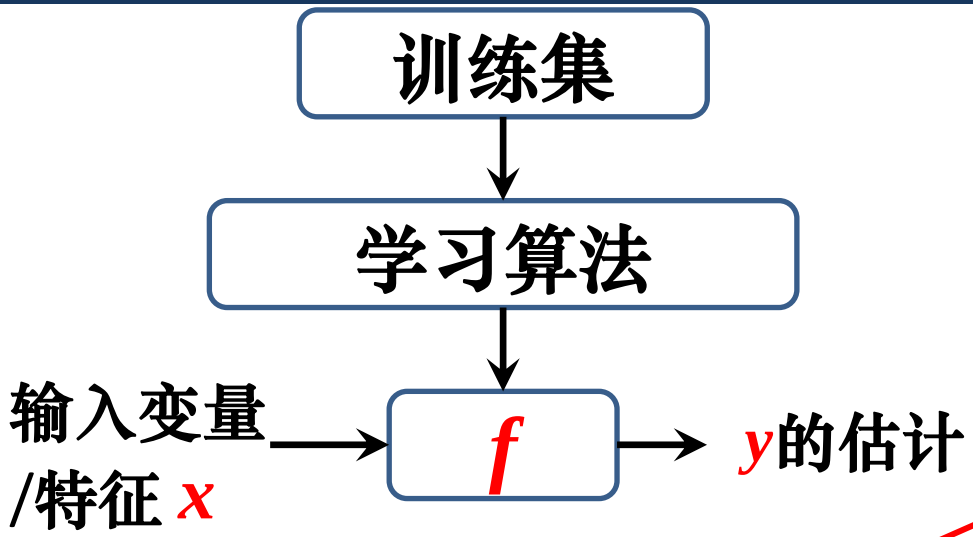

$$
\begin{aligned}
f(\mathbf{x}) &= w_0 + w_1 x_1 + \ldots + w_m x_m \\
&= w_0 + \sum_{i=1}^{m} w_i x_i \\
&= \sum_{i=0}^{m} w_i x_i
\end{aligned}
$$

如何表示 *f*？

线性回归：假设函数 *f* 为输入为*x*的线性函数：

$$
\begin{aligned}
f(\mathbf{x}) &= w_0 + w_1 x_1 + \ldots + w_m x_m \\
&= w_0 + \sum_{j=1}^{m} w_i x_i
\end{aligned}
$$

写成向量形式（增加一维w_0，表示截距项）：

$$f(\mathbf{x}) = \boxed{\mathbf{w}^T}\mathbf{x}$$

线性回归：用训练集中的样本估计参数，使得模型在<u>最小平方误差意义</u>下能够最好地拟合样本。

问题求解

- 问题：如何选择模型中的参数$\mathbf{w}^T$
- 基本思想：在训练集中，预测 f 与真正的输出 y的差异要最小
- 因此目标函数(又叫成本函数Cost function)定义为：

$$J(\mathbf{w}) = \frac{1}{2}\sum_{i=1}^{N}(f(\mathbf{x}_i) - y_i)^2$$

- 进一步：

$$\hat{\mathbf{w}} = \arg\min_{\mathbf{w}} J(\mathbf{w}) = \arg\min_{\mathbf{w}} \left[\frac{1}{2}\sum_{i=1}^{N}(f(\mathbf{x}_i) - y_i)^2\right]$$

梯度下降（Gradient descent）

- 代价函数：$J(\theta)$ ，优化目标：$\min_{\theta} J(\theta)$
- 初始化参数(θ) ;每个训练轮次计算梯度进行参数 (θ) 更新,直至得到最小化的代价函数和模型参数。

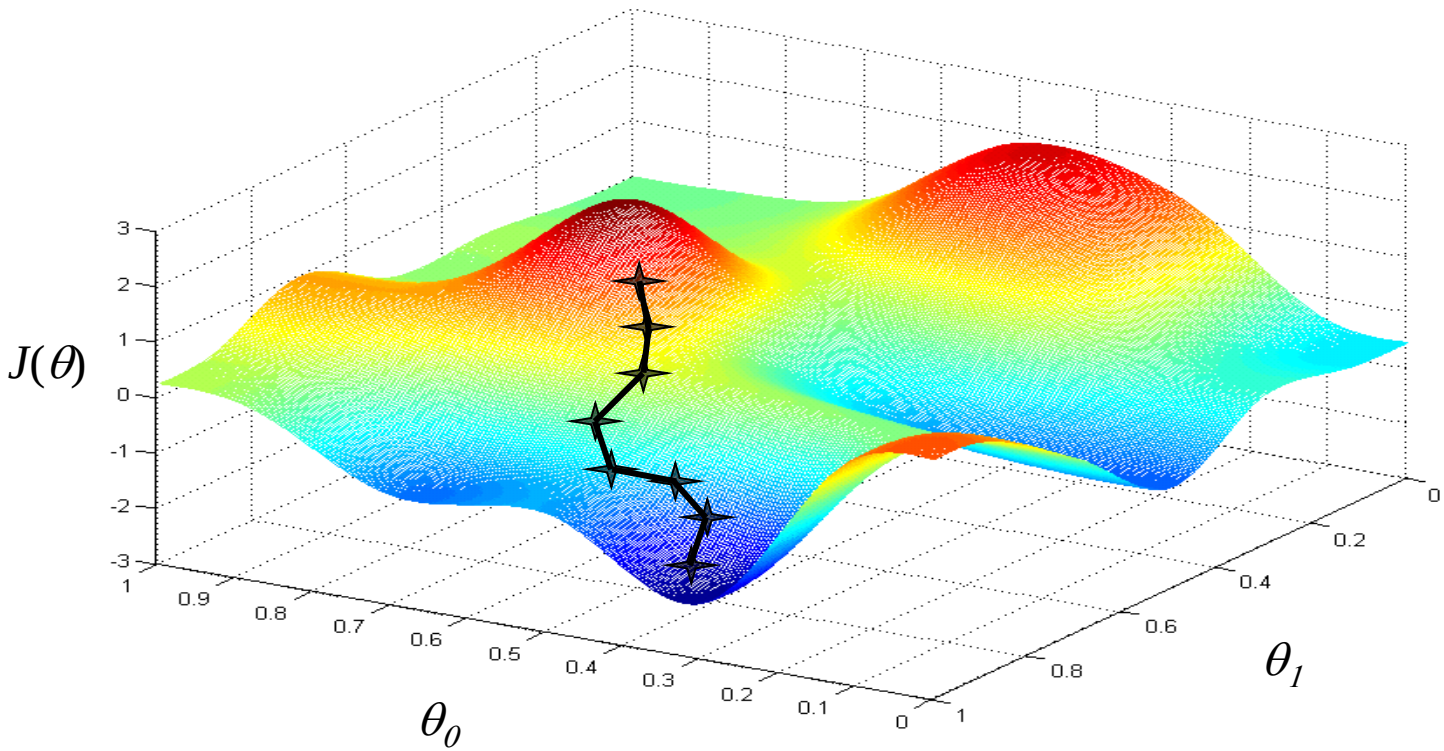

梯度下降（Gradient descent）

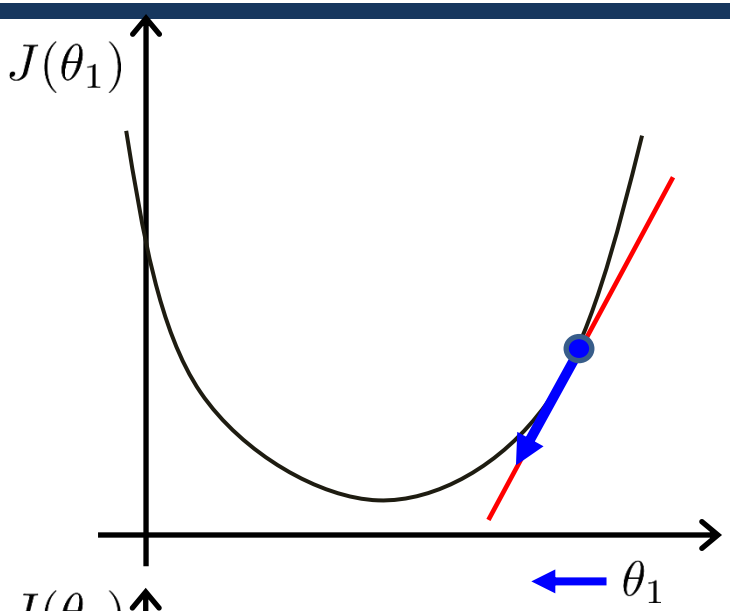

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

$$\frac{\partial}{\partial \theta_1} J(\theta_1) \geq 0$$

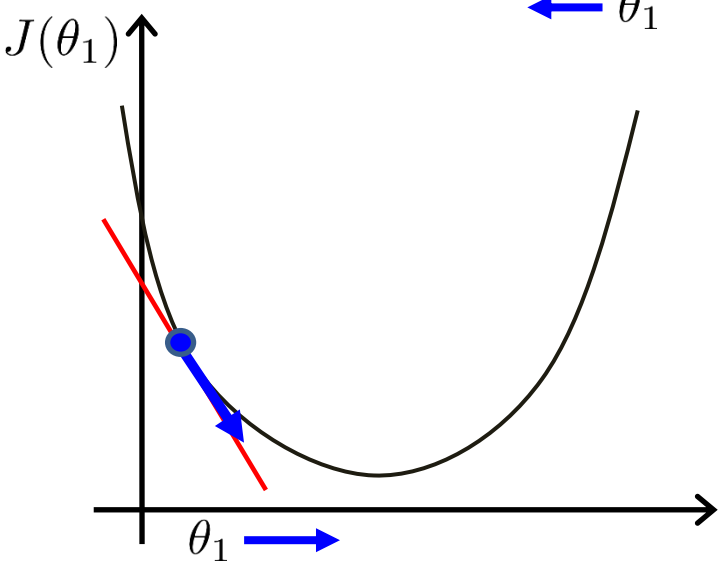

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

$$\frac{\partial}{\partial \theta_1} J(\theta_1) \leq 0$$

梯度下降（Gradient descent）

- **梯度下降算法**

重复该过程直至收敛{

$$\theta_j := \theta_j - \boxed{\alpha} \boxed{\frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1, \ldots, \theta_n)}$$

}

学习率　　**偏导**

梯度下降（Gradient descent）

- 梯度下降：

  -给定初始值w^0

  -更新w使得$J(w)$越来越小

$$\frac{\partial}{\partial w_j} J(\mathbf{w}) = \sum_{i=1}^{N} (f(\mathbf{x}_i) - y_i) \cdot \mathbf{x}_{i,j}$$

$$w_j^t = w_j^{t-1} - \alpha \frac{\partial}{\partial w_j} J(\mathbf{w})$$

  -同时更新w的各维 $f(\mathbf{x}_i) = [\mathbf{w}^{t-1}]^T \mathbf{x}_i$

  - α为学习率（Learning rate）或更新步长

批处理梯度下降
(Batch Gradient Descent)

- 在上面的梯度下降中，每次更新都利用了所有的数据：

$$w_j^t = w_j^{t-1} - \alpha \boxed{\sum_{i=1}^{N}} (f(\mathbf{x}_i) - y_i) \cdot x_j$$

-这种方法称为批处理梯度下降（Batch Gradient Descent）

-在大样本情况下，批处理梯度下降的迭代速度很慢

随机梯度下降（Stochastic Gradient Descent）

- 思想：如果对条件C所有的样本都成立，则对任一样本也成立
- 随机梯度下降：每次只用一个样本 $(\mathbf{x}_r, y_r)$

$$w_j^t = w_j^{t-1} - \alpha(f(\mathbf{x}_r) - y_r) \cdot \mathbf{x}_{r,j}$$

-收敛速度较快
-不太容易陷入局部极值（每次样本随机，可能跳出极值）
-对大样本数据较有效
-又叫在线学习（Online learning）
-但不能保证每次得到的方向是损失函数减小的方向，搜索路径曲折

- 变种
-可离线学习，对所有样本循环使用多次（一次循环称为一个epoch）
-每次可以看一些样本（mini-batch），精度和速度平衡

另一种求解方法

正规方程组
（Normal Equations）

- 目标函数：

$$
\begin{aligned}
J(\mathbf{w}) &= \sum_{i=1}^{N} \left(f(\mathbf{x}_i) - y_i\right)^2 \\
&= \sum_{i=1}^{N} \left(\mathbf{w}^T \mathbf{x}_i - y_i\right)^2
\end{aligned}
$$

- 直接求导，并令其等于0，求得极值

正规方程组
（Normal Equations）

- 将目标函数写成矩阵形式：

$$
\begin{aligned}
J(\mathbf{w}) &= \sum_{i=1}^{N} (\mathbf{w}^T \mathbf{x}_i - y_i)^2 \\
&= (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y})
\end{aligned}
$$

- 其中：

$$
X = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \cdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_{11}, x_{12}, \cdots, x_{1m} \\ x_{21}, x_{22}, \cdots, x_{2m} \\ \vdots \qquad \ddots \\ x_{N1}, x_{N2}, \cdots, x_{Nm} \end{pmatrix} \qquad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}^T
$$

正规方程组
（Normal Equations）

- 求导：

$$\frac{\partial}{\partial \mathbf{w}} J(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}} (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y})$$
$$= 2X^T(X\mathbf{w} - \mathbf{y}) = 0$$

$$\Rightarrow X^T X \mathbf{w} = X^T \mathbf{y}$$

- 得到模型的参数估计为：

X的伪逆矩阵

$$\hat{\mathbf{w}} = \boxed{(X^T X)^{-1} X^T} \mathbf{y}$$

梯度下降 VS 正规方程组

- **梯度下降法：**

-需要选择α

-需要迭代多次

-样本量非常大时也适用

-需要Feature Scaling

- **正规方程组：**

-不需要选择α

-不需要迭代多次

-需要计算 $(X^TX)^{-1}$ ，样本量大时不适用

-无需Feature Scaling

样本量较小时选用正规方程组解法，较大时选用梯度下降法。

线性判别函数

线性判别函数的基本概念

- **线性回归：**

线性回归： $y(x) = w^T x + w_0$

利用样本估计*w*，对于给定*x*，计算*y*。

- **利用样本集直接设计分类器：**

$$y(x) = f(w^T x + w_0) \quad f(a) = \begin{cases} +1, & a \geqslant 0 \\ -1, & a < 0 \end{cases}$$

$$w^T x + w_0 \geq 0 \Rightarrow C_1$$

$$w^T x + w_0 \leq 0 \Rightarrow C_2$$

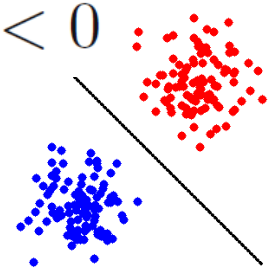

将分类器设计问题转化为求准则函数极值的问题

准则函数：分类器设计的某些要求的函数形式

线性判别函数的基本概念

- d维空间中的**线性判别函数（决策面）**的一般形式：

$$g(x) = w^T x + w_0$$

- 其中：

  x是样本向量-样本在d维特征空间中的描述， w是权向量，w_0是一个常数(阈值权)：

$$x = [x_1, x_2, \dots, x_d]^T$$
$$w = [w_1, w_2, \dots, w_d]^T$$

线性判别函数的基本概念

- 两类问题的线性分类可采用如下**决策规则**:

$$\text{如果}\begin{cases} g(x) > 0\text{，则决策}x \in \omega_1 \\ g(x) < 0\text{，则决策}x \in \omega_2 \\ g(x) = 0\text{，可将其任意分类或拒绝} \end{cases}$$

- $g(x) = 0$ 定义了一个决策面，把两类实例分开。如果$g(x)$是**线性**的，则决策面是一个**超平面**。

- 如果x_1和x_2都在决策面上，则:

$$w^T x_1 + w_0 = w^T x_2 + w_0$$

- 或:

$$w^T(x_1 - x_2) = 0$$

线性判别函数的基本概念

- 对于超平面H上的点x_1和x_2，有：

$$w^T(x_1 - x_2) = 0$$

- 说明w与超平面上任一向量正交，即：**w是H的法向量**
- 一般来说H将空间分成两个**决策域**R_1和R_2。当x在R_1中，g(x)>0, 法向量是指向R_1的。有时称R_1中所有的x在H的**正侧**，相应地R_2中的x在H的**负侧**。

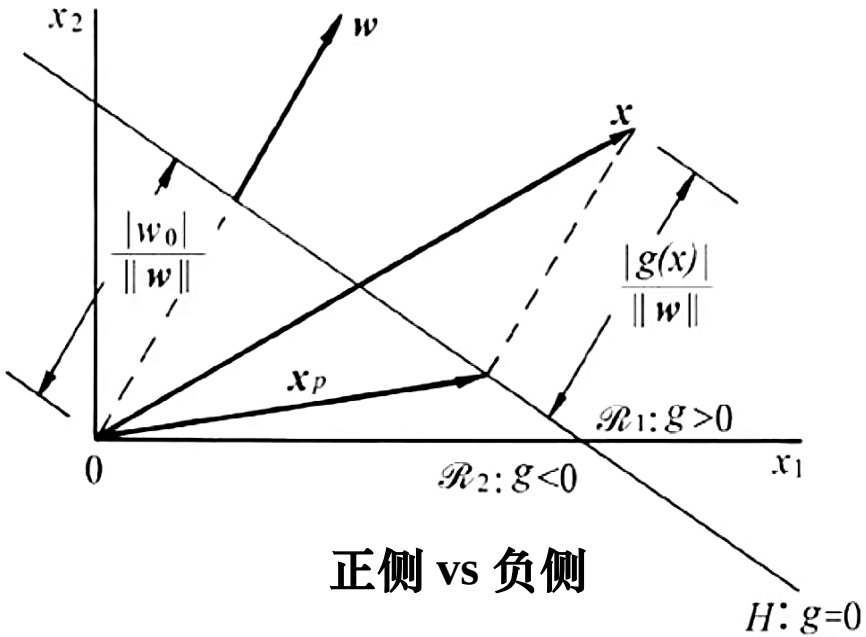

正侧 vs 负侧

线性判别函数的基本概念

- 判别函数$g(x)$也可以**看作是特征空间中某个点x到超平面距离的一种代数度量**。若把x表示为：

$$x = x_p + r\frac{w}{||w||}$$

- 其中，x_p是x到H的射影向量，r是x到H的垂直距离，$\frac{w}{||w||}$是**w方向上**的单位向量。

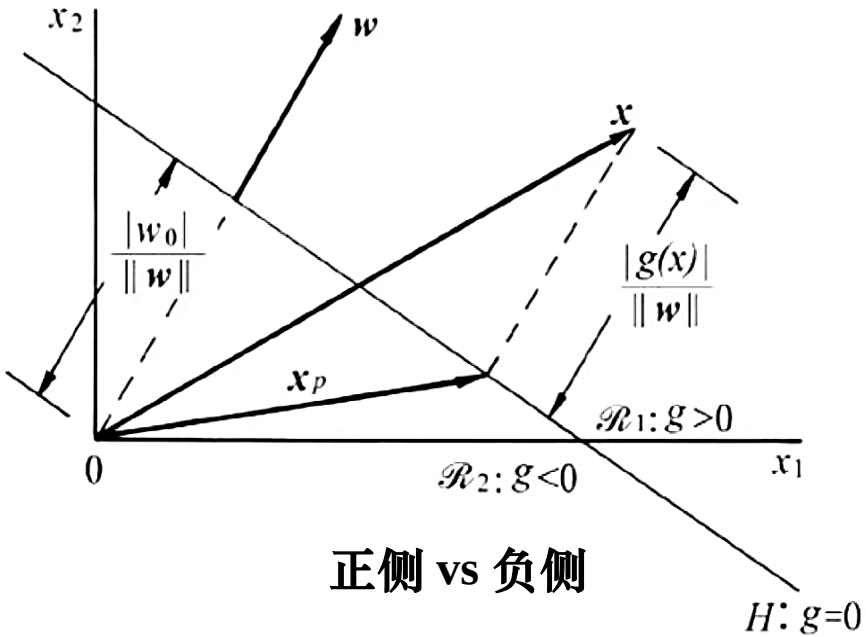

正侧 vs 负侧

线性判别函数的基本概念

- 可进一步写为：

$$g(x) = w^T\left(x_p + r\frac{w}{||w||}\right) + \omega_0 = w^T x_p + \omega_0 + r\frac{w^T w}{||w||}$$
$$= r||w||$$

- 可进一步写为： $r = \frac{g(x)}{||w||}$
- 若x为原点，则$g(x) = \omega_0$
- 原点到超平面H的距离可以写作： $r_0 = \frac{\omega_0}{||w||}$

线性判别函数的基本概念

- 特殊情况 – 若x为原点：

$$g(x) = \omega_0$$

则，原点到超平面的距离为：

$$r_0 = \frac{\omega_0}{||w||}$$

$\omega_0 > 0$ – 原点在H的负侧；$\omega_0 < 0$ – 原点在H的正侧；$\omega_0 = 0$ – 超平面通过原点；

- 总之，利用线性判别函数进行决策，就是用一个超平面把特征空间分割成两个决策区域。超平面的方向由权向量ω确定，它的位置由ω_0确定。
- 判别函数g(x)正比于x点到超平面的代数距离（带正负号）。当x在H正侧时，g(x)>0；反之，g(x)<0。

广义线性判别函数

- 两类问题, X是一维样本空间

若 $x < a$ 或 $x > b$, $x \in w_1$

若 $a < x < b$, $x \in w_2$

如果建立 $g(x) = (x-a)(x-b)$

决策规则 $\begin{cases} g(x) > 0, x \in w_1 \\ g(x) < 0, x \in w_2 \end{cases}$

一般形式 $g(x) = c_0 + c_1 x + c_2 x^2$

可转化为 $g(x) = a^T y = \sum_{i=1}^{3} a_i y_i$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix} \quad a = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix}$$

称 $g(x) = a^T y$ 广义线性判别函数

a 广义权向量

不适用于非凸和多连通区域划分

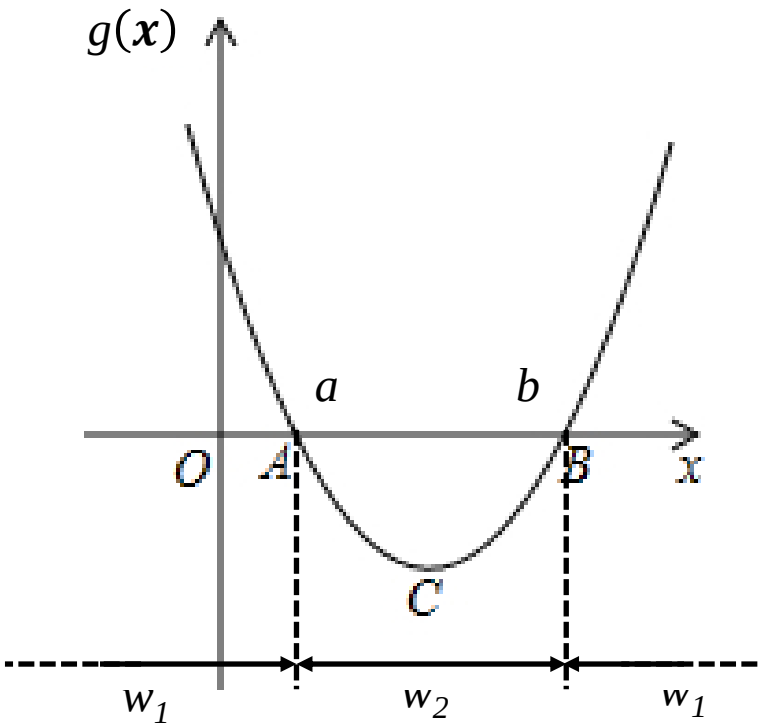

利用线性函数的简单性解决复杂问题

维数大大增加→“维数灾难”

线性判别函数齐次化

- **线性判别函数** $g(x) = w^T x + w_0$

改写成 $g(x) = w_0 + \sum_{i=1}^{d} w_i x_i = \sum_{i=1}^{d} a_i y_i = a^T y$

称为线性判别函数的齐次简化

$y = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} 1 \\ x \end{bmatrix}$**增广样本向量**；$a = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} w_0 \\ w \end{bmatrix}$**增广权向量**

$\hat{d} = d + 1$; ***y*比*x*增加一维，保持样本空间欧式距离不变，变换后的样本仍全部位于*d*维子空间(原*X*空间)中。**

方程 $a^T y = 0$**在*Y*空间确定了一个通过原点的超平面$\hat{H}$, 它对*d*维子空间的划分与原决策面** $w^T x + w_0 = 0$**对原*X*空间的划分完全相同。*Y*空间中任意一点*y*到$\hat{H}$的距离:**

$$r = \frac{g(x)}{\|a\|} = \frac{a^T y}{\|a\|}$$

线性分类器设计

- 利用训练样本建立线性判别函数

$$g(x) = \boxed{w^T} x + \boxed{w_0}$$

$$g(x) = w_0 + \sum_{i=1}^{d} w_i x_i = \sum_{i=1}^{d} a_i y_i = \boxed{a^T} y$$

最好的结果一般出现在准则函数的极值点上，所以**将分类器设计问题转化为求准则函数极值** w^*, w_0^* **或** a^* **的问题。**

步骤1： 具有类别标志的样本集$\mathcal{X} = \{x_1, x_2, \dots x_N\}$或其增广样本集$\mathcal{Y}$。

步骤2： 确定准则函数$\mathcal{J}$，满足①$\mathcal{J}$是样本集和w, w_0或a的函数；②$\mathcal{J}$的值反应分类器的性能，其极值对应“最好”的决策。

步骤3： 优化求解准则函数极值w^*, w_0^* 或a^* 。

最终得到线性判别函数：$g(x) = w^{*T} x + w_0^*$ 或 $g(x) = a^{*T} y$ ，对于未知类别样本x_k，计算$g(x_k)$并通过决策规则判断其类别。

准则函数

- Fisher准则
- 感知机准则
- 最小平方误差准则
- 最小错分样本数准则
- …

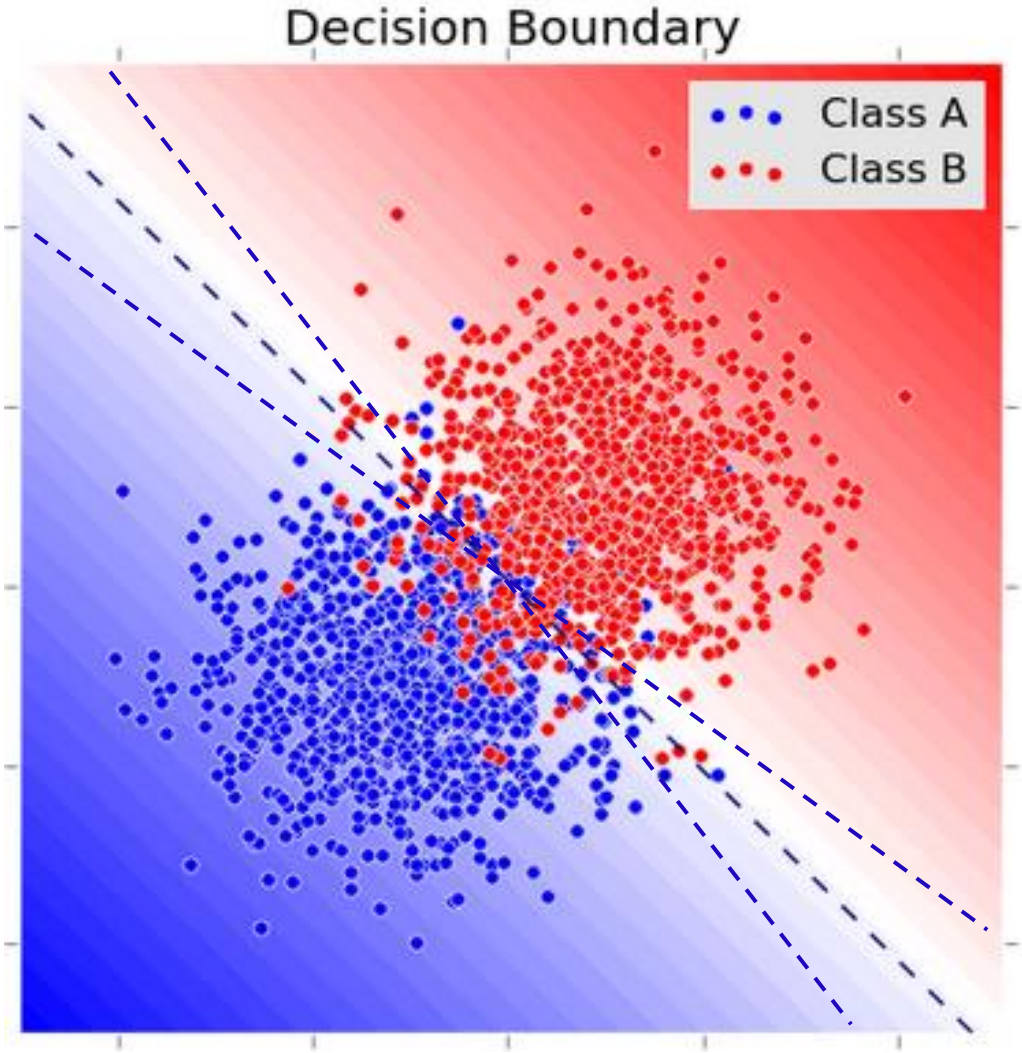

回顾：线性判别函数的基本概念

- 判别函数$g(x)$也可以**看作是特征空间中某个点x到超平面距离的一种代数度量**。若把x表示为：

$$\mathbf{x} = \boldsymbol{x}_p + r\frac{\boldsymbol{w}}{||\boldsymbol{w}||}$$

- 其中，**x_p是x到H的射影向量**，r是x到H的垂直距离，$\frac{\boldsymbol{w}}{||\boldsymbol{w}||}$是**$w$方向上**的单位向量。

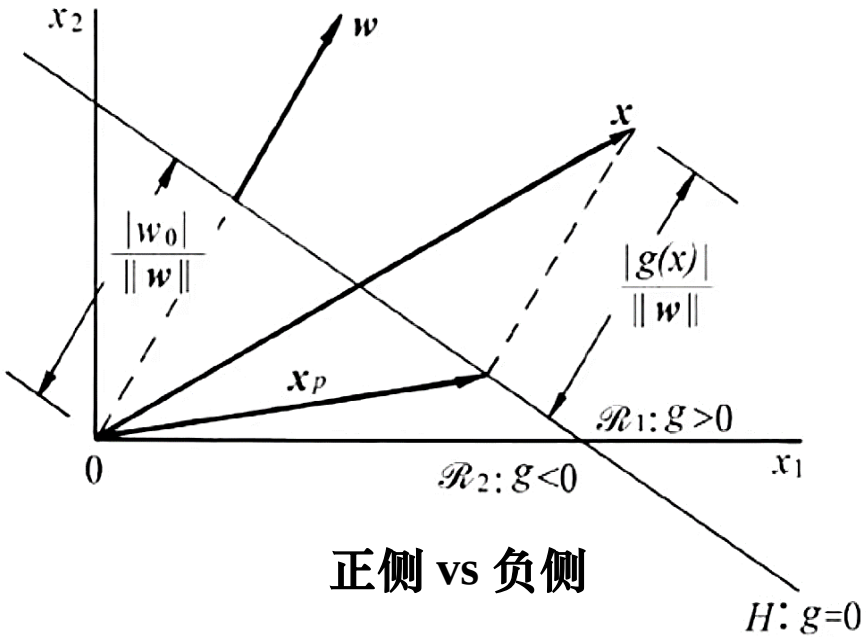

正侧 vs 负侧

Fisher准则

- **R. A. Fisher (1936年论文)**

考虑把 *d* 维空间的样本投影到一条直线上形成一维空间。在一般情况下总可以找到某个方向，使样本在这个方向的直线上的投影分开得最好。

Fisher准则就是要解决
如何根据实际情况找到这条最好的、最易于分类的投影线的问题

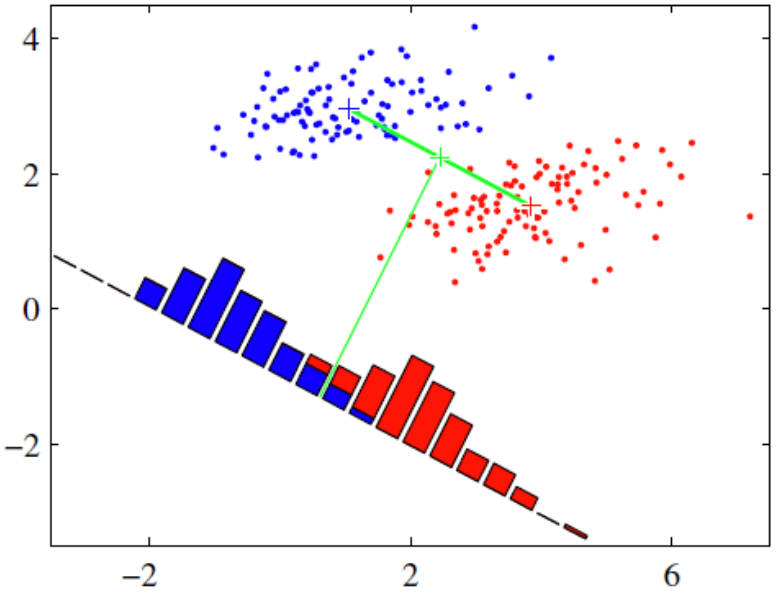

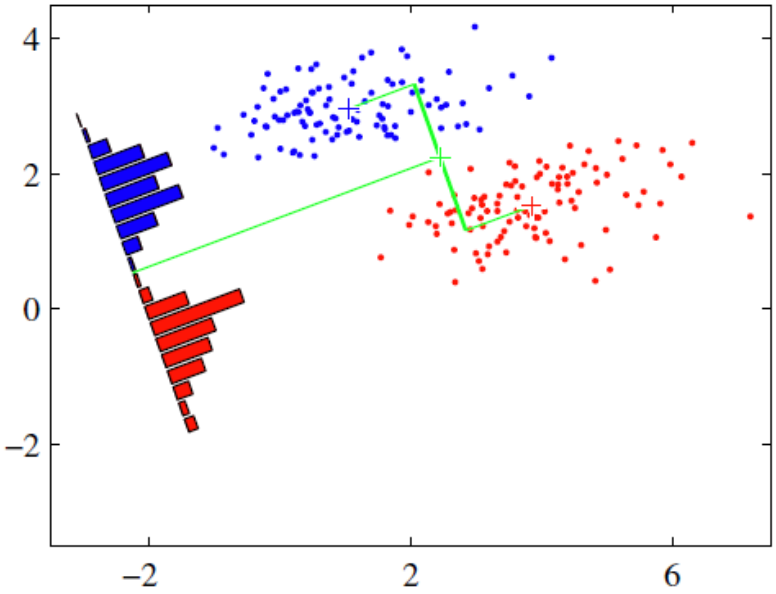

Fisher准则

- 寻找最好投影方向 w^*，首先定义目标准则的数学表达：

以二分类问题为例，d维样本$x_1, x_2, \ldots x_N$, 其中N_1个属于w_1类记为子集X_1, N_2个属于w_2类记为子集X_2。

在d维X空间

(1)各类样本的均值向量m_i $m_i = \frac{1}{N_i}\sum_{x\in\chi_i} x, i = 1, 2$

(2)原始空间内样本类内离散度矩阵S_i和总类内离散度矩阵S_w

$$S_i = \sum_{x\in\chi_i}(x - m_i)(x - m_i)^T, i = 1, 2$$

$$S_w = S_1 + S_2 \qquad S_w = P(w_1)S_1 + P(w_2)S_2$$

(3)样本类间离散度矩阵S_b

$$S_b = (m_1 - m_2)(m_1 - m_2)^T$$

$$S_b = P(w_1)P(w_2)(m_1 - m_2)(m_1 - m_2)^T$$

Fisher准则

- 寻找最好投影方向 w^*

以二分类问题为例，d维样本$x_1, x_2, \ldots x_N$, 其中N_1个属于w_1类记为子集X_1, N_2个属于w_2类记为子集X_2。

在投影以后的一维Y空间 $y_n = w^T x_n$

(1)各类样本均值$\tilde{m}_i$ $\tilde{m}_i = \frac{1}{N_i} \sum_{y \in \eta_i} y, i = 1, 2$

(2)样本类内离散度$\tilde{S}_i^2$和总类内离散度$\tilde{S}_w$

$$\tilde{S}_i^2 = \sum_{y \in \eta_i} (y - \tilde{m}_i)^2, i = 1, 2$$

$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$$

(3)而类间离散度$\tilde{S}_b$就成为了两类均值差的平方$(\tilde{m}_1 - \tilde{m}_2)^2$。

Fisher准则

- 希望投影后在一维Y空间中各类样本尽可能分开，即两类均值之差$(\tilde{m}_1 - \tilde{m}_2)$越大越好；同时希望各类样本内部尽量密集，即类内离散度越小越好。

Fisher准则函数：$J_F(w) = \dfrac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$

类间距

总类内离散度

Fisher线性判别分析

- **Fisher判别的基本思想:**

  希望投影后的一维数据满足: 1）两类之间的距离尽可能远; 2）每一类自身尽可能紧凑。

- **准则的描述:**

  用投影后数据的统计性质—均值和离散度的函数作为判别优劣的标准。

- **称** $S_b = (m_1 - m_2)(m_1 - m_2)^T$ **为类间离散度矩阵。**
- **称** $S_{\mathrm{w}} = S_1 + S_2$ **类内总离散度矩阵。代入到投影函数可得到关于w的函数:**

$$J_F(w) = \frac{w^T S_b w}{w^T S_{\mathrm{w}} w}$$

Fisher线性判别分析

- **Fisher准则的合理性：** $J_F(w)$**只与投影方向有关，与** w**的大小无关。即：若**w**是一个最优解,** kw**也是最优解，其中**k**是任何不为零的常数。**
- **因此，在求解时，可以假定分母项为非零的常数而最大化分子部分，可以转化为如下问题：**

$$\max\ \boldsymbol{w}^T\boldsymbol{S}_b\boldsymbol{w} \quad s.t.\ \boldsymbol{w}^T\boldsymbol{S}_w\boldsymbol{w} = c \neq 0$$

Fisher线性判别分析

- 对于该带等式约束的极值求解问题，可以使用Lagrange乘子法，转化为无约束的极值求解问题：

$$L(w,\lambda) = w^T S_b w - \lambda(w^T S_w w - \mathrm{c}).$$

$$\frac{\partial L(w,\lambda)}{\partial w} = S_b w - \lambda S_w w.$$

- 在极值处，应满足：

$$\frac{\partial L(w,\lambda)}{\partial w} = \mathbf{0}$$

- 最优解满足：

$$S_b \boldsymbol{w}^* - \lambda S_w \boldsymbol{w}^* = 0.$$

Fisher线性判别分析

- 假定S_w 是非奇异的，可以得到:

$$S_w^{-1}S_b w^* = \lambda w^*$$

- 也就是说，w^*是$S_w^{-1}S_b$ 的本征向量。把S_b代入，可进一步写为:

$$\lambda w^* = S_w^{-1}(m_1 - m_2)(m_1 - m_2)^T w^*$$

- 应该注意，$(m_1 - m_2)^T w^*$是标量，不影响w^*的方向，w^*的方向是由$S_w^{-1}(m_1 - m_2)$决定的，因此可取:

$$w^* = S_w^{-1}(m_1 - m_2) = (S_1 + S_2)^{-1}(m_1 - m_2)$$

- 这就是Fisher判别准则下的最优投影方向。

Fisher线性判别分析

- 步骤1：至此，我们还没有解决分类问题，只是将d维映射到1维（只给出了投影方向，没给出分类面），将d维分类问题转划为1维分类问题，如何分类?

- 步骤2：在投影之后的方向上确定分类阈值

Fisher线性判别分析

- 分类阈值b的确定
- 当两类样本总体先验概率相等时：
  - 两类均值的中点

$$b = \frac{\mu_1 + \mu_2}{2}$$

  - 投影后数据的均值（n_1, n_2是两类样本的个数）

$$b = \frac{n_1\mu_1 + n_2\mu_2}{n_1 + n_2}$$

在先验概率相同的情况下，以平分点为两类的分界点；
在先验概率不同时，分界点向先验概率小的一侧偏移。

感知机准则

- F. Rosenblatt(1950-1960年提出)

感知准则是一种自学习判别函数的生成方法，由于Rosenblatt试图将其用于脑模型感知器，因此得名。该方法对随意给定的判别函数初始值，通过样本分类训练过程逐步对其修正直至最终确定。

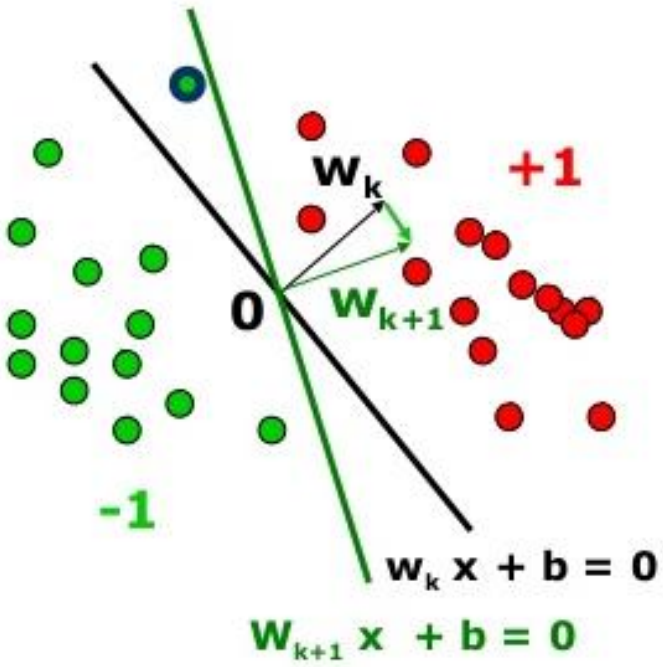

几个基本概念

- **线性可分性**

一组容量为N的样本集$y_1, y_2, \ldots y_N$, 其中y_n为$\hat{d}$维增广样本向量, 分别来自w_1类和w_2类, 如果存在权向量a, 使得对于任何$y \in w_1$, 都有$a^T y > 0$, 而对于任何$y \in w_2$, 都有$a^T y < 0$, 则称这组样本为线性可分的, 反之亦然成立。

- **样本的规范化**

$$\begin{cases} a^T y_i > 0, y_i \in w_1 \\ a^T y_j < 0, y_j \in w_2 \end{cases}$$

$$y_n' = \begin{cases} y_i > 0, y_i \in w_1 \\ -y_j < 0, y_j \in w_2 \end{cases}$$

规范化增广样本向量

$$a^T y_n' > 0, n = 1, 2, \ldots, N$$

线性可分的条件：存在向量a^*，使得上式成立； a^*为解向量

几个基本概念

- 解向量：存在向量a*，使得上式成立
- 解区：在权值空间内所有的解向量组成的区域

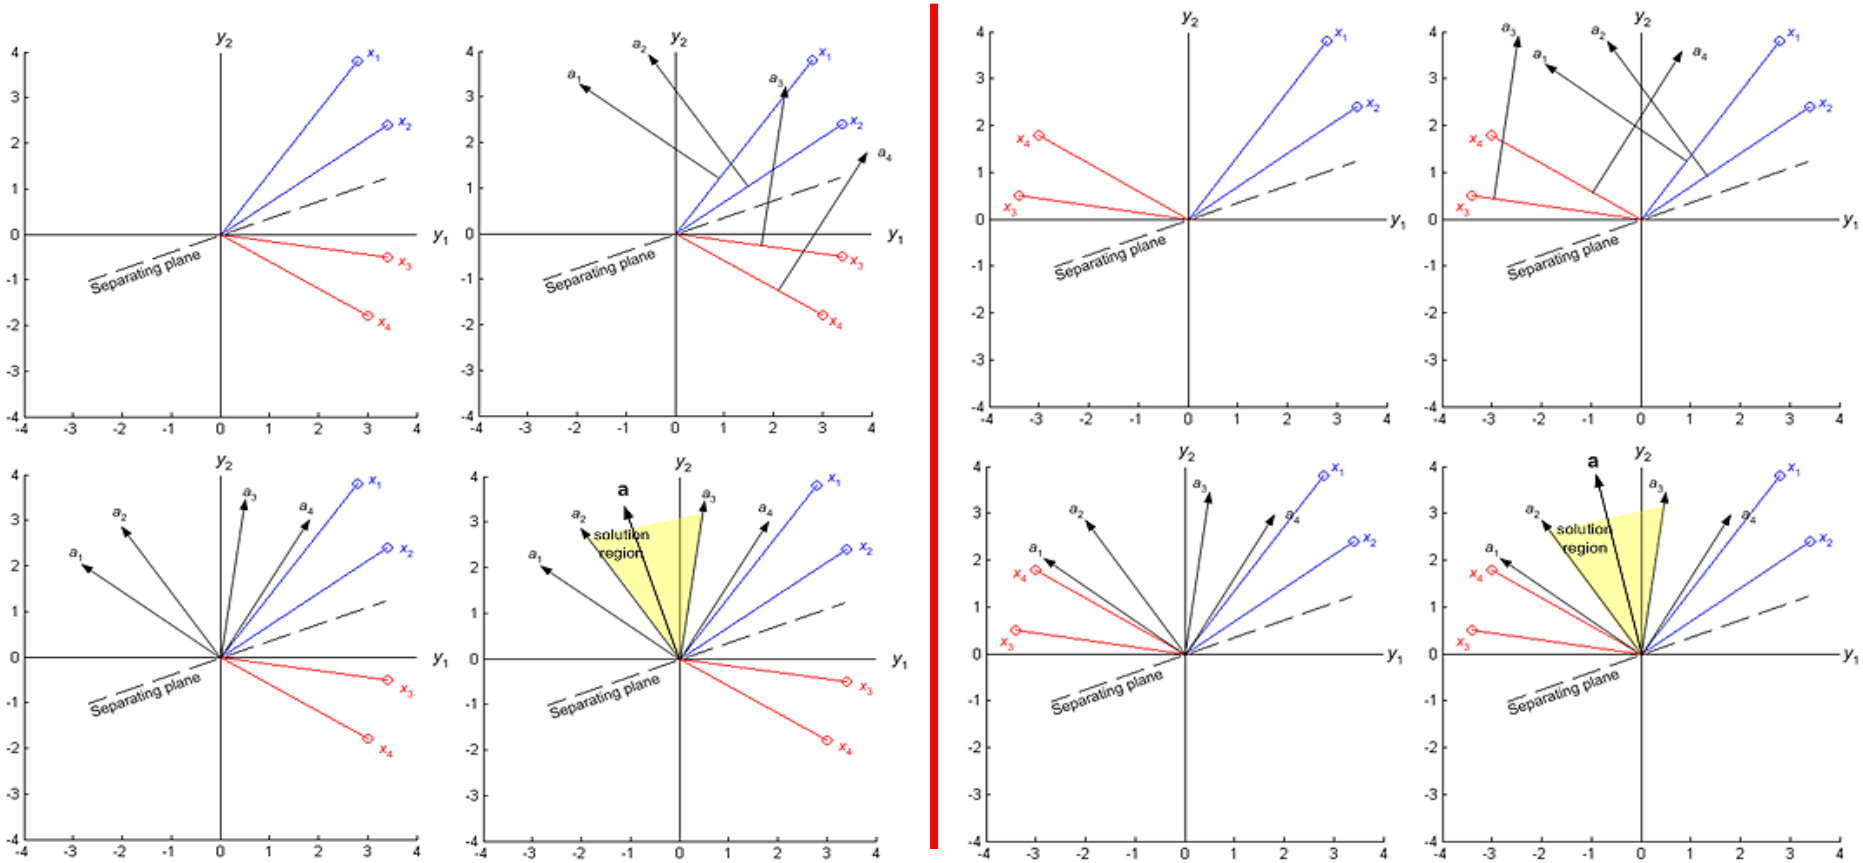

未规范化　　规范化

几个基本概念

- 对解区的限制：考虑噪声、数值误差等因素，靠近解区中间的解向量应该更加可靠。因此，提出余量的概念。

使解向量更可靠 $a^T y_n \geq b > 0$ ，避免解收敛到解区边界的某点上

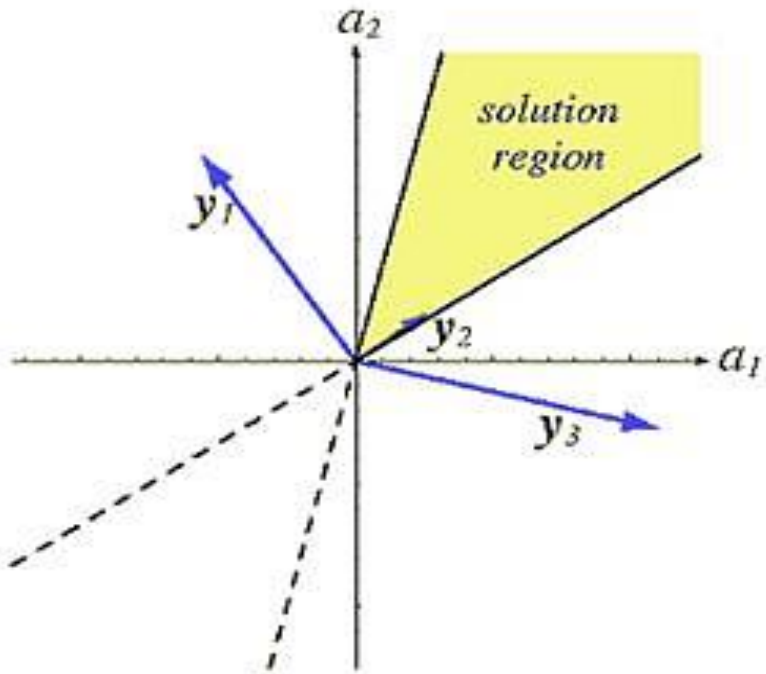

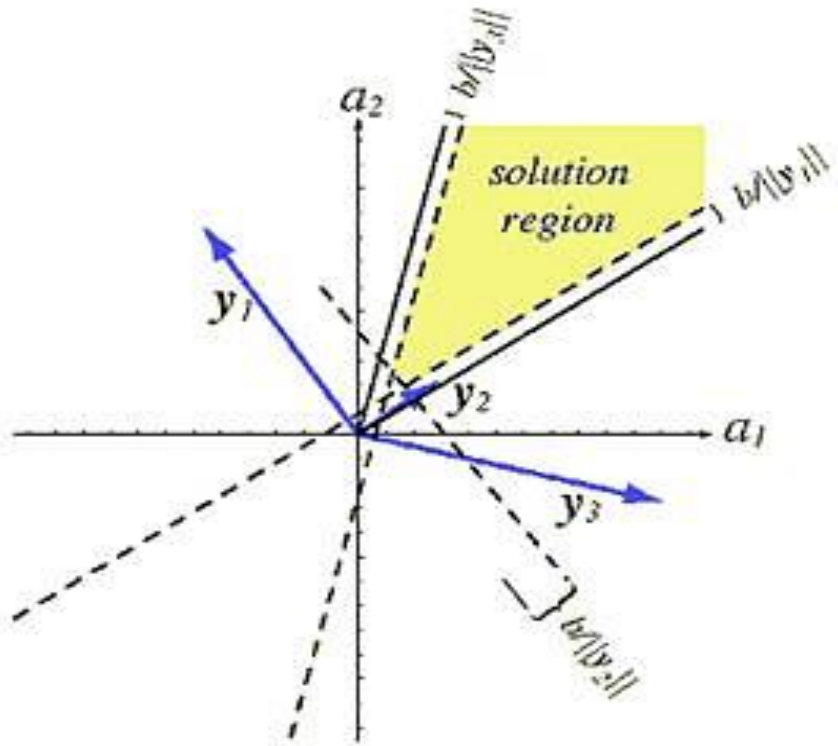

感知机准则

- **寻找解向量*a****

对于一组样本$y_1, y_2, \ldots y_N$, 其中y_n是规范化增广样本向量, 使得:

$$a^T y_n > 0, n = 1, 2, \ldots, N$$

对于线性可分问题，构造准则函数 $J_P(a) = \sum_{y \in \eta^k} (-a^T y)$

其中 η^k **是被权向量*a*错分的样本集合，即当*y*被错分时，就有** $a^T y_n \leq 0$

因此 $J_P(a) \geq 0$**，仅当*a*为解向量或在解区边界时**$J_P(a) = 0$

也就是说，当且仅当 η^k **为空集时** $J_P^*(a) = min J_P(a) = 0$

此时无错分样本，这时的*a*就是解向量*a。**

感知准则函数－梯度下降

- 求使 $J_P(a)$ 达到**最小值**的**a***，采用梯度下降法求解：

$$J_P(a) = \sum_{y \in \eta^k} (-a^T y)$$

$$\nabla J_P(a) = \frac{\partial J_P(a)}{\partial a} = \sum_{y \in \eta^k} (-y)$$

$$a(k+1) = a(k) - \rho_k \nabla J$$ **梯度下降法迭代公式**

$$a(k+1) = a(k) + \rho_k \nabla \sum_{y \in \eta^k} y$$

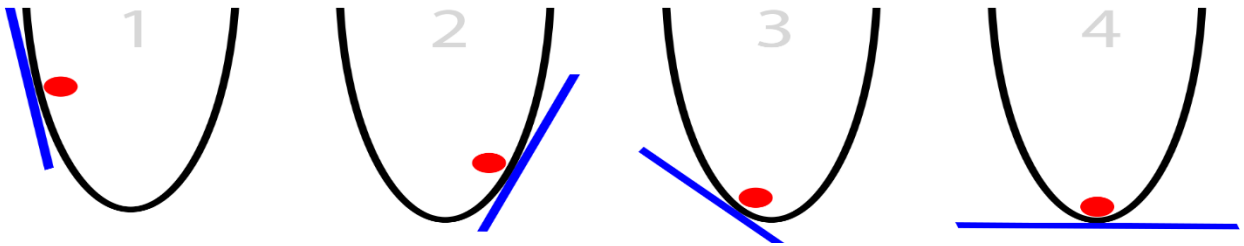

- 梯度下降算法：对(迭代)向量沿某函数的负梯度方向修正，可较快到达该函数极小值。

感知准则函数－梯度下降

- 算法具体步骤：

- 初值：任意给定一向量初始值 $a(0)$；
- 迭代：第k+1次迭代时的权向量 $a(k+1)$ 等于第 k 次的权向量 $a(k)$加上被错分类的所有样本之和与r_k的乘积；
- 终止：对所有样本正确分类。

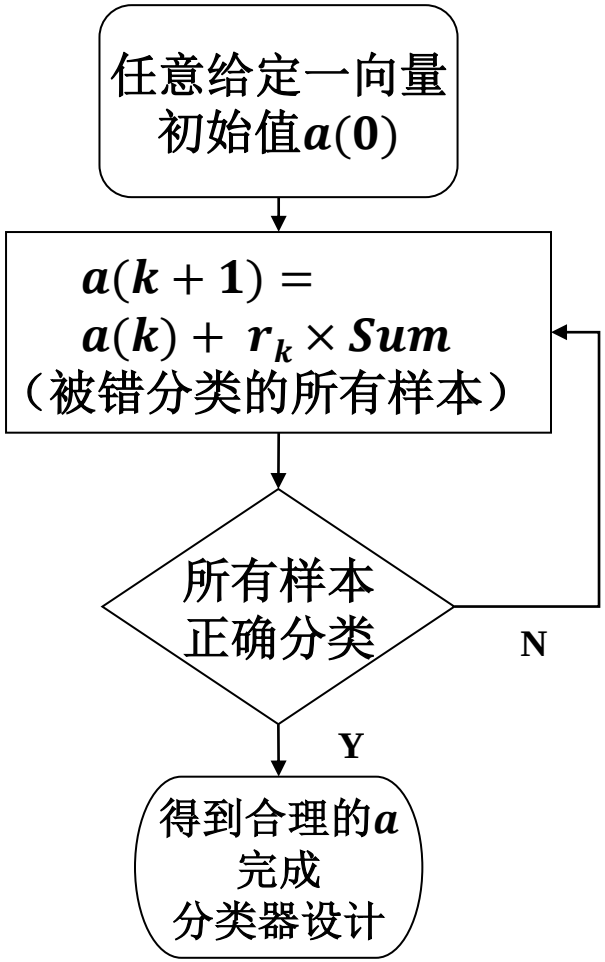

感知准则函数

- 固定增量法与可变增量法
- 批量样本修正法与单样本修正法
  - 单样本修正法：样本集视为不断重复出现的序列，逐个样本检查，修正权向量
  - 批量样本修正法：样本成批或全部检查后，修正权向量
- 只要解区间存在，那么经过有限的步骤后可以得到一个解向量。

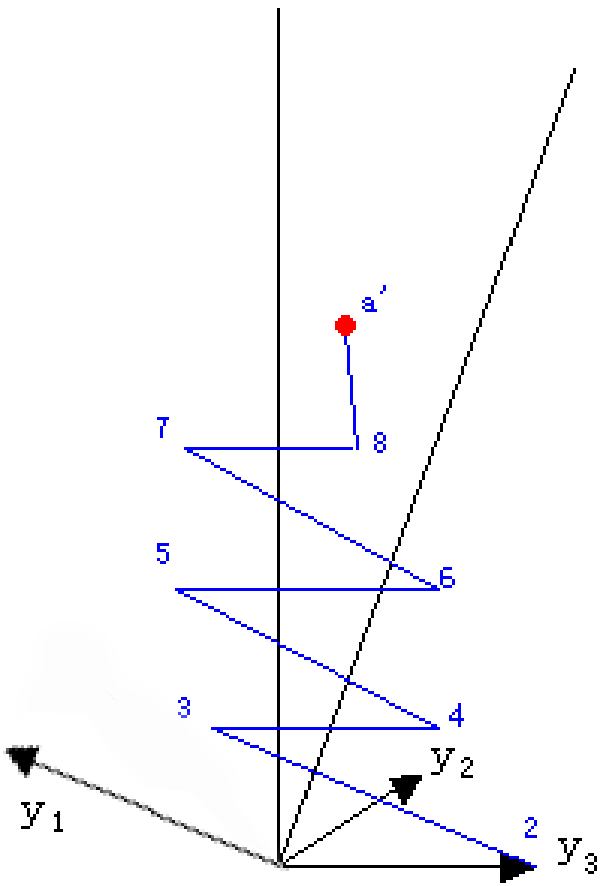

感知机准则-示例

- Sample set for two-class case
  - Class 1

$$\mathbf{x}_1 = \begin{pmatrix} -2 \\ 2 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} -2 \\ -2 \end{pmatrix} \qquad \mathbf{y}_1 = \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix}, \mathbf{y}_2 = \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix}$$

  - Class 2

$$\mathbf{x}_3 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \mathbf{x}_4 = \begin{pmatrix} 2 \\ -1 \end{pmatrix} \qquad \mathbf{y}_3 = \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix}, \mathbf{y}_4 = \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix}$$

  - Initial weight vector

$$\mathbf{a}(1) = \begin{pmatrix} 0 \\ 2 \\ 1 \end{pmatrix} \qquad \mathbf{a}(1)^t = \begin{pmatrix} 0 & 2 & 1 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (1) $\mathbf{y}^{(1)t} = \begin{pmatrix} 1 & -2 & 2 \end{pmatrix}$

$$\mathbf{a}(1)^t \mathbf{y}^{(1)} = \begin{pmatrix} 0 & 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix} = -2 < 0$$

$$\mathbf{a}(2)^t = \begin{pmatrix} 0 & 2 & 1 \end{pmatrix} + \begin{pmatrix} 1 & -2 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 3 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (2) $\mathbf{y}^{(2)t} = \begin{pmatrix} 1 & -2 & -2 \end{pmatrix}$

$$\mathbf{a}(2)^t \mathbf{y}^{(2)} = \begin{pmatrix} 1 & 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix} = -5 < 0$$

$$\mathbf{a}(3)^t = \begin{pmatrix} 1 & 0 & 3 \end{pmatrix} + \begin{pmatrix} 1 & -2 & -2 \end{pmatrix} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (3)

$$\mathbf{y}^{(3)t} = \begin{pmatrix} -1 & -2 & -1 \end{pmatrix}$$

$$\mathbf{a}(3)^t \mathbf{y}^{(3)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix} = 1 > 0$$

$$\mathbf{a}(4)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \text{ (no chnage)}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (4) $\mathbf{y}^{(4)t} = \begin{pmatrix} -1 & -2 & 1 \end{pmatrix}$

$$\mathbf{a}(4)^t \mathbf{y}^{(3)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix} = 3 > 0$$

$$\mathbf{a}(5)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \text{ (no chnage)}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (5)

$$\mathbf{y}^{(5)t} = \begin{pmatrix} 1 & -2 & 2 \end{pmatrix}$$

$$\mathbf{a}(5)^t \mathbf{y}^{(1)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix} = 8 > 0$$

$$\mathbf{a}(6)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \qquad \text{(no change)}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (6)

$$\mathbf{y}^{(6)t} = \begin{pmatrix} 1 & -2 & -2 \end{pmatrix}$$

$$\mathbf{a}(6)^t \mathbf{y}^{(2)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix} = 4 > 0$$

$$\mathbf{a}(7)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (7)

$$\mathbf{y}^{(7)t} = \begin{pmatrix} -1 & -2 & -1 \end{pmatrix}$$

$$\mathbf{a}(7)^t \mathbf{y}^{(7)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix} = 1 > 0$$

$$\mathbf{a}(8)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \text{ (no chnage)}$$

感知准则函数－小结

- 感知准则函数方法的思路：
- 先随意找一个初始向量$a(1)$，然后用训练样本集中的每个样本来计算。
- 若发现一个y出现$a^T y < 0$，则只要$a(k+1) = a(k) + r_k y$，r_k为正(步长系数)，则必有$a(k+1)^T y = a(k)^T y + r_k y^T y$，就有趋势做到使$a(k+1)^T y > 0$。
- 当然，修改后的$a(k+1)$还可以使某些y出现$a(k+1)^T y < 0$的情况，理论证明，只要训练样本集线性可分，无论$a(1)$的初值是什么，经过有限次叠代，都可收敛。

感知准则函数－小结

- 结果不唯一且在线性不可分情况下不收敛

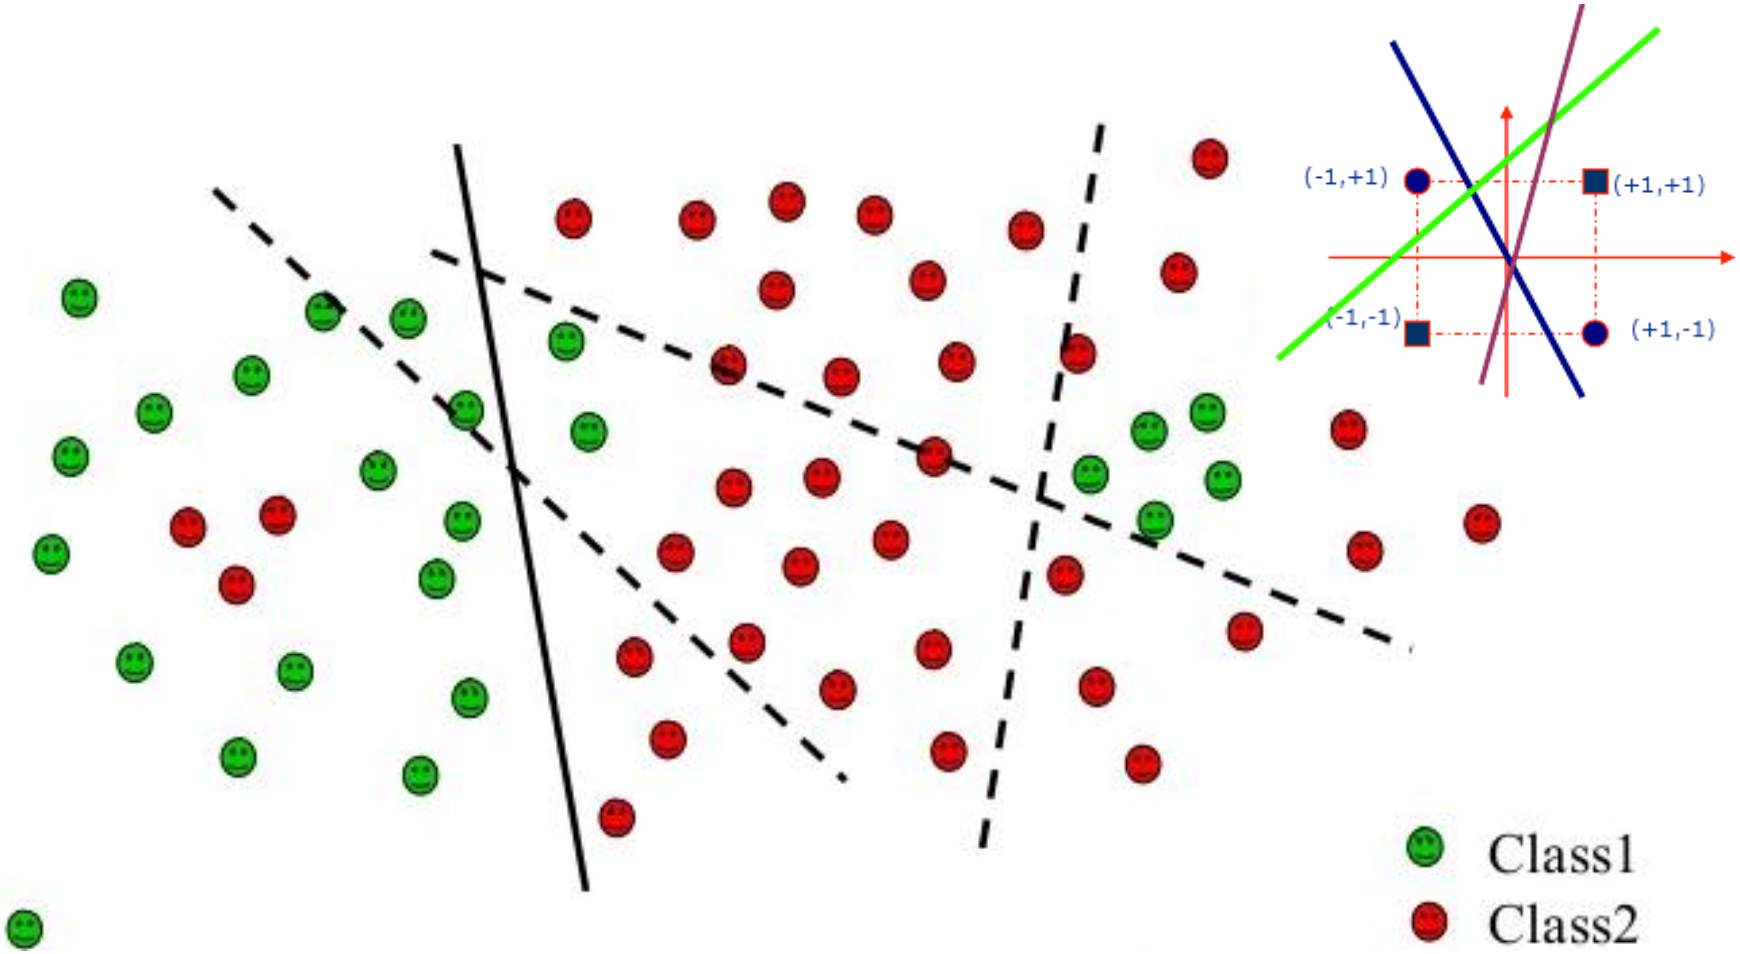

最小平方误差准则函数

- A.-M. Legendre(1806提出)，C. Gauss(1809提出/1829证明)

最小二乘法(最小平方误差法)通过最小化误差的平方和寻找数据的最佳函数匹配，即可以使求得的数据与实际数据之间误差的平方和最小。

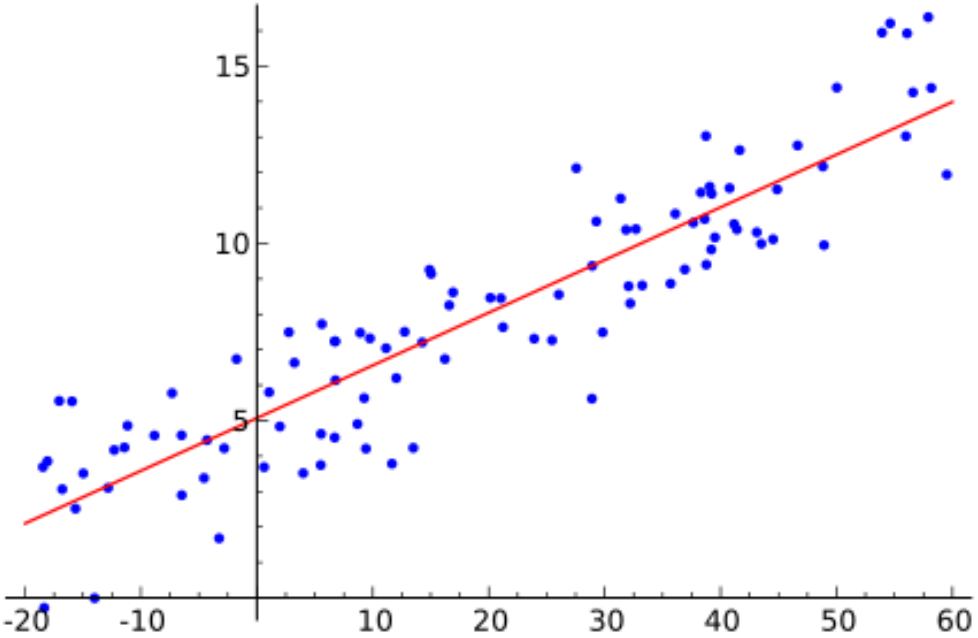

最小平方误差准则函数

- 寻找最好投影方向 a^*

$$a^T y_n > 0$$

通常采用搜索算法求解

$$a^T y_n = b_n > 0$$

b_n是任意给定的正常数

方程组形式：

$$Ya = b$$

$$Y = \begin{bmatrix} y_1^T \\ y_2^T \\ \vdots \\ y_N^T \end{bmatrix} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1\hat{d}} \\ y_{21} & y_{22} & \cdots & y_{2\hat{d}} \\ \cdots & \cdots & \cdots & \cdots \\ y_{N1} & y_{N2} & \cdots & y_{N\hat{d}} \end{bmatrix}$$

y_n是规范化增广向量样本

Y是$N \times \hat{d}$维矩阵，通常$N > \hat{d}$，一般为列满秩阵

$$b = [b_1 \quad b_2 \quad \cdots \quad b_N]$$

b是N维向量，b_n>0， n=1, 2, …, N

方程数多于未知数的矛盾方程组通常没有精确解

定义误差向量：$e = Ya - b$，及平方误差准则函数：

$$J_S(a) = \|e\|^2 = \|Ya - b\|^2 = \sum_{n-1}^{N} (a^T y_n - b_n)^2$$

最小平方误差准则函数

- 求使 $J_S(a)$ 最小的a^* (最小二乘近似解/伪逆解/MSE解)

采用解析法求伪逆解 $J_S(a) = \|e\|^2 = \|Ya - b\|^2 = \sum_{1}^{N}(a^T y_n - b_n)^2$

$$\nabla J_S(a) = \sum_{n-1}^{N} 2(a^T y_n - b_n) y_n = 2Y^T(Ya - b)$$

令 $\nabla J_S(a) = 0$

得 $Y^T Y a^* = Y^T b$ 矩阵$Y^T Y$是$\hat{d} \times \hat{d}$方阵一般非奇异

唯一解 $a^* = (Y^T Y)^{-1} Y^T b = Y^+ b$

其中$\hat{d} \times N$矩阵 $Y^+ = (Y^T Y)^{-1} Y^T$ 是长方矩阵Y的左逆矩阵/伪逆

如何选b?

$$\boldsymbol{b} = \begin{bmatrix} N/N_1 \\ \cdots \\ N/N_1 \\ N/N_2 \\ \cdots \\ N/N_2 \end{bmatrix} \begin{matrix} N_1\text{个} \\ \\ \\ N_2\text{个} \end{matrix}$$

➡ 如果同一类样本对应的b_i为相同的值，a*等价于Fisher解

$$\boldsymbol{N \to \infty, b = [\underbrace{1, 1, \cdots, 1}_{N\text{个}}]^T}$$

➡ $g_0(x) = P(w_1|x) - P(w_2|x)$

以最小均方误差逼近贝叶斯判别函数

最小平方误差准则函数

- 求使 $J_S(a)$ 最小的a^* (最小二乘近似解/伪逆解/MSE解)

$$a^* = Y^+ b \qquad Y^+ = (Y^T Y)^{-1} Y^T$$

问题：①要求Y^TY非奇异；②求Y^+计算量大同时可能引入较大误差。

采用梯度下降法求解：$\nabla J_S(a) = 2Y^T(Ya - b)$

$$\begin{cases} a(1), Random \\ a(k+1) = a(k) - \rho_k Y^T(Ya - b) \end{cases}$$

可以证明，选择 $\rho_k = \dfrac{\rho_1}{k}$，$\rho_1$是任意常数

该算法权向量收敛于使 $\nabla J_S(a) = 2Y^T(Ya - b) = 0$ 的权向量a^*

不要求Y^TY奇异与否，只计算$\hat{d} \times \hat{d}$方阵Y^TY，比$\hat{d} \times N$阵Y^+计算量小

最小平方误差准则函数

- 对于异常值(Outlier)非常敏感

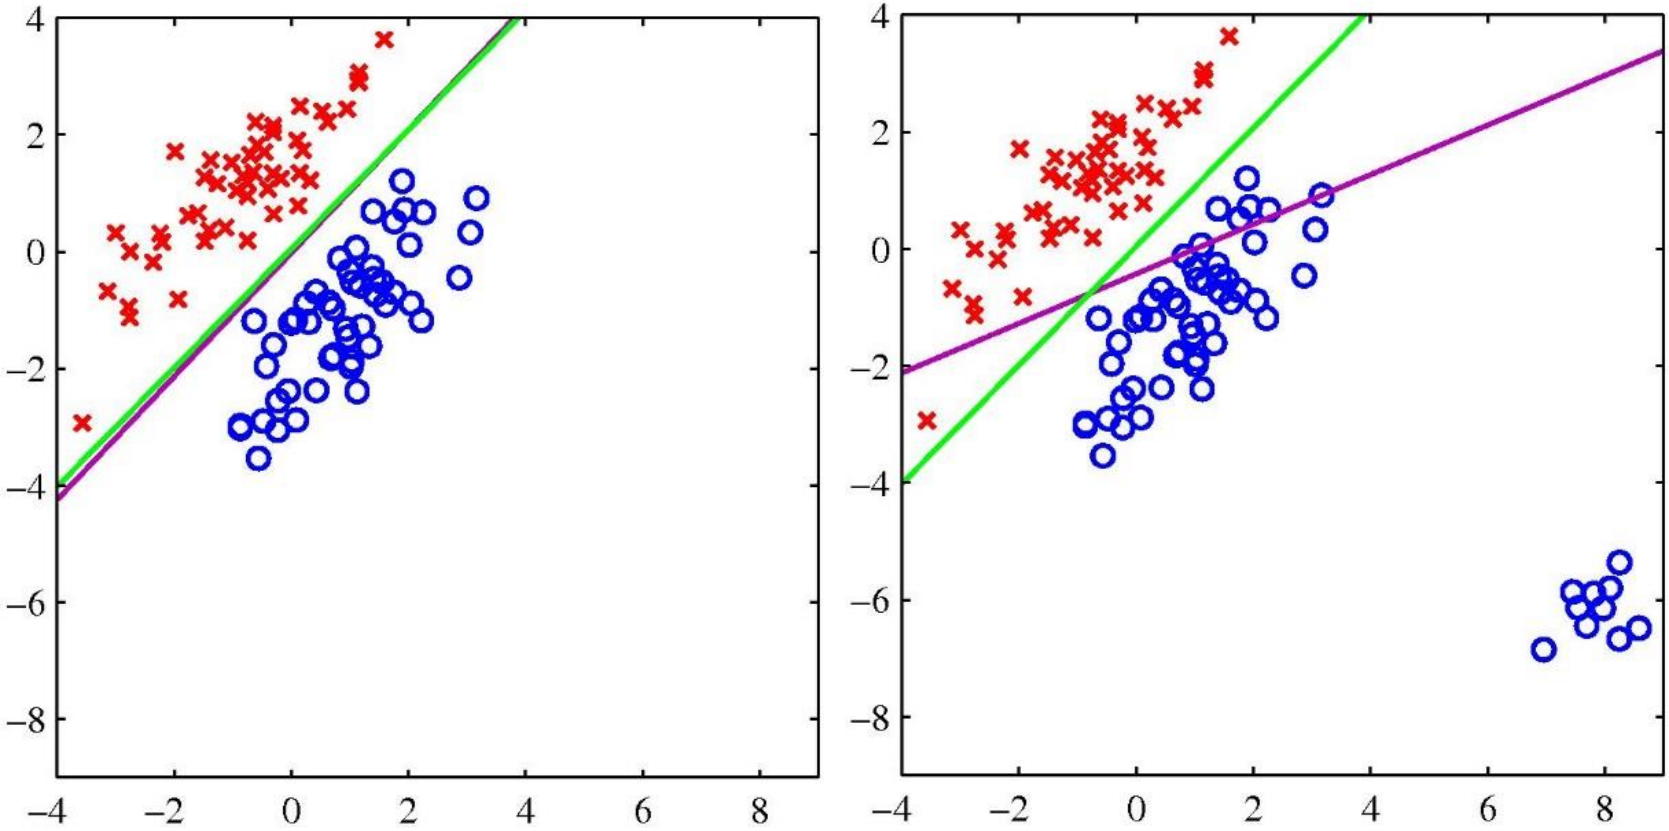

最小平方误差准则函数

- 对于异常值(Outlier)非常敏感

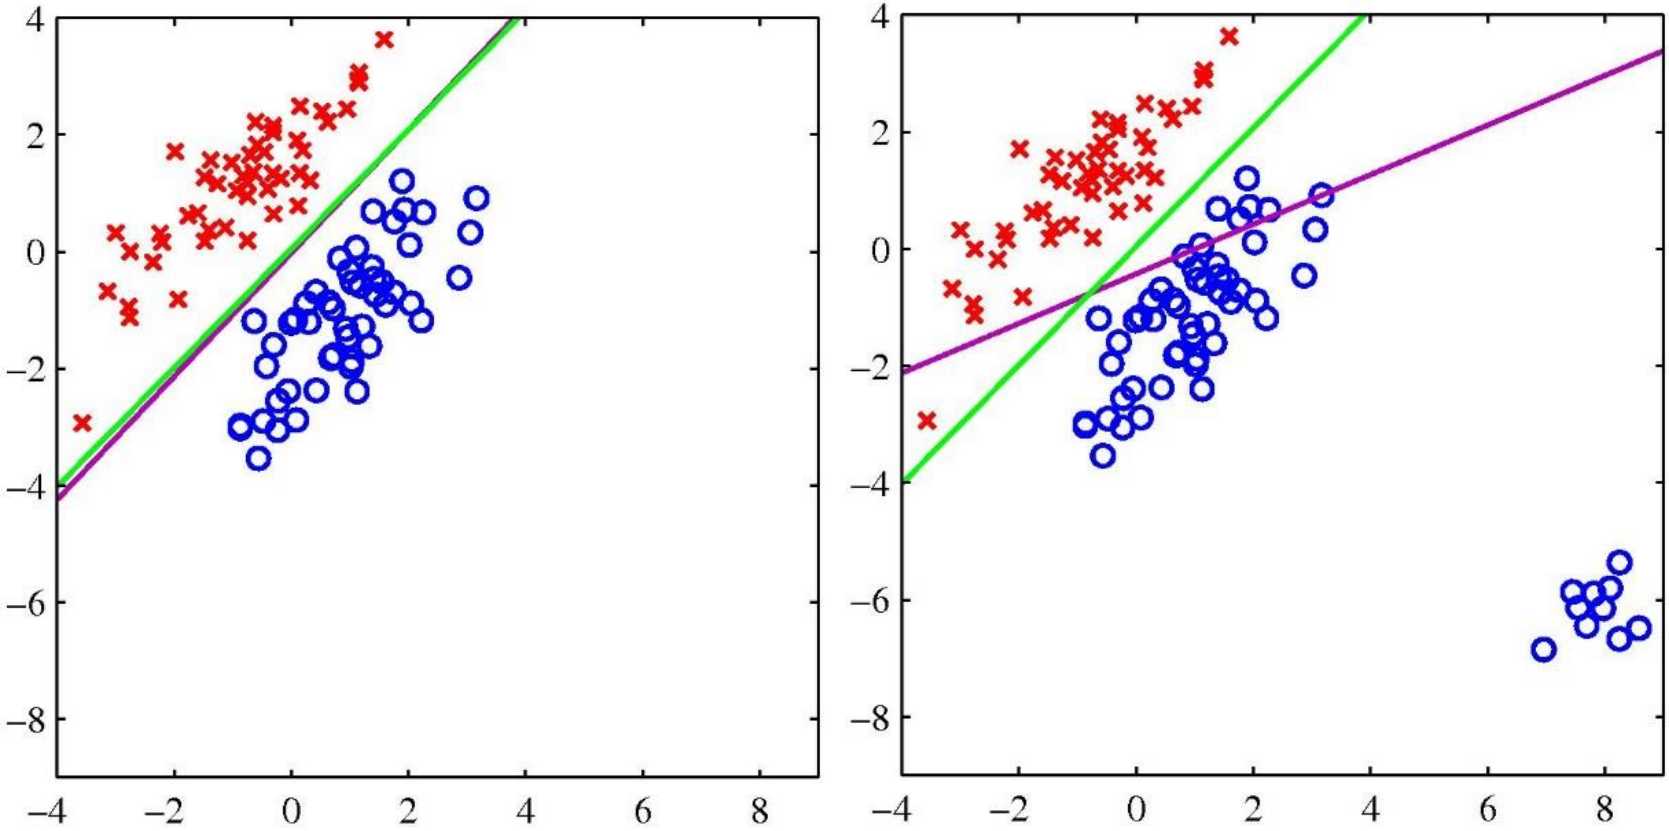

最小平方误差准则– 示例

假设函数：$h_\theta(x)$

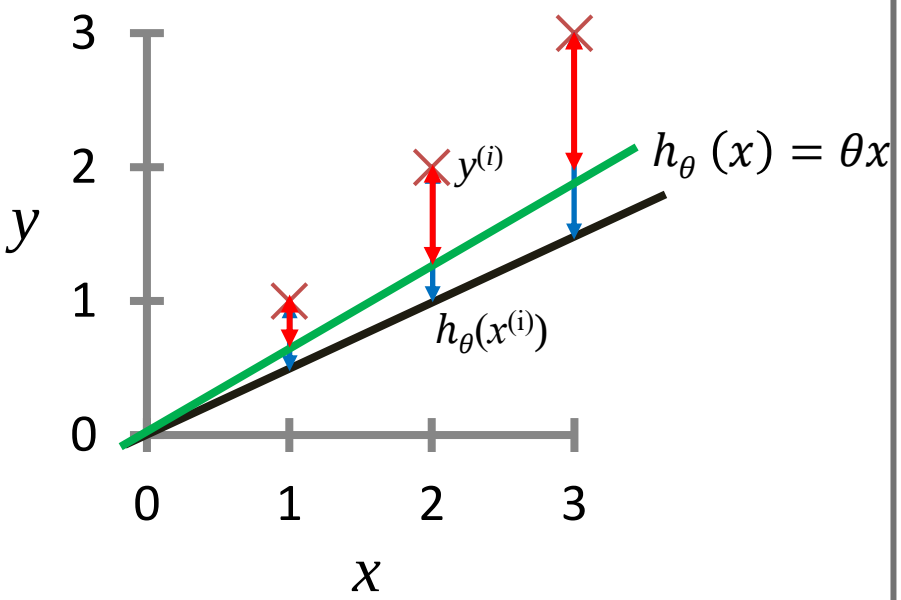

代价函数：$J(\theta)$

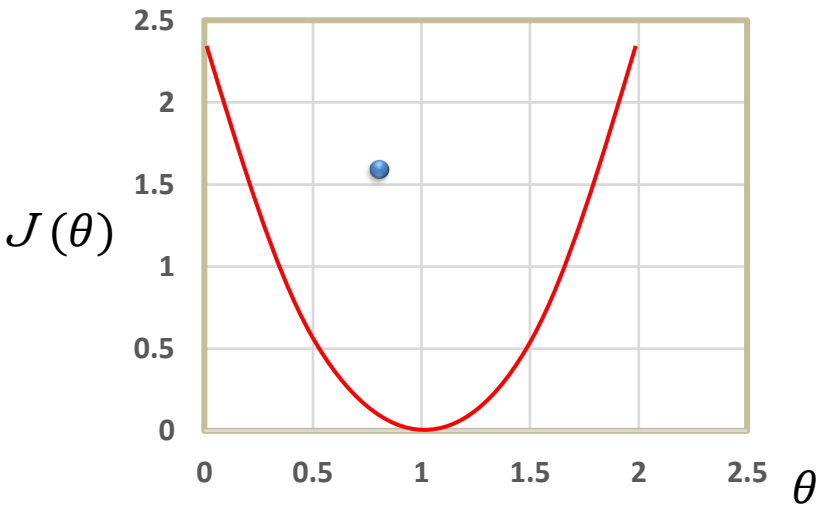

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})^2$$

最小平方误差准则– 示例

假设函数： $h_\theta(x)$

代价函数： $J(\theta_0, \theta_1)$

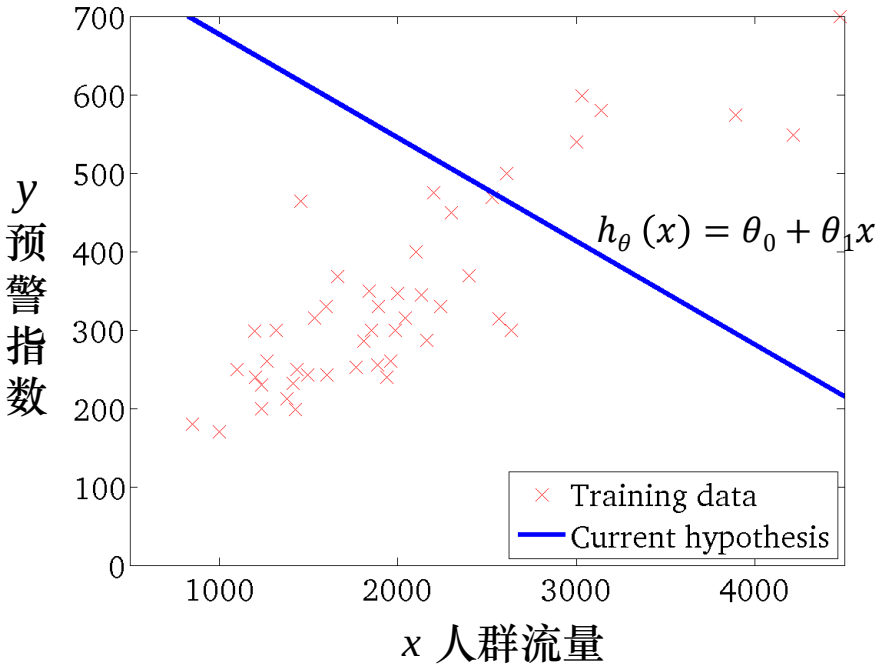

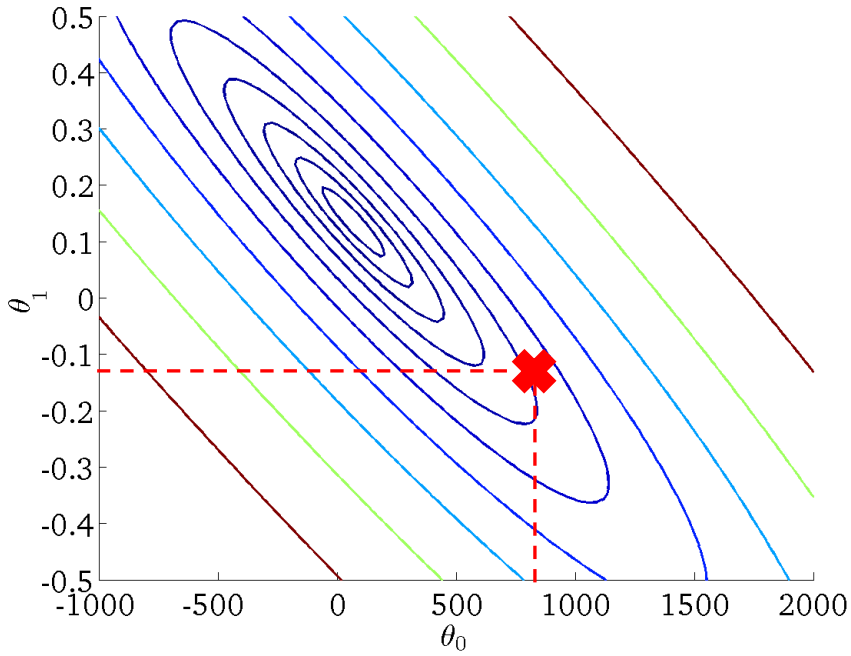

最小平方误差准则– 示例

假设函数： $h_\theta(x) = \theta_0 + \theta_1 x$

代价函数： $J(\theta_0, \theta_1)$

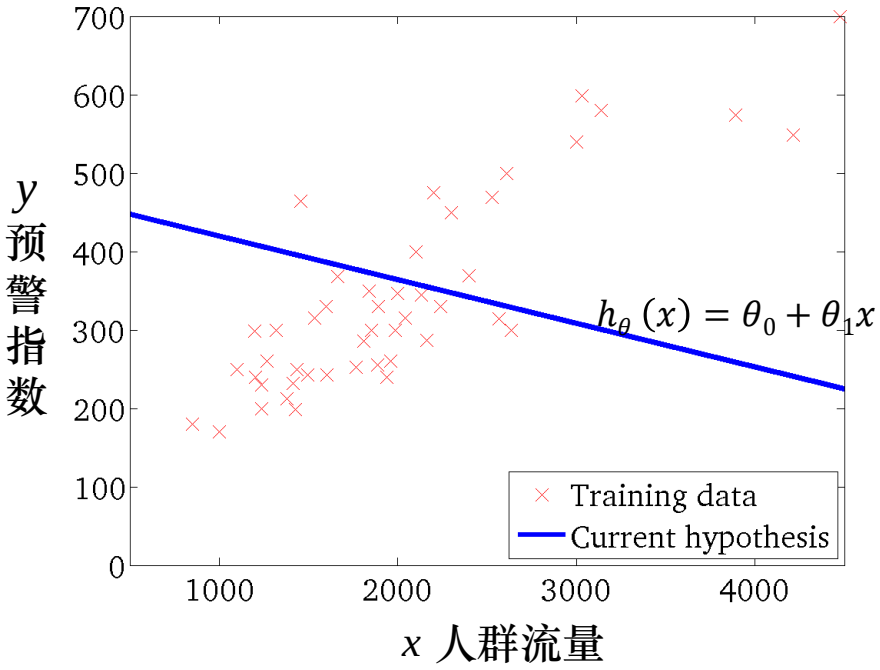

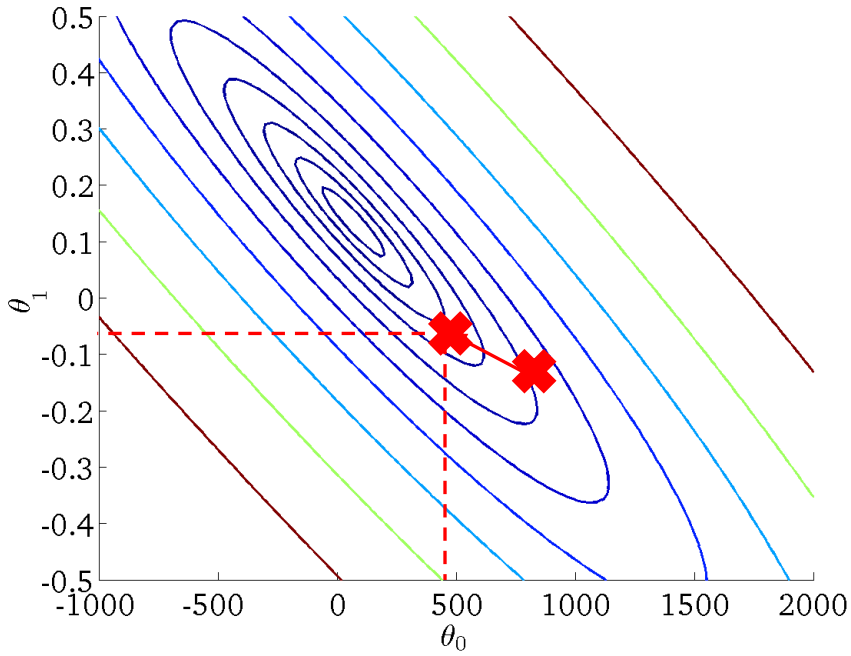

最小平方误差准则– 示例

假设函数： $h_\theta(x)$

代价函数： $J(\theta_0, \theta_1)$

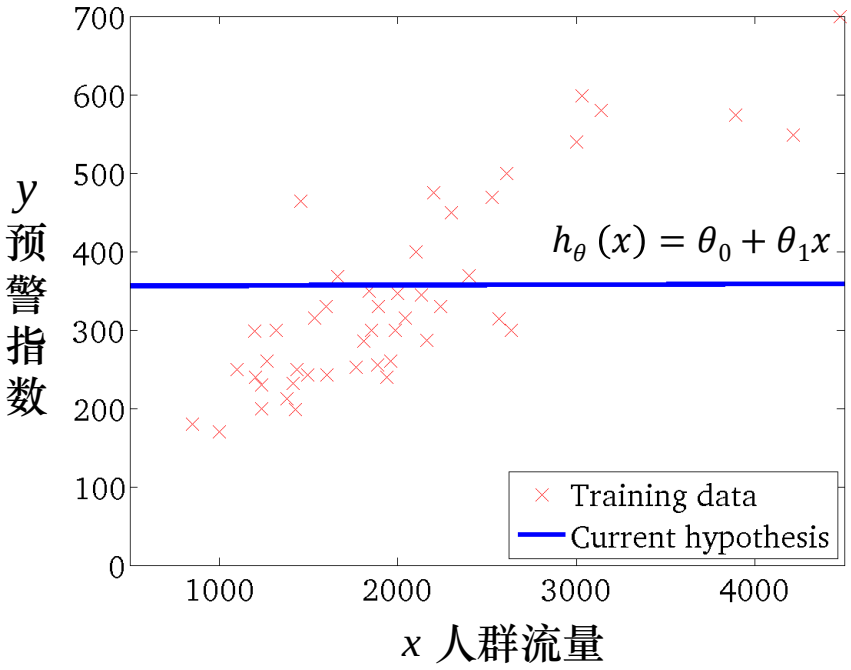

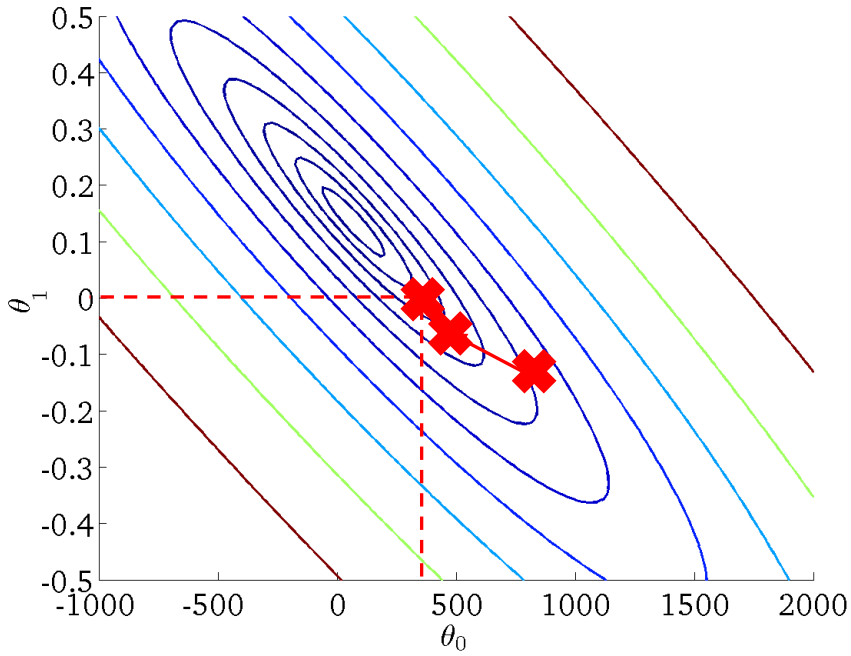

最小平方误差准则– 示例

假设函数： $h_\theta(x)$

代价函数： $J(\theta_0, \theta_1)$

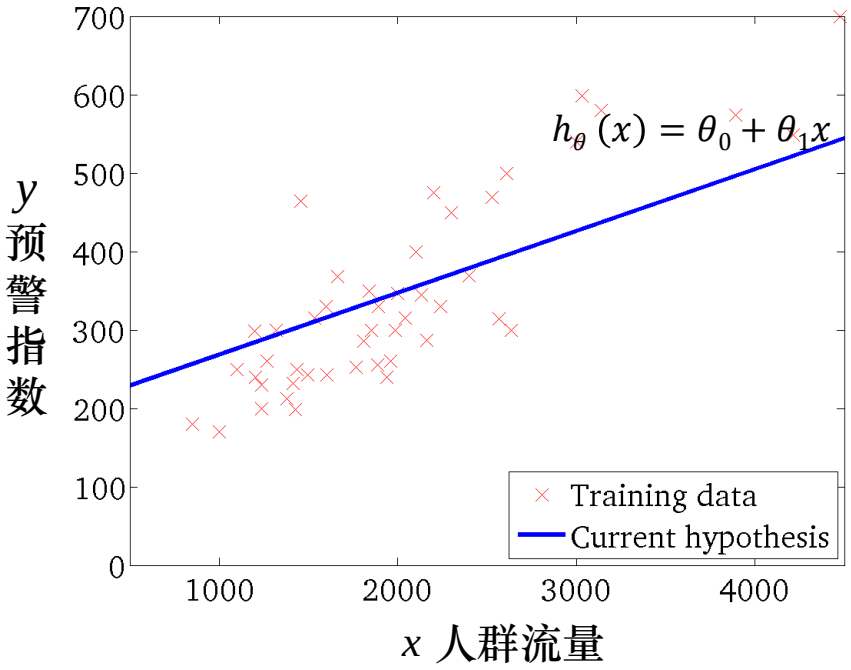

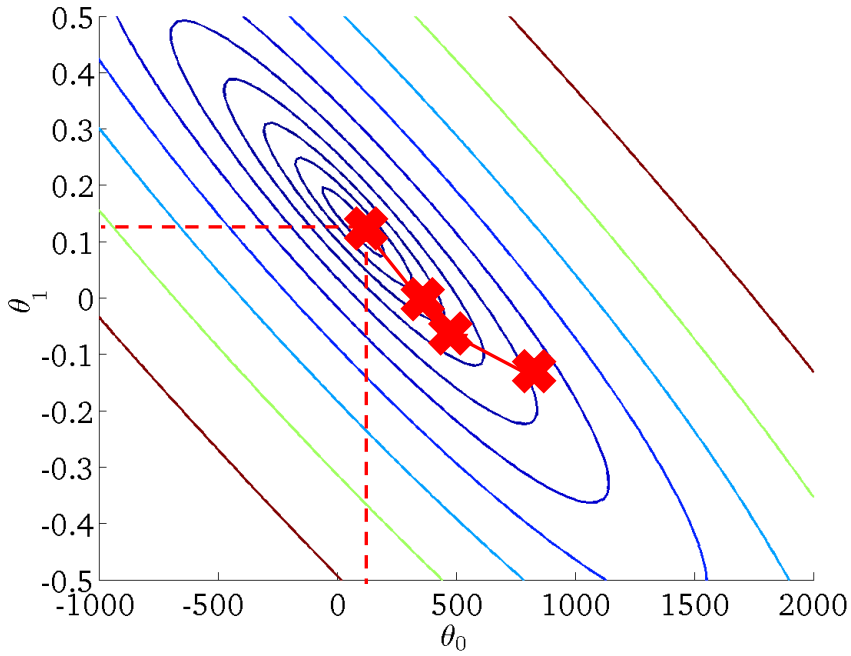

最小平方误差准则函数

- 感知准则 v.s.最小平方误差准则

Perceptron

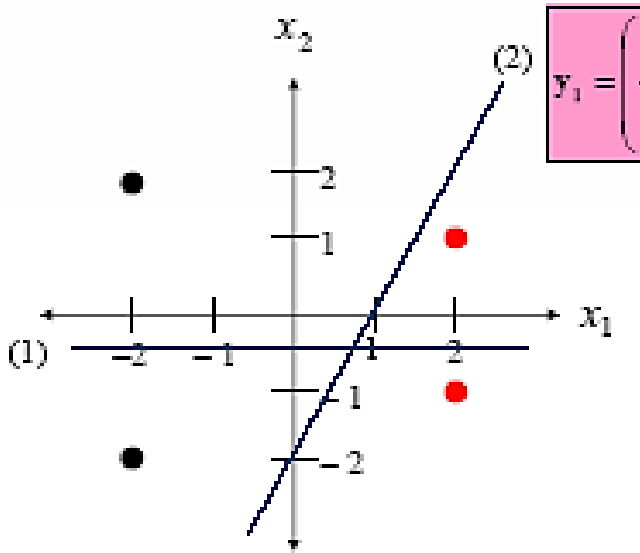

$$y_1 = \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix}, y_2 = \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix}$$

$$Ya = b$$

$$\begin{pmatrix} 1 & -2 & 2 \\ 1 & -2 & -2 \\ -1 & -2 & -1 \\ -1 & -2 & 1 \end{pmatrix} \begin{pmatrix} 2 \\ -2 \\ 1 \end{pmatrix} = \begin{pmatrix} 8 \\ 4 \\ 1 \\ 3 \end{pmatrix}$$

$$a = \begin{pmatrix} 2 \\ -2 \\ 1 \end{pmatrix}$$

MSE

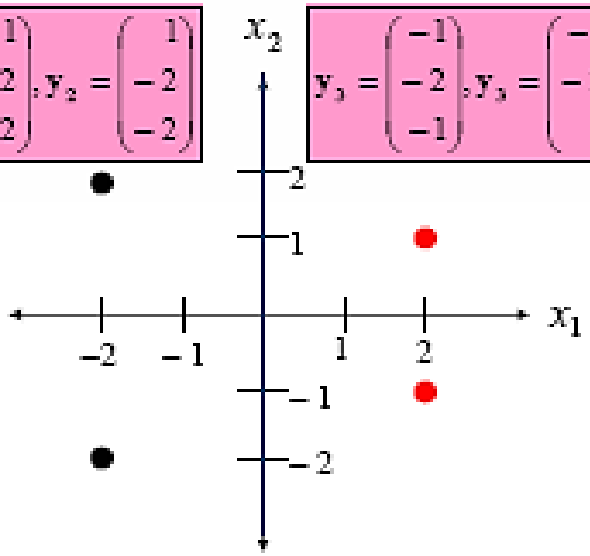

$$y_3 = \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix}, y_3 = \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & -2 & 2 \\ 1 & -2 & -2 \\ -1 & -2 & -1 \\ -1 & -2 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ -20 \\ 0 \end{pmatrix} = \begin{pmatrix} 40 \\ 40 \\ 40 \\ 40 \end{pmatrix}$$

$$a = \begin{pmatrix} 0 \\ -20 \\ 0 \end{pmatrix}$$

最小平方误差准则函数

- **感知准则**
  - 如果类是线性可分的，感知器规则总是找到一个解；但如果类是不可分的，则不会收敛。
- **最小平方误差准则**
  - MSE的解具有收敛性。但是尽管对于线性可分的类别，MSE准则找到的超平面可能仍无法准确地分离所有样本；
  - MSE试图最小化训练数据到超平面距离的平方和，而不是找到一个完全可分的超平面。

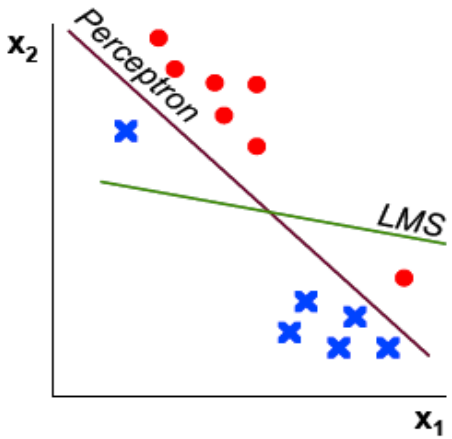

多分类问题

- **三类方法**
- c-1 two-class problems 用c-1个超平面把特征空间划分为c个区域
  - Separate points assigned to ω_i from those not assigned to ω_i
- $c(c-1)/2$ two-class problems 每两类构造一个分类器
  - Separate every pair of classes.
- Define c linear discriminant functions 所有线性分类器转化为线性判别判别函数
  - Assign x to ω_i if $g_i(x)>g_j(x)$ for all $j \neq i$

$$g_i(x) = w_i^t x + w_{i0} \quad i=1,\ldots,c$$

多分类问题

- c-1 二分类问题
- 问题：1）两类样本不均衡导致分类面有偏，样本数量少的类别易发生分类错误
- 问题：2）往往不会恰好得到c个区域，造成特征空间内部分区域歧义

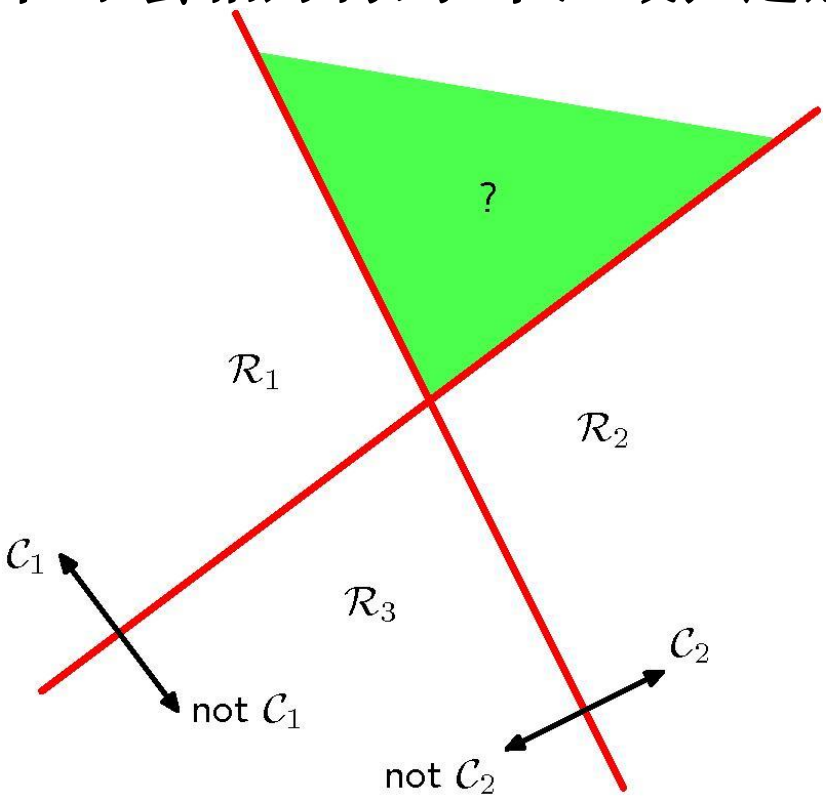

多类问题

- c(c-1)/2 二分类问题
- 可以转换为比较多个两类线性分类器的输出的问题

A

$H_{12}: 1 > 2$
$H_{13}: 1 > 3$
$H_{14}: 1 > 4$
$H_{23}: 2 > 3$
$H_{24}: 4 > 2$
$H_{34}: 3 > 4$

B

$H_{12}: 1 > 2$
$H_{13}: 3 > 1$
$H_{14}: 4 > 1$
$H_{23}: 2 > 3$
$H_{24}: 4 > 2$
$H_{34}: 3 > 4$

C

$H_{12}: 2 > 1$
$H_{13}: 1 > 3$
$H_{14}: 1 > 4$
$H_{23}: 2 > 3$
$H_{24}: 2 > 4$
$H_{34}: 4 > 3$

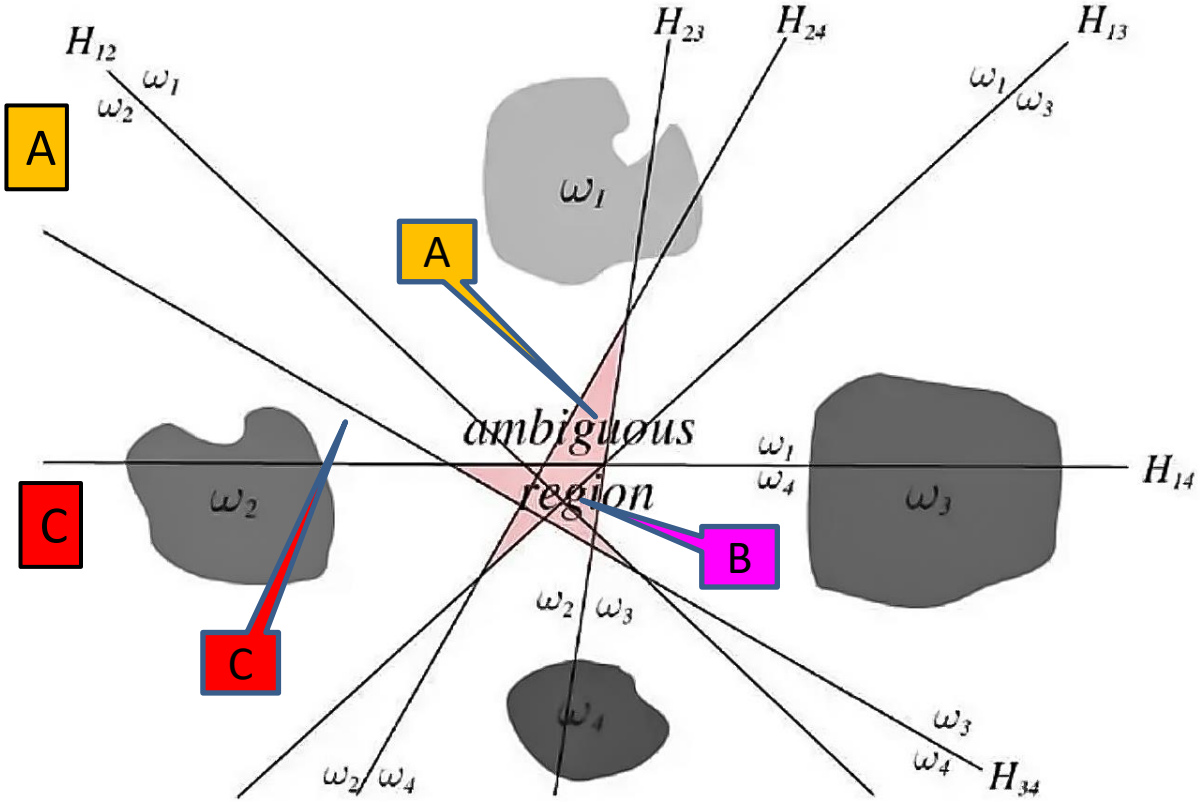

多类问题

- 多类线性判别函数

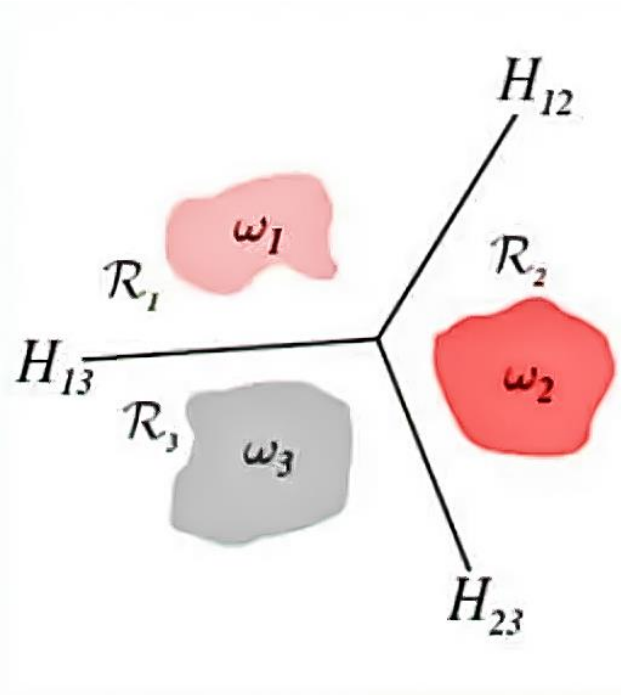

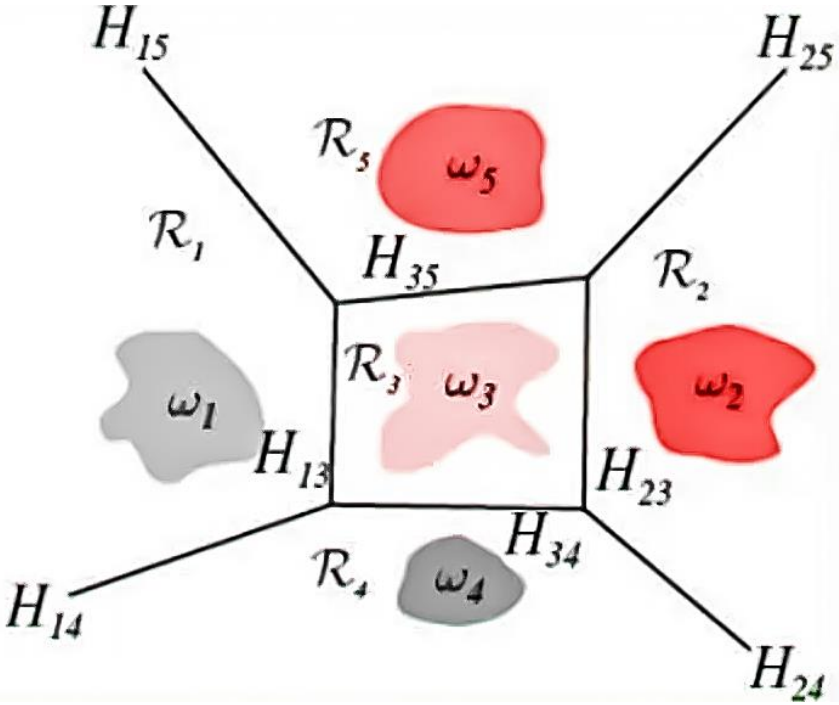

补充

回归和分类

- 线性回归和逻辑回归

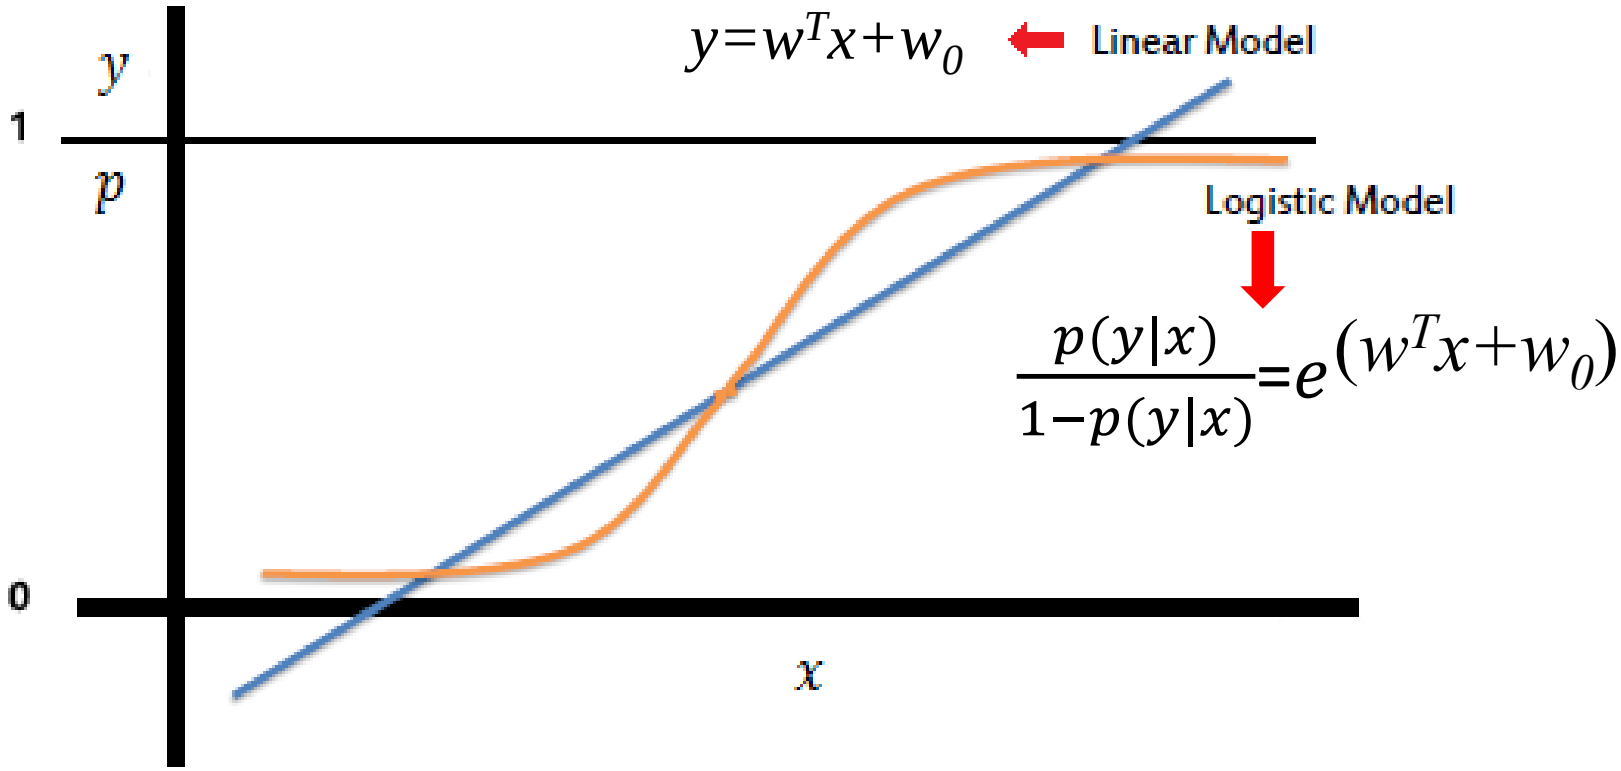

- 反映了当x变化时，样本属于y=1类的几率（相对可能性）在对数尺度上增加的幅度

逻辑回归(Logistic Regression)

- **将回归问题转为分类问题**

逻辑回归是概率型非线性回归，但其本质是线性回归，只是在特征到结果的映射中加入了一层函数映射，即先把特征线性求和，然后使用函数σ(z)（Sigmoid函数）来预测。

$$\sigma(a) = \frac{1}{1+\exp(-a)} \qquad a = w^T x$$

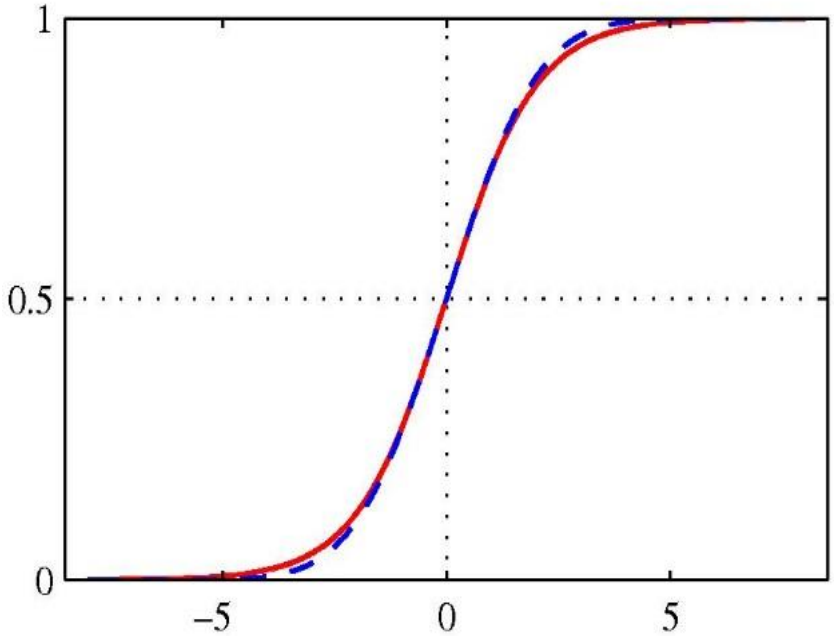

Sigmoid函数性质：

①可以将连续值映射到0和1区间上

②可导性 $\frac{d\sigma}{da} = \sigma(1-\sigma)$

③对称性 $\sigma(-a) = 1 - \sigma(a)$

④反转性 $a = ln(\frac{\sigma}{1-\sigma}) = ln\frac{p(C_1|x)}{p(C_2|x)}$

可根据已有样本，定义目标函数为模型的似然函数的负对数，并采用梯度下降算法进行优化求解

逻辑回归(Logistic Regression)

- **将回归问题转为分类问题**

逻辑回归是概率型非线性回归，但其本质是线性回归，只是在特征到结果的映射中加入了一层函数映射，即先把特征线性求和，然后使用函数 σ(z) 来预测。

多类问题：

$$p(C_k|\mathbf{x}) = \frac{p(\mathbf{x}|C_k)p(c_k)}{\sum_j p(\mathbf{x}|C_j)p(c_j)} = \frac{\exp(a_k)}{\sum_j \exp(a_j)}$$

$$a_k = \ln p(\mathbf{x}|C_k)p(c_k)$$

归一化指数
Normalized Exponential

Softmax函数

是一个平滑的max函数，如果 $a_k \gg a_j$ **，对于所有的** $k \neq j$**，有** $p(C_k|\mathbf{x}) \simeq 1$
$p(C_j|\mathbf{x}) \simeq 0$

模式识别

第二章：线性判别函数

北京航空航天大学 人工智能研究院
Institute of Artificial Intelligence， Beihang University

杨鸿宇

2022年秋季学期

Fall 2022